Amazon Kinesis Data Streams

Guia do desenvolvedor

Amazon Kinesis Data Streams: Guia do desenvolvedor

Copyright © Amazon Web Services, Inc. and/or its affiliates. All rights reserved.

As marcas comerciais e imagens comerciais da Amazon não podem ser usadas no contexto de nenhum produto ou serviço que não seja da Amazon, nem de qualquer maneira que possa gerar confusão entre os clientes ou que deprecie ou desprestigie a Amazon. Todas as outras marcas comerciais que não pertencem à Amazon pertencem a seus respectivos proprietários, que podem ou não ser afiliados, patrocinados pela Amazon ou ter conexão com ela.

Table of Contents

O que é o Amazon Kinesis Data Streams?

Você pode usar o Amazon Kinesis Data Streams para coletar e processar grandescórregosde registros de dados em tempo real. Você pode criar aplicativos de processamento de dados, conhecidos comoAplicativos Kinesis Data Streams. Um aplicativo típico do Kinesis Data Streams do lê dados de umstream de dadoscomo registros de dados. Esses aplicativos podem usar a Kinesis Client Library e serem executados em instâncias do Amazon EC2. Você pode enviar os registros processados para painéis, usá-los para gerar alertas, alterar dinamicamente as estratégias de definição de preços e publicidade ou enviar dados para uma variedade de outrosAWSServiços da . Para obter informações sobre os recursos e definição de preços do Kinesis Data Streams, consulteAmazon Kinesis Data Streams.

O Kinesis Data Streams faz parte da plataforma de streaming de dados do Kinesis, junto com oKinesis Data Firehose,Kinesis Video Streams, eKinesis Data Analytics.

Para obter mais informações sobreAWSSoluções de big data, consulteBig data emAWS. Para obter mais informações sobreAWSSoluções de streaming de dados do, consulteO que são dados de streaming?.

Tópicos

O que posso fazer com o Kinesis Data Streams?

Você pode usar o Kinesis Data Streams para entrada e agregação de dados rápidas e contínuas. O tipo de dados usado pode incluir dados de log de infraestrutura de TI, logs de aplicativo, mídias sociais, feeds de dados de mercado e dados de sequência de cliques da web. Como o tempo de resposta para a entrada e o processamento de dados é em tempo real, o processamento geralmente é leve.

A seguir, alguns cenários típicos de uso do Kinesis Data Streams:

Log acelerado e consumo e processamento de dados

Você pode ter produtores que gerem dados diretamente em um stream. Por exemplo, gere logs de sistemas e aplicativos e eles estarão disponíveis para processamento em segundos. Isso evita que os dados de log sejam perdidos se o servidor de front-end ou de aplicativos falhar. O Kinesis Data Streams fornece uma entrada acelerada de dados, pois você não organiza os dados em lotes nos servidores antes de enviá-los para entrada.

Métricas e relatórios em tempo real

Você pode usar os dados coletados no Kinesis Data Streams para simples análise de dados e geração de relatórios em tempo real. Por exemplo, seu aplicativo de processamento de dados pode funcionar em métricas e geração de relatórios para logs do sistema e de aplicativos à medida que os dados passam por ele em vez de esperar receber lotes de dados.

Análise de dados em tempo real

Ela combina o poder do processamento paralelo com o valor de dados em tempo real. Por exemplo, processar clickstreams do site em tempo real e, em seguida, analisar o envolvimento da capacidade

de uso do site usando vários aplicativos do Kinesis Data Streams diferentes do Kinesis Data Streams sendo executados em paralelo.

Complexo processamento de stream

Você pode criar Directed Acyclic Graphs (DAGs — Gráficos acíclicos dirigidos) de aplicativos do Kinesis Data Streams. Isso normalmente envolve colocar dados de vários aplicativos do Kinesis Data Streams em outro streaming para processamento em downstream por um aplicativo Kinesis Data Streams diferente.

Benefícios do uso do Kinesis Data Streams

Embora você possa usar o Kinesis Data Streams para resolver vários problemas de dados em streaming, um uso comum é a agregação em tempo real de dados seguida do carregamento de dados agregados para um data warehouse ou cluster de redução de mapa.

Os dados são colocados em streamings de dados do Kinesis, o que garante a durabilidade e a elasticidade. O atraso entre o momento em que um registro é colocado no streaming e o momento em que ele pode ser recuperado (put-to-getO atraso) normalmente é de menos de 1 segundo. Em outras palavras, um aplicativo Kinesis Data Streams pode começar a consumir os dados do streaming quase que imediatamente após a adição dos dados. O aspecto de serviço gerenciado do Kinesis Data Streams libera você do peso operacional de criação e execução de um pipeline de entrada de dados. Você pode criar aplicativos do tipo de redução de mapa de streaming. A elasticidade do Kinesis Data Streams permite escalar o streaming, de maneira que você nunca perca registros de dados antes que eles expirem.

Vários aplicativos do Kinesis Data Streams podem consumir dados de um streaming, de modo que várias ações, como arquivamento e processamento, podem ocorrer de maneira simultânea e independente. Por exemplo, dois aplicativos podem ler dados do mesmo stream. O primeiro aplicativo calcula executando agregados e atualiza uma tabela do Amazon DynamoDB, e o segundo aplicativo compacta e arquiva dados em um armazenamento de dados, como o Amazon Simple Storage Service (Amazon S3). A tabela DynamoDB com agregados em execução é, então, lida por um painel doup-to-therelatórios de minutos.

A Kinesis Client Library permite o consumo de dados tolerante a falhas de streamings e oferece suporte à escalabilidade para aplicativos Kinesis Data Streams.

Serviços relacionados

Para obter informações sobre como usar clusters do Amazon EMR para ler e processar streamings de dados do Kinesis diretamente, consulteConector Kinesis.

Terminologia e conceitos do Amazon Kinesis Data Streams

Conforme começar a usar o Amazon Kinesis Data Streams, você poderá se beneficiar da compreensão de sua arquitetura e terminologia.

Tópicos

Arquitetura de alto nível do Kinesis Data Streams

O diagrama a seguir ilustra a arquitetura de alto nível do Kinesis Data Streams. Ofabricantesenviar dados continuamente para o Kinesis Data Streams e oconsumidoresProcessar os dados em tempo real. Os consumidores (como um aplicativo personalizado em execução no Amazon EC2 ou um stream de entrega do Amazon Kinesis Data Firehose) podem armazenar seus resultados usando umAWSserviço como Amazon DynamoDB, Amazon Redshift ou Amazon S3.

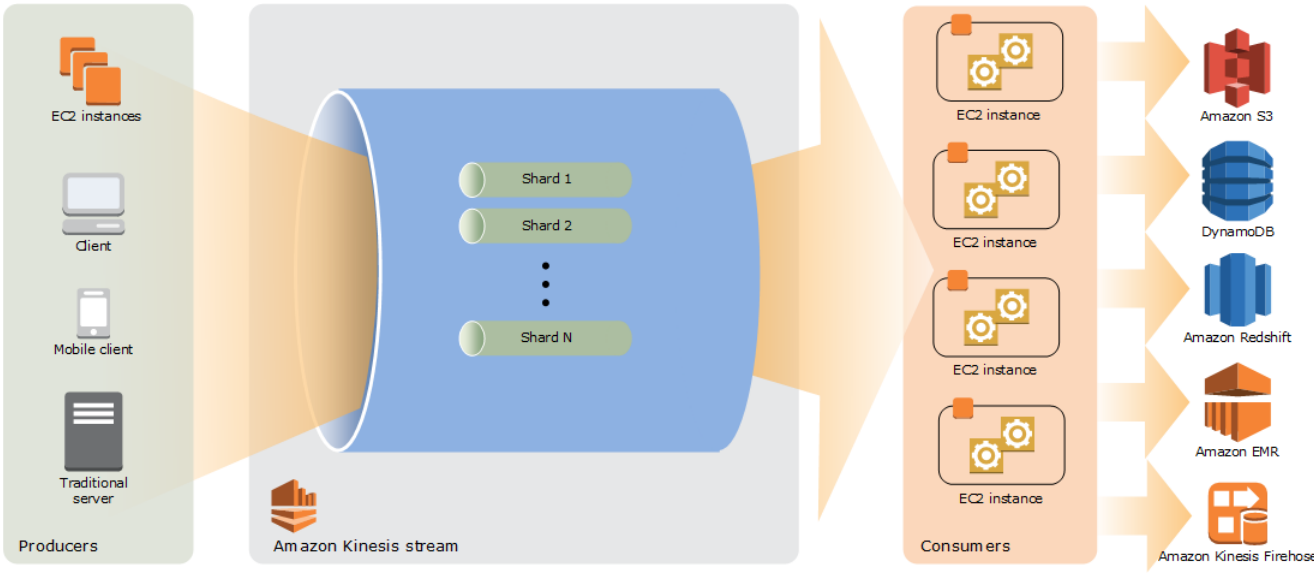

Terminologia do Kinesis Data Streams

Kinesis Data Streams

UMAstream de dados do Kinesisé um conjunto decacos (p. 5). Cada estilhaço tem uma sequência de registros de dados. Cada registro de dados tem umnúmero de sequência (p. 5)O que é atribuído pelo Kinesis Data Streams.

Registro de dados

UMAregistro de dadosÉ a unidade de dados armazenada em umstream de dados do Kinesis (p. 3). Os registros de dados são compostos de umnúmero de sequência (p. 5), umchave de partição (p. 5)E um blob de dados, que é uma sequência de bytes imutável. O Kinesis Data Streams não inspeciona, interpreta ou altera dados no blob. Um blob de dados pode ter até 1 MB.

Modo de capacidade

Um stream de dadosModo de capacidadedetermina como a capacidade é gerenciada e como você é cobrado pelo uso do fluxo de dados. Atualmente, no Kinesis Data Streams, você pode escolher entre umSob demandamode e umprovisionadoMode para os fluxos de dados. Para obter mais informações, consulte Escolher o modo de capacidade do fluxo de dados (p. 68).

Com aSob demandamodo, o Kinesis Data Streams gerencia automaticamente os fragmentos para fornecer a taxa de transferência necessária. Você é cobrado apenas pela taxa de transferência real usada e o Kinesis Data Streams acomoda automaticamente as necessidades de taxa de transferência de suas cargas de trabalho à medida que elas crescem ou diminuem. Para obter mais informações, consulte Modo sob demanda (p. 69).

Com aprovisionadoMode, você deve especificar o número de estilhaços para o stream de dados. A capacidade total de um stream de dados é a soma das capacidades de seus estilhaços. Você pode aumentar ou diminuir o número de estilhaços em um stream de dados, conforme necessário, e você será cobrado pelo número de estilhaços a uma taxa horária. Para obter mais informações, consulte Modo provisionado (p. 70).

Período de retenção

O período de retenção é o tempo em que os registros de dados permanecem acessíveis depois de serem adicionados ao streaming. O período de retenção de um stream é definido para um padrão de 24 horas após a criação. Você pode aumentar o período de retenção até8760horas (365dias) usando oIncreaseStreamRetentionPeriode diminuir o período de retenção até um mínimo de 24 horas usando oDecreaseStreamRetentionPeriodoperação. Encargos adicionais incidem sobre streams com período de retenção definido acima de 24 horas. Para obter mais informações, consulte Definição de preço do Amazon Kinesis Streams.

Produtor

Produtores doColoque registros no Amazon Kinesis Data Streams. Por exemplo, um servidor web que envia dados de log para um stream é um produtor.

Consumidor

Consumidores doObter registros do Amazon Kinesis Data Streams e processá-los. Esses consumidores são conhecidos como Aplicativo do Amazon Kinesis Data Streams (p. 4).

Aplicativo do Amazon Kinesis Data Streams

UmaAplicativo do Amazon Kinesis Data StreamsÉ um consumidor de um stream que normalmente é executado em uma frota de instâncias do EC2.

Há dois tipos de consumidores que você pode desenvolver: consumidores avançados compartilhados e consumidores avançados aprimorados. Para saber mais sobre as diferenças entre eles, e para

ver como você pode criar cada tipo de consumidor, consulte Lendo dados do Amazon Kinesis Data Streams (p. 118).

A saída de um aplicativo do Kinesis Data Streams pode ser inserida em outro stream, permitindo que você crie topologias complexas que processam dados em tempo real. Um aplicativo também pode enviar dados para vários outrosAWSServiços da . Pode haver vários aplicativos para um stream, e cada aplicativo pode consumir dados do stream de forma independente e simultaneamente.

Estilhaço

Um estilhaço é uma sequência de registros de dados identificada de forma exclusiva em um streaming. Um stream é composto de um ou mais estilhaços, sendo que cada um deles fornece uma unidade fixa de capacidade. Cada fragmento pode suportar até 5 transações por segundo para leituras, até uma taxa total máxima de leitura de dados de 2 MB por segundo e até 1.000 registros por segundo para gravações, até uma taxa total máxima de gravação de dados de 1 MB por segundo (incluindo chaves de partição). A capacidade de dados do seu stream é uma função do número de estilhaços que você especifica para o stream. A capacidade total do stream é a soma das capacidades de seus estilhaços.

Se a taxa de dados aumenta, você pode aumentar ou diminuir o número de estilhaços alocados para seu stream. Para obter mais informações, consulte Reestilhaçar um stream (p. 79).

Chave de partição

UMAchave de partiçãoÉ usado para agrupar os dados por estilhaço dentro de um stream. O Kinesis Data Streams segrega os registros de dados pertencentes a um stream em vários estilhaços. Ele usa a chave de partição associada a cada registro de dados para determinar a qual estilhaço um determinado registro de dados pertence. As chaves de partição são strings Unicode, com um limite de tamanho máximo de 256 caracteres para cada chave. Uma função de hash MD5 é usada para mapear chaves de partição para valores inteiros de 128 bits e para mapear registros de dados associados para estilhaços usando os intervalos de chaves de hash dos estilhaços. Quando um aplicativo insere dados em um stream, ele deve especificar uma chave de partição.

Número de sequência

Cada registro de dados tem umnúmero de sequênciaque é único por chave de partição dentro de seu fragmento. O Kinesis Data Streams`client.putRecords`ou`client.putRecord`. Geralmente, os números de sequência da mesma chave de partição aumentam ao longo do tempo. Quanto maior for o período entre as solicitações de gravação, maiores serão os números de sequência.

> Note
>
> Os números de sequência não podem ser usados como índices para conjuntos de dados dentro do mesmo stream. Para separar logicamente conjuntos de dados, use chaves de partição ou crie um stream separado para cada conjunto de dados.

Biblioteca de cliente Kinesis

A Biblioteca de cliente do Kinesis é compilada em seu aplicativo para permitir o consumo de dados tolerante a falhas do stream. A Biblioteca de cliente do Kinesis garante que para cada estilhaço exista um processador de registros em execução e processando esse estilhaço. A biblioteca também simplifica a leitura de dados do stream. A Biblioteca de cliente do Kinesis usa uma tabela do Amazon DynamoDB para armazenar dados de controle. Ela cria uma tabela para cada aplicativo que está processando dados.

Há duas versões principais da Biblioteca de cliente do Kinesis. Aquela que você usa depende do tipo de consumidor que deseja criar. Para obter mais informações, consulte Lendo dados do Amazon Kinesis Data Streams (p. 118).

Nome do aplicativo

O nome de um aplicativo do Amazon Kinesis Data Streams identifica o aplicativo. Cada um dos seus aplicativos deve ter um nome exclusivo delimitado para oAWSconta e região usadas pelo aplicativo. Esse nome é usado para a tabela de controle no Amazon DynamoDB e o namespace da AmazonCloudWatchMétricas do .

Criptografia do lado do servidor

O Amazon Kinesis Data Streams pode criptografar automaticamente dados confidenciais à medida que um produtor os insere em um stream. O Kinesis Data StreamsAWS KMSChaves mestras do na criptografia. Para obter mais informações, consulte Proteção de dados no Amazon Kinesis Data Streams (p. 221).

> Note
>
> Para ler ou gravar um em um stream criptografado, aplicativos produtores e consumidores devem ter permissão para acessar a chave mestra. Para obter informações sobre a concessão de permissões para aplicativos produtores e consumidores, consulte the section called “Permissões para usar as chaves mestras do KMS geradas pelo usuário” (p. 224).

> Note
>
> O uso de criptografia no lado do servidor incorre em custos do AWS Key Management Service (AWS KMS). Para obter mais informações, consulteAWSPreços do Key Management Service.

Cotas e limites

O Amazon Kinesis Data Streams tem as seguintes cotas e limites de streamings e estilhaços.

- Não há um cota máxima para o número de streamings com o modo provisionado que você pode ter em uma conta.
- Dentro do seuAWSPor padrão, você pode criar até 50 fluxos de dados com o modo de capacidade sob demanda. Se você precisar de um aumento dessa cota, entre em contatoAWSSuporte do.
- A cota padrão é de 500 estilhaços porAWSconta para o seguinteAWSregiões: Leste dos EUA (Norte da Virgínia), Oeste dos EUA (Oregon) e Europa (Irlanda). Para todas as outras regiões, a cota padrão é de 200 estilhaços porAWSconta. Esse limite só é aplicável para fluxos de dados com o modo de capacidade provisionada.

  Para solicitar um aumento de cota de fragmentos por stream de dados, siga o procedimento descrito em Solicitar um aumento de cota.
- Um único estilhaço pode consumir até 1 MB de dados por segundo (incluindo as chaves de partição) ou 1.000 registros por segundo para gravações. Da mesma forma, se você escalar o streaming para 5.000 estilhaços, ele poderá ingerir até 5 GB por segundo ou 5 milhões de registros por segundo. Se precisar de mais capacidade de consumo, você poderá aumentar facilmente o número de estilhaços no streaming usando oAWS Management Consoleou oUpdateShardContagemAPI.
- O tamanho máximo da carga útil de dados de um registro antes da codificação em base64 é de até 1 MB.
- GetRecordsÉ possível recuperar até 10 MB de dados por chamada de um único estilhaço e até 10.000 registros por chamada. Cada chamada para `GetRecords` é contada como uma transação de leitura.
- Cada estilhaço pode oferecer suporte a até cinco transações de leitura por segundo. Cada transação de leitura pode fornecer até 10.000 registros com uma cota máxima de 10 MB por transação.
- Cada estilhaço pode oferecer suporte a uma taxa total de leitura de dados máxima de até 2 MB por segundo por meio deGetRecords. Se uma chamada para `GetRecords` retornar 10 MB, as chamadas subsequentes feitas nos próximos 5 segundos lançarão uma exceção.
- Por padrão, novos fluxos de dados criados com o modo de capacidade sob demanda têm 4 MB/s de 'gravação' e 8 MB/s de taxa de transferência de “leitura”. À medida que o tráfego aumenta, os fluxos de dados com o modo de capacidade sob demanda escalam até 200 MB/s de “gravação” e taxa de transferência de “leitura” de 400 MB/s. Se você precisar de taxa de transferência adicional, entre em contatoAWSSuporte do.
- Dentro do seuAWSPor padrão, você pode criar até 50 fluxos de dados com o modo de capacidade sob demanda. Se você precisar de um aumento dessa cota, entre em contatoAWSSuporte do.
- Você pode criar 5 consumidores registrados para cada fluxo de dados com o modo de capacidade sob demanda. Se você precisar de um aumento dessa cota, entre em contatoAWSSuporte do.
- Para cada fluxo de dados em seuAWSconta, você pode alternar entre os modos de capacidade sob demanda e provisionada duas vezes em 24 horas.

Limites do API

Como a maioriaAWSAs APIs e as operações da API do Kinesis Data Streams são limitadas por taxa. Os limites a seguir se aplicam porAWSconta por região. Para obter mais informações sobre as APIs do Kinesis Data Streams, consulte oReferência da API do Amazon Kinesis.

Limites de API do plano de controle do KDS

A seção a seguir descreve os limites das APIs do plano de controle do KDS. As APIs do plano de controle do KDS permitem que você crie e gerencie os streams de dados. Esses limites se aplicam porAWSconta por região.

Limites de API do plano de controle

API	Limite de chamada de API	Limite do nível de streaming	Outros detalhes
AddTagsToStream	5 transações por segundo (TPS)	50 tags por stream de dados por conta por região	
CreateStream	5 TPS	Não há um cota máxima para o número de streamings que você pode ter em uma conta.	Você recebe umLimitExceededExceção ao fazer umCreateStreamWITHIN quando você tenta executar uma das seguintes ações: • Ter mais de cinco streams no estado `CREATING` em qualquer momento. • Criar mais fragmentos do que o autorizado para sua conta.
DecreaseStreamRetentionPeriod	5 TPS	O valor mínimo do período de retenção de um stream de dados é de 24 horas.	
DeleteStream	5 TPS	N/D	
DeregisterStreamConsumer	5 TPS	N/D	
DescribeLimits	1 TPS		
DescribeStream	10 TPS	N/D	
DescribeStreamConsumer	20 TPS	N/D	
DescribeStreamSummary (Resumo)	20 TPS	N/D	
DisableEnhancedMonitoring	5 TPS	N/D	
EnableEnhancedMonitoring	5 TPS	N/D	
IncreaseStreamRetentionPeriod	5 TPS	O valor máximo do período de retenção de um stream é de 8760 horas (365 dias).	
ListShards	100 TPS	N/D	

API	Limite de chamada de API	Limite do nível de streaming	Outros detalhes
ListStreamConsumidores do	5 TPS	N/D	
ListStreams	5 TPS	N/D	
ListTagsForStream	5 TPS	N/D	
MergeShards	5 TPS	N/D	
RegisterStreamConsumidor	5 TPS	É possível registrar até 20 consumidores por stream de dados. Um consumidor só pode ser registrado em um stream de dados de cada vez. Apenas cinco consumidores podem ser criados simultaneamente. Em outras palavras, não é possível ter mais de cinco consumidores em um status CRIANDO ao mesmo tempo. Registrar um sexto consumidor enquanto há 5 em um status CRIANDO resultará em umLimitExceededException.	
RemoveTagsFromStream	5 TPS	N/D	
SplitShard	5 TPS	N/D	
StartStreamCriptografia			Você pode aplicar com sucesso um novoAWSChave KMS para criptografia no lado do servidor 25 vezes em um período contínuo de 24 horas.
StopStreamCriptografia			É possível desabilitar com êxito a criptografia no lado do servidor 25 vezes em um período contínuo de 24 horas.

API	Limite de chamada de API	Limite do nível de streaming	Outros detalhes
UpdateShardContagem		• Dimensionar mais de dez vezes por um período contínuo de 24 horas por stream • Expandir para mais do que o dobro da contagem de fragmentos atual de um stream • Reduzir abaixo da metade da contagem de fragmentos atual de um stream • Expandir para até mais de 10000 fragmentos em um stream • Reduzir um stream com mais de 10000 fragmentos, a menos que o resultado seja inferior a 10000 fragmentos • Expandir para além do limite de fragmentos da sua conta	
UpdateStreamMode		• Para cada fluxo de dados em seuAWSconta, você pode alternar entre os modos de capacidade sob demanda e provisionada duas vezes em 24 horas.	

Limites de API do plano de dados do KDS

A seção a seguir descreve os limites para as APIs do plano de dados do KDS. As APIs do plano de dados do KDS permitem que você use os streams de dados para coletar e processar registros de dados em tempo real. Esses limites se aplicam por fragmento dentro dos streams de dados.

Limites de API do plano de dados

API	Limite de chamada de API	Limite de carga útil	Outros detalhes
GetRecords	5 TPS	O número máximo de registros que podem ser retornados por chamada é 10.000.	Se uma chamada retornar essa quantidade de dados, as chamadas

API	Limite de chamada de API	Limite de carga útil	Outros detalhes
		Tamanho máximo de dados queGetRecordsO pode retornar é 10 MB.	subsequentes feitas nos próximos 5 segundos lançam ProvisionedThroughputExceededExcep Se houver uma taxa de transferência provisionada insuficiente no streaming, as chamadas subsequentes feitas no próximo segundo lançam ProvisionedThroughputExceededExcep
GetShardIterador	5 TPS		Um iterador de fragmentos expira cinco minutos depois que é retornado ao solicitante. Em caso deGetShardA solicitação do Iterator é feita com muita frequência, você recebe um ProvisionedThroughputExceededExcep
PutRecord	1000 TPS	Cada fragmento pode oferecer suporte a gravações de até 1.000 registros por segundo, até um total máximo de gravação de dados de 1 MB por segundo.	
PutRecords		EACHPutRecordsA solicitação pode oferecer suporte a até 500 registros. Cada registro na solicitação pode ter no máximo 1 MB, até um limite de 5 MB para toda a solicitação, incluindo chaves de partição. Cada fragmento pode oferecer suporte a gravações de até 1.000 registros por segundo, até um total máximo de gravação de dados de 1 MB por segundo.	

API	Limite de chamada de API	Limite de carga útil	Outros detalhes
SubscribeToEstilhaço	Você pode fazer uma chamada paraSubscribeToEstilhaço por segundo por consumidor registrado por estilhaço.		Se você ligarSubscribeToShard novamente com o mesmo consumerARN eShardIdEm até 5 segundos de uma chamada bem-sucedida, você receberá umResourceInUseException.

Aumento de cotas

É possível usar cotas de serviço para solicitar um aumento para uma cota, se a cota for ajustável. Algumas solicitações são resolvidas automaticamente, enquanto outras são enviadas paraAWSSupport do. É possível acompanhar o status de uma solicitação de aumento de cota enviada paraAWSSupport do. As solicitações para aumentar as cotas de serviço não recebem suporte prioritário. Se você tiver uma solicitação urgente, entre em contatoAWSSupport do. Para obter mais informações, consulte O que são cotas de serviço?

Para solicitar um aumento de cota de serviço, siga o procedimento descrito em Solicitar um aumento de cota.

Configuração do Amazon Kinesis Data Streams

Antes de usar o Amazon Kinesis Data Streams pela primeira vez, execute as seguintes tarefas.

Tarefas

- Cadastre-se na AWS (p. 13)
- Fazer download de bibliotecas e ferramentas (p. 13)
- Configurar seu ambiente de desenvolvimento (p. 14)

Cadastre-se na AWS

Ao se cadastrar na Amazon Web Services (AWS), seuAWSA conta da é automaticamente cadastrada em todos os serviçosAWS, incluindo Kinesis Data Streams. Você será cobrado apenas pelos serviços que usar.

Se já tiver uma conta da AWS, passe para a próxima tarefa. Se você ainda não possuir uma conta da AWS, use o procedimento a seguir para criar uma.

Para se cadastrar em uma conta da AWS

1. Abra https://portal.aws.amazon.com/billing/signup.
2. Siga as instruções online.

   Parte do procedimento de cadastro envolve uma chamada telefônica e a digitação de um código de verificação usando o teclado do telefone.

Fazer download de bibliotecas e ferramentas

As seguintes bibliotecas e ferramentas ajudarão você a trabalhar com o Kinesis Data Streams:

- OReferência da API do Amazon KinesisÉ o conjunto básico de operações com o Kinesis Data Streams com suporte do Kinesis Data Streams. Para obter mais informações sobre a execução de operações básicas usando código Java, consulte o seguinte:
  - Desenvolver produtores usando a API do Amazon Kinesis Data Streams com oAWS SDK for Java (p. 100)
  - Desenvolver consumidores personalizados com taxa de transferência compartilhada usando o AWS SDK for Java (p. 158)
  - Criar e gerenciar streamings (p. 68)
- OAWSSDKs para oGo,Java,JavaScript,.NET,Node.js,PHP,Python, eRubyincluem suporte e amostras do Kinesis Data Streams. Se a sua versão doAWS SDK for JavaNão inclui exemplos do Kinesis Data Streams, você pode fazer download delesGitHub.
- A Kinesis Client Library (KCL) fornece umeasy-to-usemodelo de programação para processamento de dados. A KCL pode ajudar você a começar a usar rapidamente o Kinesis Data Streams em Java, Node.js, .NET, Python e Ruby. Para obter mais informações, consulte Ler dados de streamings (p. 118).

- OAWS Command Line InterfaceSuporte ao Kinesis Data Streams. OAWS CLIpermite que você controle váriosAWSServiços s a partir da linha de comando e automatize-os usando scripts.

Configurar seu ambiente de desenvolvimento

Para usar a KCL, certifique-se de que seu ambiente de desenvolvimento Java atende aos seguintes requisitos:

- Java 1.7 (Java SE 7 JDK) ou posterior. Você pode fazer download do software Java mais recente em Java SE Downloads no site da Oracle.
- Pacote Apache Commons (código, cliente HTTP e logs)
- Processador Jackson JSON

Observe que o AWS SDK for Java inclui o Apache Commons e o Jackson na pasta de terceiros. No entanto, o SDK for Java funciona com o Java 1.6, enquanto a Kinesis Client Library requer o Java 1.7.

Conceitos básicos do Amazon Kinesis Data Streams

As informações desta seção ajudam você a começar a usar o Amazon Kinesis Data Streams. Se você não estiver familiarizado com o Kinesis Data Streams, comece familiarizando-se com os conceitos e a terminologia apresentados emTerminologia e conceitos do Amazon Kinesis Data Streams (p. 3).

Esta seção mostra como executar operações básicas do Amazon Kinesis Data Streams usando aAWS Command Line Interface. Você conhecerá os princípios fundamentais do fluxo de dados do Kinesis Data Streams e as etapas necessárias para colocar e obter dados de um stream de dados do Kinesis.

Tópicos

Para acesso à CLI, você precisa de uma ID da chave de acesso e uma chave de acesso secreta. Use as chaves de acesso do usuário IAM em vez das chaves de acesso do usuário raiz da Conta da AWS. O IAM permite que você controle com segurança o acesso aServiços da AWSe recursos em suaConta da AWS. Para obter mais informações sobre como criar chaves de acesso, consulte Noções básicas e como obter suas credenciais de segurança na Referência geral da AWS.

Você pode localizar detalhadostep-by-stepInstruções de configuração do IAM e chave de segurança emCriar um usuário do IAM.

Nesta seção, os comandos específicos discutidos são fornecidos textualmente, exceto onde valores específicos são necessariamente diferentes para cada execução. Além disso, os exemplos estão usando a região Oeste dos EUA (Oregon), mas as etapas desta seção funcionam em qualquer um dosas regiões em que o Kinesis Data Streams é suportado.

Instalar e configurar o AWS CLI

Instalar o AWS CLI

Para obter etapas detalhadas sobre como instalar oAWS CLIPara Windows e para sistemas operacionais Linux, OS X e Unix, consulteInstalar oAWSCLI.

Use o comando a seguir para listar as opções e os serviços disponíveis:

```
aws help
```

Você usará o serviço Kinesis Data Streams do para poder analisar oAWS CLISubcomandos relacionados ao Kinesis Data Streams usando o seguinte comando:

```
aws kinesis help
```

Esse comando gera uma saída que inclui os comandos disponíveis do Kinesis Data Streams do:

```
AVAILABLE COMMANDS

       o add-tags-to-stream

       o create-stream

       o delete-stream

       o describe-stream

       o get-records

       o get-shard-iterator

       o help

       o list-streams

       o list-tags-for-stream

       o merge-shards

       o put-record

       o put-records

       o remove-tags-from-stream

       o split-shard

       o wait
```

Essa lista de comandos corresponde à API do Kinesis Data Streams do documentada naReferência de API do serviço Amazon Kinesis. Por exemplo, o comando `create-stream` corresponde à ação `CreateStream` da API.

A AWS CLI agora está instalada, mas não configurada. Isso é mostrado na próxima seção.

Configurar o AWS CLI

Para uso geral, o comando `aws configure` é a maneira mais rápida de configurar sua instalação da AWS CLI. Para obter mais informações, consulteConfigurar aAWSCLI.

Executar operações básicas de fluxo de dados do Kinesis usando a AWS CLI

Esta seção descreve o uso básico de um stream de dados do Kinesis a partir da linha de comando usando aAWS CLI. Certifique-se de estar familiarizado com os conceitos discutidos em Terminologia e conceitos do Amazon Kinesis Data Streams (p. 3).

> **Note**
>
> Depois de criar um stream, sua conta incorre em cobranças nominais pelo uso do Kinesis Data Streams, pois o Kinesis Data Streams não está qualificado para oAWSnível gratuito. Quando você concluir este tutorial, exclua seuAWSrecursos para parar de incorrer em cobranças. Para obter mais informações, consulte Etapa 4: Limpar (p. 20).

Tópicos

Etapa 1: Criar um fluxo

Sua primeira etapa é criar um stream e verificar se ele foi criado com êxito. Use o comando a seguir para criar um stream denominado "Foo":

```
aws kinesis create-stream --stream-name Foo
```

Em seguida, emita o comando a seguir para verificar o andamento da criação do stream:

```
aws kinesis describe-stream-summary --stream-name Foo
```

Você deve obter uma saída semelhante ao exemplo a seguir:

```
{
    "StreamDescriptionSummary": {
        "StreamName": "Foo",
        "StreamARN": "arn:aws:kinesis:us-west-2:123456789012:stream/Foo",
        "StreamStatus": "CREATING",
        "RetentionPeriodHours": 48,
        "StreamCreationTimestamp": 1572297168.0,
        "EnhancedMonitoring": [
            {
                "ShardLevelMetrics": []
            }
        ],
        "EncryptionType": "NONE",
        "OpenShardCount": 3,
        "ConsumerCount": 0
    }
}
```

Neste exemplo, o stream tem o status CREATING, o que significa que não está pronto para uso. Verifique novamente em alguns instantes para ver uma saída semelhante ao exemplo a seguir:

```
{
    "StreamDescriptionSummary": {
        "StreamName": "Foo",
        "StreamARN": "arn:aws:kinesis:us-west-2:123456789012:stream/Foo",
        "StreamStatus": "ACTIVE",
        "RetentionPeriodHours": 48,
        "StreamCreationTimestamp": 1572297168.0,
        "EnhancedMonitoring": [
            {
                "ShardLevelMetrics": []
            }
        ],
        "EncryptionType": "NONE",
        "OpenShardCount": 3,
        "ConsumerCount": 0
    }
}
```

```
```

Há informações nessa saída com que você não precisa se preocupar neste tutorial. O principal agora é `"StreamStatus": "ACTIVE"`, que mostra que o stream está pronto para uso, e as informações sobre o único estilhaço que você solicitou. Você também pode verificar a existência do novo stream usando o comando `list-streams`, como mostrado aqui:

```
aws kinesis list-streams
```

Resultado:

```
{
    "StreamNames": [
        "Foo"
    ]
}
```

Etapa 2: Inserir um registro

Agora que tem um stream ativo, você está pronto para colocar alguns dados. Neste tutorial, você usará o comando mais simples possível, `put-record`, que coloca um único registro de dados contendo o texto "testdata" no stream:

```
aws kinesis put-record --stream-name Foo --partition-key 123 --data testdata
```

Se bem-sucedido, esse comando gerará uma saída semelhante ao seguinte exemplo:

```
{
    "ShardId": "shardId-000000000000",
    "SequenceNumber": "49546986683135544286507457936321625675700192471156785154"
}
```

Parabéns, você adicionou dados a um stream! Em seguida, você verá como obter dados do stream.

Etapa 3: Obter o registro

GetShardIterador

Antes de obter dados do stream, você precisa obter o iterador referente ao estilhaço do seu interesse. Um iterador de estilhaços representa a posição do stream e do estilhaço da qual o consumidor (neste caso, o comando `get-record`) lerá. Você usará o comando `get-shard-iterator` da seguinte forma:

```
aws kinesis get-shard-iterator --shard-id shardId-000000000000 --shard-iterator-type
 TRIM_HORIZON --stream-name Foo
```

Lembre-se de que `aws kinesis`Os comandos têm o suporte de uma API do Kinesis Data Streams, portanto, caso você tenha curiosidade sobre algum parâmetro mostrado, leia sobre ele na`GetShardIterator`Tópico de referência da API. A execução bem-sucedida gerará uma saída semelhante ao exemplo a seguir (role no sentido horizontal para ver a saída inteira):

```
{
    "ShardIterator": "AAAAAAAAAAHSywljv0zEgPX4NyKdZ5wryMzP9yALs8NeKbUjp1IxtZs1Sp
+KEd9I6AJ9ZG4lNR1EMi+9Md/nHvtLyxpfhEzYvkTZ4D9DQVz/mBYWRO6OTZRKnW9gd+efGN2aHFdkH1rJl4BL9Wyrk
+ghYG22D2T1Da2EyNSH1+LAbK33gQweTJADBdyMwlo5r6PqcP2dzhg="
```

```
}
```

A string longa de caracteres aparentemente aleatórios é o iterador de estilhaços (a sua será diferente). Você precisará copiar/colar o iterador de estilhaços no comando get, mostrado a seguir. Os iteradores de estilhaços têm um ciclo de vida de 300 segundos, tempo que deve ser suficiente para você copiar/colar o iterador de estilhaços no próximo comando. Você precisará remover quaisquer novas linhas do seu iterador de estilhaços antes de colá-lo no próximo comando. Se você receber uma mensagem de erro de que o iterador de estilhaços não é mais válido, basta executar o comando `get-shard-iterator` novamente.

GetRecords

O`get-records`O comando recebe dados do stream, resultando em uma chamada para o`GetRecords`na API do Kinesis Data Streams. O iterador de estilhaços especifica a posição, no estilhaço, de onde você quer começar a ler os registros de dados em sequência. Se não houver registros disponíveis na parte do estilhaço para onde o iterador aponta, `GetRecords` retornará uma lista vazia. Poderá demorar várias chamadas para se chegar a uma parte do estilhaço que contenha registros.

No exemplo a seguir do comando `get-records` (role horizontalmente para ver o comando inteiro):

```
aws kinesis get-records --shard-iterator
 AAAAAAAAAAHSywljv0zEgPX4NyKdZ5wryMzP9yALs8NeKbUjp1IxtZs1Sp+KEd9I6AJ9ZG4lNR1EMi
+9Md/nHvtLyxpfhEzYvkTZ4D9DQVz/mBYWRO6OTZRKnW9gd+efGN2aHFdkH1rJl4BL9Wyrk
+ghYG22D2T1Da2EyNSH1+LAbK33gQweTJADBdyMwlo5r6PqcP2dzhg=
```

Se você estiver executando este tutorial a partir de um processador de comando do tipo Unix, como bash, poderá automatizar a aquisição de iterador de estilhaços usando um comando aninhado, como este (role horizontalmente para ver o comando inteiro):

```
SHARD_ITERATOR=$(aws kinesis get-shard-iterator --shard-id shardId-000000000000 --shard-
iterator-type TRIM_HORIZON --stream-name Foo --query 'ShardIterator')

aws kinesis get-records --shard-iterator $SHARD_ITERATOR
```

Se você estiver executando este tutorial a partir de um sistema compatívelPowerShell, você pode automatizar a aquisição do iterador de estilhaços usando um comando como este (role horizontalmente para ver o comando inteiro):

```
aws kinesis get-records --shard-iterator ((aws kinesis get-shard-iterator --shard-id
 shardId-000000000000 --shard-iterator-type TRIM_HORIZON --stream-name Foo).split('"')[4])
```

O resultado bem-sucedido do comando `get-records` solicitará registros do seu stream para o estilhaço que você especificou quando obteve o iterador de estilhaços, como no exemplo a seguir (role horizontalmente para ver a saída inteira):

```
{
  "Records":[ {
    "Data":"dGVzdGRhdGE=",
    "PartitionKey":"123",
    "ApproximateArrivalTimestamp": 1.441215410867E9,
    "SequenceNumber":"49544985256907370027570885864065577703022652638596431874"
  } ],
  "MillisBehindLatest":24000,

 "NextShardIterator":"AAAAAAAAAAEDOW3ugseWPE4503kqN1yN1UaodY8unE0sYslMUmC6lX9hlig5+t4RtZM0/
tALfiI4QGjunVgJvQsjxjh2aLyxaAaPr
+LaoENQ7eVs4EdYXgKyThTZGPcca2fVXYJWL3yafv9dsDwsYVedI66dbMZFC8rPMWc797zxQkv4pSKvPOZvrUIudb8UkH3VMzx58Is=
}
```

Observe que `get-records` é descrito acima como uma solicitação, ou seja, você pode receber zero ou mais registros mesmo que haja registros em seu stream, e os registros retornados podem não representar todos os registros que existem atualmente no stream. Isso é perfeitamente normal, e o código de produção simplesmente sondará o stream quanto aos registros em intervalos apropriados (essa velocidade de sondagem varia de acordo com os requisitos de design específicos do aplicativo).

A primeira coisa que você provavelmente verá sobre o seu registro nesta parte do tutorial é que os dados parecem lixo, e não o em texto limpo`testdata`enviamos. Isso ocorre devido ao modo como `put-record` usa a codificação Base64 para permitir que você envie dados binários. No entanto, o Kinesis Data Streams oferece suporte noAWS CLInão fornece Base64decodificandoComo essa decodificação para conteúdo binário bruto impresso em stdout acarretará comportamento indesejado e possíveis problemas de segurança em algumas plataformas e terminais. Se você usar um decodificador Base64 (por exemplo, https://www.base64decode.org/) para decodificar `dGVzdGRhdGE=` manualmente, verá que ele é, na verdade, `testdata`. Isso é suficiente para os fins deste tutorial, pois, na prática, a AWS CLI raramente é usada para consumir dados. Ela é usada com mais frequência para monitorar o estado do stream e obter informações, como mostrado anteriormente (`describe-stream` e `list-streams`). Tutoriais futuros mostrarão como criar aplicativos de consumidor de qualidade de produção usando a Kinesis Client Library (KCL), que se encarregará da Base64 para você. Para obter mais informações sobre o KCL, consulteDesenvolver consumidores personalizados com taxa de transferência compartilhada usando a KCL.

Nem sempre `get-records` retornará todos os registros no stream/estilhaço especificado. Quando isso acontecer, use o `NextShardIterator` a partir do último resultado para obter o próximo conjunto de registros. Portanto, se mais dados estavam sendo colocados no stream (situação normal em aplicativos de produção), você pode continuar sondando dados usando `get-records` todas as vezes. No entanto, se você não chamar `get-records` usando o próximo iterador de estilhaços dentro do tempo de vida de 300 segundos do iterador de estilhaços, receberá uma mensagem de erro e precisará usar o comando `get-shard-iterator` para obter um novo iterador de estilhaços.

Essa saída também fornece `MillisBehindLatest`, que é o número de milissegundos em que a resposta da operação GetRecords está da ponta do stream, indicando o atraso do consumidor em relação ao tempo atual. Um valor zero indica que o processamento de registros foi alcançado e não há nenhum registro novo para processar no momento. No caso deste tutorial, se você está lendo tudo conforme avança, poderá ver um número muito grande. Isso não é problema, pois por padrão, os registros de dados permanecem em um stream por 24 horas, aguardando você recuperá-los. Esse período, chamado de período de retenção, é configurável para até 365 dias.

Observe que um resultado bem-sucedido de `get-records` sempre terá um `NextShardIterator`, mesmo que não haja mais nenhum registro atualmente no stream. Este é um modelo de sondagem que assume que um produtor colocará mais registros no stream em um determinado momento. Você pode criar suas próprias rotinas de sondagem, porém, se usar a KCL mencionada anteriormente para desenvolver aplicativos de consumidor, ela se encarregará dessa sondagem para você.

Se você chamar `get-records` até que não haja mais registros no stream e o estilhaço do qual você está extraindo, verá uma saída com registros vazios, semelhante ao exemplo a seguir (role horizontalmente para ver a saída inteira):

```
{
    "Records": [],
    "NextShardIterator": "AAAAAAAAAAGCJ5jzQNjmdhO6B/YDIDE56jmZmrmMA/r1WjoHXC/
kPJXc1rckt3TFL55dENfe5meNgdkyCRpUPGzJpMgYHaJ53C3nCAjQ6s7ZupjXeJGoUFs5oCuFwhP+Wul/
EhyNeSs5DYXLSSC5XCapmCAYGFjYER69QSdQjxMmBPE/hiybFDi5qtkT6/PsZNz6kFoqtDk="
}
```

Etapa 4: Limpar

Por fim, convém excluir seu stream para liberar recursos e evitar cobranças indesejadas à sua conta, como observado anteriormente. Faça isso efetivamente sempre que tiver criado um stream que não será

usado, pois as cobranças incidem por stream mesmo que ele não seja usado para colocar e obter dados. O comando de limpeza é simples:

```
aws kinesis delete-stream --stream-name Foo
```

Como o êxito do comando não gera saída, você pode usar `describe-stream` para verificar o andamento da exclusão:

```
aws kinesis describe-stream-summary --stream-name Foo
```

Se você executar este comando imediatamente após o comando de exclusão, provavelmente verá que parte de saída é semelhante ao exemplo a seguir:

```
{
    "StreamDescriptionSummary": {
        "StreamName": "samplestream",
        "StreamARN": "arn:aws:kinesis:us-west-2:123456789012:stream/samplestream",
        "StreamStatus": "ACTIVE",
```

Após a exclusão total do stream, `describe-stream` gerará um erro "não encontrado":

```
A client error (ResourceNotFoundException) occurred when calling the DescribeStreamSummary
 operation:
Stream Foo under account 123456789012 not found.
```

Exemplo de tutoriais do Amazon Kinesis Data Streams

Os exemplos de tutoriais desta seção são projetados para oferecer mais auxílio na compreensão da funcionalidade e de conceitos do Amazon Kinesis Data Streams.

Tópicos

Tutorial: Processar dados de ações em tempo real usando a KCL e a KCL 2.

O cenário deste tutorial envolve consumir negociações de ações em um stream de dados e escrever um aplicativo do Amazon Kinesis Data Streams simples que realiza cálculos no streaming. Você aprenderá a enviar um streaming de registros para o Kinesis Data Streams e implementar um aplicativo que consome e processa os registros quase em tempo real.

> Important
>
> Depois de criar um streaming, sua conta incorre em cobranças nominais pelo uso do Kinesis Data Streams, pois o Kinesis Data Streams não está qualificado para oAWSNível gratuito. Depois que for iniciado, o aplicativo consumidor também incorrerá em cobranças nominais pelo uso do Amazon DynamoDB. O aplicativo consumidor usa o DynamoDB para rastrear o estado do processamento. Quando você terminar de usar este aplicativo, exclua suaAWSrecursos para parar de incorrer em cobranças. Para obter mais informações, consulte Etapa 7: Concluir (p. 35).

O código não acessa os dados reais da bolsa de valores, ele simula o stream de negociações de ações. Isso é feito com o uso de um gerador de negociações de ações aleatórias cujo ponto de partida são dados do mercado real referente às 25 principais ações por capitalização de mercado em fevereiro de 2015. Se tiver acesso a um streaming de negociações de ações em tempo real, você poderá se interessar em derivar estatísticas úteis e em tempo hábil desse streaming. Por exemplo, talvez convenha executar uma análise de janela deslizante na qual você determina a ação mais popular que foi adquirida nos últimos 5 minutos. Ou talvez convenha uma notificação sempre que uma ordem de venda for muito grande (ou seja, tenha muitas quotas). Você pode estender o código nesta série para oferecer essa funcionalidade.

É possível executar as etapas deste tutorial no desktop ou laptop e executar o código de produtor e de consumidor na mesma máquina ou em qualquer plataforma que ofereça suporte aos requisitos definidos.

Os exemplos mostrados usam a região Oeste dos EUA (Oregon), mas funcionam em qualquer um dosAWSregiõesque oferecem suporte ao Kinesis Data Streams.

Tarefas

Pré-requisitos

É necessário atender aos seguintes requisitos para concluir este tutorial:

Conta da Amazon Web Services

Antes de começar, familiarize-se com os conceitos abordados em Terminologia e conceitos do Amazon Kinesis Data Streams (p. 3), especialmente com fluxos, estilhaços, produtores e consumidores. Também é útil concluir as etapas no seguinte guia: Instalar e configurar o AWS CLI (p. 15).

São necessários uma conta da AWS e um navegador da web para acessar o AWS Management Console.

Para acessar o console, use seu nome de usuário e senha do IAM para fazer login noAWS Management ConsoledoPágina de login do IAM. O IAM permite que você controle com segurança o acesso aoServiços da AWSe recursos noConta da AWS. Para obter detalhes sobre credenciais programáticas e de console, consulteCompreender e obter suas credenciais de segurançanoAWSReferência geral.

Para obter mais informações sobre o IAM e instruções de configuração de chave de segurança, consulteCriar um usuário do IAM.

Requisitos de software do sistema

O sistema usado para executar o aplicativo deve ter o Java 7 ou posterior instalado. Para fazer download e instalar o Java Development Kit (JDK) mais recente, acesse o Site de instalação do Java SE da Oracle.

Se você tiver um Java IDE, como o Eclipse, será possível usá-lo para abrir, editar, compilar e executar o código-fonte.

Você precisa da versão mais recente do AWS SDK for Java. Se você usar o Eclipse como o IDE, poderá instalar oAWSToolkit for EclipseEm vez disso.

O aplicativo consumidor requer a Kinesis Client Library (KCL) versão 2.2.9 ou superior, que você pode obter daGitHubemhttps://github.com/awslabs/amazon-kinesis-client/árvore/master.

Próximas etapas

Etapa 1: Criar um streaming de dados (p. 23)

Etapa 1: Criar um streaming de dados

Primeiro, é necessário criar o fluxo de dados que você usará nas etapas seguintes deste tutorial.

Para criar um fluxo

1. Faça login no AWS Management Console e abra o console do Kinesis em https://console.aws.amazon.com/kinesis.
2. Selecione Data Streams (Streams de dados) no painel de navegação.
3. Na barra de navegação, expanda o seletor de região e escolha uma região.
4. Escolha Create Kinesis stream (Criar streaming do Kinesis).
5. Insira um nome para seu fluxo de dados (por exemplo, **`StockTradeStream`**).
6. Digite **`1`** como o número de estilhaços, mas deixe Estimate the number of shards you'll need (Estimar o número de estilhaços de que você precisará) recolhido.
7. Escolha Create Kinesis stream (Criar streaming do Kinesis).

NoStreams do KinesisPágina de lista, o status do streaming aparece como`CREATING`enquanto o streaming está sendo criado. Quando o stream fica pronto para uso, o status é alterado para `ACTIVE`.

Se você escolher o nome do fluxo, na página exibida, a guia Details (Detalhes) exibirá um resumo da configuração do fluxo de dados. A seção Monitoring (Monitoramento) exibe informações de monitoramento do streaming.

Próximas etapas

Etapa 2: Criar uma política e um usuário do IAM (p. 24)

Etapa 2: Criar uma política e um usuário do IAM

Práticas Recomendadas de segurança paraAWSDitar o uso de permissões granulares para controlar o acesso a recursos diferentes.AWS Identity and Access Management O (IAM) permite gerenciar usuários e permissões de usuário noAWS. Uma Política do IAM lista explicitamente as ações permitidas e os recursos aos quais as ações são aplicáveis.

Veja a seguir as permissões mínimas comumente necessárias para um produtor e um consumidor do Kinesis Data Streams.

Produtor

Ações	Recurso	Finalidade
`DescribeStream`, `DescribeStreamSummary`, `DescribeStreamConsumer`	Fluxo de dados do Kinesis	Antes de tentar ler registros, o consumidor verifica se o fl estão contidos no fluxo de dados.
`SubscribeToShard`, `RegisterStreamConsumer`	Fluxo de dados do Kinesis	Assina e registra os consumidores em um estilhaço.
`PutRecord`, `PutRecords`	Fluxo de dados do Kinesis	Grava registros no Kinesis Data Streams.

Consumidor

Ações	Recurso	Finalidade
`DescribeStream`	Fluxo de dados do Kinesis	Antes de tentar ler registros, o consumidor verifica se o fl estão contidos no fluxo de dados.

Ações	Recurso	Finalidade
`GetRecords`, `GetShardIterator`	Fluxo de dados do Kinesis	Lê registros de um estilhaço.
`CreateTable`, `DescribeTable`, `GetItem`, `PutItem`, `Scan`, `UpdateItem`	Tabela do Amazon DynamoDB	Se o consumidor é desenvolvido usando a Kinesis Client permissões para uma tabela do DynamoDB para rastrear
`DeleteItem`	Tabela do Amazon DynamoDB	Para quando o consumidor executar operações de divisã Streams.
`PutMetricData`	AmazôniaCloudWatchtora	A KCL também faz upload de métricas para o CloudWatc

Neste tutorial, você criará uma única política do IAM que concede todas as permissões acima. Na produção, talvez você queira criar duas políticas, uma para produtores e outra para consumidores.

Para criar uma política do IAM

1. Localize o nome de recurso da Amazon (ARN) para o novo fluxo de dados criado na etapa acima. Você pode encontrar esse ARN listado como Stream ARN (ARN do streaming) na parte superior da guia Details (Detalhes). O formato do ARN é o seguinte:

   ```
   arn:aws:kinesis:region:account:stream/name
   ```

   região

   OAWSCódigo da região; por exemplo,`us-west-2`. Para obter mais informações, consulte Conceitos de região e zona de disponibilidade.

   conta

   OAWSID da conta, conforme mostrado emConfigurações da conta.

   name

   O nome do fluxo de dados criado na etapa acima, que é `StockTradeStream`.
2. Determine o ARN da tabela do DynamoDB a ser usada pelo consumidor (e a ser criada pela primeira instância de consumidor). Ele deve estar no seguinte formato:

   ```
   arn:aws:dynamodb:region:account:table/name
   ```

   A região e o ID da conta são idênticos aos valores no ARN do fluxo de dados que você está usando neste tutorial, mas onomeÉ o nome da tabela do DynamoDB criada e usada pelo aplicativo consumidor. A KCL usa o nome do aplicativo como nome da tabela. Nesta etapa, use`StockTradesProcessor`Para o nome da tabela do DynamoDB, porque esse é o nome do aplicativo usado nas etapas posteriores deste tutorial.
3. No console do IAM, noPolíticas(https://console.aws.amazon.com/iam/home#policies), escolhaCriar política. Se esta for a primeira vez que você trabalha com políticas do IAM, escolhaComece a usar,Criar política.
4. Escolha Select (Selecionar) ao lado de Policy Generator (Gerador de políticas).
5. SelecioneAmazon Kinesiscomo oAWSServiço.
6. Selecione `DescribeStream`, `GetShardIterator`, `GetRecords`, `PutRecord`e `PutRecords` como ações permitidas.
7. Insira o ARN do fluxo de dados que você está usando neste tutorial.
8. Use Add Statement (Adicionar instrução) para cada um dos seguintes:

AWS Serviço	Ações	ARN
Amazon DynamoDB	`CreateTable`, `DeleteItem`, `DescribeTable`, `GetItem`, `PutItem`, `Scan`, `UpdateItem`	O ARN da tabela do DynamoDB criada na Etapa 2 deste procedimento.
Amazon CloudWatch	`PutMetricData`	*

O asterisco (*) é usado quando não é necessário especificar um ARN. Nesse caso, é porque não há nenhum recurso específico no CloudWatch para o qual a ação `PutMetricData` é invocada.

9. Escolha Next Step.
10. Altere Policy Name (Nome da política) para `StockTradeStreamPolicy`, analise o código e escolha Create Policy (Criar política).

O documento de política resultante deve ser semelhante a:

```
{
  "Version": "2012-10-17",
  "Statement": [
    {
      "Sid": "Stmt123",
      "Effect": "Allow",
      "Action": [
        "kinesis:DescribeStream",
        "kinesis:PutRecord",
        "kinesis:PutRecords",
        "kinesis:GetShardIterator",
        "kinesis:GetRecords",
        "kinesis:ListShards",
        "kinesis:DescribeStreamSummary",
        "kinesis:RegisterStreamConsumer"
      ],
      "Resource": [
        "arn:aws:kinesis:us-west-2:123:stream/StockTradeStream"
      ]
    },
    {
      "Sid": "Stmt234",
      "Effect": "Allow",
      "Action": [
        "kinesis:SubscribeToShard",
        "kinesis:DescribeStreamConsumer"
      ],
      "Resource": [
        "arn:aws:kinesis:us-west-2:123:stream/StockTradeStream/*"
      ]
    },
    {
      "Sid": "Stmt456",
      "Effect": "Allow",
      "Action": [
        "dynamodb:*"
      ],
      "Resource": [
        "arn:aws:dynamodb:us-west-2:123:table/StockTradesProcessor"
      ]
    },
    {
      "Sid": "Stmt789",
```

```
      "Effect": "Allow",
      "Action": [
        "cloudwatch:PutMetricData"
      ],
      "Resource": [
        "*"
      ]
    }
  ]
}
```

Para criar um usuário do IAM

1. Abra o console do IAM em https://console.aws.amazon.com/iam/.
2. Na página Users (Usuários), selecione Add user (Adicionar usuário).
3. Para User name, digite `StockTradeStreamUser`.
4. para oTipo de acesso, escolhaAcesso programáticoe, depois, escolhaPróximo: Permissions
5. Selecione Attach existing policies directly.
6. Pesquise por nome a política criada no procedimento acima (`StockTradeStreamPolicy`. Selecione a caixa à esquerda do nome da política e escolhaPróximo: Análise.
7. Revise os detalhes e o resumo e, em seguida, escolha Create user (Criar usuário).
8. Copie o Access key ID (ID da chave de acesso) e salve-o de forma privada. Em Secret access key (Chave de acesso secreta), escolha Show (Mostrar) e salve a chave de forma privada também.
9. Cole as chaves de acesso e chaves secretas em um arquivo local em lugar seguro que somente você possa acessar. Para esse aplicativo, crie um arquivo denominado `~/.aws/credentials` (com permissões restritas). O arquivo deverá estar no seguinte formato:

```
[default]
aws_access_key_id=access key
aws_secret_access_key=secret access key
```

Para anexar uma política do IAM a um usuário

1. No console do IAM, abra oPolíticase escolhaAções de políticas.
2. Escolha `StockTradeStreamPolicy` e Attach (Anexar).
3. Escolha `StockTradeStreamUser` e Attach Policy (Anexar política).

Próximas etapas

Etapa 3: Faça download e crie o código (p. 27)

Etapa 3: Faça download e crie o código

Este tópico fornece um exemplo de código de implementação para o exemplo de ingestão de transações de ações no fluxo de dados (produtor) e o processamento desses dados (consumidor).

Como fazer download e criar o código

1. Faça download do código-fonte dohttps://github.com/aws-samples/amazon-kinesis-learning GitHubrepo para o computador.
2. Crie um projeto no IDE com o código-fonte, respeitando a estrutura de diretório fornecida.

3. Adicione as seguintes bibliotecas ao projeto:
   - Amazon Kinesis Client Library (KCL)
   - AWS SDK
   - ApacheHttpCore
   - ApacheHttpClient
   - Apache Commons Lang
   - Apache Commons Logging
   - Guava (Google Core Libraries For Java)
   - Jackson Annotations
   - Jackson Core
   - Jackson Databind
   - Jackson Dataformat: CBOR
   - Joda Time
4. Dependendo do seu IDE, o projeto pode ser compilado automaticamente. Se não, compile o projeto usando as etapas apropriadas para o seu IDE.

Se concluiu essas etapas com êxito, você agora está pronto para ir para a próxima seção, the section called “Etapa 4: Implementar o produtor” (p. 28).

Próximas etapas

(p. 28)

Etapa 4: Implementar o produtor

Este tutorial usa o cenário do mundo real de monitoramento de transações da bolsa de valores. Os princípios a seguir explicam brevemente como este cenário é mapeado para o produtor e a estrutura de código de suporte.

Consulte o código-fonte e analise as informações a seguir.

StockTradeclasse

Uma negociação de ação individual é representada por uma instância da classe StockTrade. Essa instância contém atributos como o símbolo ticker, o preço, o número de ações, o tipo da negociação (compra ou venda) e um ID que identifica a negociação com exclusividade. Essa classe é implementada para você.

Registro de stream

Um stream é uma sequência de registros. Um registro é uma serialização de uma instância `StockTrade` no formato JSON. Por exemplo:

```
{
  "tickerSymbol": "AMZN",
  "tradeType": "BUY",
  "price": 395.87,
  "quantity": 16,
  "id": 3567129045
}
```

StockTradeClasse geradora

StockTradeO gerador tem um método chamadogetRandomTrade()O que retorna uma nova negociação de ações gerada aleatoriamente sempre que ela é invocada. Essa classe é implementada para você.

StockTradesClasse de gravador

Omainmétodo do produtor,StockTradesO Writer recupera continuamente uma negociação aleatória e a envia ao Kinesis Data Streams executando as seguintes tarefas:

1. Lê o nome do fluxo de dados e o nome da região como entrada.
2. Usa o `KinesisAsyncClientBuilder` para definir região, credenciais e configuração do cliente.
3. Verifica se o stream existe e está ativo (se não, ele será encerrado com um erro).
4. Em um loop contínuo, chama o método `StockTradeGenerator.getRandomTrade()` e o método `sendStockTrade` para enviar a negociação ao stream a cada 100 milissegundos.

O método `sendStockTrade` da classe `StockTradesWriter` tem o seguinte código:

```
private static void sendStockTrade(StockTrade trade, KinesisAsyncClient kinesisClient,
            String streamName) {
        byte[] bytes = trade.toJsonAsBytes();
        // The bytes could be null if there is an issue with the JSON serialization by
 the Jackson JSON library.
        if (bytes == null) {
            LOG.warn("Could not get JSON bytes for stock trade");
            return;
        }

        LOG.info("Putting trade: " + trade.toString());
        PutRecordRequest request = PutRecordRequest.builder()
                .partitionKey(trade.getTickerSymbol()) // We use the ticker symbol as
 the partition key, explained in the Supplemental Information section below.
                .streamName(streamName)
                .data(SdkBytes.fromByteArray(bytes))
                .build();
        try {
            kinesisClient.putRecord(request).get();
        } catch (InterruptedException e) {
            LOG.info("Interrupted, assuming shutdown.");
        } catch (ExecutionException e) {
            LOG.error("Exception while sending data to Kinesis. Will try again next
 cycle.", e);
        }
    }
```

Consulte o desmembramento do código a seguir:

- A API `PutRecord` espera uma matriz de bytes, e é necessário converter a transação para o formato JSON. Essa única linha de código executa a seguinte operação:

```
byte[] bytes = trade.toJsonAsBytes();
```

- Antes de enviar a transação, crie uma nova instância de `PutRecordRequest` (chamada solicitação neste caso). Cada `request` exige o nome do fluxo, uma chave de partição e um blob de dados.

```
PutPutRecordRequest request = PutRecordRequest.builder()
```

```
    .partitionKey(trade.getTickerSymbol()) // We use the ticker symbol as the
 partition key, explained in the Supplemental Information section below.
    .streamName(streamName)
    .data(SdkBytes.fromByteArray(bytes))
    .build();
```

O exemplo usa um tíquete de ações como uma chave de partição, que mapeia o registro para um determinado estilhaço. Na prática, você deve ter centenas ou milhares de chaves de partição por estilhaço, de forma que os registros sejam uniformemente disseminados no seu stream. Para obter mais informações sobre como adicionar dados a um stream, consulte Gravando dados no Amazon Kinesis Data Streams (p. 88).

Agora, `request` está pronto para enviar para o cliente (operação put):

```
   kinesisClient.putRecord(request).get();
```

- A verificação e o registro de erros são sempre inclusões úteis. Este código registra condições de erro:

```
if (bytes == null) {
    LOG.warn("Could not get JSON bytes for stock trade");
    return;
}
```

Adicione o bloco try/catch ao redor da operação `put`:

```
try {
  kinesisClient.putRecord(request).get();
} catch (InterruptedException e) {
            LOG.info("Interrupted, assuming shutdown.");
} catch (ExecutionException e) {
            LOG.error("Exception while sending data to Kinesis. Will try again next
 cycle.", e);
}
```

Isso ocorre porque uma operação put do Kinesis Data Streams pode falhar devido a erro de rede ou porque o fluxo de dados pode atingir o limite de taxa de transferência e ficar limitado. É recomendado considerar cuidadosamente sua política de tentativa para operações `put` a fim de evitar perda de dados, por exemplo, usando como uma simples tentativa.

- O registro de status é útil mas opcional:

```
LOG.info("Putting trade: " + trade.toString());
```

O produtor mostrado aqui usa a funcionalidade de registro único da API do Kinesis Data Streams,`PutRecord`. Na prática, se um produtor individual gerar muitos registros, costuma ser mais eficiente usar a funcionalidade de vários registros de `PutRecords` e enviar lotes de registros por vez. Para obter mais informações, consulte Gravando dados no Amazon Kinesis Data Streams (p. 88).

Para executar o produtor

1. Verifique se a chave de acesso e o par de chaves secretas recuperados em Etapa 2: Criar uma política e um usuário do IAM (p. 24) estão salvos no arquivo `~/.aws/credentials`.
2. Execute a classe `StockTradeWriter` com os seguintes argumentos:

```
StockTradeStream us-west-2
```

   Se você criou o fluxo em uma região diferente de `us-west-2`, será necessário especificar essa região aqui.

Você deve ver saída semelhante a:

```
Feb 16, 2015 3:53:00 PM
com.amazonaws.services.kinesis.samples.stocktrades.writer.StockTradesWriter sendStockTrade
INFO: Putting trade: ID 8: SELL 996 shares of BUD for $124.18
Feb 16, 2015 3:53:00 PM
com.amazonaws.services.kinesis.samples.stocktrades.writer.StockTradesWriter sendStockTrade
INFO: Putting trade: ID 9: BUY 159 shares of GE for $20.85
Feb 16, 2015 3:53:01 PM
com.amazonaws.services.kinesis.samples.stocktrades.writer.StockTradesWriter sendStockTrade
INFO: Putting trade: ID 10: BUY 322 shares of WMT for $90.08
```

Suas transações de ações estão sendo ingeridas pelo Kinesis Data Streams.

Próximas etapas

Etapa 5: Implementar o consumidor (p. 31)

Etapa 5: Implementar o consumidor

O aplicativo consumidor neste tutorial processa continuamente as transações de ações em seu fluxo de dados. Em seguida, ele produz as ações mais populares compradas e vendidas a cada minuto. O aplicativo é compilado sobre a Kinesis Client Library (KCL), que faz grande parte do trabalho pesado comum a aplicativos consumidores. Para obter mais informações, consulte Usar a biblioteca de cliente Kinesis (p. 120).

Consulte o código-fonte e analise as informações a seguir.

StockTradesClasse de processador

Principal classe do consumidor fornecida e que executa as seguintes tarefas:

- Lê o aplicativo, o fluxo de dados e os nomes de região passados como argumentos.
- Cria uma instância de `KinesisAsyncClient` com o nome da região.
- Cria uma instância de `StockTradeRecordProcessorFactory` que veicula instâncias de `ShardRecordProcessor`, implementadas por uma instância de `StockTradeRecordProcessor`.
- Cria uma instância de `ConfigsBuilder` com a instância de `KinesisAsyncClient`, `StreamName`, `ApplicationName` e `StockTradeRecordProcessorFactory`. Isso é útil para criar todas as configurações com valores padrão.
- Cria um programador da KCL (anteriormente, nas versões 1.x da KCL, era conhecido como o operador da KCL) com a instância de `ConfigsBuilder`.

- O programador cria um novo thread para cada estilhaço (atribuído a essa instância de consumidor), que faz loop continuamente para ler registros do fluxo de dados. Em seguida, ele invoca a instância de `StockTradeRecordProcessor` para processar cada lote de registros recebidos.

StockTradeRecordProcessorclasse

Implementação da instância de `StockTradeRecordProcessor`, que, por sua vez, implementa cinco métodos necessários: `initialize`, `processRecords`, `leaseLost`, `shardEnded` e `shutdownRequested`.

Os métodos `initialize` e `shutdownRequested` são usados pela KCL para permitir que o processador de registros saiba quando ele deve estar pronto para começar a receber registros e quando ele deve esperar parar de receber registros, respectivamente, para que ele possa executar qualquer configuração específica do aplicativo e tarefas de encerramento. `leaseLost` e `shardEnded` são usados para implementar qualquer lógica para o que fazer quando um contrato de aluguel é perdido ou um processamento chegou ao fim de um estilhaço. Neste exemplo, simplesmente registramos mensagens indicando esses eventos.

O código para esses métodos é fornecido para você. O processamento principal ocorre no método `processRecords`, que, por sua vez, usa `processRecord` para cada registro. Esse último método é fornecido como o código esqueleto quase todo vazio, para você implementar na próxima etapa, onde é explicado em mais detalhes.

Observe também a implementação dos métodos de suporte de `processRecord`: `reportStats` e `resetStats`, que estão vazios no código-fonte original.

O método `processRecords`, implementado para você, executa as seguintes etapas:

- Para cada registro passado, ele chama `processRecord`.
- Se tiver decorrido pelo menos 1 minuto após o último relatório, chamará `reportStats()`, que imprime as estatísticas mais recentes e, em seguida, `resetStats()`, que limpa as estatísticas para que o próximo intervalo inclua apenas registros novos.
- Define o próximo horário para geração de relatórios.
- Se tiver decorrido pelo menos 1 minuto após o último ponto de verificação, chamará `checkpoint()`.
- Define o próximo horário do ponto de verificação.

Este método usa intervalos de 60 segundos como taxa de geração de relatórios e definição de pontos de verificação. Para obter mais informações sobre definição de pontos de verificação, consulteUsando a biblioteca de cliente do Kinesis.

StockStatsclasse

Essa classe fornece retenção de dados e rastreamento de estatísticas em relação às ações mais populares ao longo do tempo. Esse código, fornecido para você, contém os seguintes métodos:

- `addStockTrade(StockTrade)`: injeta o `StockTrade` conhecido nas estatísticas correntes.
- `toString()`: retorna as estatísticas em uma string formatada.

Essa classe rastreia as ações mais populares mantendo uma contagem corrente do número total de negociações de cada ação e a contagem máxima. Ela atualiza essas contagens sempre que chega uma negociação de ação.

Adicione código aos métodos da classe `StockTradeRecordProcessor`, como mostrado nas etapas a seguir.

Para implementar o consumidor

1. Implemente o método `processRecord` instanciando um objeto `StockTrade` de tamanho correto e adicionando a ele os dados do registro, registrando um aviso caso ocorra problema.

```
byte[] arr = new byte[record.data().remaining()];
record.data().get(arr);
StockTrade trade = StockTrade.fromJsonAsBytes(arr);
    if (trade == null) {
        log.warn("Skipping record. Unable to parse record into StockTrade. Partition
 Key: " + record.partitionKey());
        return;
        }
stockStats.addStockTrade(trade);
```

2. Implemente um método `reportStats` simples. Sinta-se à vontade para modificar o formato de saída mais adequado às suas preferências.

```
System.out.println("****** Shard " + kinesisShardId + " stats for last 1 minute ******
\n" +
stockStats + "\n" +
"*************************************************************\n");
```

3. Implemente o método `resetStats`, que cria uma nova instância de `stockStats`.

```
stockStats = new StockStats();
```

4. Implemente os seguintes métodos exigidos pela interface `ShardRecordProcessor`

```
@Override
public void leaseLost(LeaseLostInput leaseLostInput) {
    log.info("Lost lease, so terminating.");
}

@Override
public void shardEnded(ShardEndedInput shardEndedInput) {
    try {
        log.info("Reached shard end checkpointing.");
        shardEndedInput.checkpointer().checkpoint();
    } catch (ShutdownException | InvalidStateException e) {
        log.error("Exception while checkpointing at shard end. Giving up.", e);
    }
}

@Override
public void shutdownRequested(ShutdownRequestedInput shutdownRequestedInput) {
    log.info("Scheduler is shutting down, checkpointing.");
    checkpoint(shutdownRequestedInput.checkpointer());
}

private void checkpoint(RecordProcessorCheckpointer checkpointer) {
    log.info("Checkpointing shard " + kinesisShardId);
    try {
        checkpointer.checkpoint();
    } catch (ShutdownException se) {
        // Ignore checkpoint if the processor instance has been shutdown (fail over).
        log.info("Caught shutdown exception, skipping checkpoint.", se);
    } catch (ThrottlingException e) {
        // Skip checkpoint when throttled. In practice, consider a backoff and retry
 policy.
```

```
        log.error("Caught throttling exception, skipping checkpoint.", e);
    } catch (InvalidStateException e) {
        // This indicates an issue with the DynamoDB table (check for table,
 provisioned IOPS).
        log.error("Cannot save checkpoint to the DynamoDB table used by the Amazon
 Kinesis Client Library.", e);
    }
}
```

Para executar o consumidor

1. Execute o produtor escrito em (p. 28) para injetar registros de negociações de ações no streaming.
2. Verifique se o par chave de acesso/chave secreta recuperado anteriormente (durante a criação do usuário do IAM) foi salvo no arquivo`~/.aws/credentials`.
3. Execute a classe `StockTradesProcessor` com os seguintes argumentos:

   ```
   StockTradesProcessor StockTradeStream us-west-2
   ```

   Observe que, se você criou o fluxo em uma região diferente de `us-west-2`, será necessário especificar essa região aqui.

Depois de um minuto, deverá aparecer uma saída como a seguir, atualizada a cada minuto a partir de então:

```
****** Shard shardId-000000000001 stats for last 1 minute ******
Most popular stock being bought: WMT, 27 buys.
Most popular stock being sold: PTR, 14 sells.
****************************************************************
```

Próximas etapas

Etapa 6: (Opcional) Estender o consumidor (p. 34)

Etapa 6: (Opcional) Estender o consumidor

Esta seção opcional mostra como estender o código de consumidor para um cenário um pouco mais elaborado.

Se quiser saber mais sobre os maiores pedidos de venda a cada minuto, você poderá modificar a classe `StockStats` em três locais para acomodar essa nova prioridade.

Para estender o consumidor

1. Adicione novas variáveis de instância:

   ```
   // Ticker symbol of the stock that had the largest quantity of shares sold
   private String largestSellOrderStock;
   // Quantity of shares for the largest sell order trade
   private long largestSellOrderQuantity;
   ```

2. Adicione o seguinte código a `addStockTrade`:

```
if (type == TradeType.SELL) {
     if (largestSellOrderStock == null || trade.getQuantity() >
 largestSellOrderQuantity) {
         largestSellOrderStock = trade.getTickerSymbol();
         largestSellOrderQuantity = trade.getQuantity();
     }
 }
```

3. Modifique o método `toString` para imprimir as informações adicionais:

```
public String toString() {
    return String.format(
        "Most popular stock being bought: %s, %d buys.%n" +
        "Most popular stock being sold: %s, %d sells.%n" +
        "Largest sell order: %d shares of %s.",
        getMostPopularStock(TradeType.BUY), getMostPopularStockCount(TradeType.BUY),
        getMostPopularStock(TradeType.SELL), getMostPopularStockCount(TradeType.SELL),
        largestSellOrderQuantity, largestSellOrderStock);
}
```

Se você executar o consumidor agora (lembre-se de executar o produtor também), deverá aparecer uma saída semelhante a esta:

```
****** Shard shardId-000000000001 stats for last 1 minute ******
Most popular stock being bought: WMT, 27 buys.
Most popular stock being sold: PTR, 14 sells.
Largest sell order: 996 shares of BUD.
****************************************************************
```

Próximas etapas

Etapa 7: Concluir (p. 35)

Etapa 7: Concluir

Como você está pagando para usar o stream de dados do Kinesis, certifique-se de excluí-lo e excluir a tabela do Amazon DynamoDB correspondente quando concluir. As cobranças nominais ocorrerão em um stream ativo mesmo quando você não estiver enviando e recebendo registros. Isso ocorre porque um stream ativo usa recursos por meio da "escuta" contínua de registros recebidos e solicitações para obter registros.

Para excluir o stream e tabela

1. Desligue os produtores e consumidores que possam estar em execução.
2. Abra o console do Kinesis em https://console.aws.amazon.com/kinesis.
3. Escolha o stream que você criou para este aplicativo (`StockTradeStream`).
4. Escolha Delete Stream (Excluir streaming).
5. Abra o console do DynamoDB em https://console.aws.amazon.com/dynamodb/.
6. Exclua a tabela `StockTradesProcessor`.

Resumo

Para processar uma grande quantidade de dados quase em tempo real, não é preciso escrever nenhum código mágico nem desenvolver uma imensa infraestrutura. É tão simples quanto escrever lógica processar uma pequena quantidade de dados (como escrever`processRecord(Record)`), só que usando o Kinesis Data Streams para escalar de modo que funcione para uma grande quantidade de dados de streaming. Você não precisa se preocupar com a escalabilidade do processamento, porque o Kinesis Data Streams cuida disso para você. Você só precisa enviar seus registros de streaming ao Kinesis Data Streams e escrever a lógica para processar cada novo registro recebido.

Veja aqui alguns aprimoramentos potenciais para este aplicativo.

Agregar em todos os estilhaços

Atualmente, você obtém estatísticas resultantes da agregação de registros de dados recebidos por um único operador proveniente de um único estilhaço. (Um estilhaço não pode ser processado por mais de um operador em um aplicativo ao mesmo tempo). Naturalmente, quando escala e tem mais de um estilhaço, você pode agregar em todos os estilhaços. É possível fazer isso tendo uma arquitetura de pipeline em que a saída de cada operador é alimentada em outro fluxo com um único estilhaço, o qual é processado por um operador que agrega as saídas do primeiro estágio. Como os dados do primeiro estágio são limitados (um exemplo por minuto por estilhaço), eles podem ser facilmente tratados por um estilhaço.

Escalar o processamento

Quando o stream é expandido para ter muitos estilhaços (porque muitos produtores estão enviando dados), a maneira de escalar o processamento é adicionando mais operadores. Você pode executar os operadores nas instâncias do Amazon EC2 e usar os grupos do Auto Scaling.

Usar conectores para o Amazon S3/DynamoDB/Amazon Redshift/Storm

Como um stream é processado continuamente, sua saída pode ser enviada a outros destinos.AWSfornececonectoresPara integrar o Kinesis Data Streams com outrosAWSServiços da e ferramentas de terceiros.

Tutorial: Processar dados de ações em tempo real usando KCL e KCL 1.x

O cenário deste tutorial envolve consumir negociações de ações em um stream de dados e escrever um aplicativo do Amazon Kinesis Data Streams que realiza cálculos no streaming. Você aprenderá a enviar um stream de registros ao Kinesis Data Streams e implementar um aplicativo que consome e processa os registros quase em tempo real.

> **Important**
>
> Depois de criar um streaming, sua conta incorre em cobranças nominais pelo uso do Kinesis Data Streams, pois o Kinesis Data Streams não está qualificado para oAWSNível gratuito. Depois que for iniciado, o aplicativo consumidor também incorrerá em cobranças nominais pelo uso do Amazon DynamoDB. O aplicativo consumidor usa o DynamoDB para rastrear o estado de processamento. Quando você terminar de usar este aplicativo, exclua seuAWSrecursos para parar de incorrer em cobranças. Para obter mais informações, consulte Etapa 7: Concluir (p. 49).

O código não acessa os dados reais da bolsa de valores, ele simula o stream de negociações de ações. Isso é feito com o uso de um gerador de negociações de ações aleatórias cujo ponto de partida são dados do mercado real referente às 25 principais ações por capitalização de mercado em fevereiro de 2015. Se tiver acesso a um streaming de negociações de ações em tempo real, você poderá se interessar em

derivar estatísticas úteis e em tempo hábil desse streaming. Por exemplo, talvez convenha executar uma análise de janela deslizante na qual você determina a ação mais popular que foi adquirida nos últimos 5 minutos. Ou talvez convenha uma notificação sempre que uma ordem de venda for muito grande (ou seja, tenha muitas quotas). Você pode estender o código nesta série para oferecer essa funcionalidade.

Você pode executar as etapas deste tutorial no desktop ou laptop e executar o código de produtor e de consumidor na mesma máquina ou em qualquer plataforma compatível com os requisitos definidos, como o Amazon Elastic Compute Cloud (Amazon EC2).

Os exemplos mostrados usam a região Oeste dos EUA (Oregon), mas funcionam em qualquer uma dasAWSRegiões compatíveis com o Kinesis Data Streams.

Tarefas

Pré-requisitos

Estes são os requisitos para concluir o Tutorial: Processar dados de ações em tempo real usando KCL e KCL 1.x (p. 36).

Conta da Amazon Web Services

Antes de começar, familiarize-se com os conceitos abordados em Terminologia e conceitos do Amazon Kinesis Data Streams (p. 3), especialmente fluxos, estilhaços, produtores e consumidores. Também é útil ter concluído Instalar e configurar o AWS CLI (p. 15).

Você precisa de uma conta da AWS e de um navegador da web para acessar o AWS Management Console.

Para acessar o console, use seu nome de usuário e senha do IAM para fazer login noAWS Management ConsoledoPágina de login do IAM. O IAM permite que você controle com segurança o acesso aoServiços da AWSE recursos do seuConta da AWS. Para obter detalhes sobre credenciais programáticas e de console, consulteCompreender e obter suas credenciais de segurançanoAWSReferência geral.

Para obter mais informações sobre o IAM e instruções de configuração de chave de segurança, consulteCriar um usuário do IAM.

Requisitos de software do sistema

O sistema usado para executar o aplicativo precisa ter o Java 7 ou superior instalado. Para fazer download e instalar o Java Development Kit (JDK) mais recente, acesse o Site de instalação do Java SE da Oracle.

Se você tiver um Java IDE, como o Eclipse, poderá abrir o código-fonte, editá-lo, compilá-lo e executá-lo.

Você precisa da versão mais recente do AWS SDK for Java. Se você usar o Eclipse como IDE, poderá instalar oAWSToolkit for EclipseEm vez disso.

O aplicativo consumidor requer a Kinesis Client Library (KCL) versão 1.2.1 ou superior, que você pode obter doGitHubemKinesis Client Library (Java).

Próximas etapas

Etapa 1: Criar um streaming de dados (p. 38)

Etapa 1: Criar um streaming de dados

Na primeira etapa do Tutorial: Processar dados de ações em tempo real usando KCL e KCL 1.x (p. 36), você cria o streaming que usará em etapas subsequentes.

Para criar um fluxo

1. Faça login no AWS Management Console e abra o console do Kinesis em https://console.aws.amazon.com/kinesis.
2. Selecione Data Streams (Streams de dados) no painel de navegação.
3. Na barra de navegação, expanda o seletor de região e escolha uma região.
4. Escolha Create Kinesis stream (Criar streaming do Kinesis).
5. Insira um nome para seu streaming (por exemplo, **`StockTradeStream`**).
6. Digite **`1`** como o número de estilhaços, mas deixe Estimate the number of shards you'll need (Estimar o número de estilhaços de que você precisará) recolhido.
7. Escolha Create Kinesis stream (Criar streaming do Kinesis).

NoStreams do KinesisPágina de listagem, o status do seu streaming é`CREATING`Enquanto o stream está sendo criado. Quando o stream fica pronto para uso, o status é alterado para `ACTIVE`. Escolha o nome do fluxo. Na página exibida, a guia Details (Detalhes) exibe um resumo da configuração do streaming. A seção Monitoring (Monitoramento) exibe informações de monitoramento do streaming.

Informações adicionais sobre estilhaços

Ao começar a usar o Kinesis Data Streams fora deste tutorial, você poderá precisar planejar o processo de criação do streaming mais cuidadosamente. Você deve se planejar para a demanda máxima esperada ao provisionar estilhaços. Usando este cenário como exemplo, o tráfego de negociações da bolsa de valores dos EUA atinge o pico durante o dia (fuso horário do leste dos EUA) e, a partir desse horário, é preciso tirar amostras das estimativas de demanda. Em seguida, você tem a opção de provisionar para a máxima demanda esperada ou expandir e reduzir o stream em resposta às variações de demanda.

Um estilhaço é uma unidade de capacidade de taxa de transferência. NoCriar streaming do Kinesispágina, expandaEstimate the number of shards you need. Digite o tamanho médio do registro, o máximo de registros gravados por segundo e o número de aplicativos de consumo usando as seguintes diretrizes:

Tamanho médio do registro

> Uma estimativa do tamanho médio calculado dos registros. Se você não sabe esse valor, use o tamanho de registro máximo estimado.

Máximo de registros gravados

> Leve em conta o número de entidades que fornecem dados e o número aproximado de registros por segundo produzidos por cada um. Por exemplo, se você recebe dados de negociações de ações provenientes de 20 servidores mercantis, com cada um gerando 250 negociações por segundo, o número total de transações (registros) por segundo é 5.000 por segundo.

Número de aplicativos de consumo

> Número de aplicativos que fazem leitura do stream de forma independente para processar o stream de outro modo e produzir saída diferente. Cada aplicativo pode ter várias instâncias em execução em máquinas diferentes (ou seja, execução em um cluster) para dar conta de um streaming de alto volume.

Se o número estimado de estilhaços mostrado exceder o limite atual de estilhaços, poderá ser necessário enviar uma solicitação para aumentar esse limite para poder criar um streaming com esse número de estilhaços. Para solicitar um aumento no limite de estilhaços, use oFormulário de limites do Kinesis Data Streams. Para obter mais informações sobre streams e estilhaços, consulteCriar e gerenciar streamings (p. 68).

Próximas etapas

Etapa 2: Criar uma política e um usuário do IAM (p. 39)

Etapa 2: Criar uma política e um usuário do IAM

Práticas Recomendadas de segurança paraAWSDite o uso de permissões granular para controlar o acesso a recursos diferentes.AWS Identity and Access Management O (IAM) permite gerenciar usuários e permissões de usuário noAWS. Uma Política do IAM lista explicitamente as ações permitidas e os recursos aos quais as ações são aplicáveis.

Veja a seguir as permissões mínimas comumente necessárias para um produtor e um consumidor do Kinesis Data Streams.

Produtor

Ações	Recurso	Finalidade
`DescribeStream`, `DescribeStreamSummary`, `DescribeStreamConsumer`	Fluxo de dados do Kinesis	Antes de tentar gravar registros, o produtor verifica se o s contidos no stream e se o stream tem um consumidor.
`SubscribeToShard`, `RegisterStreamConsumer`	Fluxo de dados do Kinesis	Faz a inscrição e registra um consumidor em um estilhaç
`PutRecord`, `PutRecords`	Fluxo de dados do Kinesis	Grave registros no Kinesis Data Streams.

Consumidor

Ações	Recurso	Finalidade
`DescribeStream`	Fluxo de dados do Kinesis	Antes de tentar ler registros, o consumidor verifica se o st contidos no stream.
`GetRecords`, `GetShardIterator`	Fluxo de dados do Kinesis	Ler registros de um estilhaço do Kinesis Data Streams.
`CreateTable`, `DescribeTable`, `GetItem`, `PutItem`, `Scan`, `UpdateItem`	Tabela do Amazon DynamoDB	Se o consumidor é desenvolvido usando a Kinesis Client tabela do DynamoDB para rastrear o estado de processa cria a tabela.
`DeleteItem`	Tabela do Amazon DynamoDB	Para quando o consumidor executar operações de divisã Streams.
`PutMetricData`	AmazôniaCloudWatchtora	A KCL também faz upload de métricas para o CloudWatc

Para esse aplicativo, você cria uma única política do IAM que concede todas as permissões anteriores. Na prática, talvez convenha considerar a criação de duas políticas, uma para produtores e uma para consumidores.

Para criar uma política do IAM

1. Localize o Nome de recurso da Amazon (ARN) para o novo stream. Você pode encontrar esse ARN listado como Stream ARN (ARN do streaming) na parte superior da guia Details (Detalhes). O formato do ARN é o seguinte:

   ```
   arn:aws:kinesis:region:account:stream/name
   ```

   região

   Código da região; por exemplo, `us-west-2`. Para obter mais informações, consulte Conceitos de região e zona de disponibilidade.

   conta

   OAWSID da conta, conforme mostrado emConfigurações da conta.

   name

   Nome do stream de Etapa 1: Criar um streaming de dados (p. 38), que é `StockTradeStream`.

2. Determine o ARN da tabela do DynamoDB a ser usada pelo consumidor (e criada pela primeira instância de consumidor). Ele deve estar no seguinte formato:

   ```
   arn:aws:dynamodb:region:account:table/name
   ```

   A região e a conta são do mesmo local que a etapa anterior, mas desta vez name é o nome da tabela criada e usada pelo aplicativo de consumidor. A KCL usada pelo consumidor usa o nome do aplicativo como o nome da tabela. Use o nome do aplicativo que será usado mais tarde, `StockTradesProcessor`.

3. No console do IAM, emPolíticas(https://console.aws.amazon.com/iam/home#policies), escolhaCriar política. Se esta for a primeira vez que você trabalha com políticas do IAM, escolhaComece a usar,Criar política.
4. Escolha Select (Selecionar) ao lado de Policy Generator (Gerador de políticas).
5. SelecioneAmazon Kinesiscomo oAWSserviço.
6. Selecione `DescribeStream`, `GetShardIterator`, `GetRecords`, `PutRecord`e `PutRecords` como ações permitidas.
7. Digite o ARN criado na Etapa 1.
8. Use Add Statement (Adicionar instrução) para cada um dos seguintes:

AWS Serviço	Ações	ARN
Amazon DynamoDB	`CreateTable`, `DeleteItem`, `DescribeTable`, `GetItem`, `PutItem`, `Scan`, `UpdateItem`	O ARN que você criou na etapa 2
Amazon CloudWatch	`PutMetricData`	*

   O asterisco (*) é usado quando não é necessário especificar um ARN. Nesse caso, é porque não há nenhum recurso específico no CloudWatch para o qual a ação `PutMetricData` é invocada.

9. Escolha Next Step.
10. Altere Policy Name (Nome da política) para `StockTradeStreamPolicy`, analise o código e escolha Create Policy (Criar política).

O documento de política resultante deve ser algo como o exemplo a seguir:

```
{
  "Version": "2012-10-17",
  "Statement": [
    {
      "Sid": "Stmt123",
      "Effect": "Allow",
      "Action": [
        "kinesis:DescribeStream",
        "kinesis:PutRecord",
        "kinesis:PutRecords",
        "kinesis:GetShardIterator",
        "kinesis:GetRecords",
        "kinesis:ListShards",
        "kinesis:DescribeStreamSummary",
        "kinesis:RegisterStreamConsumer"
      ],
      "Resource": [
        "arn:aws:kinesis:us-west-2:123:stream/StockTradeStream"
      ]
    },
    {
      "Sid": "Stmt234",
      "Effect": "Allow",
      "Action": [
        "kinesis:SubscribeToShard",
        "kinesis:DescribeStreamConsumer"
      ],
      "Resource": [
        "arn:aws:kinesis:us-west-2:123:stream/StockTradeStream/*"
      ]
    },
    {
      "Sid": "Stmt456",
      "Effect": "Allow",
      "Action": [
        "dynamodb:*"
      ],
      "Resource": [
        "arn:aws:dynamodb:us-west-2:123:table/StockTradesProcessor"
      ]
    },
    {
      "Sid": "Stmt789",
      "Effect": "Allow",
      "Action": [
        "cloudwatch:PutMetricData"
      ],
      "Resource": [
        "*"
      ]
    }
  ]
}
```

Para criar um usuário do IAM

1. Abra o console do IAM em https://console.aws.amazon.com/iam/.
2. Na página Users (Usuários), selecione Add user (Adicionar usuário).
3. Para User name, digite `StockTradeStreamUser`.
4. para oTipo de acesso, escolhaAcesso programáticoE, depois, escolhaPróximo: Permissions

5. Selecione Attach existing policies directly.
6. Pesquise por nome a política que você criou. Selecione a caixa à esquerda do nome da política e, depois, escolhaPróximo: Análise.
7. Revise os detalhes e o resumo e, em seguida, escolha Create user (Criar usuário).
8. Copie o Access key ID (ID da chave de acesso) e salve-o de forma privada. Em Secret access key (Chave de acesso secreta), escolha Show (Mostrar) e salve a chave de forma privada também.
9. Cole as chaves de acesso e chaves secretas em um arquivo local em lugar seguro que somente você possa acessar. Para esse aplicativo, crie um arquivo denominado `~/.aws/credentials` (com permissões restritas). O arquivo deverá estar no seguinte formato:

```
[default]
aws_access_key_id=access key
aws_secret_access_key=secret access key
```

Para anexar uma política do IAM a um usuário

1. No console do IAM, abraPolíticase escolhaAções de políticas.
2. Escolha `StockTradeStreamPolicy` e Attach (Anexar).
3. Escolha `StockTradeStreamUser` e Attach Policy (Anexar política).

Próximas etapas

Etapa 3: Baixar e criar o código de implementação (p. 42)

Etapa 3: Baixar e criar o código de implementação

O código esqueleto é fornecido para o the section called “Tutorial: Processar dados de ações em tempo real usando KCL e KCL 1.x” (p. 36). Ele contém uma implementação de stub para o consumo do streaming de negociações de ações (produtor) e para o processamento dos dados (consumidor). O procedimento a seguir mostra como concluir as implementações.

Para fazer download e compilação do código de implementação

1. Faça download do código-fonte no computador.
2. Crie um projeto no IDE favorito com o código-fonte, respeitando a estrutura de diretório fornecida.
3. Adicione as seguintes bibliotecas ao projeto:
   - Amazon Kinesis Client Library (KCL)
   - AWS SDK
   - ApacheHttpCore
   - ApacheHttpClient
   - Apache Commons Lang
   - Apache Commons Logging
   - Guava (Google Core Libraries For Java)
   - Jackson Annotations
   - Jackson Core
   - Jackson Databind
   - Jackson Dataformat: CBOR
   - Joda Time

4. Dependendo do seu IDE, o projeto pode ser compilado automaticamente. Se não, compile o projeto usando as etapas apropriadas para o seu IDE.

Se concluiu essas etapas com êxito, você agora está pronto para ir para a próxima seção, the section called “Etapa 4: Implementar o produtor” (p. 43). Se a compilação gerar erros em qualquer estágio, investigue e os corrija antes de continuar.

Próximas etapas

(p. 43)

Etapa 4: Implementar o produtor

O aplicativo no Tutorial: Processar dados de ações em tempo real usando KCL e KCL 1.x (p. 36) usa o cenário real de monitoramento de negociações em bolsa de valores. Os princípios a seguir explicam brevemente como este cenário é mapeado para o produtor e a estrutura de código de apoio.

Consulte o código-fonte e analise as informações a seguir.

StockTradeclasse

Uma negociação de ação individual é representada por uma instância da classe `StockTrade`. Essa instância contém atributos como o símbolo ticker, o preço, o número de ações, o tipo da negociação (compra ou venda) e um ID que identifica a negociação com exclusividade. Essa classe é implementada para você.

Registro de stream

Um stream é uma sequência de registros. Um registro é uma serialização de uma instância `StockTrade` no formato JSON. Por exemplo:

```
{
  "tickerSymbol": "AMZN",
  "tradeType": "BUY",
  "price": 395.87,
  "quantity": 16,
  "id": 3567129045
}
```

StockTradeClasse geradora

`StockTradeGenerator` tem um método denominado `getRandomTrade()`, que retorna uma nova negociação de ações gerada aleatoriamente sempre que ela é invocada. Essa classe é implementada para você.

StockTradesClasse de gravador

O`main`método do produtor,`StockTradesWriter`Recupera continuamente uma transação aleatória e a envia ao Kinesis Data Streams executando as seguintes tarefas:

1. Lê o nome do stream e o nome da região como entrada.
2. Cria um `AmazonKinesisClientBuilder`.
3. Usa o criador do cliente para definir região, credenciais e configuração do cliente.
4. Cria um cliente `AmazonKinesis` usando o criador do cliente.
5. Verifica se o stream existe e está ativo (se não, ele será encerrado com um erro).
6. Em um loop contínuo, chama o método `StockTradeGenerator.getRandomTrade()` e o método `sendStockTrade` para enviar a negociação ao stream a cada 100 milissegundos.

O método `sendStockTrade` da classe `StockTradesWriter` tem o seguinte código:

```
private static void sendStockTrade(StockTrade trade, AmazonKinesis kinesisClient,
 String streamName) {
    byte[] bytes = trade.toJsonAsBytes();
    // The bytes could be null if there is an issue with the JSON serialization by the
 Jackson JSON library.
    if (bytes == null) {
        LOG.warn("Could not get JSON bytes for stock trade");
        return;
    }

    LOG.info("Putting trade: " + trade.toString());
    PutRecordRequest putRecord = new PutRecordRequest();
    putRecord.setStreamName(streamName);
    // We use the ticker symbol as the partition key, explained in the Supplemental
 Information section below.
    putRecord.setPartitionKey(trade.getTickerSymbol());
    putRecord.setData(ByteBuffer.wrap(bytes));

    try {
        kinesisClient.putRecord(putRecord);
    } catch (AmazonClientException ex) {
        LOG.warn("Error sending record to Amazon Kinesis.", ex);
    }
}
```

Consulte o desmembramento do código a seguir:

- A API de `PutRecord` espera uma matriz de bytes, e você precisa converter `trade` no formato JSON. Essa única linha de código executa a seguinte operação:

  ```
  byte[] bytes = trade.toJsonAsBytes();
  ```

- Antes de enviar a negociação, você cria uma nova instância de `PutRecordRequest` (denominada `putRecord` neste caso):

  ```
  PutRecordRequest putRecord = new PutRecordRequest();
  ```

  Cada chamada a `PutRecord` requer o nome do stream, uma chave de partição e um blob de dados. O código a seguir preenche esses campos no objeto `putRecord` usando seus métodos `setXxxx()`:

  ```
  putRecord.setStreamName(streamName);
  putRecord.setPartitionKey(trade.getTickerSymbol());
  putRecord.setData(ByteBuffer.wrap(bytes));
  ```

  O exemplo usa um tíquete de ações como uma chave de partição, que mapeia o registro para um determinado estilhaço. Na prática, você deve ter centenas ou milhares de chaves de partição por estilhaço, de forma que os registros sejam uniformemente disseminados no seu stream. Para obter mais informações sobre como adicionar dados a um stream, consulte Adicionar dados a um stream (p. 101).

  Agora `putRecord` está pronto para enviar para o cliente (operação `put`):

  ```
  kinesisClient.putRecord(putRecord);
  ```

- A verificação e o registro de erros são sempre inclusões úteis. Este código registra condições de erro:

```
if (bytes == null) {
    LOG.warn("Could not get JSON bytes for stock trade");
    return;
}
```

Adicione o bloco try/catch ao redor da operação `put`:

```
try {
       kinesisClient.putRecord(putRecord);
} catch (AmazonClientException ex) {
       LOG.warn("Error sending record to Amazon Kinesis.", ex);
}
```

Isso ocorre porque um Kinesis Data Streams`put`A operação do pode falhar devido a erro de rede ou porque o stream pode atingir o limite de taxa de transferência e ficar limitado. Recomendamos considerar cuidadosamente sua política de retentativa para operações `put` a fim de evitar perda de dados, por exemplo, usando como uma simples retentativa.

- O registro de status é útil mas opcional:

```
LOG.info("Putting trade: " + trade.toString());
```

O produtor mostrado aqui usa a funcionalidade de registro único da API do Kinesis Data Streams,`PutRecord`. Na prática, se um produtor individual gerar muitos registros, costuma ser mais eficiente usar a funcionalidade de vários registros de `PutRecords` e enviar lotes de registros por vez. Para obter mais informações, consulte Adicionar dados a um stream (p. 101).

Para executar o produtor

1. Verifique se o par chave de acesso e chave secreta recuperado anteriormente (durante a criação do usuário do IAM) foi salvo no arquivo`~/.aws/credentials`.
2. Execute a classe `StockTradeWriter` com os seguintes argumentos:

```
StockTradeStream us-west-2
```

Se você criou o stream em uma região diferente de `us-west-2`, precisará especificar essa região aqui.

Você deve ver saída semelhante a:

```
Feb 16, 2015 3:53:00 PM
com.amazonaws.services.kinesis.samples.stocktrades.writer.StockTradesWriter sendStockTrade
INFO: Putting trade: ID 8: SELL 996 shares of BUD for $124.18
Feb 16, 2015 3:53:00 PM
com.amazonaws.services.kinesis.samples.stocktrades.writer.StockTradesWriter sendStockTrade
INFO: Putting trade: ID 9: BUY 159 shares of GE for $20.85
Feb 16, 2015 3:53:01 PM
com.amazonaws.services.kinesis.samples.stocktrades.writer.StockTradesWriter sendStockTrade
INFO: Putting trade: ID 10: BUY 322 shares of WMT for $90.08
```

Seu stream de negociações de ações agora está sendo ingerido pelo Kinesis Data Streams.

Próximas etapas

Etapa 5: Implementar o consumidor (p. 46)

Etapa 5: Implementar o consumidor

O aplicativo consumidor no Tutorial: Processar dados de ações em tempo real usando KCL e KCL 1.x (p. 36) processa continuamente o streaming de negociações de ações criado em (p. 43). Em seguida, ele produz as ações mais populares compradas e vendidas a cada minuto. O aplicativo é compilado na Kinesis Client Library (KCL), que faz grande parte do trabalho pesado comum dos aplicativos consumidores. Para obter mais informações, consulte Desenvolver consumidores do KCL 1.x (p. 133).

Consulte o código-fonte e analise as informações a seguir.

StockTradesClasse de processador

Principal classe do consumidor fornecida e que executa as seguintes tarefas:

- Lê o aplicativo, o streaming e os nomes de região passados como argumentos.
- Lê credenciais de `~/.aws/credentials`.
- Cria uma instância de `RecordProcessorFactory` que veicula instâncias de `RecordProcessor`, implementadas por uma instância de `StockTradeRecordProcessor`.
- Cria um trabalhador KCL com o`RecordProcessorFactory`Instância e uma configuração padrão, inclusive o nome do streaming, as credenciais e o nome do aplicativo.
- O operador cria um novo thread para cada estilhaço (atribuído a essa instância de consumidor), que faz loop continuamente para ler registros do Kinesis Data Streams. Em seguida, ele invoca a instância de `RecordProcessor` para processar cada lote de registros recebidos.

StockTradeRecordProcessorclasse

Implementação da instância de `RecordProcessor`, que, por sua vez, implementa três métodos necessários: `initialize`, `processRecords` e `shutdown`.

Como os nomes sugerem,`initialize`e`shutdown`São usados pela Kinesis Client Library para permitir que o processador de registros saiba quando deve estar pronto para começar a receber registros e quando deve esperar parar de receber registros, respectivamente, para que possa realizar qualquer tarefa de configuração e encerramento específica ao aplicativo. O código disso é fornecido para você. O processamento principal ocorre no método `processRecords`, que, por sua vez, usa `processRecord` para cada registro. Esse último método é fornecido como um código esqueleto quase todo vazio, para você implementar na próxima etapa, onde é melhor explicado.

Observe também a implementação dos métodos de suporte de `processRecord`: `reportStats` e `resetStats`, que estão vazios no código-fonte original.

O método `processRecords`, implementado para você, executa as seguintes etapas:

- Para cada registro passado, chama `processRecord`.
- Se tiver decorrido pelo menos 1 minuto após o último relatório, chamará `reportStats()`, que imprime as estatísticas mais recentes e, em seguida, `resetStats()`, que limpa as estatísticas para que o próximo intervalo inclua apenas registros novos.
- Define o próximo horário para geração de relatórios.
- Se tiver decorrido pelo menos 1 minuto após o último ponto de verificação, chamará `checkpoint()`.
- Define o próximo horário do ponto de verificação.

Este método usa intervalos de 60 segundos como taxa de geração de relatórios e definição de pontos de verificação. Para obter mais informações sobre definição de pontos de verificação, consulte Informações adicionais sobre o consumidor (p. 48).

StockStatsclasse

Essa classe fornece retenção de dados e rastreamento de estatísticas em relação às ações mais populares ao longo do tempo. Esse código, fornecido para você, contém os seguintes métodos:

- `addStockTrade(StockTrade)`: injeta o `StockTrade` conhecido nas estatísticas correntes.

- `toString()`: retorna as estatísticas em uma string formatada.

  Essa classe rastreia as ações mais populares mantendo uma contagem corrente do número total de negociações de cada ação e a contagem máxima. Ela atualiza essas contagens sempre que chega uma negociação de ação.

Adicione código aos métodos da classe `StockTradeRecordProcessor`, como mostrado nas etapas a seguir.

Para implementar o consumidor

1. Implemente o método `processRecord` instanciando um objeto `StockTrade` de tamanho correto e adicionando a ele os dados do registro, registrando um aviso caso ocorra problema.

```
StockTrade trade = StockTrade.fromJsonAsBytes(record.getData().array());
if (trade == null) {
    LOG.warn("Skipping record. Unable to parse record into StockTrade. Partition Key: "
 + record.getPartitionKey());
    return;
}
stockStats.addStockTrade(trade);
```

2. Implemente um método `reportStats` simples. Sinta-se à vontade para modificar o formato de saída conforme suas preferências.

```
System.out.println("****** Shard " + kinesisShardId + " stats for last 1 minute ******
\n" +
                   stockStats + "\n" +
                   "****************************************************************
\n");
```

3. Finalmente, implemente o método `resetStats`, que cria uma nova instância de `stockStats`.

```
stockStats = new StockStats();
```

Para executar o consumidor

1. Execute o produtor escrito em (p. 43) para injetar registros de negociações de ações no streaming.
2. Verifique se o par chave de acesso e chave secreta recuperado anteriormente (durante a criação do usuário do IAM) foi salvo no arquivo`~/.aws/credentials`.
3. Execute a classe `StockTradesProcessor` com os seguintes argumentos:

```
StockTradesProcessor StockTradeStream us-west-2
```

   Observe que, se você criou o stream em uma região diferente de `us-west-2`, precisará especificar essa região aqui.

Depois de um minuto, deverá aparecer uma saída como a seguir, atualizada a cada minuto a partir de então:

```
****** Shard shardId-000000000001 stats for last 1 minute ******
Most popular stock being bought: WMT, 27 buys.
Most popular stock being sold: PTR, 14 sells.
****************************************************************
```

Informações adicionais sobre o consumidor

Se você estiver familiarizado com as vantagens da Kinesis Client Library, discutida emDesenvolver consumidores do KCL 1.x (p. 133)E em outros lugares, você pode se perguntar por que deve usá-la aqui. Embora você use apenas um streaming de estilhaço e uma instância de consumidor para processá-la, ainda é mais fácil implementar o consumidor usando a KCL. Compare as etapas de implementação do código na seção do produtor para o consumidor para ver a facilidade comparativa para implementar um consumidor. Isso se deve, em grande parte, aos serviços que a KCL fornece.

Nesse aplicativo, você se concentra na implementação de uma classe de processador de registros, capaz de processar registros individuais. Você não precisa se preocupar com a forma como os registros são obtidos do Kinesis Data Streams; A KCL obtém os registros e invoca o processador de registros sempre que há novos registros disponíveis. Além disso, você não precisa se preocupar com a quantidade de estilhaços e de instâncias de consumidor. Se o streaming for escalonado, você não precisará reescrever o aplicativo para lidar com mais de um estilhaço ou com uma instância de consumidor.

O termo definição de pontos de verificação significa registrar o ponto no streaming até os registros de dados que foram consumidos e processados até o momento, de modo que, se o aplicativo falhar, o streaming será lido a partir daquele ponto e não do início do streaming. O assunto da definição de pontos de verificação e os vários padrões de design e melhores práticas relativos estão fora do escopo deste capítulo. No entanto, é algo que você pode encontrar em ambientes de produção.

Como você aprendeu em (p. 43), `oput`As operações na Kinesis Data Streams API usam umchave de partiçãocomo entrada. O Kinesis Data Streams usa uma chave de partição como um mecanismo para dividir registros em vários estilhaços (quando há mais de um estilhaço no streaming). A mesma chave de partição sempre roteia para o mesmo estilhaço. Isso permite que o consumidor que processa um determinado estilhaço seja projetado com a premissa de que os registros com a mesma chave de partição só sejam enviados a esse consumidor, e nenhum registro com a mesma chave de partição termine em qualquer outro consumidor. Portanto, o operador de um consumidor pode agregar todos os registros com a mesma chave de partição sem se preocupar com a ausência de dados necessários.

Neste aplicativo, o processamento de registros do consumidor não é intensivo, então você pode usar um estilhaço e fazer o processamento no mesmo thread da KCL. No entanto, na prática, considere primeiro escalar o número de estilhaços. Em alguns casos, talvez convenha mudar o processamento para outro thread ou usar um grupo de threads se for esperado que o processamento de registros seja intensivo. Dessa forma, a KCL pode obter novos registros mais rapidamente, enquanto outros threads podem processar os registros em paralelo. O design multithread não é trivial e deve ser planejado com técnicas avançadas, portanto, aumentar a contagem de estilhaços costuma ser a maneira mais eficiente e econômica de escalar.

Próximas etapas

Etapa 6: (Opcional) Estender o consumidor (p. 48)

Etapa 6: (Opcional) Estender o consumidor

O aplicativo no Tutorial: Processar dados de ações em tempo real usando KCL e KCL 1.x (p. 36) já pode ser suficiente para os seus propósitos. Esta seção opcional mostra como estender o código de consumidor para um cenário um pouco mais elaborado.

Se quiser saber mais sobre os maiores pedidos de venda a cada minuto, você poderá modificar a classe `StockStats` em três locais para acomodar essa nova prioridade.

Para estender o consumidor

1. Adicione novas variáveis de instância:

```
// Ticker symbol of the stock that had the largest quantity of shares sold
```

```
private String largestSellOrderStock;
// Quantity of shares for the largest sell order trade
private long largestSellOrderQuantity;
```

2. Adicione o seguinte código a `addStockTrade`:

```
if (type == TradeType.SELL) {
    if (largestSellOrderStock == null || trade.getQuantity() >
largestSellOrderQuantity) {
        largestSellOrderStock = trade.getTickerSymbol();
        largestSellOrderQuantity = trade.getQuantity();
    }
}
```

3. Modifique o método `toString` para imprimir as informações adicionais:

```
public String toString() {
    return String.format(
            "Most popular stock being bought: %s, %d buys.%n" +
            "Most popular stock being sold: %s, %d sells.%n" +
            "Largest sell order: %d shares of %s.",
            getMostPopularStock(TradeType.BUY),
getMostPopularStockCount(TradeType.BUY),
            getMostPopularStock(TradeType.SELL),
getMostPopularStockCount(TradeType.SELL),
            largestSellOrderQuantity, largestSellOrderStock);
}
```

Se você executar o consumidor agora (lembre-se de executar o produtor também), deverá aparecer uma saída semelhante a esta:

```
****** Shard shardId-000000000001 stats for last 1 minute ******
 Most popular stock being bought: WMT, 27 buys.
 Most popular stock being sold: PTR, 14 sells.
 Largest sell order: 996 shares of BUD.
 ****************************************************************
```

Próximas etapas

Etapa 7: Concluir (p. 49)

Etapa 7: Concluir

Como você está pagando para usar o stream de dados do Kinesis, certifique-se de excluí-lo e excluir a tabela do Amazon DynamoDB correspondente ao concluir. As cobranças nominais ocorrerão em um stream ativo mesmo quando você não estiver enviando e recebendo registros. Isso ocorre porque um stream ativo usa recursos por meio da "escuta" contínua de registros recebidos e solicitações para obter registros.

Para excluir o stream e tabela

1. Desligue os produtores e consumidores que possam estar em execução.
2. Abra o console do Kinesis em https://console.aws.amazon.com/kinesis.
3. Escolha o stream que você criou para este aplicativo (`StockTradeStream`).
4. Escolha Delete Stream (Excluir streaming).
5. Abra o console do DynamoDB em https://console.aws.amazon.com/dynamodb/.
6. Exclua a tabela `StockTradesProcessor`.

Resumo

Para processar uma grande quantidade de dados quase em tempo real, não é preciso escrever nenhum código mágico nem desenvolver uma imensa infraestrutura. É tão simples quanto escrever lógica processar uma pequena quantidade de dados (como escrever`processRecord(Record)`), só que usando o Kinesis Data Streams para escalar de modo que funcione para uma grande quantidade de dados de streaming. Você não precisa se preocupar com a escalabilidade do processamento, porque o Kinesis Data Streams cuida disso para você. Você só precisa enviar seus registros de streaming ao Kinesis Data Streams e escrever a lógica para processar cada novo registro recebido.

Veja aqui alguns aprimoramentos potenciais para este aplicativo.

Agregar em todos os estilhaços

Atualmente, você obtém estatísticas resultantes da agregação de registros de dados recebidos por um único operador proveniente de um único estilhaço. (Um estilhaço não pode ser processado por mais de um operador em um aplicativo ao mesmo tempo). Naturalmente, quando escala e tem mais de um estilhaço, você pode agregar em todos os estilhaços. É possível fazer isso tendo uma arquitetura de pipeline em que a saída de cada operador é alimentada em outro fluxo com um único estilhaço, o qual é processado por um operador que agrega as saídas do primeiro estágio. Como os dados do primeiro estágio são limitados (um exemplo por minuto por estilhaço), eles podem ser facilmente tratados por um estilhaço.

Escalar o processamento

Quando o stream é expandido para ter muitos estilhaços (porque muitos produtores estão enviando dados), a maneira de escalar o processamento é adicionando mais operadores. Você pode executar os operadores em instâncias do Amazon EC2 e usar os grupos do Auto Scaling.

Usar conectores para o Amazon S3/DynamoDB/Amazon Redshift/Storm

Como um stream é processado continuamente, sua saída pode ser enviada a outros destinos.AWSfornececonectoresPara integrar o Kinesis Data Streams com outrosAWSServiços e ferramentas de terceiros.

Próximas etapas

- Para obter mais informações sobre como usar as operações da API Kinesis Data Streams, consulteDesenvolver produtores usando a API do Amazon Kinesis Data Streams com oAWS SDK for Java (p. 100),Desenvolver consumidores personalizados com taxa de transferência compartilhada usando o AWS SDK for Java (p. 158), eCriar e gerenciar streamings (p. 68).
- Para obter mais informações sobre a Kinesis Client Library, consulteDesenvolver consumidores do KCL 1.x (p. 133).
- Para obter mais informações sobre como otimizar seu aplicativo, consulte Tópicos avançados (p. 184).

Tutorial: Analisar dados de ações em tempo real usando o Kinesis Data Analytics para aplicativos do Flink

O cenário deste tutorial envolve consumir negociações de ações em um fluxo de dados e escrever umAmazon Kinesis Data Analyticsaplicativo que executa cálculos no fluxo. Você aprenderá a enviar um streaming de registros para o Kinesis Data Streams e implementar um aplicativo que consome e processa os registros quase em tempo real.

Com o Amazon Kinesis Data Analytics para aplicativos Flink, você pode usar o Java ou o Scala para processar e analisar dados de streaming. O serviço permite que você crie e execute o código Java ou o Scala em origens de streaming para executar análises por tempo, alimentar painéis em tempo real e criar métricas em tempo real.

Você pode criar aplicativos do Flink no Kinesis Data Analytics usando bibliotecas de código aberto baseadas emApache Flink. O Apache Flink é uma estrutura popular e um mecanismo para o processamento de fluxos de dados.

> Important
>
> Depois de criar dois fluxos de dados e um aplicativo, sua conta incorre em cobranças nominais pelo uso do Kinesis Data Streams e do Kinesis Data Analytics porque eles não estão qualificados para oAWSNível gratuito. Quando terminar de usar este aplicativo, exclua seuAWSrecursos para parar de incorrer em cobranças.

O código não acessa os dados reais da bolsa de valores, ele simula o stream de negociações de ações. Isso é feito com o uso de um gerador de negociações de ações aleatórias. Se tiver acesso a um streaming de negociações de ações em tempo real, você poderá se interessar em derivar estatísticas úteis e em tempo hábil desse streaming. Por exemplo, talvez convenha executar uma análise de janela deslizante na qual você determina a ação mais popular que foi adquirida nos últimos 5 minutos. Ou talvez convenha uma notificação sempre que uma ordem de venda for muito grande (ou seja, tenha muitas quotas). Você pode estender o código nesta série para oferecer essa funcionalidade.

Os exemplos mostrados usam a região Oeste dos EUA (Oregon), mas funcionam em qualquer uma dasAWSRegiões que oferecem suporte ao Kinesis Data Analytics.

Tarefas

- Pré-requisitos para concluir os exercícios (p. 51)
- Etapa 1: Configurar umAWSConta e criar um usuário administrador (p. 52)
- Etapa 2: Configurar a AWS Command Line Interface (AWS CLI) (p. 54)
- Etapa 3: Criar e executar um aplicativo Kinesis Data Analytics para Flink (p. 55)

Pré-requisitos para concluir os exercícios

Para concluir as etapas neste guia, você deve ter o seguinte:

- Java Development Kit (JDK) versão 8. Defina a variável do ambiente`JAVA_HOME` para apontar para o local de instalação do JDK.
- Recomendamos que você use um ambiente de desenvolvimento (como Eclipse Java Neon ou IntelliJ Idea) para desenvolver e compilar seu aplicativo.
- Cliente do Git. Instale o cliente do Git se você ainda não tiver feito isso.
- Apache Maven Compiler Plugin. Maven deve estar em seu caminho de trabalho. Para testar a instalação do Apache Maven, insira o seguinte:

```
$ mvn -version
```

Para começar a usar, vá até Etapa 1: Configurar umAWSConta e criar um usuário administrador (p. 52).

Etapa 1: Configurar umAWSConta e criar um usuário administrador

Antes de usar o Amazon Kinesis Data Analytics para aplicativos do Flink pela primeira vez, execute as seguintes tarefas:

1. Cadastre-se na AWS (p. 52)
2. Criar um usuário do IAM (p. 52)

Cadastre-se na AWS

Quando você se cadastrar na Amazon Web Services (AWS), seuAWSA conta da é automaticamente cadastrada em todos os serviços doAWS, incluindo o Amazon Kinesis Data Analytics. Você será cobrado apenas pelos serviços que usar.

Com o Kinesis Data Analytics, você paga apenas pelos recursos que usa. Se você for um novoAWSCliente, você pode começar a usar o Kinesis Data Analytics gratuitamente. Para obter mais informações, consulte Nível gratuito da AWS.

Se já tiver uma conta da AWS, passe para a próxima tarefa. Se você não tiver umAWS, siga estas etapas para criar uma.

Para criar uma conta da AWS

1. Abra https://portal.aws.amazon.com/billing/signup.
2. Siga as instruções online.

   Parte do procedimento de inscrição envolve receber uma chamada telefônica e inserir um código de verificação no teclado do telefone.

Observe oAWSO ID da conta da, pois você precisará dele na próxima tarefa.

Criar um usuário do IAM

Serviços daAWSComo o Amazon Kinesis Data Analytics, exigem o fornecimento de credenciais quando acessá-los. Dessa maneira, o serviço pode determinar se você tem permissões para acessar os recursos próprios desse serviço. O AWS Management Console exige que você insira sua senha.

Você pode criar chaves de acesso para oAWSconta para acessar oAWS Command Line Interface(AWS CLI) ou API. No entanto, não recomendamos que você acesse a AWS usando as credenciais de sua conta da AWS. Em vez disso, recomendamos usar o AWS Identity and Access Management (IAM) Crie um usuário do IAM, adicione o usuário a um grupo do IAM com permissões administrativas e, em seguida, conceda permissões administrativas ao usuário do IAM criado. Em seguida, você pode acessar a AWS usando uma URL especial e as credenciais desse usuário do IAM.

Se você se inscreveu paraAWSMas você não criou um usuário do IAM para você mesmo, você pode criar um usando o console do IAM.

Os exercícios de conceitos básicos deste guia pressupõem que você tenha um usuário (`adminuser`) com permissões de administrador. Siga o procedimento para criar `adminuser` na conta.

Para criar um grupo de administradores

1. Faça login no AWS Management Console e abra o console do IAM em https://console.aws.amazon.com/iam/.

2. No painel de navegação, escolha Groups (Grupos) e Create New Group (Criar novo grupo).
3. Em Group Name (Nome do grupo), digite um nome para o grupo, como **`Administrators`** e escolha Next Step (Próxima etapa).
4. Na lista de políticas, marque a caixa de seleção ao lado da política AdministratorAccess. Você pode usar o menu Filtro e a caixa Pesquisar para filtrar a lista de políticas.
5. Selecione Next Step (Próximo passo) e, em seguida, Create Group (Criar grupo).

O grupo novo é listado em Group Name (Nome do grupo).

Para criar um usuário do IAM para você mesmo, adicioná-lo ao grupo Administradores e criar uma senha

1. No painel de navegação, escolha Usuários e depois Adicionar usuário.
2. Na caixa User name (Nome de usuário), insira um nome de usuário.
3. Escolha ambosAcesso programáticoeAWSAcesso ao Management Console de.
4. Selecione Next (Próximo): Permissions
5. Marque a caixa de seleção ao lado do grupo Administrators (Administradores). Depois, selecione Next (Próximo): Análise.
6. Escolha Criar usuário.

Como fazer login como o novo usuário do IAM

1. Saia do AWS Management Console.
2. Use o seguinte formato de URL para fazer login no console:

   `https://aws_account_number.signin.aws.amazon.com/console/`

   O*`aws_account_number`*É o seuAWSID da conta sem hífens. Por exemplo, se suas necessidadesAWSO ID da conta da é 1234-5678-9012, substitua*`aws_account_number`*com**`123456789012`**. Para obter informações sobre como localizar o número da conta, consulteSuasAWSID da conta da e seu aliasnoManual do usuário do IAM.
3. Insira o nome e a senha de usuário do IAM que você acabou de criar. Quando você está conectado, a barra de navegação exibe *`your_user_name`* @ *`your_aws_account_id`*.

   Note

   Se você não quiser que a URL da página de cadastro contenha o ID da sua conta da AWS, crie um alias da conta.

Para criar ou remover um alias de conta

1. Abra o console do IAM em https://console.aws.amazon.com/iam/.
2. No painel de navegação, selecione Dashboard (Painel).
3. Encontre o link de login dos usuários do IAM.
4. Para criar o alias, escolha Customize (Personalizar). Insira o nome que você deseja usar para o alias e escolha Yes, Create (Sim, criar).
5. Para remover o alias, selecione Personalizar e, em seguida, selecione Sim, excluir. A URL de login será revertida para o ID da sua conta da AWS.

Para fazer o login depois de criar o alias de uma conta, use o seguinte URL:

```
https://your_account_alias.signin.aws.amazon.com/console/
```

Para verificar o link de cadastro para usuários do IAM para a conta, abra o console do IAM e marque IAM users sign-in link no painel.

Para obter mais informações sobre IAM, consulte o seguinte:

- AWS Identity and Access Management (IAM)
- Conceitos básicos
- Guia do usuário do IAM

Próxima etapa

Etapa 2: Configurar a AWS Command Line Interface (AWS CLI) (p. 54)

Etapa 2: Configurar a AWS Command Line Interface (AWS CLI)

Nesta etapa, você faz download e configura oAWS CLIUsar com o Amazon Kinesis Data Analytics for Flink Applications.

> Note
>
> Os exercícios de conceitos básicos neste guia pressupõem que você esteja usando credenciais de administrador (`adminuser`) em sua conta para executar as operações.

> Note
>
> Se você já tiver a AWS CLI instalada, pode ser necessário atualizá-la para obter as funcionalidades mais recentes. Para obter mais informações, consulteInstalar oAWSInterface da linha de comandonoAWS Command Line InterfaceGuia do usuário do. Para verificar a versão da AWS CLI, execute o seguinte comando:

```
aws --version
```

Os exercícios neste tutorial requerem a seguinte versão da AWS CLI ou posterior:

```
aws-cli/1.16.63
```

Para configurar a AWS CLI

1. Faça download e configure a AWS CLI. Para obter instruções, consulte os seguintes tópicos no Manual do usuário do AWS Command Line Interface:
   - Instalar o AWS Command Line Interface
   - Configurar a AWS CLI
2. Adicione um perfil nomeado para o usuário administrador no arquivo config da AWS CLI. Você pode usar esse perfil ao executar os comandos da AWS CLI. Para obter mais informações sobre perfis nomeados, consultePerfis nomeadosnoAWS Command Line InterfaceGuia do usuário do.

```
[profile adminuser]
aws_access_key_id = adminuser access key ID
```

```
aws_secret_access_key = adminuser secret access key
region = aws-region
```

Para obter uma lista de disponíveisAWSRegiões, consulteAWSRegiões e endpoints donoReferência geral do Amazon Web Services.

3. Verifique a configuração digitando o seguinte comando no prompt de comando:

```
aws help
```

Depois de configurar umAWSconta e oAWS CLIVocê pode tentar o próximo exercício, no qual configura um aplicativo de amostra e testa a end-to-end Configuração do.

Próxima etapa

Etapa 3: Criar e executar um aplicativo Kinesis Data Analytics para Flink (p. 55)

Etapa 3: Criar e executar um aplicativo Kinesis Data Analytics para Flink

Neste exercício, você cria um aplicativo Kinesis Data Analytics para Flink com fluxos de dados como origem e um destino.

Esta seção contém as seguintes etapas:

Criação de dois Amazon Kinesis Data Streams

Antes de criar um aplicativo do Kinesis Data Analytics para o Flink para este exercício, crie dois fluxos de dados do Kinesis (`ExampleInputStream`e`ExampleOutputStream`). O aplicativo usa esses fluxos para os fluxos de origem e de destino do aplicativo.

Crie esses streams usando o console do Amazon Kinesis ou o seguinteAWS CLIcomando. Para instruções do console, consulte Criar e atualizar streamings de dados.

Como criar os fluxos de dados (AWS CLI)

1. Para criar o primeiro fluxo (`ExampleInputStream`), use o seguinte Amazon Kinesis`create-stream` AWS CLIcomando.

```
$ aws kinesis create-stream \
--stream-name ExampleInputStream \
--shard-count 1 \
--region us-west-2 \
--profile adminuser
```

2. Execute o mesmo comando, alterando o nome do fluxo para `ExampleOutputStream`, a fim de criar o segundo fluxo que o aplicativo usará para gravar a saída.

```
$ aws kinesis create-stream \
--stream-name ExampleOutputStream \
--shard-count 1 \
--region us-west-2 \
--profile adminuser
```

Gravação de registros de amostra no fluxo de entrada

Nesta seção, você usa um script Python para gravar registros de amostra no fluxo para o aplicativo processar.

> **Note**
>
> Essa seção requer AWS SDK for Python (Boto).

1. Crie um arquivo denominado `stock.py` com o conteúdo a seguir.

```
import datetime
import json
import random
import boto3

STREAM_NAME = "ExampleInputStream"


def get_data():
    return {
        'EVENT_TIME': datetime.datetime.now().isoformat(),
        'TICKER': random.choice(['AAPL', 'AMZN', 'MSFT', 'INTC', 'TBV']),
        'PRICE': round(random.random() * 100, 2)}


def generate(stream_name, kinesis_client):
    while True:
        data = get_data()
        print(data)
        kinesis_client.put_record(
            StreamName=stream_name,
            Data=json.dumps(data),
            PartitionKey="partitionkey")


if __name__ == '__main__':
    generate(STREAM_NAME, boto3.client('kinesis'))
```

2. Mais adiante neste tutorial, você executa o script `stock.py` para enviar dados para o aplicativo.

```
$ python stock.py
```

Baixar e examinar o código Java Apache Flink Streaming

O código de aplicativo Java destas amostras está disponível no GitHub. Para fazer download do código do aplicativo, faça o seguinte:

1. Duplique o repositório remoto com o seguinte comando:

```
git clone https://github.com/aws-samples/amazon-kinesis-data-analytics-java-
examples.git
```

2. Navegue até o diretório `GettingStarted`.

O código do aplicativo está localizado nos arquivos `CloudWatchLogSink.java` e `CustomSinkStreamingJob.java`. Observe o seguinte sobre o código do aplicativo:

- O aplicativo usa uma origem do Kinesis para ler do fluxo de origem. O trecho a seguir cria o sumidouro Kinesis:

```
return env.addSource(new FlinkKinesisConsumer<>(inputStreamName,
                new SimpleStringSchema(), inputProperties));
```

Compilar o código do aplicativo

Nesta seção, você usa o compilador do Apache Maven para criar o código Java para o aplicativo. Para obter informações sobre como instalar o Apache Maven e o Java Development Kit (JDK), consulte Pré-requisitos para concluir os exercícios (p. 51).

Seu aplicativo Java requer os seguintes componentes:

- Um arquivo Project Object Model (pom.xml). Esse arquivo contém informações sobre a configuração e as dependências do aplicativo, incluindo as bibliotecas do Kinesis Data Analytics para aplicativos do Flink.
- Um método `main` que contém a lógica do aplicativo.

> **Note**
>
> Para usar o conector Kinesis para o aplicativo a seguir, você precisa fazer download do código-fonte do conector e compilá-lo como descrito naDocumentação do Apache Flink.

Como criar e compilar o código do aplicativo

1. Crie um aplicativo Java/Maven em seu ambiente de desenvolvimento. Para obter informações sobre como criar um aplicativo, consulte a documentação do seu ambiente de desenvolvimento:
   - Como criar seu primeiro projeto Java (Eclipse Java Neon) (em inglês)
   - Como criar, executar e empacotar seu primeiro aplicativo Java (IntelliJ Idea) (em inglês)
2. Use o código a seguir para um arquivo chamado `StreamingJob.java`.

```
package com.amazonaws.services.kinesisanalytics;

import com.amazonaws.services.kinesisanalytics.runtime.KinesisAnalyticsRuntime;
import org.apache.flink.api.common.serialization.SimpleStringSchema;
import org.apache.flink.streaming.api.datastream.DataStream;
import org.apache.flink.streaming.api.environment.StreamExecutionEnvironment;
import org.apache.flink.streaming.connectors.kinesis.FlinkKinesisConsumer;
import org.apache.flink.streaming.connectors.kinesis.FlinkKinesisProducer;
import org.apache.flink.streaming.connectors.kinesis.config.ConsumerConfigConstants;

import java.io.IOException;
import java.util.Map;
```

```
import java.util.Properties;



public class StreamingJob {

    private static final String region = "us-east-1";
    private static final String inputStreamName = "ExampleInputStream";
    private static final String outputStreamName = "ExampleOutputStream";

    private static DataStream<String>
 createSourceFromStaticConfig(StreamExecutionEnvironment env) {
        Properties inputProperties = new Properties();
        inputProperties.setProperty(ConsumerConfigConstants.AWS_REGION, region);
        inputProperties.setProperty(ConsumerConfigConstants.STREAM_INITIAL_POSITION,
 "LATEST");

        return env.addSource(new FlinkKinesisConsumer<>(inputStreamName, new
 SimpleStringSchema(), inputProperties));
    }

    private static DataStream<String>
 createSourceFromApplicationProperties(StreamExecutionEnvironment env) throws
 IOException {
        Map<String, Properties> applicationProperties =
 KinesisAnalyticsRuntime.getApplicationProperties();
        return env.addSource(new FlinkKinesisConsumer<>(inputStreamName, new
 SimpleStringSchema(),
                applicationProperties.get("ConsumerConfigProperties")));
    }

    private static FlinkKinesisProducer<String> createSinkFromStaticConfig() {
        Properties outputProperties = new Properties();
        outputProperties.setProperty(ConsumerConfigConstants.AWS_REGION, region);
        outputProperties.setProperty("AggregationEnabled", "false");

        FlinkKinesisProducer<String> sink = new FlinkKinesisProducer<>(new
 SimpleStringSchema(), outputProperties);
        sink.setDefaultStream(outputStreamName);
        sink.setDefaultPartition("0");
        return sink;
    }

    private static FlinkKinesisProducer<String> createSinkFromApplicationProperties()
 throws IOException {
        Map<String, Properties> applicationProperties =
 KinesisAnalyticsRuntime.getApplicationProperties();
        FlinkKinesisProducer<String> sink = new FlinkKinesisProducer<>(new
 SimpleStringSchema(),
                applicationProperties.get("ProducerConfigProperties"));

        sink.setDefaultStream(outputStreamName);
        sink.setDefaultPartition("0");
        return sink;
    }

    public static void main(String[] args) throws Exception {
        // set up the streaming execution environment
        final StreamExecutionEnvironment env =
 StreamExecutionEnvironment.getExecutionEnvironment();


         /* if you would like to use runtime configuration properties, uncomment the
 lines below
         * DataStream<String> input = createSourceFromApplicationProperties(env);
         */
```

```
        DataStream<String> input = createSourceFromStaticConfig(env);


         /* if you would like to use runtime configuration properties, uncomment the
 lines below
         * input.addSink(createSinkFromApplicationProperties())
         */

        input.addSink(createSinkFromStaticConfig());

        env.execute("Flink Streaming Java API Skeleton");
    }
}
```

Observe o seguinte sobre o exemplo de código anterior:

- Este arquivo contém o método `main` que define a funcionalidade do aplicativo.
- Seu aplicativo cria conectores de origem e de destino para acessar recursos externos usando um objeto `StreamExecutionEnvironment`.
- O aplicativo cria conectores de origem e de destino usando propriedades estáticas. Para usar as propriedades do aplicativo dinâmico, use os métodos `createSinkFromApplicationProperties` e `createSourceFromApplicationProperties` para criar os conectores. Esses métodos leem as propriedades do aplicativo para configurar os conectores.

3. Para usar o seu código de aplicativo, compile-o e empacote-o em um arquivo JAR. Há duas formas de compilar e empacotar o código:

   - Use a ferramenta de linha de comando do Maven. Crie seu arquivo JAR executando o seguinte comando no diretório que contém o arquivo `pom.xml`:

     ```
     mvn package
     ```

   - Use o ambiente de desenvolvimento. Consulte a documentação de seu ambiente de desenvolvimento para obter mais detalhes.

   Você pode carregar o pacote como um arquivo JAR, ou pode compactar o pacote e carregá-lo como um arquivo ZIP. Se você criar seu aplicativo usando a AWS CLI, especifique o tipo de conteúdo de código (JAR ou ZIP).
4. Se houver erros durante a compilação, verifique se sua variável de ambiente `JAVA_HOME` está definida corretamente.

Se o aplicativo é compilado com êxito, o arquivo a seguir é criado:

`target/java-getting-started-1.0.jar`

Fazer upload do código Java Apache Flink Streaming

Nesta seção, você cria um bucket do Amazon Simple Storage Service (Amazon S3) e faz upload do código do aplicativo.

Como fazer upload do código do aplicativo

1. Abra o console do Amazon S3 em https://console.aws.amazon.com/s3/.
2. Selecione Create bucket (Criar bucket).

3. Insira **ka-app-code-*<username>*** no campo Bucket name (Nome do bucket). Adicione um sufixo para o nome do bucket, como o nome do usuário, para torná-lo globalmente exclusivo. Escolha Next (Próximo).
4. Na etapa Configure options (Configurar opções), mantenha as configurações como estão e selecione Next (Próximo).
5. Na etapa Set permissions (Definir permissões), mantenha as configurações como estão e selecione Next (Próximo).
6. Selecione Create bucket (Criar bucket).
7. No console do Amazon S3, escolha oka-app-code-***<username>***balde, e escolhaCarregar.
8. Na etapa Select files (Selecionar arquivos), selecione Add files (Adicionar arquivos). Navegue até o arquivo `java-getting-started-1.0.jar` que você criou na etapa anterior. Escolha Next (Próximo).
9. Na etapa Set permissions (Definir permissões), mantenha as configurações como estão. Escolha Next (Próximo).
10. Na etapa Set properties (Definir propriedades), mantenha as configurações como estão. Escolha Upload (Carregar).

O código do aplicativo agora está armazenado em um bucket do Amazon S3, onde o aplicativo pode acessá-lo.

Criar e executar o aplicativo do Kinesis Data Analytics

Você pode criar e executar um aplicativo Kinesis Data Analytics para o Flink usando o console ou aAWS CLI.

> Note
>
> Quando você cria o aplicativo usando o console, seuAWS Identity and Access Management(IAM) e Amazon CloudWatch Os recursos de registros são criados para você. Quando cria o aplicativo usando a AWS CLI, você cria esses recursos separadamente.

Tópicos

Criar e executar o aplicativo (console)

Siga estas etapas para criar, configurar, atualizar e executar o aplicativo usando o console.

Criar o aplicativo do

1. Abra o console do Kinesis em https://console.aws.amazon.com/kinesis.
2. No painel do Amazon Kinesis, escolhaCriar aplicativo de análise.
3. Na página Kinesis Analytics - Create application (Kinesis Analytics – Criar aplicativo), forneça os detalhes do aplicativo da seguinte forma:
   - Em Application name (Nome do aplicativo), insira **`MyApplication`**.
   - Em Descrição, insira **`My java test app`**.
   - Em Runtime (Tempo de execução), escolha Apache Flink 1.6.
4. para oPermissões de acesso, escolhaCriar/atualizar a função do IAM**`kinesis-analytics-MyApplication-us-west-2`**.
5. Selecione Criar aplicativo.

Note

Quando cria um aplicativo do Kinesis Data Analytics para o Flink usando o console, você tem a opção de criar uma função do IAM e política do para o seu aplicativo. O aplicativo usa essa função e política para acessar os recursos dependentes. Esses recursos do IAM são nomeados usando o nome do aplicativo e a região da seguinte forma:

- Política: `kinesis-analytics-service-MyApplication-us-west-2`
- Função: `kinesis-analytics-MyApplication-us-west-2`

Editar a política do IAM

Edite a política do IAM para adicionar permissões para acessar os fluxos de dados do Kinesis.

1. Abra o console do IAM em https://console.aws.amazon.com/iam/.
2. Escolha Policies (Políticas). Escolha a política **`kinesis-analytics-service-MyApplication-us-west-2`** que o console criou para você na seção anterior.
3. Na página Summary (Resumo), escolha Edit policy (Editar política). Escolha a guia JSON.
4. Adicione a seção destacada do exemplo de política a seguir à política. Substitua os exemplos de IDs de conta (*012345678901*) pelo ID da conta.

```
{
    "Version": "2012-10-17",
    "Statement": [
        {
            "Sid": "ReadCode",
            "Effect": "Allow",
            "Action": [
                "s3:GetObject",
                "s3:GetObjectVersion"
            ],
            "Resource": [
                "arn:aws:s3:::ka-app-code-username/java-getting-started-1.0.jar"
            ]
        },
        {
            "Sid": "ListCloudwatchLogGroups",
            "Effect": "Allow",
            "Action": [
                "logs:DescribeLogGroups"
            ],
            "Resource": [
                "arn:aws:logs:us-west-2:012345678901:log-group:*"
            ]
        },
        {
            "Sid": "ListCloudwatchLogStreams",
            "Effect": "Allow",
            "Action": [
                "logs:DescribeLogStreams"
            ],
            "Resource": [
                "arn:aws:logs:us-west-2:012345678901:log-group:/aws/kinesis-analytics/
MyApplication:log-stream:*"
            ]
        },
        {
            "Sid": "PutCloudwatchLogs",
            "Effect": "Allow",
            "Action": [
                "logs:PutLogEvents"
```

```
            ],
            "Resource": [
                "arn:aws:logs:us-west-2:012345678901:log-group:/aws/kinesis-analytics/
MyApplication:log-stream:kinesis-analytics-log-stream"
            ]
        },
        {
            "Sid": "ReadInputStream",
            "Effect": "Allow",
            "Action": "kinesis:*",
            "Resource": "arn:aws:kinesis:us-west-2:012345678901:stream/
ExampleInputStream"
        },
        {
            "Sid": "WriteOutputStream",
            "Effect": "Allow",
            "Action": "kinesis:*",
            "Resource": "arn:aws:kinesis:us-west-2:012345678901:stream/
ExampleOutputStream"
        }
    ]
}
```

Configurar o aplicativo

1. Na página MyApplication, escolha Configure (Configurar).
2. Na página Configure application (Configurar aplicativo), forneça o Code location (Local do código):
   - para oBucket do Amazon S3., insira**ka-app-code-*<username>***.
   - para oCaminho do objeto do Amazon S3, insira**java-getting-started-1.0.jar**.
3. UNDERAcesso aos recursos do aplicativo, paraPermissões de acesso, escolhaCriar/atualizar a função do IAM**kinesis-analytics-MyApplication-us-west-2**.
4. Em Properties (Propriedades), Group ID (ID do grupo), insira **ProducerConfigProperties**.
5. Insira as seguintes propriedades e valores de aplicativo:

Chave	Valor
flink.inputstream.initpos	**LATEST**
aws:region	**us-west-2**
AggregationEnabled	**false**

6. Em Monitoring (Monitoramento), confirme se Monitoring metrics level (Nível de monitoramento de métricas) está definido como Application (Aplicativo).
7. Em CloudWatch logging (Registro em log do CloudWatch), marque a caixa de seleção Enable (Habilitar).
8. Escolha Update (Atualizar).

> **Note**
>
> Quando você opta por ativar CloudWatch Em log, o Kinesis Data Analytics cria um grupo de logs e um fluxo de logs para você. Os nomes desses recursos são os seguintes:
>
> - Grupo de logs: `/aws/kinesis-analytics/MyApplication`
> - Fluxo de logs: `kinesis-analytics-log-stream`

Executar o aplicativo

1. Na página MyApplication, escolha Run (Executar). Confirme a ação.
2. Quando o aplicativo estiver em execução, atualize a página. O console mostra o Application graph (Gráfico do aplicativo).

Interromper o aplicativo

Na página MyApplication, escolha Stop (Interromper). Confirme a ação.

Atualizar o aplicativo

Usando o console, você pode atualizar configurações do aplicativo, como as propriedades do aplicativo, as configurações de monitoramento e a localização ou o nome do arquivo JAR do aplicativo. Você também pode recarregar o JAR do aplicativo do bucket do Amazon S3 se precisar atualizar o código do aplicativo.

Na página MyApplication, escolha Configure (Configurar). Atualize as configurações do aplicativo e escolha Update (Atualizar).

Criar e executar o aplicativo (AWS CLI)

Nesta seção, use oAWS CLIPara criar e executar o aplicativo do Kinesis Data Analytics. O Kinesis Data Analytics for Flink Applications usa o`kinesisanalyticsv2` AWS CLIcomando para criar e interagir com os aplicativos do Kinesis Data Analytics.

Criar uma política de permissões

Primeiro, crie uma política de permissões com duas instruções: uma que concede permissões para a ação `read` no fluxo de origem, e outra que concede permissões para ações `write` no fluxo de destino. Em seguida, anexe a política a uma função do IAM (que você cria na próxima seção). Assim, quando o Kinesis Data Analytics assume a função, o serviço terá as permissões necessárias para ler o fluxo de origem e gravar no fluxo de destino.

Use o código a seguir para criar a política de permissões `KAReadSourceStreamWriteSinkStream`. Substituir*username*Com o nome de usuário que você usou para criar o bucket do Amazon S3 para armazenar o código do aplicativo. Substitua o ID da conta nos Nomes de recurso da Amazon (ARNs) (*012345678901*) pelo ID da conta.

```
{
    "Version": "2012-10-17",
    "Statement": [
        {
            "Sid": "S3",
            "Effect": "Allow",
            "Action": [
                "s3:GetObject",
                "s3:GetObjectVersion"
            ],
            "Resource": ["arn:aws:s3:::ka-app-code-username",
                "arn:aws:s3:::ka-app-code-username/*"
            ]
        },
        {
            "Sid": "ReadInputStream",
            "Effect": "Allow",
            "Action": "kinesis:*",
            "Resource": "arn:aws:kinesis:us-west-2:012345678901:stream/ExampleInputStream"
        },
        {
```

```
            "Sid": "WriteOutputStream",
            "Effect": "Allow",
            "Action": "kinesis:*",
            "Resource": "arn:aws:kinesis:us-west-2:012345678901:stream/ExampleOutputStream"
        }
    ]
}
```

para o step-by-step Instruções para criar uma política de permissões, consulteTutorial: Criar e anexar a sua primeira política gerenciada pelo clientenoManual do usuário do IAM.

> **Note**
>
> Para acessar outrosAWSServiços da, você pode usar oAWS SDK for Java. O Kinesis Data Analytics define automaticamente as credenciais exigidas pelo SDK para aquelas da função do IAM de execução de serviço que está associada ao seu aplicativo. Não é necessária nenhuma etapa adicional.

Criar uma função do IAM

Nesta seção, você cria uma função do IAM que o aplicativo Kinesis Data Analytics para o Flink pode assumir para ler um fluxo de origem e gravar no fluxo de destino.

O Kinesis Data Analytics não pode acessar seu fluxo sem permissões. Você concede essas permissões por meio de uma função do IAM. Cada função do IAM tem duas políticas anexadas. A política de confiança concede ao Kinesis Data Analytics permissão para assumir a função e a política de permissões determina o que o Kinesis Data Analytics pode fazer depois de assumir a função.

Você anexa a política de permissões que criou na seção anterior a essa função.

Para criar uma função do IAM

1. Abra o console do IAM em https://console.aws.amazon.com/iam/.
2. No painel de navegação, escolha Roles (Funções) e Create Role (Criar função).
3. UNDERSelecione o tipo de identidade confiável, escolhaAWSServiço. Em Choose the service that will use this role (Escolher o serviço que usará esta função), escolha Kinesis. Em Select your use case (Selecionar seu caso de uso), escolha Kinesis Analytics.

   Selecione Next (Próximo): Permissions
4. NoAnexe políticas de permissõesPágina, escolhaPróximo: Análise. Você pode anexar políticas de permissões depois de criar a função.
5. Na página Create role (Criar função), insira **`KA-stream-rw-role`** em Role name (Nome da função). Selecione Create role (Criar função).

   Agora você criou uma função do IAM chamada`KA-stream-rw-role`. Em seguida, você atualiza as políticas de confiança e de permissões para a função.
6. Anexe a política de permissões à função.

   > **Note**
   >
   > Para este exercício, o Kinesis Data Analytics assume essa função para ler dados de um streaming de dados do Kinesis (origem) e gravar a saída em outro fluxo de dados do Kinesis. Depois, você anexa a política que criou na etapa anterior, the section called “Criar uma política de permissões” (p. 63).

   a. Na página Summary (Resumo), escolha a guia Permissions (Permissões).

   b. Escolha Attach Policies.

c. Na caixa de pesquisa, insira **`KAReadSourceStreamWriteSinkStream`** (a política que você criou na seção anterior).

d. Escolha a política KAReadInputStreamWriteOutputStream e escolha Attach policy (Anexar política).

Agora você criou a função de execução de serviço que seu aplicativo usa para acessar os recursos. Anote o ARN da nova função.

para o step-by-step Instruções para criar uma função, consulteCriação de uma função do IAM (console)noManual do usuário do IAM.

Criar o aplicativo do Kinesis Data Analytics

1. Salve o seguinte código JSON em um arquivo chamado `create_request.json`. Substitua o ARN da função de amostra pelo ARN da função que você criou anteriormente. Substitua o sufixo do ARN do bucket (*`username`*) pelo sufixo que você escolheu na seção anterior. Substitua o ID da conta de exemplo (*`012345678901`*) na função de execução do serviço pelo ID da conta.

```
{
    "ApplicationName": "test",
    "ApplicationDescription": "my java test app",
    "RuntimeEnvironment": "FLINK-1_6",
    "ServiceExecutionRole": "arn:aws:iam::012345678901:role/KA-stream-rw-role",
    "ApplicationConfiguration": {
        "ApplicationCodeConfiguration": {
            "CodeContent": {
                "S3ContentLocation": {
                    "BucketARN": "arn:aws:s3:::ka-app-code-username",
                    "FileKey": "java-getting-started-1.0.jar"
                }
            },
            "CodeContentType": "ZIPFILE"
        },
        "EnvironmentProperties":  {
         "PropertyGroups": [
            {
               "PropertyGroupId": "ProducerConfigProperties",
               "PropertyMap" : {
                    "flink.stream.initpos" : "LATEST",
                    "aws.region" : "us-west-2",
                    "AggregationEnabled" : "false"
               }
            },
            {
               "PropertyGroupId": "ConsumerConfigProperties",
               "PropertyMap" : {
                    "aws.region" : "us-west-2"
               }
            }
         ]
      }
    }
}
```

2. Execute a ação `CreateApplication` com a solicitação anterior para criar o aplicativo:

```
aws kinesisanalyticsv2 create-application --cli-input-json file://create_request.json
```

O aplicativo agora é criado. Você inicia o aplicativo na próxima etapa.

Iniciar o aplicativo

Nesta seção, você usa a ação `StartApplication` para iniciar o aplicativo.

Para iniciar o aplicativo

1. Salve o seguinte código JSON em um arquivo chamado `start_request.json`.

```
{
    "ApplicationName": "test",
    "RunConfiguration": {
        "ApplicationRestoreConfiguration": {
         "ApplicationRestoreType": "RESTORE_FROM_LATEST_SNAPSHOT"
         }
    }
}
```

2. Execute a ação `StartApplication` com a solicitação anterior para iniciar o aplicativo:

```
aws kinesisanalyticsv2 start-application --cli-input-json file://start_request.json
```

O aplicativo agora está em execução. Você pode verificar as métricas do Kinesis Data Analytics na Amazon CloudWatch Console para verificar se o aplicativo está funcionando.

Interromper o aplicativo

Nesta seção, você usa a ação `StopApplication` para interromper o aplicativo.

Como interromper o aplicativo

1. Salve o seguinte código JSON em um arquivo chamado `stop_request.json`.

```
{"ApplicationName": "test"
}
```

2. Execute a ação `StopApplication` com a seguinte solicitação para interromper o aplicativo:

```
aws kinesisanalyticsv2 stop-application --cli-input-json file://stop_request.json
```

O aplicativo agora está interrompido.

Tutorial: O uso doAWSO Lambda com o Amazon Kinesis Data Streams

Neste tutorial, você cria uma função do Lambda para consumir eventos de um fluxo de dados do Kinesis. Neste cenário de exemplo, um aplicativo personalizado grava registros em um fluxo de dados do Kinesis.AWS O Lambda sonda esse fluxo de dados e, quando detecta novos registros de dados, invoca sua função do Lambda.AWS O Lambda executa a função do Lambda assumindo a função de execução especificada quando você criou a função do Lambda.

Para obter instruções detalhadas passo a passo, consulteTutorial: O uso doAWSO Lambda com o Amazon Kinesis.

Note

Este tutorial presume que você tenha algum conhecimento de operações básicas do Lambda e do console do Lambda. Caso ainda não tenha, siga as instruções emConceitos básicos doAWSLambdapara criar sua primeira função do Lambda.

AWSSolução de dados de streaming para Amazon Kinesis

OAWSA solução de dados de streaming para Amazon Kinesis configura automaticamente oAWSserviços necessários para capturar, armazenar, processar e fornecer dados de streaming facilmente. A solução fornece várias opções para resolver casos de uso de dados de streaming que usam váriosAWSServiços como Kinesis Data Streams,AWS Lambda, Amazon API Gateway e Amazon Kinesis Data Analytics.

Cada solução inclui os seguintes componentes:

- UMAAWS CloudFormationpacote para implantar o exemplo completo.
- UMACloudWatchpainel de controle para exibir métricas de aplicativos.
- CloudWatchalarmes nas métricas de aplicativos mais relevantes.
- Todas as funções e políticas do IAM necessárias.

A solução pode ser encontrada aqui: Solução de dados de streaming para Amazon Kinesis

Criar e gerenciar streamings

O Amazon Kinesis Data Streams consome uma grande quantidade de dados em tempo real, armazena os dados de forma durável e os torna disponíveis para consumo. A unidade de dados armazenada pelo Kinesis Data Streams é umregistro de dados. Um stream de dados representa um grupo de registros de dados. Os registros de dados em um stream de dados são distribuídos em estilhaços.

Um estilhaço tem uma sequência de registros de dados em um streaming. Ele serve como uma unidade de taxa de transferência básica de um fluxo de dados do Kinesis. Um fragmento suporta 1 MB/s e 1000 registros por segundo paraescrevee 2 MB/s paraleiturasnos modos de capacidade sob demanda e provisionada. Os limites do fragmento garantem um desempenho previsível, facilitando o design e a operação de um fluxo de trabalho de streaming de dados altamente confiável.

Tópicos

Escolher o modo de capacidade do fluxo de dados

Tópicos

O que é um modo de capacidade de fluxo de dados?

Um modo de capacidade determina como a capacidade de um fluxo de dados é gerenciada e como você é cobrado pelo uso do fluxo de dados. No Amazon Kinesis Data Streams, você pode escolher entre umsob demandamodo eprovisionadoModo para os fluxos de dados.

- Sob demanda- fluxos de dados com um modo sob demanda não requerem planejamento de capacidade e escalam automaticamente para lidar com gigabytes de taxa de transferência de gravação e leitura por minuto. Com o modo sob demanda, o Kinesis Data Streams gerencia automaticamente os fragmentos para fornecer a taxa de transferência necessária.
- Provisionada- Para os streams de dados com um modo provisionado, você deve especificar o número de estilhaços para o stream de dados do. A capacidade total de um stream de dados é a soma das

capacidades de seus estilhaços. Você pode aumentar ou diminuir o número de estilhaços em um stream de dados conforme necessário.

Você pode usar o Kinesis Data Streams`PutRecord`e`PutRecords`APIs para gravar dados em seus fluxos de dados nos modos de capacidade sob demanda e provisionada. Para recuperar dados, ambos os modos de capacidade suportam consumidores padrão que usam o`GetRecords`Consumidores de API e Fan-Out Avançado (EFO) que usam o`SubscribeToShard`API.

Todos os recursos do Kinesis Data Streams, incluindo modo de retenção, criptografia, métricas de monitoramento e outros, são suportados tanto para os modos sob demanda quanto provisionado. O Kinesis Data Streams fornece a alta durabilidade e disponibilidade nos modos de capacidade sob demanda e provisionada.

Modo sob demanda

Os fluxos de dados no modo sob demanda não exigem planejamento de capacidade e são dimensionados automaticamente para lidar com gigabytes deescrever e lerTaxa de transferência por minuto. O modo sob demanda simplifica a ingestão e o armazenamento de grandes volumes de dados com baixa latência porque eleeliminaprovisionamento e gerenciamento de servidores, armazenamento ou taxa de transferência. Você pode ingerir bilhões de registros por dia sem sobrecarga operacional.

O modo sob demanda é ideal para atender às necessidades de tráfego de aplicativos altamente variável e imprevisível. Você não precisa mais provisionar essas cargas de trabalho para capacidade de pico, o que pode resultar em custos mais altos devido à baixa utilização. O modo sob demanda é adequado para cargas de trabalho com padrões de tráfego imprevisíveis e altamente variáveis.

Com o modo de capacidade sob demanda, você paga por GB de dados gravados e lidos de seus fluxos de dados. Você não precisa especificar a taxa de transferência de leitura e gravação que você espera que seu aplicativo execute. O Kinesis Data Streams acomoda instantaneamente o crescimento e a redução das workloads para cima ou para baixo. Para obter mais informações, consulte Definição de preço do Amazon Kinesis Data Streams.

You pode criar um novo fluxo de dados com o modo sob demanda usando o console, as APIs ou os comandos da CLI do Kinesis Data Streams.

Um fluxo de dados no modo sob demanda acomoda até o dobro da taxa de transferência de gravação de pico observada nos 30 dias anteriores. À medida que a taxa de transferência de gravação do fluxo de dados atinge um novo pico, o Kinesis Data Streams dimensiona a capacidade do fluxo de dados automaticamente. Por exemplo, se o fluxo de dados tiver uma taxa de transferência de gravação que varia entre 10 MB/s e 40 MB/s, o Kinesis Data Streams garante que você possa intermitir facilmente para dobrar sua taxa de transferência de pico anterior ou 80 MB/s. Se o mesmo fluxo de dados sustentar uma nova taxa de transferência de pico de 50 MB/s, o Kinesis Data Streams garante que haja capacidade suficiente para ingerir 100 MB/s de taxa de transferência de gravação. No entanto, a limitação de gravação pode ocorrer se o tráfego aumentar para mais do que o dobro do pico anterior dentro de uma duração de 15 minutos. Você precisa repetir essas solicitações limitadas.

A capacidade de leitura agregada de um fluxo de dados com o modo sob demanda aumenta proporcionalmente à taxa de transferência de gravação. Isso ajuda a garantir que os aplicativos do consumidor sempre tenham uma taxa de transferência de leitura adequada para processar dados recebidos em tempo real. Você obtém pelo menos o dobro da taxa de transferência de gravação em comparação com os dados de leitura usando o`GetRecords`API. Recomendamos que você use um aplicativo de consumidor com o`GetRecord`API, para que ele tenha espaço suficiente para acompanhar quando o aplicativo precisa se recuperar do tempo de inatividade. É recomendável usar o recurso Enhanced Fan-Out do Kinesis Data Streams para cenários que exigem a adição de mais de um aplicativo de consumidor. O Fan-Out aprimorado suporta a adição de até 20 aplicativos do consumidor a um fluxo de dados usando o`SubscribeToShard`API, com cada aplicativo do consumidor com taxa de transferência dedicada.

Como lidar com exceções de taxa de transferência de leitura e gravação

Com o modo de capacidade sob demanda (o mesmo que com o modo de capacidade provisionada), você deve especificar uma chave de partição com cada registro para gravar dados em seu fluxo de dados. O Kinesis Data Streams usa suas chaves de partição para distribuir dados entre fragmentos. O Kinesis Data Streams monitora o tráfego de cada fragmento. Quando o tráfego de entrada excede 500 KB/s por fragmento, ele divide o fragmento em 15 minutos. Os valores da chave de hash do fragmento pai são redistribuídos uniformemente entre fragmentos filhos.

Se o tráfego de entrada exceder o dobro do pico anterior, você poderá experimentar exceções de leitura ou gravação por cerca de 15 minutos, mesmo quando seus dados forem distribuídos uniformemente pelos fragmentos. Recomendamos que você tente novamente todas essas solicitações para que todos os registros sejam armazenados corretamente no Kinesis Data Streams.

Você pode experimentar exceções de leitura e gravação se estiver usando uma chave de partição que leva a uma distribuição de dados irregular, e os registros atribuídos a um fragmento específico excedem seus limites. Com o modo sob demanda, o fluxo de dados se adapta automaticamente para lidar com padrões de distribuição de dados irregulares, a menos que uma única chave de partição exceda a taxa de transferência de 1 MB/s de um fragmento e limites de 1000 registros por segundo.

No modo sob demanda, o Kinesis Data Streams divide os fragmentos uniformemente quando detecta um aumento no tráfego. No entanto, ele não detecta e isola chaves de hash que estão direcionando uma parte maior do tráfego de entrada para um fragmento específico. Se você estiver usando chaves de partição altamente irregulares, poderá continuar recebendo exceções de gravação. Para esses casos de uso, recomendamos usar o modo de capacidade provisionada que aceita divisões de estilhaços granulares.

Modo provisionado

Com o modo provisionado, após criar o stream de dados do, você pode dinamicamente escalonar a capacidade do seu estilhaço para cima ou para baixo usando oAWS Management Consoleou oUpdateShardContagemAPI. Você poderá fazer atualizações enquanto houver um produtor do Kinesis Data Streams ou aplicativo de consumidor gravando ou lendo dados do streaming.

O modo provisionado é adequado para tráfego previsível com requisitos de capacidade fáceis de prever. Você pode usar o modo provisionado se quiser um controle refinado sobre como os dados são distribuídos entre fragmentos.

Com o modo provisionado, você deve especificar o número de estilhaços para o stream de dados. Para determinar o tamanho de um stream de dados no modo provisionado, você precisará dos seguintes valores de entrada:

- O tamanho médio do registro de dados gravado no stream do em kilobytes (KB) arredondando para o próximo 1 KB (`average_data_size_in_KB`).
- O número de registros de dados gravados e lidos no stream por segundo (`records_per_second`).
- O número de consumidores, que são aplicativos do Kinesis Data Streams que consomem dados simultânea e independentemente do streaming (`number_of_consumers`).
- A largura de banda de gravação de entrada em KB (`incoming_write_bandwidth_in_KB`), que é igual a `average_data_size_in_KB` multiplicado por `records_per_second`.
- A largura de banda de leitura de saída em KB (`outgoing_read_bandwidth_in_KB`), que é igual a `incoming_write_bandwidth_in_KB` multiplicado por `number_of_consumers`.

É possível calcular o número de estilhaços (`number_of_shards`) de que seu stream precise usando os valores de entrada na seguinte fórmula.

```
number_of_shards = max(incoming_write_bandwidth_in_KiB/1024,
 outgoing_read_bandwidth_in_KiB/2048)
```

Você ainda pode experimentar exceções de taxa de transferência de leitura e gravação no modo provisionado se não configurar seu fluxo de dados para lidar com seu pico de throughput. Nesse caso, você deve dimensionar manualmente o fluxo de dados para acomodar o tráfego de dados.

Você também pode experimentar exceções de leitura e gravação se estiver usando uma chave de partição que leva a uma distribuição desigual de dados e os registros atribuídos a um fragmento excedem seus limites. Para resolver esse problema no modo provisionado, identifique esses fragmentos e divida-os manualmente para acomodar melhor seu tráfego. Para obter mais informações, consulteReestilhaçar um stream.

Alternando entre modos de capacidade

Você pode alternar o modo de capacidade do fluxo de dados de sob demanda para provisionado ou de provisionado para sob demanda. Para cada fluxo de dados em seuAWSconta, você pode alternar entre os modos de capacidade sob demanda e provisionada duas vezes em 24 horas.

Alternar entre os modos de capacidade de um fluxo de dados não causa interrupções em seus aplicativos que usam esse fluxo de dados. Você pode continuar escrevendo e lendo desse fluxo de dados. À medida que você está alternando entre os modos de capacidade, seja de sob demanda para provisionado ou de provisionado para sob demanda, o status do fluxo é definido comoAtualizar o. Você deve aguardar o status do fluxo de dados chegar aoAtivoantes que você possa modificar suas propriedades novamente.

Quando você muda do modo de capacidade provisionado para o modo de capacidade sob demanda, seu fluxo de dados inicialmente retém qualquer contagem de fragmentos que tinha antes da transição e, a partir desse ponto, o Kinesis Data Streams monitora o tráfego de dados e dimensiona a contagem de fragmentos desse fluxo de dados sob demanda, dependendo da taxa de transferência de gravação.

Quando você muda do modo sob demanda para o modo provisionado, seu fluxo de dados também retém inicialmente qualquer contagem de fragmentos que tinha antes da transição, mas a partir deste ponto, você é responsável por monitorar e ajustar a contagem de fragmentos desse fluxo de dados para acomodar adequadamente sua taxa de transferência de gravação.

Criar uma transmissão por meio daAWSManagement Console

Você pode criar um fluxo usando o console do Kinesis Data Streams, a API do Kinesis Data Streams ou aAWS Command Line Interface(AWS CLI).

Para criar um stream de dados usando o console

1. Faça login no AWS Management Console e abra o console do Kinesis em https://console.aws.amazon.com/kinesis.
2. Na barra de navegação, expanda o seletor de região e escolha uma região.
3. Selecione Create data stream (Criar stream de dados).
4. NoCriar streaming do Kinesis, insira um nome para o streaming de dados do e, em seguida, escolha oSob demandaouProvisionadamodo de capacidade. OSob demandaO modo é selecionado por padrão. Para obter mais informações, consulte Escolher o modo de capacidade do fluxo de dados (p. 68).

Com aSob demandamodo, você pode escolherCriar streaming do KinesisPara criar o stream de dados. Com aProvisionadaEm seguida, você deve especificar o número de estilhaços necessários e, em seguida, escolherCriar streaming do Kinesis.

Na página Kinesis streams (Streamings do Kinesis), o Status do streaming é Creating (Criando) enquanto o streaming está sendo criado. Quando o streaming estiver pronto para ser usado, o Status mudará para Active (Ativo).

5. Escolha o nome do fluxo. A página Stream Details (Detalhes do streaming) exibe um resumo da configuração do streaming com informações de monitoramento.

Para criar um fluxo usando a API do Kinesis Data Streams

- Para obter informações sobre a criação de um streaming usando a API do Kinesis Data Streams, consulteCriando um fluxo por meio das APIs (p. 72).

Para criar um stream usando a AWS CLI

- Para obter informações sobre a criação de um streaming usando a AWS CLI, consulte o comando create-stream.

Criando um fluxo por meio das APIs

Use as etapas a seguir para criar seu fluxo de dados do Kinesis.

Criar o cliente do Kinesis Data Streams

Para trabalhar com streamings de dados do Kinesis, você precisa criar um objeto de cliente. O seguinte código Java cria uma instância de um criador de cliente e a usa para definir a região, as credenciais e a configuração do cliente. Em seguida, ele cria um objeto do cliente.

```
AmazonKinesisClientBuilder clientBuilder = AmazonKinesisClientBuilder.standard();

clientBuilder.setRegion(regionName);
clientBuilder.setCredentials(credentialsProvider);
clientBuilder.setClientConfiguration(config);

AmazonKinesis client = clientBuilder.build();
```

Para obter mais informações, consulteRegiões e endpoints do Kinesis Data StreamsnoAWSReferência geral.

Criar o stream

Agora que criou seu cliente do Kinesis Data Streams, pode criar um stream com o qual trabalhar. Isso pode ser feito com o console do Kinesis Data Streams ou de forma programática. Para criar um fluxo programaticamente, instancie um`CreateStreamRequest`e especifique um nome para o stream e (se você quiser usar o modo provisionado) o número de estilhaços para o stream usar.

- Sob demanda:

```
CreateStreamRequest createStreamRequest = new CreateStreamRequest();
createStreamRequest.setStreamName( myStreamName );
```

- Provisionada:

```
CreateStreamRequest createStreamRequest = new CreateStreamRequest();
createStreamRequest.setStreamName( myStreamName );
createStreamRequest.setShardCount( myStreamSize );
```

O nome do stream identifica o stream. O nome é definido pelo escopo doAWSConta usada pelo aplicativo. Ele também é delimitado por região. Ou seja, dois fluxos em dois diferentesAWSAs contas podem ter o mesmo nome, e dois streams no mesmoAWSmas em duas regiões diferentes podem ter o mesmo nome, mas não dois streams na mesma conta e na mesma região.

A taxa de transferência do stream depende do número de estilhaços: mais estilhaços são necessários para uma maior taxa de transferência provisionada. Mais estilhaços também aumentam o custo queAWScobranças para o fluxo. Para obter mais informações sobre como calcular um número apropriado de estilhaços para o aplicativo, consulte Escolher o modo de capacidade do fluxo de dados (p. 68).

Depois que o objeto `createStreamRequest` é configurado, crie um stream chamando o método `createStream` para o cliente. Após chamar `createStream`, aguarde o stream alcançar o estado `ACTIVE` antes de executar qualquer operação nele. Para verificar o estado do stream, chame o método `describeStream`. Se o stream não existir, `describeStream` lançará uma exceção, portanto, coloque a chamada a `describeStream` em um bloco `try/catch`.

```
client.createStream( createStreamRequest );
DescribeStreamRequest describeStreamRequest = new DescribeStreamRequest();
describeStreamRequest.setStreamName( myStreamName );

long startTime = System.currentTimeMillis();
long endTime = startTime + ( 10 * 60 * 1000 );
while ( System.currentTimeMillis() < endTime ) {
  try {
    Thread.sleep(20 * 1000);
  }
  catch ( Exception e ) {}

  try {
    DescribeStreamResult describeStreamResponse =
 client.describeStream( describeStreamRequest );
    String streamStatus = describeStreamResponse.getStreamDescription().getStreamStatus();
    if ( streamStatus.equals( "ACTIVE" ) ) {
      break;
    }
    //
    // sleep for one second
    //
    try {
      Thread.sleep( 1000 );
    }
    catch ( Exception e ) {}
  }
  catch ( ResourceNotFoundException e ) {}
}
if ( System.currentTimeMillis() >= endTime ) {
  throw new RuntimeException( "Stream " + myStreamName + " never went active" );
}
```

Como atualizar um stream

Você pode atualizar os detalhes de um stream usando o console do Kinesis Data Streams, a API do Kinesis Data Streams ou aAWS CLI.

Note

Você pode ativar a criptografia no lado do servidor para streams existentes ou para os recém-criados.

Para atualizar um stream de dados usando o console

1. Abra o console do Amazon Kinesis emhttps://console.aws.amazon.com/kinesis/.
2. Na barra de navegação, expanda o seletor de região e escolha uma região.
3. Escolha o nome do streaming na lista. A página Stream Details (Detalhes do streaming) exibe um resumo das informações de configuração e monitoramento do streaming.
4. Para alternar entre os modos de capacidade sob demanda e provisionada para um fluxo de dados, escolhaModo de edição de capacidadenoConfiguraçãoguia. Para obter mais informações, consulte Escolher o modo de capacidade do fluxo de dados (p. 68).

   Important

   Para cada fluxo de dados em seuAWSconta, você pode alternar entre os modos sob demanda e provisionado duas vezes em 24 horas.
5. Para um fluxo de dados com o modo provisionado, para editar o número de fragmentos, escolhaEditar estilhaços provisionadosnoConfiguraçãoe insira uma nova contagem de estilhaços.
6. Para ativar a criptografia de registros de dados no lado do servidor, selecione Edit (Editar) na seção Server-side encryption (Criptografia no lado do servidor). Escolha uma chave do KMS para usar como a chave mestra de criptografia, ou use a chave mestra padrão,aws/kinesis, gerenciado pelo Kinesis. Se você habilitar a criptografia para um streaming e usar a própria chave mestra do AWS KMS, verifique se os aplicativos de produtor e de consumidor têm acesso à chave mestra do AWS KMS que você usou. Para atribuir permissões a um aplicativo para acessar uma chave do AWS KMS gerada pelo usuário, consulte the section called “Permissões para usar as chaves mestras do KMS geradas pelo usuário” (p. 224).
7. Para editar o período de retenção de dados, selecione Edit (Editar) na seção Data retention period (Período de retenção de dados) e insira um novo período de retenção de dados.
8. Se você tiver habilitado métricas personalizadas em sua conta, selecione Edit (Editar) na seção Shard level metrics (Métricas em nível de estilhaço) e, em seguida, especifique as métricas de seu streaming. Para obter mais informações, consulte the section called “Monitorando o serviço com o CloudWatch” (p. 190).

Como atualizar um stream usando a API

Para atualizar os detalhes do stream usando a API, consulte os seguintes métodos:

- AddTagsToStream
- DecreaseStreamRetentionPeriod
- DisableEnhancedMonitoramento
- EnableEnhancedMonitoramento
- IncreaseStreamRetentionPeriod
- RemoveTagsFromStream
- StartStreamCriptografia
- StopStreamCriptografia
- UpdateShardContagem

Atualizar um streaming usando a AWS CLI

Para obter informações sobre atualização de um streaming usando a AWS CLI, consulte a Referência da CLI do Kinesis.

Listar streams

Conforme descrito na seção anterior, os streams são delimitados pelaAWSconta associada àAWSAs credenciais usadas para criar a instância do cliente Kinesis Data Streams e também pela região especificada para o cliente. UmaAWSUma conta pode ter muitos streams ativos ao mesmo tempo. Você pode listar seus streams no console do Kinesis Data Streams ou de forma programática. O código desta seção mostra como listar todos os streams para oAWSconta.

```
ListStreamsRequest listStreamsRequest = new ListStreamsRequest();
listStreamsRequest.setLimit(20);
ListStreamsResult listStreamsResult = client.listStreams(listStreamsRequest);
List<String> streamNames = listStreamsResult.getStreamNames();
```

Este exemplo de código primeiro cria uma nova instância de `ListStreamsRequest` e chama seu método `setLimit` para especificar que um máximo de 20 streams devem ser retornados para cada chamada a `listStreams`. Se você não especificar um valor para`setLimit`, o Kinesis Data Streams retorna um número de streamings menor ou igual ao número na conta. Em seguida, o código passa `listStreamsRequest` ao método `listStreams` do cliente. O valor de retorno `listStreams` é armazenado em um objeto `ListStreamsResult`. O código chama o método `getStreamNames` para esse objeto e armazena os nomes de stream retornados na lista `streamNames`. Observe que o Kinesis Data Streams pode retornar menos streams do que o limite especificado, mesmo se houver mais streams do que isso na conta e região. Para garantir que você recupere todos os streams, use o método `getHasMoreStreams` como descrito no próximo exemplo de código.

```
while (listStreamsResult.getHasMoreStreams())
{
    if (streamNames.size() > 0) {
      listStreamsRequest.setExclusiveStartStreamName(streamNames.get(streamNames.size() -
 1));
    }
    listStreamsResult = client.listStreams(listStreamsRequest);
    streamNames.addAll(listStreamsResult.getStreamNames());
}
```

Esse código chama o método `getHasMoreStreams` para `listStreamsRequest` a fim de verificar se há streams adicionais disponíveis além dos que foram retornados na chamada inicial a `listStreams`. Se houver, o código chamará o método `setExclusiveStartStreamName` com o nome do último stream que foi retornado na chamada anterior a `listStreams`. O método `setExclusiveStartStreamName` faz com que a próxima chamada a `listStreams` comece depois desse stream. Em seguida, o grupo de nomes de stream retornados pela chamada é adicionado à lista `streamNames`. Esse processo continua até que todos os nomes de stream tenham sido coletados na lista.

Os streams retornados por `listStreams` podem estar em um dos seguintes estados:

- `CREATING`
- `ACTIVE`
- `UPDATING`
- `DELETING`

Você pode verificar o estado de um stream usando o método `describeStream`, como mostrado na seção anterior, Criando um fluxo por meio das APIs (p. 72).

Listagem de estilhaços

Um fluxo de dados pode ter um ou mais estilhaços. Existem dois métodos para listar (ou recuperar) fragmentos de um fluxo de dados.

Tópicos

ListShardsAPI - Recomendado

O método recomendado para listar ou recuperar os fragmentos de um fluxo de dados é usar oListShardsAPI. O exemplo a seguir mostra como é possível obter uma lista de estilhaços em um stream de dados. Para obter uma descrição completa da operação principal usada neste exemplo e de todos os parâmetros que você pode definir para a operação, consulteListShards.

```
import software.amazon.awssdk.services.kinesis.KinesisAsyncClient;
import software.amazon.awssdk.services.kinesis.model.ListShardsRequest;
import software.amazon.awssdk.services.kinesis.model.ListShardsResponse;

import java.util.concurrent.TimeUnit;

public class ShardSample {

    public static void main(String[] args) {

        KinesisAsyncClient client = KinesisAsyncClient.builder().build();

        ListShardsRequest request = ListShardsRequest
                .builder().streamName("myFirstStream")
                .build();

        try {
            ListShardsResponse response = client.listShards(request).get(5000,
 TimeUnit.MILLISECONDS);
            System.out.println(response.toString());
        } catch (Exception e) {
            System.out.println(e.getMessage());
        }
    }
}
```

Para executar o exemplo de código anterior, você pode usar um arquivo POM, como o seguinte.

```
<?xml version="1.0" encoding="UTF-8"?>
<project xmlns="http://maven.apache.org/POM/4.0.0"
         xmlns:xsi="http://www.w3.org/2001/XMLSchema-instance"
         xsi:schemaLocation="http://maven.apache.org/POM/4.0.0 http://maven.apache.org/xsd/
maven-4.0.0.xsd">
    <modelVersion>4.0.0</modelVersion>

    <groupId>kinesis.data.streams.samples</groupId>
    <artifactId>shards</artifactId>
```

```
    <version>1.0-SNAPSHOT</version>
    <build>
        <plugins>
            <plugin>
                <groupId>org.apache.maven.plugins</groupId>
                <artifactId>maven-compiler-plugin</artifactId>
                <configuration>
                    <source>8</source>
                    <target>8</target>
                </configuration>
            </plugin>
        </plugins>
    </build>
    <dependencies>
        <dependency>
            <groupId>software.amazon.awssdk</groupId>
            <artifactId>kinesis</artifactId>
            <version>2.0.0</version>
        </dependency>
    </dependencies>
</project>
```

Com a`ListShards`API do, você pode usar oShardFilterparâmetro para filtrar a resposta da API. Você só pode especificar um filtro de cada vez.

Se você usar o`ShardFilter`parâmetro ao invocar oListShardsAPI, o`Type`É a propriedade necessária e deve ser especificada. Se você especificar o`AT_TRIM_HORIZON`,`FROM_TRIM_HORIZON`, ou`AT_LATEST`Tipos, você não precisa especificar o`ShardId`ou o`Timestamp`propriedades opcionais.

Se você especificar o`AFTER_SHARD_ID`Tipo, você também deve fornecer o valor para o opcional`ShardId`propriedade. O`ShardId`propriedade é idêntica em funcionalidade à`ExclusiveStartShardId`parâmetro doListShardsAPI. Quando`ShardId`é especificada, a resposta inclui os fragmentos que começam com o fragmento cujo ID segue imediatamente o`ShardId`que você forneceu.

Se você especificar o`AT_TIMESTAMP`ou`FROM_TIMESTAMP_ID`Tipo, você também deve fornecer o valor para o opcional`Timestamp`propriedade. Se você especificar o`AT_TIMESTAMP`type, então todos os fragmentos que estavam abertos no carimbo de data/hora fornecido são retornados. Se você especificar o`FROM_TIMESTAMP`tipo, então todos os fragmentos a partir do carimbo de data/hora fornecido para TIP são retornados.

> **Important**
>
> `DescribeStreamSummary`e`ListShard`As APIs fornecem uma maneira mais escalável de recuperar informações sobre seus fluxos de dados. Mais especificamente, as cotas para oDescribeStreamA API pode causar limitação. Para obter mais informações, consulte Cotas e limites (p. 7). Observe também que`DescribeStream`As cotas são compartilhadas entre todos os aplicativos que interagem com todos os streamings de dados do seuAWSconta. As cotas para oListShardsA API, por outro lado, é específica para um único stream de dados. Portanto, você não só obtém TPS mais alto com oListShardsAPI, mas a ação é melhor à medida que você cria mais fluxos de dados.
> Recomendamos que você migre todos os seus produtores e consumidores que chamam deDescribeStreamAPI para invocar oDescribeStreamResumo e oListShardAPIs. Para identificar esses produtores e consumidores, recomendamos usar o Athena para analisarCloudTraillogs como agentes de usuário para KPL e KCL são capturados nas chamadas de API.

```
SELECT useridentity.sessioncontext.sessionissuer.username,
useridentity.arn,eventname,useragent, count(*) FROM
cloudtrail_logs WHERE Eventname IN ('DescribeStream')  AND
eventtime
```

```
    BETWEEN ''
        AND ''
GROUP BY
 useridentity.sessioncontext.sessionissuer.username,useridentity.arn,eventname,useragent
ORDER BY  count(*) DESC LIMIT 100
```

Recomendamos também que oAWSIntegrações do Lambda e Kinesis Data Firehose com o Kinesis Data Streams que invocam o`DescribeStream`A API é reconfigurada para que as integrações invoquem`DescribeStreamSummary`e`ListShards`. Mais especificamente, paraAWSPor exemplo, você deve atualizar o mapeamento de origem do evento. Para o Kinesis Data Firehose, as permissões do IAM correspondentes devem ser atualizadas para que incluam o`ListShards`Permissão do IAM.

DescribeStreamAPI - Preterido

Important

As informações abaixo descrevem uma maneira atualmente obsoleta de recuperar fragmentos de um fluxo de dados por meio doDescribeStreamAPI. No momento, é altamente recomendável usar o`ListShards`API para recuperar os fragmentos que compõem o fluxo de dados.

O objeto de resposta retornado pelo método `describeStream` permite que você recupere informações sobre os estilhaços que compõem o stream. Para recuperar os estilhaços, chame o método `getShards` para esse objeto. Esse método pode não retornar todos os estilhaços do stream em uma única chamada. No código a seguir, verificamos o método `getHasMoreShards` em `getStreamDescription` para ver se há outros estilhaços que não foram retornados. Se houver, ou seja, se esse método retornar `true`, continuaremos chamando `getShards` em um loop, adicionando cada novo lote de estilhaços retornados à nossa lista de estilhaços. O loop é encerrado quando `getHasMoreShards` retorna `false`, ou seja, todos os estilhaços tiverem sido retornados. Observe que `getShards` não retorna estilhaços que estão no estado `EXPIRED`. Para obter mais informações sobre estados de estilhaço, incluindo o estado `EXPIRED`, consulte Roteamento de dados, persistência de dados e estado do estilhaço após um reestilhaçamento (p. 83).

```
DescribeStreamRequest describeStreamRequest = new DescribeStreamRequest();
describeStreamRequest.setStreamName( myStreamName );
List<Shard> shards = new ArrayList<>();
String exclusiveStartShardId = null;
do {
    describeStreamRequest.setExclusiveStartShardId( exclusiveStartShardId );
    DescribeStreamResult describeStreamResult =
 client.describeStream( describeStreamRequest );
    shards.addAll( describeStreamResult.getStreamDescription().getShards() );
    if (describeStreamResult.getStreamDescription().getHasMoreShards() && shards.size() >
 0) {
        exclusiveStartShardId = shards.get(shards.size() - 1).getShardId();
    } else {
        exclusiveStartShardId = null;
    }
} while ( exclusiveStartShardId != null );
```

Excluir um stream

Você pode excluir um stream no console do Kinesis Data Streams ou de forma programática. Para excluir um streaming de maneira programática, use `DeleteStreamRequest`, conforme mostrado no código a seguir.

```
DeleteStreamRequest deleteStreamRequest = new DeleteStreamRequest();
deleteStreamRequest.setStreamName(myStreamName);
client.deleteStream(deleteStreamRequest);
```

Desative todos os aplicativos que estejam operando no streaming antes de excluí-lo. Se um aplicativo tentar operar em um stream excluído, ele receberá exceções `ResourceNotFound`. Além disso, se você criar um novo streaming com o mesmo nome do streaming anterior e os aplicativos que operavam nele ainda estiverem em execução, esses aplicativos poderão tentar interagir com o streaming novo como se fosse o anterior, com resultados imprevisíveis.

Reestilhaçar um stream

> **Important**
>
> Você pode reestilhaçar o streaming usando oUpdateShardContagemAPI. Caso contrário, é possível continuar executando divisões e mesclagens, como explicado aqui.

Suporte ao Amazon Kinesis Data Streamsreestilhaçamento, o que permite ajustar o número de estilhaços no streaming para se adaptar às alterações na taxa de fluxo de dados pelo stream. O reestilhaçamento é considerado uma operação avançada. Se você é novato no Kinesis Data Streams, volte a este assunto depois de se familiarizar com todos os outros aspectos do Kinesis Data Streams.

Há dois tipos de operações de reestilhaçamento: divisão de estilhaço e mesclagem de estilhaço. Na divisão de estilhaço, um único estilhaço é dividido em dois. Na mesclagem de estilhaço, você combina dois estilhaços em um. O reestilhaçamento sempre ocorre em pares, ou seja, não é possível dividir em mais de dois estilhaços em uma única operação, e não é possível mesclar mais de dois estilhaços em uma única operação. O estilhaço (ou o par de estilhaços) que é objeto da operação de reestilhaçamento é chamado de estilhaço pai. O estilhaço (ou o par de estilhaços) resultante da operação de novo estilhaçamento é chamado de estilhaço filho.

A divisão aumenta o número de estilhaços no stream e, portanto, aumenta a capacidade de dados do stream. Como você é cobrado por estilhaço, divisão aumenta o custo do seu stream. Comparativamente, a mesclagem reduz o número de estilhaços no stream e, portanto, diminui a capacidade de dados e o custo do stream.

O reestilhaçamento costuma ser executado por um aplicativo administrativo, que é diferente dos aplicativos de produtor (put) e dos aplicativos de consumidor (get). Um aplicativo administrativo assim monitora o desempenho geral do streaming com base em métricas fornecidas pela AmazonCloudWatchou com base em métricas coletadas dos produtores e consumidores. O aplicativo administrativo também precisa de um conjunto de permissões do IAM maior, além de consumidores ou produtores, porque consumidores e produtores não costumam precisar acessar as APIs usadas para reestilhaçamento. Para obter mais informações sobre as permissões do IAM para o Kinesis Data Streams, consulteControlar o acesso a recursos do Amazon Kinesis Data Streams usando o IAM (p. 228).

Para obter mais informações sobre a refragmentação, consulteComo altero o número de fragmentos abertos no Kinesis Data Streams?

Tópicos

Estratégias para reestilhaçamento

A finalidade do reestilhaçamento no Amazon Kinesis Data Streams é permitir que o streaming se adapte às alterações na taxa do fluxo de dados. Você divide estilhaços para aumentar a capacidade (e o custo) do seu stream. Você mescla estilhaços para reduzir o custo (e a capacidade) do seu stream.

Uma abordagem de reestilhaçamento poderia dividir cada estilhaço do streaming, o que dobraria a capacidade do streaming. No entanto, isso pode fornecer mais capacidade adicional do que você realmente precisa e, portanto, gerar um custo desnecessário.

Você também pode usar as métricas para determinar quais são asquenteoufrioEstilhaços, ou seja, estilhaços que estão recebendo muito mais dados, ou muito menos dados do que o esperado. Em seguida, você pode seletivamente dividir os estilhaços quentes para aumentar a capacidade das chaves de hash que almejam esses estilhaços. Comparativamente, você pode mesclar os estilhaços frios para dar uma melhor serventia à capacidade não usada.

Você pode obter alguns dados de desempenho do streaming na AmazonCloudWatchmétricas que o Kinesis Data Streams publica. No entanto, você mesmo também pode coletar algumas métricas dos seus streams. Uma abordagem é registrar os valores de chave de hash gerados pelas chaves de partição dos seus registros de dados. Lembre-se de que você especifica a chave de partição no momento em que adiciona o registro ao stream.

```
putRecordRequest.setPartitionKey( String.format( "myPartitionKey" ) );
```

Usos do Kinesis Data StreamsMD5Para calcular a chave de hash a partir da chave de partição. Como você especifica a chave de partição do registro, pode usar MD5 para calcular o valor de chave de hash desse registro e registrá-lo.

Você também pode registrar os IDs dos estilhaços aos quais são atribuídos seus registros de dados. O ID do estilhaço é obtido usando-se o método `getShardId` do objeto `putRecordResults` retornado pelo método `putRecords` e o objeto `putRecordResult` retornado pelo método `putRecord`.

```
String shardId = putRecordResult.getShardId();
```

Com os IDs de estilhaço e os valores de chave de hash, você pode determinar quais estilhaços e chaves de hash estão recebendo a maior ou menor parte do tráfego. Em seguida, você pode usar o reestilhaçamento para fornecer mais ou menos capacidade, conforme apropriado para essas chaves.

Dividir um estilhaço

Para dividir um estilhaço no Amazon Kinesis Data Streams, você precisa especificar como valores de chave de hash dos estilhaços pais devem ser redistribuídos para os estilhaços filhos. Quando você adiciona um registro de dados a um stream, ele é atribuído a um estilhaço com base em um valor de chave de hash. O valor da chave de hash é o hash do MD5 da chave de partição que você especifica para o registro de dados no momento em que adiciona o registro de dados ao streaming. Os registros de dados que têm a mesma chave de partição também têm o mesmo valor de chave de hash.

Os valores possíveis de chave de hash de um determinado estilhaço constituem um conjunto de números inteiros contíguos, não negativos e ordenados. Esse intervalo de possíveis valores de chave de hash é determinado pelo seguinte:

```
shard.getHashKeyRange().getStartingHashKey();
shard.getHashKeyRange().getEndingHashKey();
```

Quando divide o estilhaço, você especifica um valor neste intervalo. Esse valor de chave de hash e todos os valores de chave de hash maiores são distribuídos para um dos estilhaços filhos. Todos os valores de chave de hash menores são distribuídos para os outros estilhaços filhos.

O seguinte código demonstra uma operação de divisão de estilhaço que redistribui as chaves de hash uniformemente entre cada um dos estilhaços filhos, basicamente, dividindo o estilhaço pai no meio. Essa é apenas uma das maneiras possíveis de dividir o estilhaço pai. Você pode, por exemplo, dividir o estilhaço de maneira que o terço inferior das chaves do pai vá para um estilhaço filho e os dois terços superiores das chaves vão para o outro estilhaço filho. No entanto, para muitos aplicativos, dividir os estilhaços no meio é uma abordagem eficiente.

O código pressupõe que `myStreamName` contém o nome do seu stream e a variável de objeto `shard` contém o estilhaço a dividir. Comece instanciando um novo objeto `splitShardRequest` e definindo o nome do stream e o ID do estilhaço.

```
SplitShardRequest splitShardRequest = new SplitShardRequest();
splitShardRequest.setStreamName(myStreamName);
splitShardRequest.setShardToSplit(shard.getShardId());
```

Determine o valor da chave de hash que é meio caminho entre o maior valor e o menor valor no estilhaço. Trata-se do valor de chave de hash inicial para o estilhaço filho que conterá a metade superior das chaves de hash do estilhaço pai. Especifique esse valor no método `setNewStartingHashKey`. Você precisa especificar somente esse valor. O Kinesis Data Streams distribui automaticamente as chaves de hash abaixo desse valor para os outros estilhaços filhos criados pela divisão. O último passo é chamar o`splitShard`Método no cliente do Kinesis Data Streams.

```
BigInteger startingHashKey = new BigInteger(shard.getHashKeyRange().getStartingHashKey());
BigInteger endingHashKey   = new BigInteger(shard.getHashKeyRange().getEndingHashKey());
String newStartingHashKey  = startingHashKey.add(endingHashKey).divide(new
 BigInteger("2")).toString();

splitShardRequest.setNewStartingHashKey(newStartingHashKey);
client.splitShard(splitShardRequest);
```

A primeira etapa após este procedimento é mostrada em Aguardar um stream ficar ativo novamente (p. 82).

Mesclar dois estilhaços

Uma operação de mesclagem de estilhaços usa dois estilhaços especificados e combina-os em um único estilhaço. Após a mesclagem, o único estilhaço filho recebe dados para todos os valores de chave de hash cobertos pelos dois estilhaços pais.

Adjacência de estilhaço

Para mesclar dois estilhaços, eles precisam estar adjacentes. Dois estilhaços são considerados adjacentes quando a união dos intervalos de chave de hash dos dois estilhaços forma um conjunto contíguo sem lacunas. Por exemplo, suponha que você tenha dois estilhaços, um com o intervalo de chaves de hash 276...381 e o outro com o intervalo de chaves de hash 382...454. Você pode mesclar esses dois estilhaços em um só, que teria um intervalo de chaves de hash 276...454.

Para usar outro exemplo, suponha que você tenha dois estilhaços, um com um intervalo de chaves de hash 276...381 e o outro com um intervalo de chaves de hash 455...560. Você não poderia mesclar esses dois estilhaços porque haveria um ou mais estilhaços entre eles que estariam no intervalo 382...454.

O conjunto de todos`OPEN`Os estilhaços em um stream (como um grupo) sempre abrange o intervalo inteiro de valores de chave de hash MD5. Para obter mais informações sobre esses estados de estilhaço (como `CLOSED`), consulte Roteamento de dados, persistência de dados e estado do estilhaço após um reestilhaçamento (p. 83).

Para identificar os estilhaços candidatos para mesclagem, você deve filtrar todos os estilhaços que estão no estado `CLOSED`. Estilhaços que são`OPEN`—isto é, não`CLOSED`—ter um número de sequência de término`null`. Você pode testar o número sequencial de término de um estilhaço usando:

```
if( null == shard.getSequenceNumberRange().getEndingSequenceNumber() )
{
  // Shard is OPEN, so it is a possible candidate to be merged.
}
```

Após filtrar os estilhaços fechados, classifique os estilhaços restantes pelo valor de chave de hash mais alto aceito por cada estilhaço. Você pode recuperar esse valor usando:

```
shard.getHashKeyRange().getEndingHashKey();
```

Se dois estilhaços são adjacentes nessa lista filtrada e classificada, eles podem ser mesclados.

Código da operação de mesclagem

O código a seguir mescla dois estilhaços. O código pressupõe que `myStreamName` contém o nome do seu stream e as variáveis de objeto `shard1` e `shard2` contém os dois estilhaços adjacentes a mesclar.

Para a operação de mesclagem, comece instanciando um novo objeto `mergeShardsRequest`. Especifique o nome do stream com o método `setStreamName`. Em seguida, especifique os dois estilhaços a mesclar usando os métodos `setShardToMerge` e `setAdjacentShardToMerge`. Por fim, chame `omergeShards`Método no cliente Kinesis Data Streams para executar a operação.

```
MergeShardsRequest mergeShardsRequest = new MergeShardsRequest();
mergeShardsRequest.setStreamName(myStreamName);
mergeShardsRequest.setShardToMerge(shard1.getShardId());
mergeShardsRequest.setAdjacentShardToMerge(shard2.getShardId());
client.mergeShards(mergeShardsRequest);
```

A primeira etapa após este procedimento é mostrada em Aguardar um stream ficar ativo novamente (p. 82).

Após o reestilhaçamento

Após qualquer tipo de procedimento de reestilhaçamento no Amazon Kinesis Data Streams, e antes da conclusão do processamento normal de registro, outros procedimentos e considerações são necessários. As seções a seguir descrevem esses itens.

Tópicos

Aguardar um stream ficar ativo novamente

Depois de chamar uma operação de reestilhaçamento, `splitShard` ou `mergeShards`, você precisa esperar o stream ficar ativo novamente. O código a ser usado é o mesmo de quando você espera que um streaming se torne ativo após a criação de um streaming (p. 72). Esse código é o seguinte:

```
DescribeStreamRequest describeStreamRequest = new DescribeStreamRequest();
describeStreamRequest.setStreamName( myStreamName );

long startTime = System.currentTimeMillis();
long endTime = startTime + ( 10 * 60 * 1000 );
while ( System.currentTimeMillis() < endTime )
{
```

```
  try {
    Thread.sleep(20 * 1000);
  }
  catch ( Exception e ) {}

  try {
    DescribeStreamResult describeStreamResponse =
 client.describeStream( describeStreamRequest );
    String streamStatus = describeStreamResponse.getStreamDescription().getStreamStatus();
    if ( streamStatus.equals( "ACTIVE" ) ) {
      break;
    }
   //
    // sleep for one second
    //
    try {
      Thread.sleep( 1000 );
    }
    catch ( Exception e ) {}
  }
  catch ( ResourceNotFoundException e ) {}
}
if ( System.currentTimeMillis() >= endTime )
{
  throw new RuntimeException( "Stream " + myStreamName + " never went active" );
}
```

Roteamento de dados, persistência de dados e estado do estilhaço após um reestilhaçamento

O Kinesis Data Streams é um serviço de streaming de dados em tempo real, então, seus aplicativos devem pressupor que os dados estão fluindo continuamente pelos estilhaços do seu stream. Quando você reestilhaça, os registros de dados que estavam fluindo para os estilhaços pais são re-roteados para fluírem para os estilhaços filhos com base nos valores de chave de hash para as quais são mapeadas as chaves de partição de registro de dados. No entanto, os registros de dados que estavam nos estilhaços pais antes do reestilhaçamento permanecem nesses estilhaços. Em outras palavras, os estilhaços pais não desaparecem quando o reestilhaçamento ocorre. Eles persistem com os dados que continham antes do reestilhaçamento. Os registros de dados nos estilhaços pai podem ser acessados usando o`getShardIteratoregetRecords` (p. 159)Operações na API do Kinesis Data Streams ou pela Kinesis Client Library.

> **Note**
>
> Os registros de dados podem ser acessados a partir do momento em que são adicionados ao stream até o período de retenção atual. Isso é verdadeiro independentemente de quaisquer alterações aos estilhaços no stream durante esse período. Para obter mais informações sobre o período de retenção de um stream, consulte Alterar o período de retenção de dados (p. 84).

No processo de reestilhaçamento, um estilhaço pai passa de um estado `OPEN` para um estado `CLOSED` para um estado `EXPIRED`.

- ABRIR: Antes de uma operação de reshard, um fragmento pai está no`OPEN`state, o que significa que os registros de dados podem ser adicionados ao estilhaço e recuperados do estilhaço.
- FECHADA: Após uma operação de reestilhaçamento, o estilhaço pai passa para um`CLOSED`estado. Isso significa que os registros de dados não são mais adicionados ao estilhaço. Os registros de dados que foram adicionados a esse estilhaço agora são adicionados a um estilhaço filho. No entanto, os registros de dados ainda podem ser recuperados do estilhaço por tempo limitado.
- EXPIRADO: Após a expiração do período de retenção do streaming, todos os registros de dados no estilhaço pai expiraram e não estão mais acessíveis. Neste momento, o próprio estilhaço muda para

um estado `EXPIRED`. As chamadas a `getStreamDescription().getShards` para enumerar os estilhaços no stream não incluem os estilhaços `EXPIRED` na lista de estilhaços retornados. Para obter mais informações sobre o período de retenção de um stream, consulte Alterar o período de retenção de dados (p. 84).

Depois que o reestilhaçamento ocorreu e o stream está novamente em um estado `ACTIVE`, você pode iniciar imediatamente a ler dados dos estilhaços filhos. No entanto, os estilhaços pais que permanecem após o reestilhaçamento ainda podem conter dados que ainda não foram lidos e foram adicionados ao stream antes do reestilhaçamento. Se você ler dados de estilhaços filhos antes ler todos os dados dos estilhaços pais, poderá ler dados de uma determinada chave de hash fora da ordem determinada pelos números sequenciais dos registros de dados. Portanto, pressupondo que a ordem dos dados é importante, você deve, após um reestilhaçamento, sempre continuar lendo dados dos estilhaços pais até esgotá-los. Só depois você deverá começar a ler dados dos estilhaços filhos. Quando `getRecordsResult.getNextShardIterator` retorna `null`, indica que você leu todos os dados no estilhaço pai. Se você está lendo dados usando a Biblioteca de cliente do Kinesis, a biblioteca garante que você receberá os dados em ordem, mesmo se ocorrer um reestilhaçamento.

Alterar o período de retenção de dados

O Amazon Kinesis Data Streams aceita alterações ao período de retenção de registros de dados do stream de dados. Um fluxo de dados do Kinesis é uma sequência ordenada de registros de dados na qual gravar e da qual ler em tempo real. Os registros de dados são, portanto, armazenados em estilhaços no seu stream temporariamente. O período entre o momento de adição de um registro e o momento em que ele deixa de estar acessível é chamado de período de retenção. Um fluxo de dados do Kinesis armazena registros de 24 horas por padrão (o máximo é 8760 horas) (365 dias).

Você pode atualizar o período de retenção por meio do console do Kinesis Data Streams ou usando oIncreaseStreamRetentionPeriodO e aDecreaseStreamRetentionPeriodoperações. Com o console do Kinesis Data Streams, você pode editar em massa o período de retenção de mais de um fluxo de dados ao mesmo tempo. Você pode aumentar o período de retenção até 8760 horas (365 dias) usando oIncreaseStreamRetentionPeriodoperação ou o console do Kinesis Data Streams. Você pode diminuir o período de retenção até um mínimo de 24 horas usando oDecreaseStreamRetentionPeriodoperação ou o console do Kinesis Data Streams. A sintaxe de solicitação das duas operações inclui o nome do stream e o período de retenção em horas. Finalmente, você pode verificar o período de retenção atual de um stream chamando a operação DescribeStream.

Este é um exemplo de alteração do período de retenção que usa a AWS CLI:

```
aws kinesis increase-stream-retention-period --stream-name retentionPeriodDemo --retention-period-hours 72
```

O Kinesis Data Streams deixa de tornar os registros inacessíveis novelhoperíodo de retenção vários minutos após aumentar o período de retenção. Por exemplo, alterar o período de retenção de 24 horas para 48 horas significa que os registros adicionados ao streaming 23 horas 55 minutos antes ainda estarão disponíveis depois de 24 horas.

Quase imediatamente, o Kinesis Data Streams torna inacessíveis os registros mais antigos que o novo período de retenção após a diminuição do período de retenção. Portanto, deve-se tomar muito cuidado ao chamar a operação DecreaseStreamRetentionPeriod.

Defina o período de retenção dos dados para garantir que os consumidores possam ler dados antes de expirar, se ocorrerem problemas. Você deve considerar cuidadosamente todas as possibilidades, como um problema com a lógica de processamento de registro ou a inatividade de uma dependência de downstream por um longo período. Ideia do período de retenção como uma rede de segurança para dar mais tempo

para os consumidores de dados se recuperarem. As operações da API de período de retenção permitem que você configure isso de forma proativa ou responda a eventos operacionais reativamente.

Encargos adicionais incidem sobre streams com período de retenção definido acima de 24 horas. Para obter mais informações, consulte Definição de preço do Amazon Kinesis Streams.

Atribuir tags no Amazon Kinesis Data Streams

Você pode atribuir seus próprios metadados aos streams que cria no Amazon Kinesis Data Streams na forma detags. Tag é um par de chave-valor que você define para um stream. O uso de tags é uma forma simples, mas eficiente, de gerenciar os recursos da AWS e organizar os dados, incluindo dados de faturamento.

Índice

Conceitos básicos de tags

Você usa o console do Kinesis Data StreamsAWS CLIou a API do Kinesis Data Streams para executar as seguintes tarefas:

- Adicionar tags a um stream
- Listar as tags para os streams
- Remover tags de um stream

Você pode usar tags para categorizar seus streams. Por exemplo, você pode categorizar streams por finalidade, proprietário ou ambiente. Como você define a chave e o valor para cada marca, você pode criar um conjunto de categorias personalizado para atender às suas necessidades específicas. Por exemplo, você pode definir um conjunto de tags que ajude a monitorar os streams por proprietário e aplicativo associado. Aqui estão alguns exemplos de marcas:

- : Nome do projeto
- Proprietário: Name (Nome)
- Finalidade: Testes de carga
- Aplicação: Application name
- : Produção

Monitoramento de custos com marcação

Você pode usar tags para categorizar e monitorar seus custos da AWS. Quando você aplica tags aoAWSrecursos, incluindo fluxos, seuAWSO relatório de alocação de custos da inclui o uso e os custos agrupados por tags. É possível aplicar tags que representem categorias de negócios (como centros de custos, nomes de aplicações ou proprietários) para organizar seus custos de vários serviços. Para

obter mais informações, consulte Usar etiquetas de alocação de custos para relatórios de faturamento personalizados no Manual do usuário do AWS Billing.

Restrições de tag

As restrições a seguir se aplicam a marcas.

Restrições básicas

- O número máximo de tags por recurso (stream) é 50.
- As chaves e os valores de tags diferenciam maiúsculas de minúsculas.
- Você não pode alterar nem editar as tags de um stream excluído.

Restrições de chaves de marcas

- Cada chave de marca deve ser exclusiva. Se você adicionar uma marca com uma chave que já estiver em uso, sua nova marca existente substituirá o par de chave-valor.
- Não é possível iniciar uma chave de tag com `aws:`, pois esse prefixo é reservado para uso pela AWS. A AWS cria tags que começam com esse prefixo em seu nome, mas você não pode editá-las ou excluí-las.
- As chaves de marca devem ter entre 1 e 128 caracteres Unicode.
- As chaves de tag devem consistir nos seguintes caracteres: Letras Unicode, dígitos, espaço em branco e os seguintes caracteres especiais:`_ . / = + - @`.

Restrições de valor de marcas

- Os valores de marca devem ter entre 0 e 255 caracteres Unicode.
- Os valores de marca podem estar em branco. Caso contrário, eles devem consistir nos seguintes caracteres: Letras Unicode, dígitos, espaço em branco e qualquer um dos seguintes caracteres especiais:`_ . / = + - @`.

Atribuir tags usando o console do Kinesis Data Streams

Você pode adicionar, listar e remover tags usando o console do Kinesis Data Streams.

Para visualizar as tags de um stream

1. Abra o console do Kinesis Data Streams. Na barra de navegação, expanda o seletor de região e selecione uma região.
2. Na página Stream List (Lista de streamings), selecione um streaming.
3. Na página Stream Details (Detalhes do streaming), clique na guia Tags.

Para adicionar uma tag a um stream

1. Abra o console do Kinesis Data Streams. Na barra de navegação, expanda o seletor de região e selecione uma região.
2. Na página Stream List (Lista de streamings), selecione um streaming.
3. Na página Stream Details (Detalhes do streaming), clique na guia Tags.
4. Especifique a chave da tag no campo Key (Chave). Opcionalmente, especifique um valor de tag no campo Value (Valor) e, em seguida, clique em Add Tag (Adicionar tag).

Se o botão Add Tag (Adicionar tag) não estiver habilitado, a chave ou o valor da tag que você especificou não atenderá as restrições de tag. Para obter mais informações, consulte Restrições de tag (p. 86).

5. Para visualizar a nova tag na lista da guia Tags, clique no ícone de atualização.

Para remover uma tag de um stream

1. Abra o console do Kinesis Data Streams. Na barra de navegação, expanda o seletor de região e selecione uma região.
2. Na página Stream List, selecione um stream.
3. Na página Stream Details (Detalhes do streaming), clique na guia Tags e, em seguida, clique no ícone Remove (Remover) da tag.
4. Na caixa de diálogo Delete Tag (Excluir tag), clique em Yes, Delete (Sim, excluir).

Atribuir tags a streams usando o AWS CLI

Você pode adicionar, listar e remover tags usando a AWS CLI. Para obter exemplos, consulte a seguinte documentação.

add-tags-to-stream do

Adiciona ou atualiza as tags para o stream especificado.

list-tags-for-stream do

Lista as tags para o stream especificado.

remove-tags-from-stream do

Remove as tags do stream especificado.

Atribuir tags usando a API do Kinesis Data Streams

Você pode adicionar, listar e remover tags usando a API do Kinesis Data Streams. Para obter exemplos, consulte a seguinte documentação:

AddTagsToStream

Adiciona ou atualiza as tags para o stream especificado.

ListTagsForStream

Lista as tags para o stream especificado.

RemoveTagsFromStream

Remove as tags do stream especificado.

Gravando dados no Amazon Kinesis Data Streams

UMAprodutorO é um aplicativo que grava dados no Amazon Kinesis Data Streams. Você pode criar produtores para o Kinesis Data Streams usando oAWS SDK for Javae a Kinesis Producer Library.

Se você não estiver familiarizado com o Kinesis Data Streams, comece familiarizando-se com os conceitos e a terminologia apresentados emO que é o Amazon Kinesis Data Streams? (p. 1)eConceitos básicos do Amazon Kinesis Data Streams (p. 15).

> Important
>
> O Kinesis Data Streams aceita alterações feitas no período de retenção de registros de dados do stream de dados. Para obter mais informações, consulte Alterar o período de retenção de dados (p. 84).

Para colocar dados no stream, é necessário especificar o nome do stream, uma chave de partição e o blob de dados que serão adicionados ao stream. A chave de partição é usada para determinar em que estilhaço do stream o registro de dados será adicionado.

Todos os dados no estilhaço são enviados para o mesmo operador que está processando o estilhaço. A chave de partição que você usa depende da lógica do aplicativo. O número de chaves de partição normalmente deve ser muito maior que o número de estilhaços. Isso ocorre porque a chave de partição é usada para determinar como mapear um registro de dados para um determinado estilhaço. Se você tiver um número suficiente de chaves de partição, os dados podem ser distribuídos uniformemente pelos estilhaços de um stream.

Índice

Desenvolver produtores usando a da Amazon Kinesis Producer Library

Um produtor do Amazon Kinesis Data Streams é um aplicativo que coloca registros de dados de usuário em um streaming de dados do Kinesis (também chamado deingestão de dados). A Kinesis Producer Library (KPL) simplifica o desenvolvimento de aplicativos de produtor permitindo que os desenvolvedores atinjam alta taxa de transferência de gravação em um streaming de dados do Kinesis.

Você pode monitorar a KPL com a AmazonCloudWatch. Para obter mais informações, consulte Monitorando a biblioteca do produtor Kinesis com o Amazon CloudWatch (p. 216).

Índice

> **Note**
>
> É recomendável que você atualize para a versão mais recente da KPL. A KPL é atualizada regularmente com versões mais recentes que incluem os patches de dependência e segurança mais recentes, correções de bugs e novos recursos compatíveis com versões anteriores. Para obter mais informações, consultehttps://github.com/awslabs/amazon-kinesis-producer/releases/.

Papel da KPL

O KPL é umeasy-to-use, biblioteca altamente configurável que ajuda você a gravar em um stream de dados do Kinesis. Ela atua como um intermediário entre o código do seu aplicativo de produtor e as ações da API Kinesis Data Streams. A KPL executa as seguintes tarefas principais:

- Grava em um ou mais fluxos de dados do Kinesis com um mecanismo de retentativa automático e configurável
- Coleta registros e usa `PutRecords` para gravar vários registros em vários estilhaços por solicitação
- Agrega registros de usuário para aumentar o tamanho da carga útil e melhorar a taxa de transferência
- Integra-se perfeitamente com oBiblioteca de cliente do Kinesis Client(KCL) para desagregar registros em lote no consumidor
- Envia a AmazonCloudWatchMétricas em seu nome para proporcionar visibilidade sobre o desempenho do produtor

Observe que a KPL é diferente da API do Kinesis Data Streams que está disponível naAWSSDKs da. A API do Kinesis Data Streams ajuda você a gerenciar muitos aspectos do Kinesis Data Streams (incluindo a criação de streams, reestilhaçamento e colocação e obtenção de registros), enquanto que a KPL fornece uma camada de abstração especificamente para a ingestão de dados. Para obter informações sobre a API do Kinesis Data Streams, consulte aReferência da API do Amazon Kinesis.

Vantagens do uso da KPL do

A lista a seguir representa algumas vantagens principais do uso da KPL para desenvolver produtores do Kinesis Data Streams.

A KPL pode ser usada em casos de uso síncronos ou assíncronos. Sugerimos usar o desempenho mais alto da interface assíncrona, a menos que haja um motivo específico para usar o comportamento síncrono. Para obter mais informações sobre esses dois casos de uso e o código de exemplo, consulte Escrevendo em seu Kinesis Data Stream usando a KPL (p. 95).

Benefícios de desempenho

A KPL pode ajudar a criar produtores de alto desempenho. Considere uma situação em que suas instâncias do Amazon EC2 atuam como proxy para coletar eventos de 100 bytes de centenas ou milhares de dispositivos de baixa potência e gravar registros em um streaming de dados do Kinesis. Cada instância do EC2 precisa gravar milhares de eventos por segundo no seu streaming de dados. Para alcançar a taxa de transferência necessária, os produtores precisam implementar uma lógica complexa, como agrupamento em lotes ou multithreading, lógica de retentativa e desagregação de registros no lado do consumidor. A KPL executa todas essas tarefas para você.

Facilidade de uso do lado do consumidor

Para desenvolvedores do lado do consumidor usando a KCL em Java, a KPL integra-se sem esforço adicional. Quando a KCL recupera um registro agregado do Kinesis Data Streams que consiste em vários registros de usuário da KPL, ela chama automaticamente a KPL para extrair os registros individuais de usuário antes de retorná-los ao usuário.

Para desenvolvedores do lado do consumidor que não usam a KCL, mas usam a operação da API`GetRecords`Diretamente, uma biblioteca Java da KPL está disponível para extrair os registros individuais de usuário antes de retorná-los ao usuário.

Monitoramento de produtor

Você pode coletar, monitorar e analisar seus produtores do Kinesis Data Streams usando a AmazonCloudWatche a KPL. A KPL emite taxa de transferência, erro e outras métricas paraCloudWatchEm seu nome e pode ser configurada para monitorar no nível de streaming, estilhaço ou produtor.

Arquitetura assíncrona

Como a KPL pode colocar os registros em buffer antes de enviá-los ao Kinesis Data Streams, ela não força o aplicativo chamador a bloquear e aguardar uma confirmação de que o registro chegou no servidor antes de continuar a execução. Uma chamada para colocar um registro na KPL sempre retorna imediatamente, não espera o registro ser enviado ou uma resposta ser recebida do servidor. Em vez disso, um`Future`É criado um objeto que recebe o resultado do envio do registro ao Kinesis Data Streams em um momento posterior. É o mesmo comportamento dos clientes assíncronos naAWSSDK.

Quando não usar a KPL

A KPL pode incorrer em atraso de processamento adicional de até`RecordMaxBufferedTime`dentro da biblioteca (configurável pelo usuário). Valores maiores de `RecordMaxBufferedTime` geram maiores eficiências de empacotamento e melhor desempenho. Os aplicativos que não toleram esse atraso adicional podem precisar usar aAWSSDK diretamente. Para obter mais informações sobre como usar aAWSConsulte o SDK com o Kinesis Data Streams, consulteDesenvolver produtores usando a API do Amazon Kinesis Data Streams com oAWS SDK for Java (p. 100). Para obter mais informações sobre`RecordMaxBufferedTime`E outras propriedades configuráveis pelo usuário da KPL, consulteConfigurando a Biblioteca do Produtor Kinesis (p. 96).

Instalar a KPL

A Amazon fornece binários pré-criados da Kinesis Producer Library (KPL) C++ para macOS, Windows e distribuições recentes do Linux (para saber mais sobre plataformas compatíveis, consulte a próxima

seção). Esses binários, empacotados como parte dos arquivos .jar do Java, são invocados e usados automaticamente se você está usando o Maven para instalar o pacote. Para localizar as versões mais recentes da KPL e da KCL, use os seguintes links de pesquisa do Maven:

- KPL
- KCL

O binários do Linux foram compilados com GNU Compiler Collection (GCC) e vinculados estaticamente à libstdc++ no Linux. Espera-se que eles funcionem em qualquer distribuição do Linux de 64 bits que inclua um glibc versão 2.5 ou superior.

Os usuários de distribuições anteriores do Linux podem compilar a KPL usando as instruções de criação fornecidas junto com o código-fonte naGitHub. Para baixar o KPL deGitHub, consulteBiblioteca de produtores do Kinesis.

Transição da Kinesis Producer Library para os certificados do Amazon Trust Services (ATS)

Em 9 de fevereiro de 2018, às 9:00, horário do dia, o Amazon Kinesis Data Streams instalou os certificados ATS. Para que você possa continuar a gravar registros no Kinesis Data Streams usando a Kinesis Producer Library (KPL), é necessário atualizar a instalação da KPL para que você possa continuar a gravar registros no Kinesis Data Streamsversão 0.12.6ou posterior. Essa alteração afeta todos osAWSRegiões.

Para obter informações sobre a mudança para o ATS, consulteComo se preparar paraAWS's Mover para sua própria autoridade de certificação.

Se você tiver problemas e precisar de suporte técnico,criar um casocom oAWSCentral de Support.

Plataformas compatíveis com KPL

A Kinesis Producer Library (KPL) é escrita em C++ e executada como um processo filho do processo principal do usuário. Binários nativos pré-compilados de 64 bits são fornecidos com a versão do Java e gerenciados pelo wrapper Java.

O pacote Java é executado sem a necessidade de instalar qualquer biblioteca adicional nos seguintes sistemas operacionais:

- Distribuições do Linux com kernel 2.6.18 (setembro de 2006) e posterior
- Apple OS X 10.9 e posterior
- Windows Server 2008 e posterior

> **Important**
>
> O Windows Server 2008 e posterior é compatível com todas as versões do KPL até a versão 0.14.0.
> A plataforma Windows NÃO é compatível a partir da versão KPL 0.14.0 ou superior.

Observe que a KPL é de 64 bits apenas.

Código-fonte

Se os binários fornecidos na instalação da KPL não forem suficientes para o seu ambiente, o núcleo da KPL será escrito como um módulo C++. O código-fonte do módulo C++ e a interface do Java são lançados sob a Amazon Public License e disponibilizados naGitHubemBiblioteca de produtores do Kinesis. Embora

seja possível usar a KPL em qualquer plataforma para a qual haja disponibilidade de JRE e um compilador C++ compatível com os padrões recentes, a Amazon não aceita oficialmente qualquer plataforma que não esteja na lista de plataformas compatíveis.

Principais conceitos da KPL

As seções a seguir contêm os conceitos e a terminologia necessários para entender e tirar proveito da Kinesis Producer Library (KPL).

Tópicos

Registros

Neste guia, distinguimos entre oRegistros de usuário da KPeRegistros do Kinesis Data Streams. Quando usamos o termodiscoSem um qualificador, fazemos referência a umRegistro de usuário da KP. Quando nos referirmos a um registro do Kinesis Data Streams, mencionamos explicitamente um registro do Kinesis Data StreamsRegistro do Kinesis Data Streams.

Um registro de usuário da KPL é um blob de dados que tem significado específico para o usuário. Os exemplos incluem um blob JSON que representa um evento de interface do usuário em um site ou uma entrada de log proveniente de um servidor da web.

Um registro do Kinesis Data Streams é uma instância do`Record`Estrutura de dados definida pela API de serviço Kinesis Data Streams. Ele contém uma chave de partição, um número sequencial e um blob de dados.

Agrupamento em lotes

Envio em lotes refere-se à execução de uma única ação em vários itens, em vez de executar a ação repetidamente em cada item.

Neste contexto, o “item” é um registro e a ação é enviá-los ao Kinesis Data Streams. Em uma situação sem agrupamento em lotes, você colocaria cada registro em um registro separado do Kinesis Data Streams e faria uma única solicitação HTTP para enviá-lo ao Kinesis Data Streams. Com o agrupamento em lotes, cada solicitação HTTP pode carregar vários registros, em vez de apenas um.

A KPL aceita dois tipos de agrupamento em lotes:

- Agregação— armazenamento de vários registros em um único registro do Kinesis Data Streams.
- ColetaUso da operação da API do`PutRecords`Para enviar vários registros do Kinesis Data Streams para um ou mais fragmentos no stream de dados do Kinesis.

Os dois tipos de agrupamento em lotes KPL são projetados para coexistir e podem ser ativados ou desativados de forma independente. Por padrão, ambos estão ativados.

Agregação

AgregaçãoRefere-se ao armazenamento de vários registros em um registro do Kinesis Data Streams. A agregação permite que os clientes aumentem o número de registros enviados por chamada de API, o que aumenta efetivamente a taxa de transferência do produtor.

Os estilhaços do Kinesis Data Streams oferecem suporte a até 1.000 registros do Kinesis Data Streams por segundo, ou 1 MB de taxa de transferência. O limite de registros do Kinesis Data Streams por segundo vincula os clientes aos registros menores que 1 KB. A agregação de registros permite aos clientes combinar vários registros em um único registro do Kinesis Data Streams. Isso permite que os clientes melhorem a própria taxa de transferência por estilhaço.

Considere o caso de um estilhaço na região us-east-1 que está atualmente em execução à taxa constante de 1.000 registros por segundo, com registros de 512 bytes cada. Com a agregação KPL da é possível empacotar 1.000 registros em apenas 10 registros do Kinesis Data Streams, reduzindo o RPS a 10 (50 KB cada).

Coleta

ColetaColeta refere-se ao envio em lotes de vários registros do Kinesis Data Streams e ao envio dos mesmos em uma única solicitação HTTP com uma chamada à operação da API da e ao envio dos mesmos`PutRecords`, em vez de enviar cada registro do Kinesis Data Streams em sua própria solicitação HTTP.

Isso aumenta a taxa de transferência em comparação com o uso de nenhuma coleção, pois reduz a sobrecarga de fazer muitas solicitações HTTP separadas. Na verdade, `PutRecords`, por si só, foi projetado especificamente para essa finalidade.

A coleta difere da agregação porque trabalha com grupos de registros do Kinesis Data Streams. Os registros do Kinesis Data Streams coletados ainda podem conter vários registros do usuário. O relacionamento pode ser visualizado da seguinte maneira:

```
record 0 --|
record 1   |        [ Aggregation ]
    ...    |--> Amazon Kinesis record 0 --|
    ...    |                              |
record A --|                              |
                                           |
    ...                  ...               |
                                           |
record K --|                              |
record L   |                              |      [ Collection ]
    ...    |--> Amazon Kinesis record C --|--> PutRecords Request
    ...    |                              |
record S --|                              |
                                           |
    ...                  ...               |
                                           |
record AA--|                              |
record BB  |                              |
    ...    |--> Amazon Kinesis record M --|
    ...    |
record ZZ--|
```

Integração da KPL com código de produtor

A Kinesis Producer Library (KPL) é executada em um processo separado e se comunica com o processo de usuário pai usando IPC. Essa arquitetura, às vezes chamada de microsserviço, é escolhida por dois motivos principais:

1) O processo do usuário não falhará mesmo que a KPL falhe

Seu processo pode ter tarefas não relacionadas ao Kinesis Data Streams e continuar funcionando mesmo se a KPL falhar. Também é possível ao processo de usuário pai reiniciar a KPL e recuperar um estado totalmente funcional (essa funcionalidade está nos wrappers oficiais).

Um exemplo é um servidor da web que envia métricas ao Kinesis Data Streams. O servidor pode continuar atendendo páginas mesmo que a parte do Kinesis Data Streams tenha parado de funcionar. Portanto, falhar todo o servidor devido a um erro na KPL causaria uma interrupção desnecessária.

2) Clientes arbitrários podem ser aceitos

Há sempre clientes que usam linguagens diferentes das oficialmente aceitas. Esses clientes também devem ser capazes de usar a KPL facilmente.

Matriz de uso recomendado

A matriz de uso a seguir enumera as configurações recomendadas para diferentes usuários e aconselha se e como você deve usar a KPL. Lembre-se de que, se a agregação estiver habilitada, será preciso usar a desagregação para extrair seus registros no lado do consumidor.

Linguagem do lado do produtor	Linguagem do lado do consumidor	Versão do KCL	Lógica do ponto de verificação	Você consegue usar a KPL?	Advertências
Tudo menos Java	*	*	*	Não	N/D
Java	Java	Usa o Java SDK diretamente	N/D	Sim	Se a agregação for usada, você precisará usar a biblioteca de desagregação fornecida após as chamadas a `GetRecords`.
Java	Tudo menos Java	Usa o SDK diretamente	N/D	Sim	É preciso desabilitar a agregação.
Java	Java	1.3.x	N/D	Sim	É preciso desabilitar a agregação.
Java	Java	1.4.x	Chama o ponto de verificação sem argumento algum	Sim	Nenhum
Java	Java	1.4.x	Chama o ponto de verificação com um número sequencial explícito	Sim	Desative a agregação ou altere o código para usar números sequenciais estendidos para definir pontos de verificação.
Java	Tudo menos Java	1.3.x + daemon de várias linguagens	N/D	Sim	É preciso desabilitar a agregação.

Linguagem do lado do produtor	Linguagem do lado do consumidor	Versão do KCL	Lógica do ponto de verificação	Você consegue usar a KPL?	Advertências
		+ wrapper específico de linguagem			

Escrevendo em seu Kinesis Data Stream usando a KPL

As seções a seguir mostram o código de exemplo em uma progressão desde o produtor de "barebones" mais simples possível até o código totalmente assíncrono.

Código de produtor de barebones

Só é preciso o código a seguir para gravar um produtor de trabalho mínimo. Os registros de usuário da Kinesis Producer Library (KPL) são processados em segundo plano.

```
// KinesisProducer gets credentials automatically like
// DefaultAWSCredentialsProviderChain.
// It also gets region automatically from the EC2 metadata service.
KinesisProducer kinesis = new KinesisProducer();
// Put some records
for (int i = 0; i < 100; ++i) {
    ByteBuffer data = ByteBuffer.wrap("myData".getBytes("UTF-8"));
    // doesn't block
    kinesis.addUserRecord("myStream", "myPartitionKey", data);
}
// Do other stuff ...
```

Responder aos resultados de forma síncrona

No exemplo anterior, o código não verificou se os registros de usuário da KPL foram bem-sucedidos. A KPL executa todas as novas tentativas necessárias para dar conta das falhas. No entanto, para verificar os resultados, você poderá examiná-los usando os objetos `Future` que são retornados de `addUserRecord`, como no exemplo a seguir (exemplo anterior mostrado para fins de contexto):

```
KinesisProducer kinesis = new KinesisProducer();

// Put some records and save the Futures
List<Future<UserRecordResult>> putFutures = new LinkedList<Future<UserRecordResult>>();
for (int i = 0; i < 100; i++) {
    ByteBuffer data = ByteBuffer.wrap("myData".getBytes("UTF-8"));
    // doesn't block
    putFutures.add(
        kinesis.addUserRecord("myStream", "myPartitionKey", data));
}

// Wait for puts to finish and check the results
for (Future<UserRecordResult> f : putFutures) {
    UserRecordResult result = f.get(); // this does block
    if (result.isSuccessful()) {
        System.out.println("Put record into shard " +
                           result.getShardId());
    } else {
        for (Attempt attempt : result.getAttempts()) {
```

```
            // Analyze and respond to the failure
        }
    }
}
```

Responder aos resultados de forma assíncrona

O exemplo anterior está chamando `get()` para um objeto `Future`, o que bloqueia a execução. Se não quiser bloquear a execução, você poderá usar um retorno de chamada assíncrono, como mostrado no exemplo a seguir:

```
KinesisProducer kinesis = new KinesisProducer();

FutureCallback<UserRecordResult> myCallback = new FutureCallback<UserRecordResult>() {
    @Override public void onFailure(Throwable t) {
        /* Analyze and respond to the failure  */
    };
    @Override public void onSuccess(UserRecordResult result) {
        /* Respond to the success */
    };
};

for (int i = 0; i < 100; ++i) {
    ByteBuffer data = ByteBuffer.wrap("myData".getBytes("UTF-8"));
    ListenableFuture<UserRecordResult> f = kinesis.addUserRecord("myStream",
 "myPartitionKey", data);
    // If the Future is complete by the time we call addCallback, the callback will be
 invoked immediately.
    Futures.addCallback(f, myCallback);
}
```

Configurando a Biblioteca do Produtor Kinesis

Embora as configurações padrão devam funcionar bem para a maioria dos casos de uso, talvez convenha alterar algumas configurações padrão para ajustar o comportamento do `KinesisProducer` às suas necessidades. Uma instância da classe `KinesisProducerConfiguration` pode ser passada ao construtor `KinesisProducer` para esse propósito, por exemplo:

```
KinesisProducerConfiguration config = new KinesisProducerConfiguration()
        .setRecordMaxBufferedTime(3000)
        .setMaxConnections(1)
        .setRequestTimeout(60000)
        .setRegion("us-west-1");

final KinesisProducer kinesisProducer = new KinesisProducer(config);
```

Você também pode carregar uma configuração de um arquivo de propriedades:

```
KinesisProducerConfiguration config =
 KinesisProducerConfiguration.fromPropertiesFile("default_config.properties");
```

Você pode substituir qualquer caminho e nome de arquivo a que o processo de usuário tem acesso. Você também pode chamar métodos definidos para a instância de `KinesisProducerConfiguration` criada dessa forma para personalizar a configuração.

O arquivo de propriedades deve especificar os parâmetros usando os nomes emPascalCase. Os nomes correspondem aos usados nos métodos definidos na classe `KinesisProducerConfiguration`. Por exemplo:

```
RecordMaxBufferedTime = 100
MaxConnections = 4
RequestTimeout = 6000
Region = us-west-1
```

Para obter mais informações sobre regras de uso de parâmetros de configuração e limites de valor, consulte aarquivo de propriedades de configuração de amostra emGitHub.

Observe que, depois que o `KinesisProducer` é inicializado, alterar a instância de `KinesisProducerConfiguration` que foi usada não tem mais efeito. No momento, o `KinesisProducer` não oferece suporte à reconfiguração dinâmica.

Desagregação de consumidor

A partir da versão 1.4.0, a KCL oferece suporte à desagregação automática dos registros de usuário da KPL. O código do aplicativo do consumidor escrito com as versões anteriores da KCL será compilado sem qualquer modificação depois que você atualizar a KCL. No entanto, caso a agregação da KPL esteja sendo usada no lado do produtor, há uma sutileza envolvendo definição de pontos de verificação: todos os sub-registros dentro de um registro agregado têm o mesmo número sequencial. Então, os dados adicionais precisarão ser armazenados com o ponto de verificação se for preciso distinguir os sub-registros. Esses dados adicionais são chamados de números de subsequência.

Migração das versões anteriores da KCL

Não é necessário alterar as chamadas existentes para que definam pontos de verificação em conjunto com a agregação. Ainda é certo que você pode recuperar com êxito todos os registros armazenados no Kinesis Data Streams. A KCL agora oferece duas novas operações de ponto de verificação para aceitar casos de uso específicos, descritos abaixo.

Caso o seu código existente tenha sido escrito para uma versão da KCL anterior à compatibilidade com a KPL e a operação de ponto de verificação seja chamada sem argumentos, isso equivale a definir o ponto de verificação do número sequencial do último registro de usuário da KPL no lote. Se a operação de ponto de verificação é chamada com uma string de número sequencial, isso equivale a definir o ponto de verificação do número sequencial do lote conhecido junto com o número 0 (zero) da subsequência implícita.

Chamando a nova operação de checkpoint KCL`checkpoint()`sem argumentos é semanticamente equivalente a verificar o número de seqüência do último`Record`Chamar no lote, junto com o número 0 (zero) da subsequência implícita.

Chamando a nova operação de checkpoint KCL`checkpoint(Record record)`é semanticamente equivalente ao checkapontar o dado`Record`A número de sequência da junto com o número 0 (zero) da subsequência implícita. Se a chamada a `Record` é na verdade um `UserRecord`, é definido o ponto de verificação do número sequencial `UserRecord` e do número subsequencial.

Chamando a nova operação de checkpoint KCL`checkpoint(String sequenceNumber, long subSequenceNumber)`Observe explicitamente verifica o número de sequência conhecido junto com o número subsequencial conhecido.

Em qualquer um desses casos, depois que o ponto de verificação é armazenado na tabela de ponto de verificação do Amazon DynamoDB, a KCL pode retomar corretamente a recuperação de registros, mesmo quando o aplicativo falha e reinicia. Se houver mais registros contidos na sequência, a recuperação ocorrerá a partir do próximo registro de número subsequencial dentro do registro com o número sequencial cujo ponto de verificação foi definido mais recentemente. Se o ponto de verificação mais recente inclui o último número subsequencial do registro de número sequencial anterior, a recuperação ocorrerá a partir do registro com o próximo número sequencial.

A próxima seção discute detalhes de definição do ponto de verificação de sequência e subsequência para consumidores que precisam evitar a omissão e a duplicação de registros. Se a omissão (ou duplicação) de registros ao parar e reiniciar o processamento de registros do consumidor não é importante, você pode executar seu código existente sem modificação.

Extensões do KCL para a desagregação da KPL

Como discutido anteriormente, a desagregação da KPL pode envolver definição de ponto de verificação de subsequência. Para facilitar o uso da definição de ponto de verificação de subsequência, um`UserRecord`A classe foi adicionada ao KCL:

```
public class UserRecord extends Record {
    public long getSubSequenceNumber() {
    /* ... */
    }
    @Override
    public int hashCode() {
    /* contract-satisfying implementation */
    }
    @Override
    public boolean equals(Object obj) {
    /* contract-satisfying implementation */
    }
}
```

Essa classe agora é usada em vez de `Record`. Ela não interrompe o código existente por ser uma subclasse de `Record`. A classe `UserRecord` representa os sub-registros reais e os registros padrão não agregados. Os registros não agregados podem ser considerados como registros agregadas com exatamente um sub-registro.

Além disso, duas operações novas são adicionadas a `IRecordProcessorCheckpointer`:

```
public void checkpoint(Record record);
public void checkpoint(String sequenceNumber, long subSequenceNumber);
```

Para começar a usar a definição de ponto de verificação de número subsequencial, você pode executar a seguinte conversão. Altere o seguinte código de formulário:

```
checkpointer.checkpoint(record.getSequenceNumber());
```

Novo código de formulário:

```
checkpointer.checkpoint(record);
```

Recomendamos usar o formulário `checkpoint(Record record)` para definição de ponto de verificação de subsequência. No entanto, se você já estiver armazenando `sequenceNumbers` em strings para usar na definição de pontos de verificação, agora deverá também armazenar `subSequenceNumber`, como mostrado no exemplo a seguir:

```
String sequenceNumber = record.getSequenceNumber();
long subSequenceNumber = ((UserRecord) record).getSubSequenceNumber();  // ... do other
 processing
checkpointer.checkpoint(sequenceNumber, subSequenceNumber);
```

A transmissão de `Record` para `UserRecord` sempre é bem-sucedida porque a implementação sempre usa `UserRecord` internamente. A menos que haja uma necessidade de executar aritmética nos números sequenciais, essa abordagem não é recomendada.

Durante o processamento de registros de usuário da KPL, a KCL grava o número subsequente no Amazon DynamoDB como um campo extra para cada linha. As versões anteriores da KCL usadas`AFTER_SEQUENCE_NUMBER`Para obter registros ao retomar os pontos de verificação. O KCL atual com suporte a KPL usa`AT_SEQUENCE_NUMBER`Em vez disso. Quando é recuperado o registro no número sequencial para o qual foi definido o ponto de verificação, esse número é verificado e os sub-registros são descartados conforme apropriado (que podem ser todos eles, se o último sub-registro é aquele verificado). Novamente, os registros não agregados podem ser considerados como registros agregados com um único sub-registro. Portanto, o mesmo algoritmo funciona para os registros agregados e não agregados.

O uso doGetRecordsDiretamente

Em vez de usar a KCL, você pode optar por chamar a operação da API`GetRecords`diretamente para recuperar registros do Kinesis Data Streams. Para desempacotar esses registros recuperados nos seus registros de usuário originais da KPL, chame uma das seguintes operações estáticas em`UserRecord.java`:

```
public static List<Record> deaggregate(List<Record> records)

public static List<UserRecord> deaggregate(List<UserRecord> records, BigInteger
 startingHashKey, BigInteger endingHashKey)
```

A primeira operação usa o valor `0` (zero) padrão para `startingHashKey` e o valor `2^128 -1` padrão para `endingHashKey`.

Cada uma dessas operações desagrega a lista de registros do Kinesis Data Streams em uma lista de registros de usuário da KPL. Qualquer registro de usuário da KPL cuja chave de hash explícita ou chave de partição estiver fora do intervalo da`startingHashKey`(inclusive) e a`endingHashKey`(inclusive) são descartados da lista de registros retornada.

Usando a KPL com o Kinesis Data Firehose

Se você usa a Kinesis Producer Library (KPL) para gravar dados em um streaming de dados do Kinesis, é possível usar a agregação para combinar os registros que você grava no streaming de dados do Kinesis. Se você usar esse streaming de dados como origem para o fluxo de entrega do Kinesis Data Firehose, o Kinesis Data Firehose desagregará os registros antes de entregá-los no destino. Se você configurar o fluxo de entrega para transformar os dados, o Kinesis Data Firehose desagregará os registros antes de entregá-los aoAWS Lambda. Para obter mais informações, consulte Gravar no Kinesis Data Firehose usando o Kinesis Data Streams.

Uso da KPL com aAWSRegistro de esquemas de Glue

Você pode integrar seus fluxos de dados do Kinesis com oAWSRegistro de esquema de Glue. OAWSO registro de esquemas de Glue permite detectar, controlar e evoluir centralmente esquemas, garantindo que os dados produzidos sejam continuamente validados por um esquema registrado. O esquema define a estrutura e o formato de um registro de dados. Um esquema é uma especificação versionada para publicação, consumo ou armazenamento de dados confiáveis. OAWSO Glue Schema Registry permite melhorarend-to-endqualidade de dados e governança de dados em seus aplicativos de streaming. Para obter mais informações, consulteAWSRegistro de esquemas de Glue. Uma das maneiras de configurar essa integração é através das bibliotecas KPL e Kinesis Client Library (KCL) em Java.

> Important
>
> Atualmente, o Kinesis Data Streams eAWSA integração do registro do esquema de Glue só é suportada para os fluxos de dados do Kinesis que usam produtores de KPL implementados em Java. Suporte a várias linguagens não é fornecido.

Para obter instruções detalhadas sobre como configurar a integração do Kinesis Data Streams com o Schema Registry usando a KPL, consulte a seção “Interagindo com dados usando as bibliotecas KPL/KCL” noCaso de uso: Integrar o Amazon Kinesis Data Streams com aAWSRegistro de esquemas de Glue.

Configuração de proxy da KPL

Para aplicativos que não podem se conectar diretamente à Internet, todosAWSOs clientes SDK suportam o uso de proxies HTTP ou HTTPS. Em um ambiente corporativo típico, todo o tráfego de rede de saída precisa passar por servidores proxy. Se a sua aplicação usa a Kinesis Producer Library (KPL) para coletar e enviar dados paraAWSem um ambiente que usa servidores proxy, seu aplicativo exigirá a configuração do proxy KPL. A KPL é uma biblioteca de alto nível construída sobre oAWSKinesis SDK. Ele é dividido em um processo nativo e um invólucro. O processo nativo executa todos os trabalhos de processamento e envio de registros, enquanto o wrapper gerencia o processo nativo e se comunica com ele. Para obter mais informações, consulteImplementando produtores eficientes e confiáveis com a Amazon Kinesis Producer Library.

O wrapper é escrito em Java e o processo nativo é escrito em C++ com o uso do Kinesis SDK. A versão 0.14.7 e superior da KPL agora oferece suporte à configuração de proxy no wrapper Java, que pode passar todas as configurações de proxy para o processo nativo. Para obter mais informações, consultehttps://github.com/awslabs/amazon-kinesis-producer/releases/tag/v0.14.7.

Você pode usar o seguinte código para adicionar configurações de proxy aos seus aplicativos KPL.

```
KinesisProducerConfiguration configuration = new KinesisProducerConfiguration();
// Next 4 lines used to configure proxy
configuration.setProxyHost("10.0.0.0"); // required
configuration.setProxyPort(3128); // default port is set to 443
configuration.setProxyUserName("username"); // no default
configuration.setProxyPassword("password"); // no default

KinesisProducer kinesisProducer = new KinesisProducer(configuration);
```

Desenvolver produtores usando a API do Amazon Kinesis Data Streams com oAWS SDK for Java

Você pode desenvolver produtores usando a API do Amazon Kinesis Data Streams com oAWSSDK for Java. Se você não estiver familiarizado com o Kinesis Data Streams, comece familiarizando-se com os conceitos e a terminologia apresentados emO que é o Amazon Kinesis Data Streams? (p. 1)eConceitos básicos do Amazon Kinesis Data Streams (p. 15).

Esses exemplos discutem oAPI Kinesis Data Streamse use oAWSSDK for JavaPara adicionar (colocar) dados a um stream. Contudo, na maioria dos casos de uso, é melhor usar a biblioteca KPL do Kinesis Data Streams. Para obter mais informações, consulte Desenvolver produtores usando a da Amazon Kinesis Producer Library (p. 88).

O código Java de exemplo neste capítulo demonstra como executar operações básicas da API do Kinesis Data Streams e está dividido logicamente por tipo de operação. Esses exemplos não representam um código pronto para produção, pois não verificam todas as exceções possíveis nem abrangem todas as considerações de segurança ou de performance possíveis. Além disso, você pode chamar oAPI Kinesis Data Streamsusando outras linguagens de programação. Para obter mais informações sobre todos os disponíveisAWSSDKs, consulteComece a desenvolver com a Amazon Web Services.

Cada tarefa tem pré-requisitos. Por exemplo, não é possível adicionar dados a um stream enquanto o stream não é criado, o que requer a criação de um cliente. Para obter mais informações, consulte Criar e gerenciar streamings (p. 68).

Tópicos

Adicionar dados a um stream

Quando um stream é criado, você pode adicionar dados a ele na forma de registros. Um registro é uma estrutura de dados que contém os dados a serem processados na forma de um blob de dados. Depois de armazenar dados no registro, o Kinesis Data Streams não inspeciona, interpreta ou altera dados de forma alguma. Cada registro também tem um número sequencial e uma chave de partição associados.

Há duas operações diferentes na API do Kinesis Data Streams que adicionam dados a um stream,`PutRecords`e`PutRecord`. A operação `PutRecords` envia vários registros ao stream por solicitação HTTP e a operação singular `PutRecord` envia registros ao stream um por vez (uma solicitação HTTP separada é necessária para cada registro). Talvez convenha usar `PutRecords` para a maioria dos aplicativos, pois ele atingirá uma taxa de transferência mais alta por produtor de dados. Para obter mais informações sobre cada uma dessas operações, consulte as subseções abaixo.

Tópicos

Sempre lembre-se de que, como o aplicativo de origem está adicionando dados ao stream usando a API do Kinesis Data Streams, provavelmente há um ou mais aplicativos de consumidor que estão processando dados fora do stream simultaneamente. Para obter informações sobre como os consumidores obtêm dados usando a API do Kinesis Data Streams, consulteComo obter dados de um stream (p. 159).

> Important
>
> Alterar o período de retenção de dados (p. 84)

Adicionar vários registros comPutRecords

O`PutRecords`A operação envia vários registros ao Kinesis Data Streams em uma única solicitação. Ao usar`PutRecords`Os produtores podem alcançar uma taxa de transferência mais alta ao enviar dados para seu stream de dados do Kinesis. EACH`PutRecords`A solicitação pode oferecer suporte a até 500 registros. Cada registro na solicitação pode ter no máximo 1 MB, até um limite de 5 MB para toda a solicitação, incluindo chaves de partição. Tal como acontece com o single`PutRecord`operação descrita abaixo,`PutRecords`O usa números sequenciais e chaves de partição. No entanto, o parâmetro `PutRecord` de `SequenceNumberForOrdering` não é incluído em uma chamada a `PutRecords`. A operação `PutRecords` tenta processar todos os registros na ordem natural da solicitação.

Cada registro de dados tem um número sequencial exclusivo. O número sequência é atribuído pelo Kinesis Data Streams após a chamada`client.putRecords`Para adicionar os registros de dados ao stream. Os números sequenciais da mesma chave de partição geralmente aumentam com o tempo: quanto maior o período entre as solicitações `PutRecords`, maiores ficam os números sequenciais.

> Note
>
> Os números de sequência não podem ser usados como índices para conjuntos de dados dentro do mesmo stream. Para separar logicamente conjuntos de dados, use chaves de partição ou crie um stream separado para cada conjunto de dados.

Uma solicitação `PutRecords` pode incluir registros com diferentes chaves de partição. O escopo da solicitação é um stream; cada solicitação pode incluir qualquer combinação de chaves de partição e registros, dentro dos limites da solicitação. As solicitações feitas com diferentes chaves de partição a streams com muitos estilhaços diferentes costumam ser mais rápidas do que as solicitações com um pequeno número de chaves de partição para um pequeno número de estilhaços. O número de chaves de partição deve ser muito maior do que o número de estilhaços para reduzir a latência e maximizar a taxa de transferência.

PutRecordsExemplo

O código a seguir cria 100 registros de dados com chaves de partição sequenciais e os coloca em um stream denominado `DataStream`.

```
        AmazonKinesisClientBuilder clientBuilder = AmazonKinesisClientBuilder.standard();

        clientBuilder.setRegion(regionName);
        clientBuilder.setCredentials(credentialsProvider);
        clientBuilder.setClientConfiguration(config);

        AmazonKinesis kinesisClient = clientBuilder.build();

        PutRecordsRequest putRecordsRequest  = new PutRecordsRequest();
        putRecordsRequest.setStreamName(streamName);
        List <PutRecordsRequestEntry> putRecordsRequestEntryList  = new ArrayList<>();
        for (int i = 0; i < 100; i++) {
            PutRecordsRequestEntry putRecordsRequestEntry  = new PutRecordsRequestEntry();
            putRecordsRequestEntry.setData(ByteBuffer.wrap(String.valueOf(i).getBytes()));
            putRecordsRequestEntry.setPartitionKey(String.format("partitionKey-%d", i));
            putRecordsRequestEntryList.add(putRecordsRequestEntry);
        }

        putRecordsRequest.setRecords(putRecordsRequestEntryList);
        PutRecordsResult putRecordsResult  = kinesisClient.putRecords(putRecordsRequest);
        System.out.println("Put Result" + putRecordsResult);
```

A resposta a `PutRecords` inclui uma matriz de resposta `Records`. Cada registro na matriz de resposta se correlaciona diretamente com um registro na matriz de solicitação por ordenação natural, do início ao fim da solicitação e da resposta. A matriz de resposta de `Records` sempre inclui o mesmo número de registros da matriz de solicitação.

Tratamento de falhas ao usarPutRecords

Por padrão, a falha de registros individuais em uma solicitação não interrompe o processamento de registros subsequentes em uma solicitação `PutRecords`. Isso significa que uma matriz de resposta `Records` inclui os registros com processamento bem-sucedido e malsucedido. É preciso detectar os registros com processamento malsucedido e incluí-los em uma chamada subsequente.

Os registros bem-sucedidos incluem os valores `SequenceNumber` e `ShardID`, e os registros malsucedidos incluem os valores `ErrorCode` e `ErrorMessage`. O parâmetro `ErrorCode` reflete o tipo de erro e pode ter um dos seguintes valores: `ProvisionedThroughputExceededException` ou `InternalFailure`. `ErrorMessage` fornece informações mais detalhadas sobre a exceção `ProvisionedThroughputExceededException`, incluindo o ID da conta, o nome do streaming e o ID do estilhaço do registro que foi limitado. O exemplo abaixo tem três registros em uma solicitação `PutRecords`. O segundo registro falha e isso é refletido na resposta.

Example PutRecordsSintaxe da solicitação

```
{
    "Records": [
        {
```

```
     "Data": "XzxkYXRhPl8w",
     "PartitionKey": "partitionKey1"
        },
        {
     "Data": "AbceddeRFfg12asd",
     "PartitionKey": "partitionKey1"
        },
        {
     "Data": "KFpcd98*7nd1",
     "PartitionKey": "partitionKey3"
        }
    ],
    "StreamName": "myStream"
}
```

Example PutRecordsSintaxe da resposta

```
{
    "FailedRecordCount”: 1,
    "Records": [
        {
     "SequenceNumber": "21269319989900637946712965403778482371",
     "ShardId": "shardId-000000000001"

        },
        {
     “ErrorCode":”ProvisionedThroughputExceededException”,
     “ErrorMessage": "Rate exceeded for shard shardId-000000000001 in stream
 exampleStreamName under account 111111111111."

        },
        {
     "SequenceNumber": "21269319989999637946712965403778482985",
     "ShardId": "shardId-000000000002"
        }
    ]
}
```

Os registros com processamento malsucedido podem ser incluídos nas solicitações `PutRecords` subsequentes. Primeiro, verifique o parâmetro `FailedRecordCount` no `putRecordsResult` para confirmar se há registros com falha na solicitação. Assim sendo, cada `putRecordsEntry` com um `ErrorCode` que não seja `null` deve ser adicionado a uma solicitação subsequente. Para obter um exemplo desse tipo de handler, consulte o seguinte código.

Example PutRecordsmanipulador de falhas

```
PutRecordsRequest putRecordsRequest = new PutRecordsRequest();
putRecordsRequest.setStreamName(myStreamName);
List<PutRecordsRequestEntry> putRecordsRequestEntryList = new ArrayList<>();
for (int j = 0; j < 100; j++) {
    PutRecordsRequestEntry putRecordsRequestEntry = new PutRecordsRequestEntry();
    putRecordsRequestEntry.setData(ByteBuffer.wrap(String.valueOf(j).getBytes()));
    putRecordsRequestEntry.setPartitionKey(String.format("partitionKey-%d", j));
    putRecordsRequestEntryList.add(putRecordsRequestEntry);
}

putRecordsRequest.setRecords(putRecordsRequestEntryList);
PutRecordsResult putRecordsResult = amazonKinesisClient.putRecords(putRecordsRequest);

while (putRecordsResult.getFailedRecordCount() > 0) {
    final List<PutRecordsRequestEntry> failedRecordsList = new ArrayList<>();
    final List<PutRecordsResultEntry> putRecordsResultEntryList =
 putRecordsResult.getRecords();
```

```
    for (int i = 0; i < putRecordsResultEntryList.size(); i++) {
        final PutRecordsRequestEntry putRecordRequestEntry =
 putRecordsRequestEntryList.get(i);
        final PutRecordsResultEntry putRecordsResultEntry =
 putRecordsResultEntryList.get(i);
        if (putRecordsResultEntry.getErrorCode() != null) {
            failedRecordsList.add(putRecordRequestEntry);
        }
    }
    putRecordsRequestEntryList = failedRecordsList;
    putRecordsRequest.setRecords(putRecordsRequestEntryList);
    putRecordsResult = amazonKinesisClient.putRecords(putRecordsRequest);
}
```

Adicionar um único registro comPutRecord

Cada chamada para `PutRecord` opera em um único registro. Prefira a operação `PutRecords` descrita em Adicionar vários registros comPutRecords (p. 101), a menos que seu aplicativo precise especificamente enviar sempre registos únicos por solicitação ou algum outro motivo para o não uso de `PutRecords`.

Cada registro de dados tem um número sequencial exclusivo. O número sequência é atribuído pelo Kinesis Data Streams após a chamada`client.putRecord`Para adicionar o registro de dados ao stream. Os números sequenciais da mesma chave de partição geralmente aumentam com o tempo: quanto maior o período entre as solicitações `PutRecord`, maiores ficam os números sequenciais.

Quando ocorrem colocações em rápida sucessão, não há garantia de que os números sequenciais retornados aumentem, porque as operações put aparentam ser essencialmente simultâneas ao Kinesis Data Streams. Para garantir estritamente o aumento de números sequenciais para a mesma chave de partição, use o parâmetro `SequenceNumberForOrdering`, como mostrado no código de exemplo em PutRecordExemplo (p. 104).

Se você usa ou não`SequenceNumberForOrdering`, registra que o Kinesis Data Streams recebe por meio de um`GetRecords`chamadas são estritamente ordenadas por número de sequência.

> Note
>
> Os números de sequência não podem ser usados como índices para conjuntos de dados dentro do mesmo stream. Para separar logicamente conjuntos de dados, use chaves de partição ou crie um stream separado para cada conjunto de dados.

Uma chave de partição é usada para agrupar os dados dentro de um stream. Um registro de dados é atribuído a um estilhaço dentro do stream com base em sua chave de partição. Especificamente, o Kinesis Data Streams usa a chave de partição como entrada para uma função de hash que mapeia a chave de partição (e dados associados) para um determinado estilhaço.

Como resultado desse mecanismo de hashing, todos os registros de dados com a mesma chave de partição são mapeados para o mesmo estilhaço no stream. No entanto, se o número de chaves de partição ultrapassar o número de estilhaços, alguns estilhaços conterão necessariamente registros com chaves de partição diferentes. Do ponto de vista do design, para garantir que todos os seus estilhaços sejam bem utilizados, o número de estilhaços (especificado pelo método `setShardCount` de `CreateStreamRequest`) deve ser substancialmente menor que o número de chaves de partição exclusivas, e o volume de dados que flui para uma única chave de partição deve ser substancialmente menor que a capacidade do estilhaço.

PutRecordExemplo

O código a seguir cria dez registros de dados, distribuídos entre duas chaves de partição, e os coloca em um stream denominado `myStreamName`.

```
for (int j = 0; j < 10; j++)
```

```
{
  PutRecordRequest putRecordRequest = new PutRecordRequest();
  putRecordRequest.setStreamName( myStreamName );
  putRecordRequest.setData(ByteBuffer.wrap( String.format( "testData-%d",
 j ).getBytes() ));
  putRecordRequest.setPartitionKey( String.format( "partitionKey-%d", j/5 ));
  putRecordRequest.setSequenceNumberForOrdering( sequenceNumberOfPreviousRecord );
  PutRecordResult putRecordResult = client.putRecord( putRecordRequest );
  sequenceNumberOfPreviousRecord = putRecordResult.getSequenceNumber();
}
```

O código de exemplo anterior usa `setSequenceNumberForOrdering` para garantir estritamente o aumento da ordenação dentro de cada chave de partição. Para usar esse parâmetro de forma eficaz, defina o `SequenceNumberForOrdering` do registro atual (registro n) como o número de sequência do registro anterior (registro n-1). Para obter o número sequencial de um registro que foi adicionado ao stream, chame `getSequenceNumber` para o resultado de `putRecord`.

O parâmetro `SequenceNumberForOrdering` garante estritamente o aumento de números de sequência para a mesma chave de partição. `SequenceNumberForOrdering` não fornece a ordenação de registros em várias chaves de partição.

Interagir com dados usando oAWSRegistro de esquemas

Você pode integrar seus fluxos de dados do Kinesis com oAWSRegistro de esquema de Glue. OAWSGlue Registro de esquemas do permite detectar, controlar e evoluir centralmente esquemas, garantindo que dados produzidos sejam continuamente validados por um esquema registrado. O esquema define a estrutura e o formato de um registro de dados. Um esquema é uma especificação versionada para publicação, consumo ou armazenamento de dados confiáveis. OAWSO Glue Schema Registry permite melhorarend-to-endqualidade de dados e governança de dados em seus aplicativos de streaming. Para obter mais informações, consulteAWSRegistro de esquemas. Uma das maneiras de configurar essa integração é através do`PutRecords`e`PutRecord`As APIs do Kinesis Data Streams disponíveis noAWSSDK do Java.

Para obter instruções detalhadas sobre como configurar a integração do Kinesis Data Streams com oPutRecordsePutRecordConsulte as APIs do Kinesis Data Streams, consulte a seção “Interagir com dados usando as APIs do Kinesis Data Streams” noCaso de uso: Integrar o Amazon Kinesis Data Streams com oAWSRegistro de esquemas.

Escrever no Amazon Kinesis Data Streams usando o Kinesis Agent

O Kinesis Agent é um aplicativo de software Java independente que oferece uma maneira fácil de coletar e enviar dados ao Kinesis Data Streams. O agente monitora continuamente um conjunto de arquivos e envia novos dados ao stream. Ele manipula o rodízio de arquivos, os pontos de verificação e as novas tentativas após falhas. Seus dados são entregues de maneira confiável, imediata e simples. Ele também emite AmazonCloudWatchMétricas para ajudar você a monitorar e a solução de problemas no processo de streaming.

Por padrão, os registros são analisados em cada arquivo com base no caractere de nova linha (`'\n'`). No entanto, o agente também pode ser configurado para analisar registros de várias linhas (consulte Configurações do agente (p. 107)).

Você pode instalar o agente em ambientes de servidor baseados no Linux, como servidores web, servidores de log e servidores de banco de dados. Após instalar o agente, configure-o especificando os

arquivos a serem monitorados e o stream dos dados. Depois que o agente é configurado, ele coleta dados dos arquivos de forma durável e os envia confiavelmente ao stream.

Tópicos

Pré-requisitos

- O sistema operacional deve ser o Amazon Linux AMI com versão 2015.09 ou posterior ou o Red Hat Enterprise Linux versão 7 ou posterior.
- Se você estiver usando o Amazon EC2 para executar o agente, execute a instância do EC2.
- Gerencie seuAWSCredenciais usando um dos seguintes métodos:
  - Especifique uma função do IAM ao executar a instância do EC2.
  - Especifique oAWSCredenciais ao configurar o agente (consulteawsAccessKeyId (p.)eawsSecretAccessKey (Chave) (p.)).
  - Edite`/etc/sysconfig/aws-kinesis-agent`Para especificar sua região eAWSChaves de acesso.
  - Se a instância do EC2 estiver em outraAWSConta, crie uma função do IAM para fornecer acesso ao serviço Kinesis Data Streams e especifique essa função ao configurar o agente (consulteassumeRoleARN (p.)eassumeRoleExternalId (p.)). Use um dos métodos anteriores para especificar oAWSCredenciais de um usuário na outra conta que tem permissão para assumir essa função.
- A função do IAM ouAWSAs credenciais especificadas devem ter permissão para executar o Kinesis Data StreamsPutRecordsPara que o agente envie dados ao seu stream. Se você habilitarCloudWatchMonitoramento do para o agente, permissão para executar oCloudWatch PutMetricDadosoperação também é necessária. Para obter mais informações, consulteControlar o acesso a recursos do Amazon Kinesis Data Streams usando o IAM (p. 228),Monitorar a Health do agente Kinesis Data Streams com o Amazon CloudWatch (p. 202), eCloudWatchControle de acesso.

Download e instalação do agente

Primeiro, conecte-se à instância. Para obter mais informações, consulte Conectar à sua instância no Manual do usuário do Amazon EC2 para instâncias do Linux. Se você tiver problemas para se conectar, consulteResolução de problemas para se conectar à sua instâncianoGuia do usuário do Amazon EC2 para instâncias do Linux.

Para configurar o agente usando o Amazon Linux AMI

Use o comando a seguir para fazer download do agente e instalá-lo:

```
sudo yum install -y aws-kinesis-agent
```

Para configurar o agente usando o Red Hat Enterprise Linux

Use o comando a seguir para fazer download do agente e instalá-lo:

```
sudo yum install -y https://s3.amazonaws.com/streaming-data-agent/aws-kinesis-agent-
latest.amzn1.noarch.rpm
```

Para configurar o agente usandoGitHub

1. Baixar o agente noawlabes/amazon-kinesis-agent.
2. Instale o agente navegando até o diretório de download e executando o comando a seguir:

```
sudo ./setup --install
```

Configuração e inicialização do agente

Para configurar e iniciar o agente

1. Abra e edite o arquivo de configuração (como superusuário, se você estiver usando permissões padrão de acesso a arquivos): `/etc/aws-kinesis/agent.json`

   Nesse arquivo de configuração, especifique os arquivos (`"filePattern"`) nos quais o agente coleta dados e o nome do stream (`"kinesisStream"`) ao qual o agente envia dados. Observe que o nome do arquivo é um padrão, e o agente reconhece os rodízios de arquivos. Você só pode fazer o rodízio de arquivos ou criar novos arquivos uma vez por segundo, no máximo. O agente usa o carimbo de data e hora de criação de arquivo para determinar quais arquivos serão rastreados e colocados no final do stream; a criação de novos arquivos ou o rodízio de arquivos em uma frequência superior a uma vez por segundo não permite que o agente faça a distinção entre eles corretamente.

```
{
   "flows": [
        {
            "filePattern": "/tmp/app.log*",
            "kinesisStream": "yourkinesisstream"
        }
   ]
}
```

2. Inicie o agente manualmente:

```
sudo service aws-kinesis-agent start
```

3. (Opcional) Configure o agente para ser iniciado durante a inicialização do sistema:

```
sudo chkconfig aws-kinesis-agent on
```

Agora o agente está sendo executado como um serviço do sistema em segundo plano. Ele monitora continuamente os arquivos especificados e envia dados ao stream especificado. A atividade do agent é registrada em `/var/log/aws-kinesis-agent/aws-kinesis-agent.log`.

Configurações do agente

O agente oferece suporte a duas configurações obrigatórias, `filePattern` e `kinesisStream`, além das configurações opcionais de recursos adicionais. É possível especificar configurações obrigatórias e opcionais em `/etc/aws-kinesis/agent.json`.

Sempre que você alterar o arquivo de configuração, deverá interromper e iniciar o agente, usando os seguintes comandos:

```
sudo service aws-kinesis-agent stop
sudo service aws-kinesis-agent start
```

Se desejar, você pode usar o seguinte comando:

```
sudo service aws-kinesis-agent restart
```

Estas são as configurações gerais.

Definição da configuração	Descrição
`assumeRoleARN`	O ARN da função a ser assumida pelo usuário. Para obter mais informações, consulteDelegar acesso entreAWSContas usando funções do IAMnoManual do usuário do IAM.
`assumeRoleExternalId`	Um identificador opcional que determina quem pode assumir a função. Para obter mais informações, consulteComo usar um ID externonoManual do usuário do IAM.
`awsAccessKeyId`	AWSO ID de chave de acesso da que substitui as credenciais padrão. Essa configuração tem precedência sobre todos os outros provedores de credenciais.
`awsSecretAccessKey`	AWSA chave secreta que substitui as credenciais padrão. Essa configuração tem precedência sobre todos os outros provedores de credenciais.
`cloudwatch.emitMetrics`	Permite que o agente emita métricas para o CloudWatch se definidas (true). Padrão: true
`cloudwatch.endpoint`	O endpoint regional do CloudWatch. Padrão: `monitoring.us-east-1.amazonaws.com`
`kinesis.endpoint`	O endpoint regional para o Kinesis Data Streams. Padrão: `kinesis.us-east-1.amazonaws.com`

Estas são as configurações de fluxo.

Definição da configuração	Descrição
`dataProcessingOptions`	A lista das opções de processamento aplicadas a cada registro analisado antes que ele seja enviado ao stream. As opções de processamento são executadas na ordem especificada. Para obter mais informações, consulte Uso do agente para pré-processar dados (p. 110).
`kinesisStream`	[Obrigatório] O nome do stream.
`filePattern`	[Obrigatório] Um glob para os arquivos que precisam ser monitorados pelo agente. Qualquer arquivo que corresponda a esse padrão é selecionado pelo agente automaticamente e monitorado. Para todos os arquivos correspondentes a esse padrão, deve ser concedida uma permissão de leitura a `aws-kinesis-agent-user`. Para o diretório que contém os arquivos,

Definição da configuração	Descrição
	devem ser concedidas permissões de leitura e execução a `aws-kinesis-agent-user`.
`initialPosition`	A posição em que o arquivo começou a ser analisado. Os valores válidos são `START_OF_FILE` e `END_OF_FILE`. Padrão: `END_OF_FILE`
`maxBufferAgeMillis`	O tempo máximo, em milissegundos, durante o qual o agente armazena os dados em buffer antes de enviá-los ao stream. Intervalo de valores: 1.000 a 900.000 (1 segundo a 15 minutos) Padrão: 60.000 (1 minuto)
`maxBufferSizeBytes`	O tamanho máximo, em bytes, durante o qual o agente armazena os dados em buffer antes de enviá-los ao stream. Intervalo de valores: 1 a 4.194.304 (4 MB) Padrão: 4.194.304 (4 MB)
`maxBufferSizeRecords`	O número máximo de registros para os quais o agente armazena os dados em buffer antes de enviá-los ao stream. Intervalo de valores: 1 a 500 Padrão: 500
`minTimeBetweenFilePollIntervals`	O intervalo de tempo, em milissegundos, em que o agente consulta e analisa os arquivos monitorados em busca de novos dados. Intervalo de valores: 1 ou mais Padrão: 100
`multiLineStartPattern`	O padrão de identificação do início de um registro. Um registro é composto por uma linha que corresponde ao padrão e pelas linhas subsequentes que não correspondem ao padrão. Os valores válidos são expressões regulares. Por padrão, cada nova linha nos arquivos de log é analisada como um único registro.
`partitionKeyOption`	O método para gerar a chave de partição. Os valores válidos são `RANDOM` (inteiro gerado aleatoriamente) e `DETERMINISTIC` (um valor de hash calculado a partir dos dados). Padrão: `RANDOM`
`skipHeaderLines`	O número de linhas em que o agente ignorará a análise no início dos arquivos monitorados. Intervalo de valores: 0 ou mais Padrão: 0 (zero)

Definição da configuração	Descrição
`truncatedRecordTerminator`	A string que o agente utiliza para truncar um registro analisado quando o tamanho do registro excede o limite de tamanho de registro do Kinesis Data Streams. (1,000 KB) Padrão: `'\n'` (nova linha)

Monitoramento de vários diretórios de arquivos e gravação em vários streams

Ao especificar vários fluxos de configurações, você pode configurar o agente para monitorar vários diretórios de arquivos e enviar dados a vários streams. No exemplo de configuração a seguir, o agente monitora dois diretórios de arquivos e envia dados a um stream do Kinesis e a um stream de entrega do Kinesis Data Firehose, respectivamente. Observe que você pode especificar endpoints diferentes para o Kinesis Data Streams e o Kinesis Data Firehose para que o stream do Kinesis e o stream de entrega do Kinesis Data Firehose não precisem estar na mesma região.

```
{
    "cloudwatch.emitMetrics": true,
    "kinesis.endpoint": "https://your/kinesis/endpoint",
    "firehose.endpoint": "https://your/firehose/endpoint",
    "flows": [
        {
            "filePattern": "/tmp/app1.log*",
            "kinesisStream": "yourkinesisstream"
        },
        {
            "filePattern": "/tmp/app2.log*",
            "deliveryStream": "yourfirehosedeliverystream"
        }
    ]
}
```

Para obter informações mais detalhadas sobre como usar o agente com o Kinesis Data Firehose, consulteEscrevendo no Amazon Kinesis Data Firehose com o Kinesis Agent.

Uso do agente para pré-processar dados

O agente pode pré-processar os registros analisados a partir dos arquivos monitorados antes de enviá-los ao stream. Você pode habilitar esse recurso adicionando a configuração `dataProcessingOptions` ao fluxo de arquivos. Um ou mais opções de processamento podem ser adicionadas e serão executadas na ordem especificada.

O agente oferece suporte às seguintes opções de processamento. Como o agente é de código aberto, você pode desenvolver e estender ainda mais suas opções de processamento. Você pode baixar o agente noAgente Kinesis.

Opções de processamento

`SINGLELINE`

Converte um registro de várias linhas em um registro de única linha removendo caracteres de nova linha, e espaços à esquerda e à direita.

```
{
    "optionName": "SINGLELINE"
}
```

`CSVTOJSON`

Converte um registro com formato separado por delimitador em um registro com formato JSON.

```
{
    "optionName": "CSVTOJSON",
    "customFieldNames": [ "field1", "field2", ... ],
    "delimiter": "yourdelimiter"
}
```

`customFieldNames`

[Obrigatório] Os nomes de campo usados como chaves em cada par de valores de chave JSON. Por exemplo, se você especificar `["f1", "f2"]`, o registro "v1, v2" será convertido em `{"f1":"v1","f2":"v2"}`.

`delimiter`

A string usada como delimitador no registro. O padrão é uma vírgula (,).

`LOGTOJSON`

Converte um registro com formato de log em um registro com formato JSON. Os formatos de log compatíveis são Apache Common Log, Apache Combined Log, Apache Error Log e RFC3164 Syslog.

```
{
    "optionName": "LOGTOJSON",
    "logFormat": "logformat",
    "matchPattern": "yourregexpattern",
    "customFieldNames": [ "field1", "field2", … ]
}
```

`logFormat`

[Obrigatório] O formato da entrada de log. Os valores possíveis são:

- `COMMONAPACHELOG`— O formato Apache Common Log. Cada entrada de log tem o seguinte padrão: `"%{host} %{ident} %{authuser} [%{datetime}] \"%{request}\" %{response} %{bytes}"`.
- `COMBINEDAPACHELOG`— O formato Apache Combined Log. Cada entrada de log tem o seguinte padrão: `"%{host} %{ident} %{authuser} [%{datetime}] \"%{request}\" %{response} %{bytes} %{referrer} %{agent}"`.
- `APACHEERRORLOG`— O formato Apache Error Log. Cada entrada de log tem o seguinte padrão: `"[%{timestamp}] [%{module}:%{severity}] [pid %{processid}:tid %{threadid}] [client: %{client}] %{message}"`.
- `SYSLOG`— O formato RFC3164 Syslog. Cada entrada de log tem o seguinte padrão: `"%{timestamp} %{hostname} %{program}[%{processid}]: %{message}"`.

`matchPattern`

O padrão da expressão regular usada para extrair valores de entradas de log. Essa configuração é usada se a entrada de log não estiver em um dos formatos de log predefinidos. Se essa configuração for usado, você também terá que especificar `customFieldNames`.

`customFieldNames`

Os nomes de campo personalizados usados como chaves em cada par de valores de chave JSON. Você pode usar essa configuração para definir nomes de campo para valores extraídos de `matchPattern` ou substituir os nomes de campo padrão de formatos de log predefinidos.

Example : Configuração LOGTOJSON

Aqui está um exemplo de uma configuração `LOGTOJSON` para uma entrada Apache Common Log convertida em formato JSON:

```
{
    "optionName": "LOGTOJSON",
    "logFormat": "COMMONAPACHELOG"
}
```

Antes da conversão:

```
64.242.88.10 - - [07/Mar/2004:16:10:02 -0800] "GET /mailman/listinfo/hsdivision HTTP/1.1"
 200 6291
```

Depois da conversão:

```
{"host":"64.242.88.10","ident":null,"authuser":null,"datetime":"07/
Mar/2004:16:10:02 -0800","request":"GET /mailman/listinfo/hsdivision
 HTTP/1.1","response":"200","bytes":"6291"}
```

Example : Configuração LOGTOJSON com campos personalizados

Aqui está outro exemplo de configuração `LOGTOJSON`:

```
{
    "optionName": "LOGTOJSON",
    "logFormat": "COMMONAPACHELOG",
    "customFieldNames": ["f1", "f2", "f3", "f4", "f5", "f6", "f7"]
}
```

Com essa configuração, a mesma entrada Apache Common Log do exemplo anterior é convertida em formato JSON, da seguinte forma:

```
{"f1":"64.242.88.10","f2":null,"f3":null,"f4":"07/Mar/2004:16:10:02 -0800","f5":"GET /
mailman/listinfo/hsdivision HTTP/1.1","f6":"200","f7":"6291"}
```

Example : Conversão da entrada Apache Common Log

A configuração de fluxo a seguir converte uma entrada Apache Common Log em um registro de linha única no formato JSON:

```
{
    "flows": [
        {
            "filePattern": "/tmp/app.log*",
            "kinesisStream": "my-stream",
            "dataProcessingOptions": [
                {
                    "optionName": "LOGTOJSON",
                    "logFormat": "COMMONAPACHELOG"
                }
            ]
        }
    ]
}
```

Example : Conversão de registros de várias linhas

A configuração de fluxo a seguir analisa registros de várias linha cuja primeira linha começa com "`[SEQUENCE=`". Cada registro é convertido primeiro em um registro de única linha. Em seguida, os valores são extraídos do registro com base em um delimitador por tabulações. Os valores extraídos são mapeados para os valores `customFieldNames` especificados, a fim de formar um registro de linha única no formato JSON.

```
{
    "flows": [
        {
            "filePattern": "/tmp/app.log*",
            "kinesisStream": "my-stream",
            "multiLineStartPattern": "\\[SEQUENCE=",
            "dataProcessingOptions": [
                {
                    "optionName": "SINGLELINE"
                },
                {
                    "optionName": "CSVTOJSON",
                    "customFieldNames": [ "field1", "field2", "field3" ],
                    "delimiter": "\\t"
                }
            ]
        }
    ]
}
```

Example : Configuração LOGTOJSON com padrão de correspondência

Aqui está um exemplo de configuração `LOGTOJSON` referente a uma entrada Apache Common Log convertida em formato JSON, com o último campo (bytes) omitido:

```
{
    "optionName": "LOGTOJSON",
    "logFormat": "COMMONAPACHELOG",
    "matchPattern": "^([\\d.]+) (\\S+) (\\S+) \\[([\\w:/]+\\s[+\\-]\\d{4})\\] \"(.+?)\" (\
\d{3})",
    "customFieldNames": ["host", "ident", "authuser", "datetime", "request", "response"]
}
```

Antes da conversão:

```
123.45.67.89 - - [27/Oct/2000:09:27:09 -0400] "GET /java/javaResources.html HTTP/1.0" 200
```

Depois da conversão:

```
{"host":"123.45.67.89","ident":null,"authuser":null,"datetime":"27/Oct/2000:09:27:09
 -0400","request":"GET /java/javaResources.html HTTP/1.0","response":"200"}
```

Comandos da CLI do agente

Inicie automaticamente o agente durante a inicialização do sistema:

```
sudo chkconfig aws-kinesis-agent on
```

Verifique o status do agente:

```
sudo service aws-kinesis-agent status
```

Interrompa o agente:

```
sudo service aws-kinesis-agent stop
```

Leia o arquivo de log do agente a partir deste local:

```
/var/log/aws-kinesis-agent/aws-kinesis-agent.log
```

Desinstale o agente:

```
sudo yum remove aws-kinesis-agent
```

Solucionar problemas de produtores do Amazon Kinesis Data Streams

As seções a seguir oferecem soluções para alguns problemas comuns que você pode encontrar ao trabalhar com produtores do Amazon Kinesis Data Streams.

- Aplicativo produtor está gravando a uma taxa menor que a esperada (p. 114)
- Erro de permissão de chave mestra do KMS não autorizada (p. 115)
- Problemas comuns, perguntas e ideias de solução de problemas para produtores (p. 116)

Aplicativo produtor está gravando a uma taxa menor que a esperada

Os motivos mais comuns para a taxa de transferência de gravação ser mais lenta do que o esperado são os seguintes:

- Limites de serviço excedidos (p. 114)
- Otimização do produtor (p. 115)

Limites de serviço excedidos

Para descobrir se os limites de serviço estão sendo excedidos, verifique se o produtor está lançando exceções de taxa de transferência a partir do serviço e valide quais operações da API estão sendo aceleradas. Lembre-se de que há limites diferentes de acordo com a chamada, consulte Cotas e limites (p. 7). Por exemplo, além dos limites de nível de estilhaço para gravações e leituras que são mais comumente conhecidas, há limites de nível de stream a seguir:

- CreateStream
- DeleteStream
- ListStreams
- GetShardIterador
- MergeShards
- DescribeStream

- DescribeStreamSummary (Resumo)

As operações `CreateStream`, `DeleteStream`, `ListStreams`, `GetShardIterator` e `MergeShards` são limitadas a 5 chamadas por segundo. A operação `DescribeStream` é limitada a 10 chamadas por segundo. A operação `DescribeStreamSummary` é limitada a 20 chamadas por segundo.

Se essas chamadas não forem o problema, selecione uma chave de partição que permita distribuir operações put uniformemente em todos os estilhaços e não tenha uma determinada chave de partição que esteja colidindo com os limites de serviço quando as restantes não estão. Isso requer que você meça a taxa de transferência de pico e leve em conta o número de estilhaços no seu stream. Para obter mais informações sobre o gerenciamento de streams, consulte Criar e gerenciar streamings (p. 68).

> Tip
>
> Lembre-se de arredondar para o kilobyte mais próximo para cálculos de limitação de taxa de transferência ao usar a operação de um único registro PutRecord, enquanto a operação de vários registros PutRecords é arredondada na soma cumulativa dos registros em cada chamada. Por exemplo, uma solicitação `PutRecords` com 600 registros com tamanho de 1,1 KB não serão aceleradas.

Otimização do produtor

Antes de começar a otimizar o produtor, há algumas tarefas importantes a serem concluídas. Primeiro, identifique sua taxa de transferência de pico desejada em termos de tamanho do registro e registros por segundo. Em seguida, descarte a capacidade de stream conforme o fator de limitação (Limites de serviço excedidos (p. 114)). Se você excluiu a capacidade de stream, use as seguintes dicas de solução de problemas e diretrizes de otimização para os dois tipos comuns de produtores.

Produtor grande

Um grande produtor normalmente está em execução a partir de um servidor no local ou instância do Amazon EC2. Os clientes que precisam de uma taxa de transferência mais alta de um grande produtor normalmente se preocupam com a latência por registro. As estratégias para lidar com a latência incluem o seguinte: Se o cliente puder registros de micro-lote/buffer, use oBiblioteca de produtores Kinesis(que tem lógica de agregação avançada), a operação multi-registroPutRecords, ou agregar registros em um arquivo maior antes de usar a operação de registro únicoPutRecord. Se você não puder alocar em lote/buffer, use vários threads para gravar no serviço Kinesis Data Streams ao mesmo tempo. O AWS SDK for Java e outros SDKs incluem clientes assíncronos que podem fazer isso com muito pouco código.

Produtor pequeno

Um pequeno produtor geralmente é um aplicativo móvel, dispositivo IoT ou cliente web. Se for um aplicativo móvel, recomendamos usar o`PutRecords`operação ou o Kinesis Recorder noAWSSDKs móveis do. Para obter mais informações, consulteAWS Mobile SDK for AndroidGuia de conceitos básicos eAWS Mobile SDK for iOSGuia de conceitos básicos do. Aplicativos móveis devem lidar com conexões intermitentes inerentemente e precisam de algum tipo de alocação em lote, como `PutRecords`. Se você não for capaz de alocar em lote por algum motivo, consulte as informações sobre Grande produtor acima. Se o seu produtor é um navegador, a quantidade de dados que está sendo gerada geralmente é muito pequena. No entanto, você está colocando as operações put no caminho crítico do aplicativo, o que não recomendamos.

Erro de permissão de chave mestra do KMS não autorizada

Esse erro ocorre quando um aplicativo produtor grava em um stream criptografado sem permissões na chave mestra do KMS. Para atribuir permissões a um aplicativo para acessar uma chave do KMS, consulteUsar políticas de chaves noAWSKMSe: Como usar políticas do IAMAWSKMS.

Problemas comuns, perguntas e ideias de solução de problemas para produtores

Tópicos avançados para produtores do Kinesis Data Streams

Esta seção discute como otimizar seus produtores do Amazon Kinesis Data Streams.

Tópicos

Limitação de taxas e tentativas de KPL

Quando você adiciona registros de usuários do Kinesis Producer Library (KPL) usando o KPL`addUserRecord()`Operação, um registro recebe um carimbo de data e hora e um buffer com um prazo definido pelo`RecordMaxBufferedTime`Parâmetros de configuração. Essa combinação time stamp/ prazo define a prioridade do buffer. Os registros são descarregados do buffer com base nos seguintes critérios:

- Prioridade do buffer
- Configuração de agregação
- Configuração de coleta

Os parâmetros de configuração de coleta e agregação que afetam o comportamento do buffer são os seguintes:

- `AggregationMaxCount`
- `AggregationMaxSize`
- `CollectionMaxCount`
- `CollectionMaxSize`

Os registros liberados são enviados para o stream de dados do Kinesis como registros do Amazon Kinesis Data Streams usando uma chamada para a operação da API do Kinesis Data Streams`PutRecords`. A operação `PutRecords` envia solicitações ao stream que ocasionalmente apresenta falhas parciais ou totais. Os registros com falha são automaticamente adicionados de volta ao buffer KPL do. O novo prazo é definido com base no mínimo destes dois valores:

- Metade da configuração de `RecordMaxBufferedTime` atual
- O registrotime-to-livevalor

Essa estratégia permite que registros do usuário KPL repetidos sejam incluídos em chamadas à API do Kinesis Data Streams subsequentes, para melhorar a taxa de transferência e reduzir a complexidade e, ao mesmo tempo, aplicar os registros do Kinesis Data Streamstime-to-livevalue. Não há um algoritmo de recuo, tornando essa uma estratégia de tentativa relativamente agressiva. O spam devido ao excesso de tentativas é evitado pela limitação de taxas, discutida na próxima seção.

Limitação de taxas

O KPL inclui um recurso de limitação de taxas, que limita a taxa de transferência por estilhaço enviada de um único produtor. A limitação de taxas é implementada com o uso de um algoritmo de bucket de token com buckets separados para bytes e registros do Kinesis Data Streams. Cada gravação bem-sucedida em um stream de dados do Kinesis adiciona um token (ou vários) a cada bucket, até um determinado limite. Esse limite é configurável, mas por padrão é definido como 50% maior que o limite de estilhaço real, para permitir a saturação de estilhaços a partir de um único produtor.

Você pode reduzir esse limite para diminuir o spam devido ao excesso de tentativas. No entanto, a melhor prática é que cada produtor tente novamente para uma taxa de transferência máxima de maneira agressiva e lide com qualquer limitação resultante determinada como excessiva por meio da expansão da capacidade do stream e da implementação de uma estratégia de chave de partição apropriada.

Considerações ao usar a agregação KPL do

Embora o esquema de números de sequência dos registros do Amazon Kinesis Data Streams resultantes permaneça o mesmo, a agregação faz com que a indexação dos registros do usuário do Kinesis Producer Library (KPL) contidos em um registro do Kinesis Data Streams agregado comece em 0 (zero); no entanto, desde que você não confie em sequência Os números para identificar exclusivamente seus registros de usuários da KPL, seu código pode ignorar isso, já que a agregação (dos registros de usuários da KPL em um registro do Kinesis Data Streams) e a desagregação subsequente (de um registro do Kinesis Data Streams em seus registros de usuários da KPL) automaticamente cuidam disso para você. Isso se aplica se o consumidor está usando o KCL ou oAWSSDK. Para usar essa funcionalidade de agregação, você precisará retirar a parte do Java da KPL em sua compilação se o consumidor foi criado usando a API fornecida noAWSSDK.

Se você pretende usar números de sequência como identidades exclusivas para os registros de usuários da KPL, recomendamos usar o cumprimento do contrato da`public int hashCode()`e`public boolean equals(Object obj)`operações fornecidas em`Record`e`UserRecord`para habilitar a comparação de seus registros de usuário KPL. Além disso, se você deseja examinar o número subsequente do registro de usuários da KPL, pode convertê-lo em um`UserRecord`instância e recupere seu número de subsequência.

Para obter mais informações, consulte Desagregação de consumidor (p. 97).

Lendo dados do Amazon Kinesis Data Streams

UMAconsumidorÉ um aplicativo que processa todos os dados de um stream de dados do Kinesis. Quando um consumidor usa distribuição avançada, ele recebe sua própria alocação de taxa de transferência de leitura de 2 MB/s permitindo que vários consumidores leiam dados do mesmo streaming em paralelo, sem disputa com outros consumidores por taxa de transferência de leitura. Para usar o recurso de distribuição avançada de estilhaços, consulte Desenvolver consumidores personalizados com taxa de transferência dedicada (distribuição avançada) (p. 163).

Por padrão, os estilhaços em um streaming fornecem 2 MB/s de taxa de transferência de leitura por estilhaço. Essa taxa de transferência é compartilhada entre todos os consumidores que fazem a leitura a partir de um determinado estilhaço. Em outras palavras, o padrão de 2 MB/s de taxa de transferência por estilhaço é fixo, ainda que haja vários consumidores fazendo a leitura pelo estilhaço. Para usar essa taxa de transferência padrão de estilhaços, consulte Desenvolver consumidores personalizados com taxa de transferência compartilhada (p. 132).

A tabela a seguir compara a taxa de transferência padrão para a distribuição avançada. O atraso de propagação da mensagem é definido como o tempo, em milissegundos, que uma carga enviada usando as APIs de envio de carga (comoPutRecordePutRecords) para alcançar o aplicativo do consumidor por meio das APIs que consomem carga útil (comoGetRecordseSubscribeToEstilhaçamento).

Características	Consumidores não registrados sem distribuição avançada	Consumidores registrados com distribuição avançada
Taxa de transferência de leitura de estilhaço	Corrigida em um total de 2 MB/s por estilhaço. Se houver vários consumidores lendo a partir do mesmo estilhaço, todos eles compartilham essa taxa de transferência. A soma das taxas de transferência que eles recebem do estilhaço não excede 2 MB/s.	Dimensionada de acordo com o registro dos consumidores para usar a distribuição avançada. Cada consumidor registrado para usar a distribuição avançada recebe sua própria taxa de transferência de leitura por estilhaço, de até 2 MB/s, independentemente de outros consumidores.
Atraso de propagação da mensagem	Uma média de cerca de 200 ms se você tiver um consumidor lendo no stream. Essa média chega até cerca de 1000 ms se você tiver cinco consumidores.	Normalmente, uma média de 70 ms se você tiver um ou cinco consumidores.
Custos	N/D	Há um custo de recuperação de dados e um custo de hora de estilhaço por consumidor. Para obter mais informações, consulte Definição de preço do Amazon Kinesis Streams.
Registro de modelo de entrega	Modelo Pull por HTTP usandoGetRecords.	O Kinesis Data Streams envia os registros a você por HTTP/2 usandoSubscribeToEstilhaço.

Tópicos

Desenvolver consumidores usando o AWS Lambda

Você pode usar uma função AWS Lambda para processar registros em um fluxo de dados. O AWS Lambda é um serviço de computação que permite executar código sem o provisionamento ou o gerenciamento de servidores. Ele executa seu código somente quando necessário e escala automaticamente, de algumas solicitações por dia a milhares por segundo. Você paga apenas pelo tempo de computação consumido. Não haverá cobranças quando seu código não estiver em execução. Com o AWS Lambda, você pode executar código para praticamente qualquer tipo de aplicativo ou serviço de back-end, tudo sem administração. Ele executa seu código em uma infraestrutura de computação de alta disponibilidade e executa toda a administração dos recursos computacionais, inclusive manutenção de servidor e sistema operacional, provisionamento de capacidade e escalabilidade automática, monitoramento do código e registro em log. Para obter mais informações, consulteO uso doAWS LambdaCom o Amazon Kinesis.

Para obter informações sobre a solução de problemas, consultePor que o gatilho do Kinesis Data Streams não consegue invocar minha função do Lambda?

Desenvolvendo consumidores usando o Amazon Kinesis Data Analytics

Você pode usar um aplicativo do Amazon Kinesis Data Analytics para processar e analisar dados em um stream do Kinesis usando SQL, Java ou Scala. Os aplicativos do Kinesis Data Analytics podem enriquecer os dados usando fontes de referência, agregar dados ao longo do tempo ou usar machine learning para encontrar anomalias de dados. Depois, você pode gravar os resultados da análise em outro fluxo do Kinesis, um stream de entrega do Kinesis Data Firehose ou uma função do Lambda. Para obter mais informações, consulte o .Guia do desenvolvedor do Kinesis Data Analytics para aplicativos SQLou oGuia do desenvolvedor do Kinesis Data Analytics para aplicativos Flink.

Desenvolvendo consumidores usando o Amazon Kinesis Data Firehose

Você pode usar um Kinesis Data Firehose para ler e processar registros de um stream do Kinesis. O Amazon Kinesis Data Firehose é um serviço totalmente gerenciado para fornecimento de streaming de dados em tempo real a destinos como o Amazon S3, o Amazon Redshift e o AmazonOpenSearchServiço

e Splunk. O Kinesis Data Firehose também oferece suporte a qualquer endpoint HTTP personalizado ou endpoints HTTP de propriedade de provedores de serviços de terceiros compatíveis, incluindo Datadog, MongoDB e New Relic. Você também pode configurar o Kinesis Data Firehose para transformar seus registros de dados e para converter o formato do registro antes de entregar os dados para seu destino. Para obter mais informações, consulte Gravar no Kinesis Data Firehose usando o Kinesis Data Streams.

Usar a biblioteca de cliente Kinesis

Um dos métodos de desenvolvimento de aplicativos de consumidor personalizados que podem processar dados de fluxos de dados do KDS é usar a Biblioteca de Cliente Kinesis (KCL).

Tópicos

> **Note**
>
> Tanto para o KCL 1.x quanto para o KCL 2.x, é recomendável que você atualize para a versão mais recente do KCL 1.x ou KCL 2.x, dependendo do seu cenário de uso. Tanto o KCL 1.x quanto o KCL 2.x são atualizados regularmente com versões mais recentes que incluem os patches de dependência e segurança mais recentes, correções de bugs e novos recursos compatíveis com versões anteriores. Para obter mais informações, consultehttps://github.com/awslabs/amazon-kinesis-client/releases.

O que é a biblioteca de cliente Kinesis?

A KCL ajuda você a consumir e processar dados de um stream de dados do Kinesis cuidando de muitas das tarefas complexas associadas à computação distribuída. Isso inclui balanceamento de carga entre várias instâncias de aplicativos de consumidor, resposta a falhas de instância de aplicativo de consumidor, ponto de verificação de registros processados e reação ao reestilhaçamento. A KCL cuida de todas essas subtarefas para que você possa concentrar seus esforços em escrever sua lógica personalizada de processamento de registros.

O KCL é diferente das APIs do Kinesis Data Streams que estão disponíveis naAWSSDKs. As APIs do Kinesis Data Streams ajudam você a gerenciar muitos aspectos do Kinesis Data Streams, inclusive a criação de streams, reestilhaçamento e colocação e obtenção de registros. O KCL fornece uma camada de abstração em torno de todas essas subtarefas, especificamente para que você possa se concentrar na lógica de processamento de dados personalizada do aplicativo do consumidor. Para obter informações sobre a API do Kinesis Data Streams, consulte aReferência da API do Amazon Kinesis.

> **Important**
>
> O KCL é uma biblioteca Java. O Support para idiomas diferentes do Java é fornecido usando uma interface multilíngue chamadaMultiLangDaemon. Este daemon é baseado em Java e é executado em segundo plano quando você estiver usando uma linguagem KCL diferente de Java. Por exemplo, se você instalar o KCL para Python e escrever o aplicativo de consumidor inteiramente em Python, ainda precisará do Java instalado no sistema por causa doMultiLangDaemon. Além

disso,MultiLangDaemon tem algumas configurações padrão que você pode personalizar para o caso de uso. Por exemplo, oAWSregião à qual ele se conecta. Para obter mais informações sobre oMultiLangDaemon doGitHub, consulteKCLMultiLangProjeto daemon.

A KCL atua como um intermediário entre a lógica de processamento de registro e o Kinesis Data Streams. A KCL executa as tarefas a seguir:

- Conecta-se ao stream de dados
- Enumera os estilhaços no stream de dados
- Usa arrendamentos para coordenar associações de fragmentos com seus trabalhadores
- Cria uma instância de um processador de registro para cada estilhaço que gerencia
- Extrai registros de dados do stream de dados
- Envia os registros ao processador de registros correspondente
- Registros processados pelos pontos de verificação
- Equilibra associações de shard-worker (locações) quando a contagem de instâncias do trabalhador muda ou quando o fluxo de dados é reconfigurado (os fragmentos são divididos ou mesclados)

Versões disponíveis do KCL

Atualmente, você pode usar uma das versões com suporte a seguir do KCL para criar seus aplicativos de consumidor personalizados:

- KCL 1.x

  Para obter mais informações, consulteDesenvolver consumidores do KCL 1.x (p. 133)
- KCL 2.x

  Para obter mais informações, consulteDesenvolver consumidores do KCL 2.x (p. 147)

Você pode usar o KCL 1.x ou o KCL 2.x para criar aplicativos de consumo que usam taxa de transferência compartilhada. Para obter mais informações, consulte Desenvolver consumidores personalizados com taxa de transferência compartilhada usando a KCL (p. 133).

Para criar aplicativos de consumo que usam taxa de transferência dedicada (consumidores de fan-out aprimorados), você só pode usar o KCL 2.x. Para obter mais informações, consulte Desenvolver consumidores personalizados com taxa de transferência dedicada (distribuição avançada) (p. 163).

Para obter informações sobre as diferenças entre KCL 1.x e KCL 2.x e instruções sobre como migrar do KCL 1.x para o KCL 2.x, consulteMigrar consumidores do KCL 1.x para o KCL 2.x (p. 171).

Conceitos da KCL

- Aplicativo para consumidores da KCL— um aplicativo criado sob medida usando o KCL e projetado para ler e processar registros de streams de dados.
- Instância de aplicativo do consumidor- Os aplicativos do consumidor KCL geralmente são distribuídos, com uma ou mais instâncias de aplicativos em execução simultaneamente para coordenar falhas e balancear dinamicamente o processamento de registros de dados de dados.
- Operador— uma classe de alto nível que uma instância de aplicativo consumidor KCL usa para iniciar o processamento de dados.

  Important

  Cada instância de aplicativo do consumidor KCL tem um trabalhador.

O trabalhador inicializa e supervisiona várias tarefas, incluindo sincronização de informações de fragmentos e leasing, rastreamento de atribuições de fragmentos e processamento de dados dos fragmentos. Um trabalhador fornece à KCL as informações de configuração para o aplicativo consumidor, como o nome do fluxo de dados cujos dados registram esse aplicativo consumidor da KCL processará e oAWScredenciais necessárias para acessar esse fluxo de dados. O trabalhador também inicia essa instância específica do aplicativo do consumidor KCL para entregar registros de dados do fluxo de dados para os processadores de registro.

> **Important**
>
> No KCL 1.x, essa classe é chamadaOperador. Para obter mais informações, (estes são os repositórios Java KCL), consultehttps://github.com/awslabs/amazon-kinesis-client/Blob/v1.x/SRC/Main/Java/com/Amazonaws/Services/Kinesis/ClientLibrary/Lib/Worker/Worker.java.
> No KCL 2.x, essa classe é chamadaAgendadora. O propósito do agendador no KCL 2.x é idêntico ao propósito do trabalhador no KCL 1.x. Para obter mais informações sobre a classe do Scheduler no KCL 2.x, consultehttps://github.com/awslabs/amazon-kinesis-client/blob/master/amazon-kinesis-clientArquivo /src/main/java/software/amazon/kinesis/coordinator/Scheduler.java.

- Arrendamento— dados que definem a vinculação entre um trabalhador e um fragmento. Aplicativos de consumo KCL distribuídos usam locações para particionar o processamento de registros de dados em uma frota de trabalhadores. A qualquer momento, cada fragmento de registros de dados é vinculado a um determinado trabalhador por uma locação identificada peloleaseKeyVariável.

  Por padrão, um trabalhador pode manter um ou mais arrendamentos (sujeito ao valor domaxLeasesForOperadorVariável) ao mesmo tempo.

  > **Important**
  >
  > Todo trabalhador lutará por manter todos os arrendamentos disponíveis para todos os fragmentos disponíveis em um fluxo de dados. Mas apenas um trabalhador manterá com êxito cada locação a qualquer momento.

  Por exemplo, se você tiver uma instância de aplicativo do consumidor A com o trabalhador A que esteja processando um fluxo de dados com 4 fragmentos, o trabalhador A poderá reter locações para fragmentos 1, 2, 3 e 4 ao mesmo tempo. Mas se você tiver duas instâncias de aplicativos do consumidor: A e B com o trabalhador A e o trabalhador B, e essas instâncias estão processando um fluxo de dados com 4 fragmentos, o trabalhador A e o trabalhador B não podem manter o leasing para o fragmento 1 ao mesmo tempo. Um trabalhador mantém a locação em um fragmento específico até que ele esteja pronto para interromper o processamento dos registros de dados desse fragmento ou até que ele falhe. Quando um trabalhador deixa de manter a locação, outro trabalhador ocupa e mantém a locação.

  Para obter mais informações, (estes são os repositórios Java KCL), consultehttps://github.com/awslabs/amazon-kinesis-client/blob/v1.x/src/main/java/com/Amazonaws/serviços/kinesis/locações/impl/lease.javapara KCL 1.x ehttps://github.com/awslabs/amazon-kinesis-client/blob/master/amazon-kinesis-clientArquivo /src/main/java/software/amazon/kinesis/leases/Lease.javapara KCL 2.x.
- Tabela de arrendamento- uma tabela exclusiva do Amazon DynamoDB que é usada para acompanhar os fragmentos em um fluxo de dados do KDS que está sendo alugado e processado pelos trabalhadores do aplicativo consumidor KCL. A tabela de leasing deve permanecer sincronizada (dentro de um trabalhador e em todos os trabalhadores) com as informações mais recentes do fragmento do fluxo de dados enquanto o aplicativo consumidor KCL está em execução. Para obter mais informações, consulte Usando uma tabela de leasing para rastrear os fragmentos processados pelo aplicativo do consumidor KCL (p. 123).
- Processador de registros— a lógica que define como seu aplicativo consumidor KCL processa os dados que ele obtém dos fluxos de dados. Em tempo de execução, uma instância de aplicativo do consumidor KCL instancia um trabalhador e esse trabalhador instancia um processador de registro para cada fragmento para o qual ele detém uma locação.

Usando uma tabela de leasing para rastrear os fragmentos processados pelo aplicativo do consumidor KCL

Tópicos

O que é uma tabela de locação

Para cada aplicativo do Amazon Kinesis Data Streams, a KCL usa uma tabela de leasing exclusiva (armazenada em uma tabela do Amazon DynamoDB) para acompanhar os fragmentos em um fluxo de dados do KDS que estão sendo alugados e processados pelos trabalhadores do aplicativo consumidor KCL.

> **Important**
>
> A KCL usa o nome do aplicativo de consumidor para criar o nome da tabela de arrendamento que esse aplicativo de consumidor usa, portanto, cada nome de aplicativo de consumidor precisa ser exclusivo.

Você pode visualizar a tabela de leasing usando oConsole do Amazon DynamoDBenquanto o aplicativo consumidor estiver em execução.

Se a tabela de arrendamento do seu aplicativo de consumidor do KCL não existir quando o aplicativo for iniciado, um dos operadores criará a tabela de arrendamento para esse aplicativo.

> **Important**
>
> Sua conta é cobrada pelos custos associados à tabela do DynamoDB, além dos custos associados ao próprio Kinesis Data Streams.

Cada linha na tabela de arrendamento representa um estilhaço que está sendo processado pelos operadores do seu aplicativo de consumidor. Se seu aplicativo consumidor KCL processar apenas um fluxo de dados, então`leaseKey`que é a chave de hash da tabela de arrendamento é o ID do estilhaço. Se você forProcessando vários fluxos de dados com o mesmo aplicativo KCL 2.x para consumidor Java (p. 129), então a estrutura da leaseKey se parece com isso: `account-id:StreamName:streamCreationTimestamp:ShardId`. Por exemplo,`111111111:multiStreamTest-1:12345:shardId-000000000336`.

Além do ID do estilhaço, cada linha também inclui os seguintes dados:

- Ponto de verificação: Número de sequência do ponto de verificação mais recente do estilhaço. Esse valor é exclusivo entre todos os estilhaços do stream de dados.
- checkpointSubSequence: Ao usar o recurso de agregação da Kinesis Producer Library, esta é uma extensão paraponto de verificaçãoque rastreia registros de usuários individuais dentro do registro Kinesis.
- leaseCounter: Usado para versionamento de arrendamento para que os operadores possam detectar que o arrendamento foi feito por outro operador.
- leaseKey: Um identificador exclusivo para uma locação. Cada arrendamento é específico a um estilhaço no stream de dados e é mantido por um operador por vez.

- leaseOwner: O operador que está retendo esse arrendamento.
- ownerSwitchesSincePonto de verificação: Quantas vezes esse arrendamento trocou de operador desde a última vez em que um ponto de verificação foi gravado.
- parentShardId: Usado para garantir que o estilhaço pai seja totalmente processado antes do início do processamento nos estilhaços filhos. Isso garante que os registros sejam processados na mesma ordem em que foram colocados no stream.
- hashrange: Usado pelo`PeriodicShardSyncManager`para executar sincronizações periódicas para encontrar fragmentos ausentes na tabela de leasing e criar arrendamentos para eles, se necessário.

  Note

  Esses dados estão presentes na tabela de locação para cada fragmento começando com KCL 1.14 e KCL 2.3. Para obter mais informações sobre`PeriodicShardSyncManager`e sincronização periódica entre locações e fragmentos, consulteComo uma tabela de leasing é sincronizada com os fragmentos em um fluxo de dados do KDS (p. 124).
- estilhaços infantis: Usado pelo`LeaseCleanupManager`para revisar o status de processamento do fragmento filho e decidir se o fragmento pai pode ser excluído da tabela de leasing.

  Note

  Esses dados estão presentes na tabela de locação para cada fragmento começando com KCL 1.14 e KCL 2.3.
- ShardId: O ID do fragmento.

  Note

  Esses dados só estarão presentes na tabela de leasing se você estiverProcessando vários fluxos de dados com o mesmo aplicativo KCL 2.x para consumidor Java (p. 129). Isso só é suportado no KCL 2.x para Java, começando com o KCL 2.3 para Java e além.
- nome do streamO identificador do fluxo de dados no seguinte formato:`account-id:StreamName:streamCreationTimestamp`.

  Note

  Esses dados só estarão presentes na tabela de leasing se você estiverProcessando vários fluxos de dados com o mesmo aplicativo KCL 2.x para consumidor Java (p. 129). Isso só é suportado no KCL 2.x para Java, começando com o KCL 2.3 para Java e além.

Taxa de transferência

Se o aplicativo do Amazon Kinesis Data Streams recebe exceções de taxa de transferência provisionada, você deve aumentar a taxa de transferência provisionada para a tabela do DynamoDB. A KCL cria a tabela com uma taxa de transferência provisionada de 10 leituras por segundo e 10 gravações por segundo, mas isso pode não ser suficiente para o seu aplicativo. Por exemplo, se o aplicativo Amazon Kinesis Data Streams fizer pontos de verificação com frequência ou operar em um stream que é composto por vários estilhaços, você pode precisar de uma taxa de transferência maior.

Para obter informações sobre a taxa de transferência provisionada no DynamoDB, consulteModo de capacidade de leitura/gravaçãoeTrabalho com tabelas e dadosnoGuia do desenvolvedor do Amazon DynamoDB.

Como uma tabela de leasing é sincronizada com os fragmentos em um fluxo de dados do KDS

Trabalhadores em aplicativos de consumo da KCL usam locações para processar fragmentos de um determinado fluxo de dados. As informações sobre qual trabalhador está alugando qual fragmento a

qualquer momento é armazenado em uma tabela de locação. A tabela de leasing deve permanecer em sincronia com as informações mais recentes do fragmento do fluxo de dados enquanto o aplicativo consumidor KCL estiver em execução. O KCL sincroniza a tabela de leasing com as informações de fragmentos adquiridas do serviço Kinesis Data Streams durante a inicialização do aplicativo do consumidor (quando o aplicativo consumidor é inicializado ou reiniciado) e também sempre que um fragmento que está sendo processado chega ao fim (refragmentação). Em outras palavras, os trabalhadores ou um aplicativo consumidor KCL são sincronizados com o fluxo de dados que estão processando durante o bootstrap inicial do aplicativo do consumidor e sempre que o aplicativo consumidor encontrar um evento de reshard stream de dados.

Tópicos

Sincronização em KCL 1.0 - 1,13 e KCL 2.0 - 2.2

No KCL 1.0 - 1.13 e KCL 2.0 - 2.2, durante a inicialização do aplicativo do consumidor e também durante cada evento de reshard stream de dados, a KCL sincroniza a tabela de leasing com as informações de fragmentos adquiridas do serviço Kinesis Data Streams invocando o`ListShards`ou o`DescribeStream`APIs de descoberta. Em todas as versões do KCL listadas acima, cada trabalhador de um aplicativo consumidor KCL conclui as etapas a seguir para executar o processo de sincronização de locação/fragmento durante o bootstrapping do aplicativo consumidor e em cada evento de reshard stream:

- Obtém todos os fragmentos para dados do fluxo que está sendo processado
- Obtém todos os arrendamentos de fragmentos da tabela de locação
- Filtra cada fragmento aberto que não tem locação na tabela de locação
- Iera sobre todos os fragmentos abertos encontrados e para cada fragmento aberto sem pai aberto:
  - Atravessa a árvore de hierarquia pelo caminho de seus antepassados para determinar se o fragmento é descendente. Um fragmento é considerado descendente, se um estilhaço ancestral estiver sendo processado (entrada de leasing para estilhaço ancestral existe na tabela de leasing) ou se um estilhaço ancestral deve ser processado (por exemplo, se a posição inicial for`TRIM_HORIZON`ou`AT_TIMESTAMP`)
  - Se o fragmento aberto no contexto for descendente, a KCL verifica o fragmento com base na posição inicial e cria arrendamentos para seus pais, se necessário

Sincronização no KCL 2.x, começando com KCL 2.3 e Beyond

Começando com as versões mais recentes suportadas do KCL 2.x (KCL 2.3) e além, a biblioteca agora suporta as seguintes alterações no processo de sincronização. Essas alterações de sincronização de lease/shard reduzem significativamente o número de chamadas de API feitas pelos aplicativos do consumidor KCL para o serviço Kinesis Data Streams e otimizam o gerenciamento de leasing em seu aplicativo de consumidor KCL.

- Durante a inicialização do aplicativo, se a tabela de leasing estiver vazia, a KCL utilizará o`ListShard`Opção de filtragem da API (o`ShardFilter`parâmetro de solicitação opcional) para recuperar e criar arrendamentos somente para um instantâneo de fragmentos abertos no momento especificado pelo`ShardFilter`parâmetro . O`ShardFilter`parâmetro permite filtrar a resposta do`ListShards`API. A única propriedade necessária do`ShardFilter`O parâmetro é`Type`. A KCL usa o`Type`propriedade filter e os seguintes valores válidos para identificar e retornar um instantâneo de fragmentos abertos que podem exigir novos arrendamentos:
  - `AT_TRIM_HORIZON`- a resposta inclui todos os fragmentos que estavam abertos em`TRIM_HORIZON`.
  - `AT_LATEST`- a resposta inclui apenas os fragmentos atualmente abertos do fluxo de dados.

- `AT_TIMESTAMP`- a resposta inclui todos os fragmentos cujo carimbo de data/hora inicial é menor ou igual ao carimbo de data/hora fornecido e o carimbo de data/hora final é maior ou igual ao carimbo de data/hora fornecido ou ainda aberto.

`ShardFilter`é usado ao criar arrendamentos para uma tabela de leasing vazia para inicializar locações para um instantâneo de fragmentos especificados em`RetrievalConfig#initialPositionInStreamExtended`.

Para obter mais informações sobre o `ShardFilter`, consulte https://docs.aws.amazon.com/kinesis/latest/APIReference/API_ShardFilter.html.

- Em vez de todos os trabalhadores realizarem a sincronização de locação/fragmento para manter a tabela de locação atualizada com os fragmentos mais recentes no fluxo de dados, um único líder de trabalhador eleito executa a sincronização de locação/fragmento.
- O KCL 2.3 usa o`ChildShards`parâmetro de retorno do`GetRecords`O e a`SubscribeToShard`APIs para executar a sincronização de locação/fragmento que acontece em`SHARD_END`para fragmentos fechados, permitindo que um trabalhador da KCL crie apenas arrendamentos para os fragmentos filhos do fragmento que concluiu o processamento. Para aplicativos compartilhados em todos os consumidores, essa otimização da sincronização de locação/fragmento usa o`ChildShards`do`GetRecords`API. Para os aplicativos de consumo dedicados de throughput (fan-out aprimorado), essa otimização da sincronização de locação/fragmento usa o`ChildShards`do`SubscribeToShard`API. Para obter mais informações, consulteGetRecords,SubscribeToEstilhaços, eChildShard.
- Com as mudanças acima, o comportamento da KCL está se movendo do modelo de todos os trabalhadores aprendendo sobre todos os fragmentos existentes para o modelo de trabalhadores aprendendo apenas sobre os fragmentos infantis dos fragmentos que cada trabalhador possui. Portanto, além da sincronização que acontece durante os eventos de inicialização e de reenvio de aplicativos do consumidor, a KCL agora também executa varreduras periódicas adicionais de fragmento/locação para identificar quaisquer possíveis falhas na tabela de leasing (em outras palavras, para aprender sobre todos os novos fragmentos) para garantir a completa o intervalo de hash do fluxo de dados está sendo processado e cria arrendamentos para eles, se necessário.`PeriodicShardSyncManager`é o componente responsável pela execução de varreduras periódicas de locação/fragmento.

Para obter mais informações sobre`PeriodicShardSyncManager`no KCL 2.3, consultehttps://github.com/awslabs/amazon-kinesis-client/blob/master/amazon-kinesis-client/src/main/java/software/amazon/kinesis/locações/LeaseManagementConfig.java #L201 -L213.

No KCL 2.3, novas opções de configuração estão disponíveis para configuração`PeriodicShardSyncManager`em`LeaseManagementConfig`:

Name (Nome)	Valor padrão	Descrição
leasesRecoveryAuditorExecutionFrequencyMillis	120000 (2 minutos)	Frequência (em millis) do trabalho do auditor para verificar locações parciais na tabela de locação. Se o auditor detectar qualquer furo nos arrendamentos de um fluxo, ele acionaria a sincronização de fragmentos com base em`leasesRecoveryAuditorI`

Name (Nome)	Valor padrão	Descrição
leasesRecoveryAuditorInconsistencyConfidenceLimite	3	Limite de confiança para o trabalho periódico do auditor para determinar se os arrendamentos para um fluxo de dados na tabela de leasing são inconsistentes. Se o auditor encontrar o mesmo conjunto de inconsistências consecutivamente para um fluxo de dados muitas vezes, ele acionaria uma sincronização de fragmentos.

NovoCloudWatchmétricas também são emitidas agora para monitorar a saúde do`PeriodicShardSyncManager`. Para obter mais informações, consulte PeriodicShardSyncManager (p. 211).

- Incluindo uma otimização para`HierarchicalShardSyncer`para criar apenas arrendamentos para uma camada de fragmentos.

Sincronização no KCL 1.x, começando com o KCL 1.14 e além

Começando com as versões mais recentes suportadas do KCL 1.x (KCL 1.14) e além, a biblioteca agora suporta as seguintes alterações no processo de sincronização. Essas alterações de sincronização de lease/shard reduzem significativamente o número de chamadas de API feitas pelos aplicativos do consumidor KCL para o serviço Kinesis Data Streams e otimizam o gerenciamento de leasing em seu aplicativo de consumidor KCL.

- Durante a inicialização do aplicativo, se a tabela de leasing estiver vazia, a KCL utilizará o`ListShard`Opção de filtragem da API (o`ShardFilter`parâmetro de solicitação opcional) para recuperar e criar arrendamentos somente para um instantâneo de fragmentos abertos no momento especificado pelo`ShardFilter`parâmetro . O`ShardFilter`parâmetro permite filtrar a resposta do`ListShards`API. A única propriedade necessária do`ShardFilter`O parâmetro é`Type`. A KCL usa o`Type`propriedade filter e os seguintes valores válidos para identificar e retornar um instantâneo de fragmentos abertos que podem exigir novos arrendamentos:
  - `AT_TRIM_HORIZON`- a resposta inclui todos os fragmentos que estavam abertos em`TRIM_HORIZON`.
  - `AT_LATEST`- a resposta inclui apenas os fragmentos atualmente abertos do fluxo de dados.
  - `AT_TIMESTAMP`- a resposta inclui todos os fragmentos cujo carimbo de data/hora inicial é menor ou igual ao carimbo de data/hora fornecido e o carimbo de data/hora final é maior ou igual ao carimbo de data/hora fornecido ou ainda aberto.

  `ShardFilter`é usado ao criar arrendamentos para uma tabela de leasing vazia para inicializar locações para um instantâneo de fragmentos especificados em`KinesisClientLibConfiguration#initialPositionInStreamExtended`.

Para obter mais informações sobre o `ShardFilter`, consulte https://docs.aws.amazon.com/kinesis/latest/APIReference/API_ShardFilter.html.

- Em vez de todos os trabalhadores realizarem a sincronização de locação/fragmento para manter a tabela de locação atualizada com os fragmentos mais recentes no fluxo de dados, um único líder de trabalhador eleito executa a sincronização de locação/fragmento.
- O KCL 1.14 usa o`ChildShards`parâmetro de retorno do`GetRecords`O e a`SubscribeToShard`APIs para executar a sincronização de locação/fragmento que acontece em`SHARD_END`para fragmentos fechados, permitindo que um trabalhador da KCL crie apenas arrendamentos para os fragmentos filhos do fragmento que concluiu o processamento. Para obter mais informações, consulteGetRecordseChildShard.
- Com as mudanças acima, o comportamento da KCL está se movendo do modelo de todos os trabalhadores aprendendo sobre todos os fragmentos existentes para o modelo de trabalhadores aprendendo apenas sobre os fragmentos infantis dos fragmentos que cada trabalhador possui. Portanto, além da sincronização que acontece durante os eventos de inicialização e de reenvio de aplicativos do consumidor, a KCL agora também executa varreduras periódicas adicionais de fragmento/locação para identificar quaisquer possíveis falhas na tabela de leasing (em outras palavras, para aprender sobre todos os novos fragmentos) para garantir a completa o intervalo de hash do fluxo de dados está sendo processado e cria arrendamentos para eles, se necessário.`PeriodicShardSyncManager`é o componente responsável pela execução de varreduras periódicas de locação/fragmento.

  Quando`KinesisClientLibConfiguration#shardSyncStrategyType`é definido como`ShardSyncStrategyType.SHARD_END`,`PeriodicShardSync leasesRecoveryAuditorInconsistencyConfidenceThreshold`é usado para determinar o limite para o número de varreduras consecutivas contendo furos na tabela de leasing após o qual impor uma sincronização de fragmentos. Quando`KinesisClientLibConfiguration#shardSyncStrategyType`é definido como`ShardSyncStrategyType.PERIODIC`,`leasesRecoveryAuditorInconsistencyConfidenceThreshold` ignorada.

  Para obter mais informações sobre`PeriodicShardSyncManager`no KCL 1.14, consultehttps://github.com/awslabs/amazon-kinesis-client/blob/v1.x/src/main/java/com/amazonaws/services/kinesis/clientlibrary/lib/worker/KinesisClientLibConfiguration.java #L987 -L999.

  No KCL 1.14, nova opção de configuração está disponível para configuração`PeriodicShardSyncManager`em`LeaseManagementConfig`:

Name (Nome)	Valor padrão	Descrição
leasesRecoveryAuditorInconsistencyConfidenceLimite	3	Limite de confiança para o trabalho periódico do auditor para determinar se os arrendamentos para um fluxo de dados na tabela de leasing são inconsistentes. Se o auditor encontrar o mesmo conjunto de inconsistências consecutivamente para um fluxo de dados muitas vezes, ele

Name (Nome)	Valor padrão	Descrição
		acionaria uma sincronização de fragmentos.

NovoCloudWatchmétricas também são emitidas agora para monitorar a saúde do`PeriodicShardSyncManager`. Para obter mais informações, consulte PeriodicShardSyncManager (p. 211).

- O KCL 1.14 agora também oferece suporte à limpeza de leasing adiada. Os arrendamentos são excluídos de forma assíncrona por`LeaseCleanupManager`ao atingir`SHARD_END`, quando um fragmento expirou após o período de retenção do fluxo de dados ou foi fechado como resultado de uma operação de recompartilhamento.

  Novas opções de configuração estão disponíveis para configuração`LeaseCleanupManager`.

Name (Nome)	Valor padrão	Descrição
leaseCleanupIntervalMillis	1 minuto	Intervalo no qual executar o segmento de limpeza de leasing.
completedLeaseCleanupIntervalMillis	5 minutos	Intervalo no qual verificar se um contrato de locação foi concluído ou não.
garbageLeaseCleanupIntervalMillis	30 minutos	Intervalo no qual verificar se um leasing é lixo (ou seja, cortado após o período de retenção do fluxo de dados) ou não.

- Incluindo uma otimização para`KinesisShardSyncer`para criar apenas arrendamentos para uma camada de fragmentos.

Processando vários fluxos de dados com o mesmo aplicativo KCL 2.x para consumidor Java

Esta seção descreve as seguintes alterações no KCL 2.x para Java que permitem criar aplicativos de consumidor KCL que podem processar mais de um fluxo de dados ao mesmo tempo.

> **Important**
>
> O processamento multistream só é suportado no KCL 2.x para Java, começando com o KCL 2.3 para Java e além.
> O processamento multistream NÃO é suportado para nenhum outro idioma em que o KCL 2.x possa ser implementado.
> O processamento multistream NÃO é suportado em nenhuma versão do KCL 1.x.

- Interface do MultistreamTracker

  Para criar um aplicativo de consumidor que possa processar vários fluxos ao mesmo tempo, você deve implementar uma nova interface chamadaMultistreamTracker. Essa interface inclui o`streamConfigList`método que retorna a lista de fluxos de dados e suas configurações a serem processadas pelo aplicativo consumidor KCL. Observe que os fluxos de dados que estão sendo processados podem ser alterados durante o tempo de execução do aplicativo do consumidor.`streamConfigList`é chamado periodicamente pelo KCL para saber mais sobre as mudanças nos fluxos de dados a serem processados.

  O`streamConfigList`Preenche oStreamConfig.

```
package software.amazon.kinesis.common;

import lombok.Data;
import lombok.experimental.Accessors;

@Data
@Accessors(fluent = true)
public class StreamConfig {
    private final StreamIdentifier streamIdentifier;
    private final InitialPositionInStreamExtended initialPositionInStreamExtended;
    private String consumerArn;
}
```

  Observe que o`StreamIdentifier`e`InitialPositionInStreamExtended`são campos obrigatórios, enquanto`consumerArn`é opcional. É necessário fornecer o`consumerArn`somente se você estiver usando o KCL 2.x para implementar um aplicativo de consumidor de fan-out aprimorado.

  Para obter mais informações sobre`StreamIdentifier`, consultehttps://github.com/awslabs/amazon-kinesis-client/blob/0c5042dadf794fe988438436252a5a8fe70b6b0b/amazon-kinesis-client/src/main/java/software/amazon/kinesis/common/StreamIdentifier.java #L29. Você pode criar uma instância de multistream para o`StreamIdentifier`do identificador de fluxo serializado. O identificador de fluxo serializado deve ter o seguinte formato:`account-id:StreamName:streamCreationTimestamp`.

```
 * @param streamIdentifierSer
    * @return StreamIdentifier
    */
   public static StreamIdentifier multiStreamInstance(String streamIdentifierSer) {
       if (PATTERN.matcher(streamIdentifierSer).matches()) {
           final String[] split = streamIdentifierSer.split(DELIMITER);
           return new StreamIdentifier(split[0], split[1], Long.parseLong(split[2]));
       } else {
           throw new IllegalArgumentException("Unable to deserialize StreamIdentifier
from " + streamIdentifierSer);
       }
   }
```

  `MultistreamTracker`também inclui uma estratégia para excluir arrendamentos de fluxos antigos na tabela de leasing (`formerStreamsLeasesDeletionStrategy`). Observe que a estratégia NÃO PODE ser alterada durante o tempo de execução do aplicativo do consumidor. Para obter mais informações, consultehttps://github.com/awslabs/amazon-kinesis-client/blob/0c5042dadf794fe988438436252a5a8fe70b6b0b/amazon-kinesis-client/src/main/java/software/amazon/kinesis/processador/FormerStreamsLeasesDeletionArquivo Strategy.java

- ConfigsBuilderé uma classe em todo o aplicativo que você pode usar para especificar todas as configurações do KCL 2.x a serem usadas ao criar seu aplicativo consumidor KCL.`ConfigsBuilder`class agora tem suporte para o`MultistreamTracker`Interface. Você pode inicializarConfigsBuildercom o nome do único fluxo de dados para consumir registros de:

```
/**
    * Constructor to initialize ConfigsBuilder with StreamName
    * @param streamName
    * @param applicationName
    * @param kinesisClient
    * @param dynamoDBClient
    * @param cloudWatchClient
    * @param workerIdentifier
    * @param shardRecordProcessorFactory
    */
   public ConfigsBuilder(@NonNull String streamName, @NonNull String applicationName,
           @NonNull KinesisAsyncClient kinesisClient, @NonNull DynamoDbAsyncClient
dynamoDBClient,
           @NonNull CloudWatchAsyncClient cloudWatchClient, @NonNull String
workerIdentifier,
           @NonNull ShardRecordProcessorFactory shardRecordProcessorFactory) {
       this.appStreamTracker = Either.right(streamName);
       this.applicationName = applicationName;
       this.kinesisClient = kinesisClient;
       this.dynamoDBClient = dynamoDBClient;
       this.cloudWatchClient = cloudWatchClient;
       this.workerIdentifier = workerIdentifier;
       this.shardRecordProcessorFactory = shardRecordProcessorFactory;
   }
```

Ou você pode inicializarConfigsBuildercom`MultiStreamTracker`se você quiser implementar um aplicativo consumidor KCL que processa vários fluxos ao mesmo tempo.

```
* Constructor to initialize ConfigsBuilder with MultiStreamTracker
    * @param multiStreamTracker
    * @param applicationName
    * @param kinesisClient
    * @param dynamoDBClient
    * @param cloudWatchClient
    * @param workerIdentifier
    * @param shardRecordProcessorFactory
    */
   public ConfigsBuilder(@NonNull MultiStreamTracker multiStreamTracker, @NonNull String
applicationName,
           @NonNull KinesisAsyncClient kinesisClient, @NonNull DynamoDbAsyncClient
dynamoDBClient,
           @NonNull CloudWatchAsyncClient cloudWatchClient, @NonNull String
workerIdentifier,
           @NonNull ShardRecordProcessorFactory shardRecordProcessorFactory) {
       this.appStreamTracker = Either.left(multiStreamTracker);
       this.applicationName = applicationName;
       this.kinesisClient = kinesisClient;
       this.dynamoDBClient = dynamoDBClient;
       this.cloudWatchClient = cloudWatchClient;
       this.workerIdentifier = workerIdentifier;
       this.shardRecordProcessorFactory = shardRecordProcessorFactory;
   }
```

- Com o suporte multistream implementado para seu aplicativo consumidor KCL, cada linha da tabela de leasing do aplicativo agora contém a ID do fragmento e o nome do fluxo dos vários fluxos de dados que esse aplicativo processa.
- Quando o suporte multistream para seu aplicativo consumidor KCL é implementado, o leaseKey assume a seguinte estrutura: `account-id:StreamName:streamCreationTimestamp:ShardId`. Por exemplo,`111111111:multiStreamTest-1:12345:shardId-000000000336`.

  Important

  Quando seu aplicativo consumidor KCL existente está configurado para processar apenas um fluxo de dados, a leaseKey (que é a chave de hash para a tabela de leasing) é a ID do fragmento. Se você reconfigurar esse aplicativo de consumidor KCL existente para processar vários fluxos de dados, ele quebrará sua tabela de leasing, pois com o suporte multistream, a estrutura do leaseKey deve ser a seguinte:`account-id:StreamName:StreamCreationTimestamp:ShardId`.

Usando a biblioteca de cliente Kinesis com aAWSRegistro de esquemas de Glue

Você pode integrar seus fluxos de dados do Kinesis com oAWSRegistro de esquema de Glue. OAWSO registro de esquemas de Glue permite detectar, controlar e evoluir centralmente esquemas, ao mesmo tempo em que garante que os dados produzidos sejam continuamente validados por um esquema registrado. O esquema define a estrutura e o formato de um registro de dados. Um esquema é uma especificação versionada para publicação, consumo ou armazenamento de dados confiáveis. OAWSO Glue Schema Registry permite melhorarend-to-endqualidade de dados e governança de dados em seus aplicativos de streaming. Para obter mais informações, consulteAWSRegistro de esquemas de Glue. Uma das maneiras de configurar essa integração é por meio do KCL em Java.

Important

Atualmente, Kinesis Data Streams eAWSA integração do registro do esquema de Glue só é suportada para os fluxos de dados do Kinesis que usam consumidores do KCL 2.3 implementados em Java. Suporte a várias linguagens não é fornecido. Os consumidores do KCL 1.0 não são suportados. Os consumidores KCL 2.x anteriores ao KCL 2.3 não são suportados.

Para obter instruções detalhadas sobre como configurar a integração do Kinesis Data Streams com o Schema Registry usando o KCL, consulte a seção “Interagindo com dados usando as bibliotecas KPL/KCL” noCaso de uso: Integrar o Amazon Kinesis Data Streams com oAWSRegistro de esquemas de Glue.

Desenvolver consumidores personalizados com taxa de transferência compartilhada

Se não precisar de taxa de transferência específica ao receber dados do Kinesis Data Streams, nem de atrasos de propagação de leitura em 200 ms, você poderá criar aplicativos de consumidor, conforme descrito nos tópicos a seguir.

Tópicos

Para obter informações sobre a criação de consumidores que podem receber streaming de dados do Kinesis com taxa de transferência específica, consulteDesenvolver consumidores personalizados com taxa de transferência dedicada (distribuição avançada) (p. 163).

Desenvolver consumidores personalizados com taxa de transferência compartilhada usando a KCL

Um dos métodos de desenvolvimento de um aplicativo de consumidor personalizado com taxa de transferência compartilhada é usar a Biblioteca de Cliente Kinesis (KCL).

Tópicos

- Desenvolver consumidores do KCL 1.x (p. 133)
- Desenvolver consumidores do KCL 2.x (p. 147)

Desenvolver consumidores do KCL 1.x

Você pode desenvolver um aplicativo de consumidor para o Amazon Kinesis Data Streams usando a Kinesis Client Library (KCL). Para obter mais informações sobre o KCL, consulte O que é a biblioteca de cliente Kinesis? (p. 120).

Índice

- Desenvolver um consumidor da Kinesis Client Library em Java (p. 133)
- Desenvolver um consumidor da Kinesis Client Library em Node.js (p. 138)
- Desenvolver um consumidor da Kinesis Client Library em .NET (p. 141)
- Desenvolver um consumidor da Kinesis Client Library em Python (p. 144)
- Desenvolver um consumidor da Kinesis Client Library em Ruby (p. 147)

Desenvolver um consumidor da Kinesis Client Library em Java

Você pode usar a Kinesis Client Library (KCL) para criar aplicativos que processam dados dos streamings de dados do Kinesis. A Kinesis Client Library está disponível em vários idiomas. Este tópico discute Java. Para visualizar a referência do Javadoc, consulte aAWSTópico Javadoc para ClasseAmazonKinesisCliente.

Para baixar o Java KCL deGitHub, consulteKinesis Client Library (Java). Para localizar a Java KCL no Apache Maven do Apache Maven, acesse aResultados da pesquisa KCL. Para baixar o código de exemplo para um aplicativo consumidor Java KCL deGitHub, consulte oProjeto de exemplo KCL para JavaPágina emGitHub.

O aplicativo de exemplo usa Apache Commons Logging. Você pode alterar a configuração do registro em log no método `configure` estático definido no arquivo `AmazonKinesisApplicationSample.java`. Para obter mais informações sobre como usar o Apache Commons Logging com Log4j eAWSAplicações Java, consulteLog4jnoAWS SDK for JavaGuia do desenvolvedor.

Você precisa concluir as tarefas a seguir ao implementar um aplicativo de consumidor da KCL em Java:

Tarefas

- Implemente o IRecordProcessorMétodos (p. 134)
- Implementar uma fábrica de classe para a IRecordProcessorInterface (p. 136)
- Criar um operador (p. 136)
- Modificar as propriedades de configuração (p. 137)

- Migrar para a versão 2 da interface do processador de registros (p. 138)

Implemente o IRecordProcessorMétodos

O KCL atualmente suporta duas versões do`IRecordProcessor`Interface: a interface original está disponível com a primeira versão do KCL e a versão 2 está disponível desde a versão 1.5.0 do KCL. As duas interfaces têm suporte total. A escolha depende dos requisitos de cenário específicos. Consulte os Javadocs criados localmente ou o código-fonte para ver todas as diferenças. As seções a seguir descrevem a implementação mínima para os conceitos básicos.

IRecordProcessorVersões do :

- Interface original (versão 1) (p. 134)
- Interface atualizada (versão 2) (p. 135)

Interface original (versão 1)

A interface `IRecordProcessor` original (`package com.amazonaws.services.kinesis.clientlibrary.interfaces`) expõe os seguintes métodos de processador de registros que o consumidor precisa implementar. O exemplo fornece implementações que você pode usar como ponto de partida (consulte `AmazonKinesisApplicationSampleRecordProcessor.java`).

```
public void initialize(String shardId)
public void processRecords(List<Record> records, IRecordProcessorCheckpointer checkpointer)
public void shutdown(IRecordProcessorCheckpointer checkpointer, ShutdownReason reason)
```

initialize

O KCL chama o`initialize`Quando o processador de registros é instanciado, passando um ID de estilhaço específico como um parâmetro. Esse processador de registros processa apenas esse estilhaço e, normalmente, o inverso também é verdadeiro (esse estilhaço é processado somente por esse processador de registro). No entanto, o consumidor deve considerar a possibilidade de que um registro de dados pode ser processado mais de uma vez. O Kinesis Data Streams tempelo menos uma vezO é semântica, o que significa que cada registro de dados de um estilhaço é processado pelo menos uma vez por um operador no consumidor. Para obter mais informações sobre casos em que um estilhaço específico pode ser processado por mais de um operador, consulte Reestilhaçamento, escalabilidade e processamento paralelo (p. 185).

```
public void initialize(String shardId)
```

processRecords

O KCL chama o`processRecords`, passando uma lista de registros de dados do estilhaço especificado pelo`initialize(shardId)`. O processador de registros processa os dados nesses registros de acordo com a semântica do consumidor. Por exemplo, o operador pode executar uma transformação nos dados e, em seguida, armazenar o resultado em um bucket do Amazon Simple Storage Service (Amazon S3).

```
public void processRecords(List<Record> records, IRecordProcessorCheckpointer
 checkpointer)
```

Além dos dados em si, o registro também contém um número de sequência e uma chave de partição. O operador pode usar esses valores ao processar os dados. Por exemplo, o operador pode escolher o bucket do S3 no qual armazenar os dados com base no valor da chave de partição. A classe `Record` expõe os seguintes métodos que oferecem acesso aos dados do registro, número de sequência e chave de partição.

```
record.getData()
record.getSequenceNumber()
record.getPartitionKey()
```

No exemplo, o método privado `processRecordsWithRetries` tem código que mostra como um operador pode acessar os dados do registro, o número de sequência e a chave de partição.

O Kinesis Data Streams requer o processador de registros para rastrear os registros que já foram processados em um estilhaço. A KCL cuida desse rastreamento para você passando um checkpointer (`IRecordProcessorCheckpointer`) para`processRecords`. O processador de registro chama o`checkpoint`Método nessa interface para informar à KCL sobre o progresso do processamento dos registros no estilhaço. Caso o operador falhe, a KCL usa essas informações para reiniciar o processamento do estilhaço no último registro processado conhecido.

Em uma operação de divisão ou mesclagem, a KCL não começará a processar os novos estilhaços até que os processadores dos estilhaços originais tenham chamado`checkpoint`para sinalizar que todo o processamento nos fragmentos originais está completo.

Se você não passar um parâmetro, o KCL pressupõe que a chamada para`checkpoint`Significa que todos os registros foram processados, até o último registro que foi passado ao processador de registros. Portanto, o processador de registros deve chamar `checkpoint` somente após ter processado todos os registros na lista que foi passada a ele. Os processadores de registros não precisam chamar `checkpoint` em cada chamada para `processRecords`. Um processador pode, por exemplo, chamar `checkpoint` a cada terceira chamada para `processRecords`. Você pode, opcionalmente, especificar o número de sequência exato de um registro como um parâmetro para `checkpoint`. Nesse caso, a KCL assume que todos os registros foram processados somente até aquele registro.

No exemplo, o método privado `checkpoint` mostra como chamar `IRecordProcessorCheckpointer.checkpoint` usando a lógica de novas tentativas e o tratamento de exceções apropriados.

A KCL conta com`processRecords`Para gerenciar todas as exceções que surjam do processamento de registros de dados. Se uma exceção for lançada de`processRecords`, a KCL ignorará os registros de dados que foram passados antes da exceção. Ou seja, esses registros não serão reenviados para o processador de registros que lançou a exceção ou para qualquer outro processador de registros no consumidor.

shutdown

O KCL chama o`shutdown`método quando o processamento termina (o motivo do desligamento é`TERMINATE`) ou quando o operador não está mais respondendo (o motivo do desligamento é`ZOMBIE`).

```
public void shutdown(IRecordProcessorCheckpointer checkpointer, ShutdownReason reason)
```

O processamento termina quando o processador de registros não recebe mais registros do estilhaço porque ele foi dividido ou intercalado, ou o stream foi excluído.

O KCL também passa por um`IRecordProcessorCheckpointer`Interface para`shutdown`. Se o motivo do desligamento é `TERMINATE`, o processador de registros deve terminar o processamento de todos os registros de dados e, em seguida, chamar o método `checkpoint` nesta interface.

Interface atualizada (versão 2)

A interface `IRecordProcessor` atualizada (`package com.amazonaws.services.kinesis.clientlibrary.interfaces.v2`) expõe os seguintes métodos de processador de registros que o consumidor precisa implementar:

```
void initialize(InitializationInput initializationInput)
void processRecords(ProcessRecordsInput processRecordsInput)
void shutdown(ShutdownInput shutdownInput)
```

Todos os argumentos da versão original da interface podem ser acessados por meio de métodos get nos objetos de contêiner. Por exemplo, para recuperar a lista de registros em `processRecords()`, você pode usar `processRecordsInput.getRecords()`.

A partir da versão 2 dessa interface (KCL 1.5.0 e posterior), as novas entradas a seguir estão disponíveis, além das entradas fornecidas pela interface original:

número de sequência inicial

No objeto `InitializationInput` passado para a operação `initialize()`, o número de sequência inicial a partir do qual os registros seriam fornecidos à instância do processador de registros. Esse é o número de sequência que foi verificado pela última vez pela instância do processador de registros que processou anteriormente o mesmo estilhaço. Isso será fornecido no caso de o aplicativo precisar de informações.

número de sequência do ponto de verificação pendente

No objeto `InitializationInput` passado para a operação `initialize()`, o número de sequência de verificação pendente (se houver) que não pôde ser confirmado antes que a instância do processador de registros anterior parasse.

Implementar uma fábrica de classe para a IRecordProcessorInterface

Você também precisará implementar uma fábrica para a classe que implementa os métodos do processador de registros. Quando o consumidor instancia o operador, ele passa uma referência a essa fábrica.

O exemplo implementa a classe de fábrica no arquivo `AmazonKinesisApplicationSampleRecordProcessorFactory.java` usando a interface de processador de registros original. Se você deseja que a fábrica da classe crie a versão 2 dos processadores de registros, use o nome do pacote `com.amazonaws.services.kinesis.clientlibrary.interfaces.v2`.

```
public class SampleRecordProcessorFactory implements IRecordProcessorFactory {
    /**
    * Constructor.
    */
    public SampleRecordProcessorFactory() {
        super();
    }
    /**
    * {@inheritDoc}
    */
    @Override
    public IRecordProcessor createProcessor() {
        return new SampleRecordProcessor();
    }
}
```

Criar um operador

Conforme discutido emImplemente o IRecordProcessorMétodos (p. 134), há duas versões da interface do processador de registros KCL para escolher, o que afeta como você cria um operador. A interface do processador de registros original usa a seguinte estrutura de código para criar um operador:

```
final KinesisClientLibConfiguration config = new KinesisClientLibConfiguration(...)
final IRecordProcessorFactory recordProcessorFactory = new RecordProcessorFactory();
final Worker worker = new Worker(recordProcessorFactory, config);
```

Com a versão 2 da interface do processador de registros, você pode usar `Worker.Builder` para criar um operador sem a necessidade de se preocupar com qual construtor usar e a ordem dos argumentos. A interface do processador de registros atualizada usa a seguinte estrutura de código para criar um operador:

```
final KinesisClientLibConfiguration config = new KinesisClientLibConfiguration(...)
final IRecordProcessorFactory recordProcessorFactory = new RecordProcessorFactory();
final Worker worker = new Worker.Builder()
    .recordProcessorFactory(recordProcessorFactory)
    .config(config)
    .build();
```

Modificar as propriedades de configuração

O exemplo fornece valores padrão para propriedades de configuração. Esses dados de configuração para o operador são então consolidados em um objeto `KinesisClientLibConfiguration`. Esse objeto e uma referência à fábrica de classe para `IRecordProcessor` são passados na chamada que instancia o operador. Você pode substituir qualquer uma dessas propriedades por seus próprios valores usando um arquivo de propriedades do Java (consulte `AmazonKinesisApplicationSample.java`).

Nome do aplicativo

A KCL exige um nome do aplicativo que seja exclusivo nos aplicativos e nas tabelas do Amazon DynamoDB na mesma região. Ela usa o valor de configuração de nome de aplicativo das seguintes formas:

- Presume-se que todos os operadores associados com esse nome de aplicativo estejam trabalhando juntos no mesmo stream. Esses operadores podem ser distribuídos em várias instâncias. Se você executa uma instância adicional do mesmo código de aplicativo, mas com um nome de aplicativo diferente, a KCL trata a segunda instância como um aplicativo totalmente separado que também opera no mesmo stream.
- A KCL cria uma tabela do DynamoDB com o nome do aplicativo e usa essa tabela para manter informações de estado (como pontos de verificação e mapeamento operador-estilhaço) referentes ao aplicativo. Cada aplicativo tem sua própria tabela do DynamoDB. Para obter mais informações, consulte Usando uma tabela de leasing para rastrear os fragmentos processados pelo aplicativo do consumidor KCL (p. 123).

Configurar credenciais

Você deve fazer o seuAWSAs credenciais disponíveis para um dos provedores de credenciais na cadeia de provedores de credencial padrão. Por exemplo, se você estiver executando o consumidor em uma instância do EC2, recomendamos que você inicie a instância com uma função do IAM.AWSAs credenciais da AWS que refletem as permissões associadas à função do IAM são disponibilizadas aos aplicativos na instância por meio de metadados da instância. Essa é a maneira mais segura de gerenciar credenciais para um consumidor em execução em uma instância do EC2.

O aplicativo de exemplo primeiro tentará recuperar as credenciais do IAM dos metadados da instância:

```
credentialsProvider = new InstanceProfileCredentialsProvider();
```

Se o aplicativo de exemplo não consegue obter credenciais dos metadados da instância, ele tenta recuperar as credenciais de um arquivo de propriedades:

```
credentialsProvider = new ClasspathPropertiesFileCredentialsProvider();
```

Para obter mais informações sobre os metadados da instância, consulteMetadados da instânciaGuia do usuário do Amazon EC2 para instâncias do Linux.

Usar o ID do operador para várias Instâncias

O código de inicialização de exemplo cria um ID para o operador, `workerId`, usando o nome do computador local e anexando um identificador exclusivo globalmente, conforme mostrado no seguinte trecho de código. Essa abordagem é compatível com o cenário de várias instâncias do aplicativo de consumidor em execução em um único computador.

```
String workerId = InetAddress.getLocalHost().getCanonicalHostName() + ":" +
 UUID.randomUUID();
```

Migrar para a versão 2 da interface do processador de registros

Se você quiser migrar o código que usa a interface original, além das etapas descritas anteriormente, as seguintes etapas serão necessárias:

1. Altere a classe do processador de registros para importar a versão 2 da interface do processador de registros:

   ```
   import com.amazonaws.services.kinesis.clientlibrary.interfaces.v2.IRecordProcessor;
   ```

2. Altere as referências para as entradas para usar métodos `get` nos objetos de contêiner. Por exemplo, na operação `shutdown()`, altere "`checkpointer`" para "`shutdownInput.getCheckpointer()`".
3. Altere a classe da fábrica do processador de registros para importar a versão 2 da interface da fábrica do processador de registros:

   ```
   import
    com.amazonaws.services.kinesis.clientlibrary.interfaces.v2.IRecordProcessorFactory;
   ```

4. Altere a construção do operador para usar `Worker.Builder`. Por exemplo:

   ```
   final Worker worker = new Worker.Builder()
       .recordProcessorFactory(recordProcessorFactory)
       .config(config)
       .build();
   ```

Desenvolver um consumidor da Kinesis Client Library em Node.js

Você pode usar a Kinesis Client Library (KCL) para criar aplicativos que processam dados dos streamings de dados do Kinesis. A Kinesis Client Library está disponível em vários idiomas. Este tópico discute Node.js.

O KCL é uma biblioteca Java; o suporte para idiomas diferentes do Java é fornecido usando uma interface multilíngue chamadaMultiLangDaemon do. Este daemon é baseado em Java e é executado em segundo plano quando você estiver usando uma linguagem KCL diferente de Java. Portanto, se você instalar o KCL para Node.js e escrever o aplicativo de consumidor inteiramente em Node.js, ainda precisará do Java instalado no sistema por causa daMultiLangDaemon do. Além disso,MultiLangO Daemon tem algumas configurações padrão que você pode personalizar para o caso de uso. Por exemplo, aAWSRegião à qual ele se conecta. Para obter mais informações sobre oMultiLangDaemon doGitHub, consulte oKCLMultiLangProjeto daemon do.

Para fazer download da KCL do Node.js emGitHub, consulteKinesis Client Library (Node.js).

Downloads de códigos de exemplo

Há dois exemplos de código disponíveis para KCL em Node.js:

- basic-sample

  Usado nas seções a seguir para ilustrar os conceitos básicos de criação de um aplicativo de consumidor da KCL em Node.js.
- click-stream-sample

  Levemente mais avançado e usa um cenário real, para depois que você se familiarizar com o código de exemplo básico. Esse exemplo não é discutido aqui, mas há um arquivo README com mais informações.

Você precisa concluir as tarefas a seguir ao implementar um aplicativo de consumidor da KCL em Node.js:

Tarefas

- Implementar o processador de registros (p. 139)
- Modificar as propriedades de configuração (p. 141)

Implementar o processador de registros

O consumidor mais simples possível usando a KCL para Node.js precisa implementar um`recordProcessor`função, que por sua vez contém as funções`initialize`,`processRecords`, e`shutdown`. O exemplo fornece uma implementação que você pode usar como ponto de partida (consulte `sample_kcl_app.js`).

```
function recordProcessor() {
  // return an object that implements initialize, processRecords and shutdown functions.}
```

initialize

O KCL chama o`initialize`Função quando o processador de registros é iniciado. Esse processador de registros processa apenas o ID do estilhaço passado como `initializeInput.shardId` e, normalmente, o inverso também é verdadeiro (esse estilhaço é processado somente por esse processador de registro). No entanto, o consumidor deve considerar a possibilidade de que um registro de dados pode ser processado mais de uma vez. Isso ocorre porque o Kinesis Data Streams tempelo menos uma vezO é semântica, o que significa que cada registro de dados de um estilhaço é processado pelo menos uma vez por um operador no consumidor. Para obter mais informações sobre casos em que um estilhaço específico pode ser processado por mais de um operador, consulte Reestilhaçamento, escalabilidade e processamento paralelo (p. 185).

```
initialize: function(initializeInput, completeCallback)
```

processRecords

A KCL chama essa função com entrada que contém uma lista de registros de dados do estilhaço especificado para a`initialize`função. O processador de registros que você implementa processa os dados nesses registros de acordo com a semântica do consumidor. Por exemplo, o operador pode executar uma transformação nos dados e, em seguida, armazenar o resultado em um bucket do Amazon Simple Storage Service (Amazon S3).

```
processRecords: function(processRecordsInput, completeCallback)
```

Além dos dados em si, o registro também contém um número de sequência e uma chave de partição, que o operador pode usar ao processar os dados. Por exemplo, o operador pode escolher o bucket do S3 no qual armazenar os dados com base no valor da chave de partição. O dicionário `record` expõe os seguintes pares de chave/valor para acessar os dados do registro, o número de sequência e a chave de partição:

```
record.data
record.sequenceNumber
record.partitionKey
```

Observe que os dados são codificados em Base64.

No exemplo básico, a função `processRecords` tem código que mostra como um operador pode acessar os dados do registro, o número de sequência e a chave de partição.

O Kinesis Data Streams requer o processador de registros para rastrear os registros que já foram processados em um estilhaço. A KCL cuida desse rastreamento com um`checkpointer`objeto passado como`processRecordsInput.checkpointer`. Seu processador de registro chama o`checkpointer.checkpoint`Para informar à KCL sobre o progresso do processamento dos registros no estilhaço. Caso o operador falhe, a KCL usa essas informações quando você reinicia o processamento do estilhaço para que ele continue a partir do último registro processado conhecido.

Em uma operação de divisão ou mesclagem, a KCL não começa a processar os novos estilhaços até que os processadores dos estilhaços originais tenham chamado`checkpoint`para sinalizar que todo o processamento nos fragmentos originais está completo.

Se você não passar o número da sequência para o`checkpoint`função, o KCL assume que a chamada para`checkpoint`Significa que todos os registros foram processados, até o último registro que foi passado ao processador de registros. Portanto, o processador de registros deve chamar `checkpoint` somente após ter processado todos os registros na lista que foi passada para ele. Os processadores de registros não precisam chamar `checkpoint` em cada chamada para `processRecords`. Um processador pode, por exemplo, chamar `checkpoint` a cada terceira chamada, ou algum evento externo para o processador de registros, como um serviço de validação/verificação personalizado que você tiver implementado.

Você pode, opcionalmente, especificar o número de sequência exato de um registro como um parâmetro para `checkpoint`. Nesse caso, a KCL assume que todos os registros foram processados somente até aquele registro.

O aplicativo de exemplo básico mostra a chamada mais simples possível para a função `checkpointer.checkpoint`. Você pode adicionar outra lógica de verificação que precisar para o consumidor neste ponto da função.

shutdown

O KCL chama o`shutdown`função quando o processamento termina (`shutdownInput.reason`é`TERMINATE`) ou o trabalhador não está mais respondendo (`shutdownInput.reason`é`ZOMBIE`).

```
shutdown: function(shutdownInput, completeCallback)
```

O processamento termina quando o processador de registros não recebe mais registros do estilhaço porque ele foi dividido ou intercalado, ou o stream foi excluído.

O KCL também passa por um`shutdownInput.checkpointer`objeto para`shutdown`. Se o motivo do desligamento for `TERMINATE`, você deverá verificar se o processador de registros terminou o processamento de todos os registros de dados e, em seguida, chamar a função `checkpoint` nessa interface.

Modificar as propriedades de configuração

O exemplo fornece valores padrão para as propriedades de configuração. Você pode substituir qualquer uma dessas propriedades por seus próprios valores (consulte `sample.properties` no exemplo básico).

Nome do aplicativo

A KCL exige um aplicativo exclusivo entre seus aplicativos e entre suas tabelas do Amazon DynamoDB na mesma região. Ela usa o valor de configuração de nome de aplicativo das seguintes formas:

- Presume-se que todos os operadores associados com esse nome de aplicativo estejam trabalhando juntos no mesmo stream. Esses operadores podem ser distribuídos em várias instâncias. Se você executa uma instância adicional do mesmo código de aplicativo, mas com um nome de aplicativo diferente, a KCL trata a segunda instância como um aplicativo totalmente separado que também opera no mesmo stream.
- A KCL cria uma tabela do DynamoDB com o nome do aplicativo e usa essa tabela para manter informações de estado (como pontos de verificação e mapeamento operador-estilhaço) referentes ao aplicativo. Cada aplicativo tem sua própria tabela do DynamoDB. Para obter mais informações, consulte Usando uma tabela de leasing para rastrear os fragmentos processados pelo aplicativo do consumidor KCL (p. 123).

Configurar credenciais

Você deve fazer o seuAWSAs credenciais disponíveis para um dos provedores de credenciais na cadeia de provedores de credencial padrão. Você pode usar a propriedade `AWSCredentialsProvider` para definir um provedor de credenciais. O arquivo `sample.properties` precisa disponibilizar as credenciais para um dos provedores de credenciais na cadeia de provedores de credenciais padrão. Se você estiver executando o consumidor em uma instância do Amazon EC2, recomendamos que configure a instância com uma função do IAM.AWSAs credenciais da AWS que refletem as permissões associadas à função do IAM são disponibilizadas aos aplicativos na instância por meio de metadados da instância. Essa é a maneira mais segura de gerenciar credenciais para um aplicativo de consumidor em execução em uma instância do EC2.

O exemplo a seguir configura a KCL para processar um stream de dados do Kinesis chamado`kclnodejssample`Usando o processador de registros fornecido em`sample_kcl_app.js`:

```
# The Node.js executable script
executableName = node sample_kcl_app.js
# The name of an Amazon Kinesis stream to process
streamName = kclnodejssample
# Unique KCL application name
applicationName = kclnodejssample
# Use default AWS credentials provider chain
AWSCredentialsProvider = DefaultAWSCredentialsProviderChain
# Read from the beginning of the stream
initialPositionInStream = TRIM_HORIZON
```

Desenvolver um consumidor da Kinesis Client Library em .NET

Você pode usar a Kinesis Client Library (KCL) para criar aplicativos que processam dados dos streamings de dados do Kinesis. A Kinesis Client Library está disponível em vários idiomas. Este tópico discute .NET.

O KCL é uma biblioteca Java; o suporte para idiomas diferentes do Java é fornecido usando uma interface multilíngue chamadaMultiLangDaemon do. Este daemon é baseado em Java e é executado em segundo plano quando você estiver usando uma linguagem KCL diferente de Java. Portanto, se você instalar o KCL para .NET e escrever o aplicativo de consumidor inteiramente em .NET, ainda precisará do Java instalado no sistema por causa daMultiLangDaemon do. Além disso,MultiLangO Daemon tem algumas configurações padrão que você pode personalizar para o caso de uso. Por exemplo, aAWSRegião

à qual ele se conecta. Para obter mais informações sobre oMultiLangDaemon doGitHub, consulte oKCLMultiLangProjeto daemon do.

Para baixar o .NET KCL doGitHub, consulteKinesis Client Library (.NET). Para fazer download do código de exemplo para um aplicativo de consumidor da de .NET KCL, acesse aProjeto de consumidor de amostra KCL para .NETPágina emGitHub.

Você precisa concluir as tarefas a seguir ao implementar um aplicativo de consumidor da KCL em .NET:

Tarefas

- Implemente o IRecordProcessorClasse Methods (Métodos) (p. 142)
- Modificar as propriedades de configuração (p. 143)

Implemente o IRecordProcessorClasse Methods (Métodos)

O consumidor precisa implementar os seguintes métodos para `IRecordProcessor`. O consumidor de exemplo fornece implementações que você pode usar como ponto de partida (consulte a classe `SampleRecordProcessor` em `SampleConsumer/AmazonKinesisSampleConsumer.cs`).

```
public void Initialize(InitializationInput input)
public void ProcessRecords(ProcessRecordsInput input)
public void Shutdown(ShutdownInput input)
```

Inicializar

A KCL chama esse método quando o processador de registros é instanciado, passando um ID de estilhaço específico na`input`parâmetro (`input.ShardId`). Esse processador de registros processa apenas esse estilhaço e, normalmente, o inverso também é verdadeiro (esse estilhaço é processado somente por esse processador de registro). No entanto, o consumidor deve considerar a possibilidade de que um registro de dados pode ser processado mais de uma vez. Isso ocorre porque o Kinesis Data Streams tempelo menos uma vezO é semântica, o que significa que cada registro de dados de um estilhaço é processado pelo menos uma vez por um operador no consumidor. Para obter mais informações sobre casos em que um estilhaço específico pode ser processado por mais de um operador, consulte Reestilhaçamento, escalabilidade e processamento paralelo (p. 185).

```
public void Initialize(InitializationInput input)
```

ProcessRecords

A KCL chama esse método passando uma lista de registros de dados na`input`parâmetro (`input.Records`) do fragmento especificado pelo`Initialize`. O processador de registros que você implementa processa os dados nesses registros de acordo com a semântica do consumidor. Por exemplo, o operador pode executar uma transformação nos dados e, em seguida, armazenar o resultado em um bucket do Amazon Simple Storage Service (Amazon S3).

```
public void ProcessRecords(ProcessRecordsInput input)
```

Além dos dados em si, o registro também contém um número de sequência e uma chave de partição. O operador pode usar esses valores ao processar os dados. Por exemplo, o operador pode escolher o bucket do S3 no qual armazenar os dados com base no valor da chave de partição. A classe `Record` expõe os seguintes itens para acessar os dados do registro, o número de sequência e a chave de partição:

```
byte[] Record.Data
string Record.SequenceNumber
string Record.PartitionKey
```

No exemplo, o método `ProcessRecordsWithRetries` tem código que mostra como um operador pode acessar os dados do registro, o número de sequência e a chave de partição.

O Kinesis Data Streams requer o processador de registros para rastrear os registros que já foram processados em um estilhaço. A KCL cuida desse rastreamento para você passando um`Checkpointer`objeto para`ProcessRecords`(`input.Checkpointer`). O processador de registro chama o`Checkpointer.Checkpoint`Para informar à KCL sobre o progresso do processamento dos registros no estilhaço. Caso o operador falhe, a KCL usa essas informações para reiniciar o processamento do estilhaço no último registro processado conhecido.

Em uma operação de divisão ou mesclagem, a KCL não começa a processar os novos estilhaços até que os processadores dos estilhaços originais tenham chamado`Checkpointer.Checkpoint`para sinalizar que todo o processamento nos fragmentos originais está completo.

Se você não passar um parâmetro, o KCL pressupõe que a chamada para`Checkpointer.Checkpoint`Significa que todos os registros foram processados, até o último registro que foi passado ao processador de registros. Portanto, o processador de registros deve chamar `Checkpointer.Checkpoint` somente após ter processado todos os registros na lista que foi passada a ele. Os processadores de registros não precisam chamar `Checkpointer.Checkpoint` em cada chamada para `ProcessRecords`. Um processador pode, por exemplo, chamar `Checkpointer.Checkpoint` a cada terceira ou quarta chamada. Você pode, opcionalmente, especificar o número de sequência exato de um registro como um parâmetro para `Checkpointer.Checkpoint`. Nesse caso, a KCL assume que os registros foram processados somente até aquele registro.

No exemplo, o método privado `Checkpoint(Checkpointer checkpointer)` mostra como chamar o método `Checkpointer.Checkpoint` usando a lógica de novas tentativas e o tratamento de exceções apropriados.

A KCL para .NET lida com exceções de maneira diferente das outras bibliotecas de idioma da KCL, pois não lida com nenhuma exceção que surge do processamento de registros de dados. As exceções não detectadas do código do usuário causam uma falha no programa.

Desligamento

O KCL chama o`Shutdown`método quando o processamento termina (o motivo do desligamento é`TERMINATE`) ou quando o operador não está mais respondendo (o desligamento`input.Reason`O valor é`ZOMBIE`).

```
public void Shutdown(ShutdownInput input)
```

O processamento termina quando o processador de registros não recebe mais registros do estilhaço porque ele foi dividido ou intercalado, ou o stream foi excluído.

O KCL também passa por um`Checkpointer`objeto para`shutdown`. Se o motivo do desligamento é `TERMINATE`, o processador de registros deve terminar o processamento de todos os registros de dados e, em seguida, chamar o método `checkpoint` nesta interface.

Modificar as propriedades de configuração

O consumidor de exemplo fornece valores padrão para as propriedades de configuração. Você pode substituir qualquer uma dessas propriedades por seus próprios valores (consulte `SampleConsumer/kcl.properties`).

Nome do aplicativo

A KCL exige um aplicativo exclusivo entre seus aplicativos e entre suas tabelas do Amazon DynamoDB na mesma região. Ela usa o valor de configuração de nome de aplicativo das seguintes formas:

- Presume-se que todos os operadores associados com esse nome de aplicativo estejam trabalhando juntos no mesmo stream. Esses operadores podem ser distribuídos em várias instâncias. Se você

executa uma instância adicional do mesmo código de aplicativo, mas com um nome de aplicativo diferente, a KCL trata a segunda instância como um aplicativo totalmente separado que também opera no mesmo stream.

- A KCL cria uma tabela do DynamoDB com o nome do aplicativo e usa essa tabela para manter informações de estado (como pontos de verificação e mapeamento operador-estilhaço) referentes ao aplicativo. Cada aplicativo tem sua própria tabela do DynamoDB. Para obter mais informações, consulte Usando uma tabela de leasing para rastrear os fragmentos processados pelo aplicativo do consumidor KCL (p. 123).

Configurar credenciais

Você deve fazer o seuAWSAs credenciais disponíveis para um dos provedores de credenciais na cadeia de provedores de credencial padrão. Você pode usar a propriedade `AWSCredentialsProvider` para definir um provedor de credenciais. As sample.properties precisam disponibilizar as credenciais para um dos provedores de credenciais na cadeia de provedores de credenciais padrão. Se você estiver executando o aplicativo de consumidor em uma instância do EC2, recomendamos que configure a instância com uma função do IAM.AWSAs credenciais da AWS que refletem as permissões associadas à função do IAM são disponibilizadas aos aplicativos na instância por meio de metadados da instância. Essa é a maneira mais segura de gerenciar credenciais para um consumidor em execução em uma instância do EC2.

O arquivo de propriedades do exemplo configura a KCL para processar um stream de dados do Kinesis chamado “words” usando o processador de registros fornecido em`AmazonKinesisSampleConsumer.cs`.

Desenvolver um consumidor da Kinesis Client Library em Python

Você pode usar a Kinesis Client Library (KCL) para criar aplicativos que processam dados dos streamings de dados do Kinesis. A Kinesis Client Library está disponível em vários idiomas. Este tópico discute Python.

O KCL é uma biblioteca Java; o suporte para idiomas diferentes do Java é fornecido usando uma interface multilíngue chamadaMultiLangDaemon do. Este daemon é baseado em Java e é executado em segundo plano quando você estiver usando uma linguagem KCL diferente de Java. Portanto, se você instalar o KCL para Python e escrever o aplicativo de consumidor inteiramente em Python, ainda precisará do Java instalado no sistema por causa doMultiLangDaemon do. Além disso,MultiLangO Daemon tem algumas configurações padrão que você pode personalizar para o caso de uso. Por exemplo, aAWSRegião à qual ele se conecta. Para obter mais informações sobre oMultiLangDaemon doGitHub, consulte oKCLMultiLangProjeto daemon do.

Para baixar o Python KCL deGitHub, consulteKinesis Client Library (Python). Para fazer download do código de exemplo para um aplicativo de consumidor da Python KCL, acesse aProjeto de amostra KCL para PythonPágina emGitHub.

Você precisa concluir as tarefas a seguir ao implementar um aplicativo de consumidor da KCL em Python:

Tarefas

- Implemente oRecordProcessorClasse Methods (Métodos) (p. 144)
- Modificar as propriedades de configuração (p. 146)

Implemente oRecordProcessorClasse Methods (Métodos)

A classe `RecordProcess` precisa estender o `RecordProcessorBase` para implementar os métodos a seguir. O exemplo fornece implementações que você pode usar como ponto de partida (consulte `sample_kclpy_app.py`).

```
def initialize(self, shard_id)
```

```
def process_records(self, records, checkpointer)
def shutdown(self, checkpointer, reason)
```

initialize

O KCL chama o`initialize`Quando o processador de registros é instanciado, passando um ID de estilhaço específico como um parâmetro. Esse processador de registros processa apenas esse estilhaço e, normalmente, o inverso também é verdadeiro (esse estilhaço é processado somente por esse processador de registro). No entanto, o consumidor deve considerar a possibilidade de que um registro de dados pode ser processado mais de uma vez. Isso ocorre porque o Kinesis Data Streams tempelo menos uma vezO é semântica, o que significa que cada registro de dados de um estilhaço é processado pelo menos uma vez por um operador no consumidor. Para obter mais informações sobre casos em que um estilhaço específico pode ser processado por mais de um operador, consulte Reestilhaçamento, escalabilidade e processamento paralelo (p. 185).

```
def initialize(self, shard_id)
```

process_records

A KCL chama esse método passando uma lista de registros de dados do estilhaço especificado pelo`initialize`. O processador de registros que você implementa processa os dados nesses registros de acordo com a semântica do consumidor. Por exemplo, o operador pode executar uma transformação nos dados e, em seguida, armazenar o resultado em um bucket do Amazon Simple Storage Service (Amazon S3).

```
def process_records(self, records, checkpointer)
```

Além dos dados em si, o registro também contém um número de sequência e uma chave de partição. O operador pode usar esses valores ao processar os dados. Por exemplo, o operador pode escolher o bucket do S3 no qual armazenar os dados com base no valor da chave de partição. O dicionário `record` expõe os seguintes pares de chave/valor para acessar os dados do registro, o número de sequência e a chave de partição:

```
record.get('data')
record.get('sequenceNumber')
record.get('partitionKey')
```

Observe que os dados são codificados em Base64.

No exemplo, o método `process_records` tem código que mostra como um operador pode acessar os dados do registro, o número de sequência e a chave de partição.

O Kinesis Data Streams requer o processador de registros para rastrear os registros que já foram processados em um estilhaço. A KCL cuida desse rastreamento para você passando um`Checkpointer`objeto para`process_records`. O processador de registro chama o`checkpoint`Método neste objeto para informar à KCL sobre o progresso do processamento dos registros no estilhaço. Caso o operador falhe, a KCL usa essas informações para reiniciar o processamento do estilhaço no último registro processado conhecido.

Em uma operação de divisão ou mesclagem, a KCL não começa a processar os novos estilhaços até que os processadores dos estilhaços originais tenham chamado`checkpoint`para sinalizar que todo o processamento nos fragmentos originais está completo.

Se você não passar um parâmetro, o KCL pressupõe que a chamada para`checkpoint`Significa que todos os registros foram processados, até o último registro que foi passado ao processador de registros. Portanto, o processador de registros deve chamar `checkpoint` somente após ter processado todos os registros na lista que foi passada a ele. Os processadores de registros não precisam chamar `checkpoint`

em cada chamada para `process_records`. Um processador pode, por exemplo, chamar `checkpoint` a cada terceira chamada. Você pode, opcionalmente, especificar o número de sequência exato de um registro como um parâmetro para `checkpoint`. Nesse caso, a KCL assume que todos os registros foram processados somente até aquele registro.

No exemplo, o método privado `checkpoint` mostra como chamar o método `Checkpointer.checkpoint` usando a lógica de novas tentativas e o tratamento de exceções apropriados.

A KCL conta com`process_records`Para gerenciar todas as exceções que surjam do processamento de registros de dados. Se uma exceção for lançada de`process_records`, a KCL ignorará os registros de dados que foram passados para`process_records`antes da exceção. Ou seja, esses registros não serão reenviados para o processador de registros que lançou a exceção ou para qualquer outro processador de registros no consumidor.

shutdown

O KCL chama o`shutdown`método quando o processamento termina (o motivo do desligamento é`TERMINATE`) ou quando o operador não está mais respondendo (o desligamento`reason`é`ZOMBIE`).

```
def shutdown(self, checkpointer, reason)
```

O processamento termina quando o processador de registros não recebe mais registros do estilhaço porque ele foi dividido ou intercalado, ou o stream foi excluído.

O KCL também passa por um`Checkpointer`objeto para`shutdown`. Se o `reason` do desligamento é `TERMINATE`, o processador de registros deve terminar o processamento de todos os registros de dados e, em seguida, chamar o método `checkpoint` nesta interface.

Modificar as propriedades de configuração

O exemplo fornece valores padrão para as propriedades de configuração. Você pode substituir qualquer uma dessas propriedades por seus próprios valores (consulte `sample.properties`).

Nome do aplicativo

A KCL exige um nome do aplicativo que seja exclusivo entre seus aplicativos e entre as tabelas do Amazon DynamoDB na mesma região. Ela usa o valor de configuração de nome de aplicativo das seguintes formas:

- Presume-se que todos os operadores associados a esse nome de aplicativo estejam trabalhando juntos no mesmo streaming. Esses operadores podem ser distribuídos em várias instâncias. Se você executa uma instância adicional do mesmo código de aplicativo, mas com um nome de aplicativo diferente, a KCL trata a segunda instância como um aplicativo totalmente separado que também opera no mesmo stream.
- A KCL cria uma tabela do DynamoDB com o nome do aplicativo e usa essa tabela para manter informações de estado (como pontos de verificação e mapeamento operador-estilhaço) referentes ao aplicativo. Cada aplicativo tem sua própria tabela do DynamoDB. Para obter mais informações, consulte Usando uma tabela de leasing para rastrear os fragmentos processados pelo aplicativo do consumidor KCL (p. 123).

Configurar credenciais

Você deve fazer o seuAWSAs credenciais disponíveis para um dos provedores de credenciais na cadeia de provedores de credencial padrão. Você pode usar a propriedade `AWSCredentialsProvider` para definir um provedor de credenciais. As sample.properties precisam disponibilizar as credenciais para um dos provedores de credenciais na cadeia de provedores de credenciais padrão. Se você estiver executando o aplicativo de consumidor em uma instância do Amazon EC2, recomendamos que configure

a instância com uma função do IAM.AWSAs credenciais da AWS que refletem as permissões associadas à função do IAM são disponibilizadas aos aplicativos na instância por meio de metadados da instância. Essa é a maneira mais segura de gerenciar credenciais para um aplicativo de consumidor em execução em uma instância do EC2.

O arquivo de propriedades do exemplo configura a KCL para processar um stream de dados do Kinesis chamado “words” usando o processador de registros fornecido em`sample_kclpy_app.py`.

Desenvolver um consumidor da Kinesis Client Library em Ruby

Você pode usar a Kinesis Client Library (KCL) para criar aplicativos que processam dados dos streamings de dados do Kinesis. A Kinesis Client Library está disponível em vários idiomas. Este tópico discute Ruby.

O KCL é uma biblioteca Java; o suporte para idiomas diferentes do Java é fornecido usando uma interface multilíngue chamadaMultiLangDaemon do. Este daemon é baseado em Java e é executado em segundo plano quando você estiver usando uma linguagem KCL diferente de Java. Portanto, se você instalar o KCL para Ruby e escrever o aplicativo de consumidor inteiramente em Ruby, ainda precisará do Java instalado no sistema por causa daMultiLangDaemon do. Além disso,MultiLangO Daemon tem algumas configurações padrão que você pode personalizar para o caso de uso. Por exemplo, aAWSRegião à qual ele se conecta. Para obter mais informações sobre oMultiLangDaemon doGitHub, consulte oKCLMultiLangProjeto daemon do.

Para baixar o Ruby KCL deGitHub, consulteKinesis Client Library (Ruby). Para fazer download do código de exemplo para um aplicativo de consumidor da Ruby KCL, acesse aProjeto de amostra KCL para RubyPágina emGitHub.

Para obter mais informações sobre a biblioteca de suporte da KCL Ruby da, consulteDocumentação do KCL Ruby Gems.

Desenvolver consumidores do KCL 2.x

Este tópico mostra como usar a versão 2.0 da Kinesis Client Library (KCL). Para obter mais informações sobre o recurso KCL, consulte a visão geral fornecida noDesenvolver consumidores usando a Kinesis Client Library 1.x.

Índice

Desenvolver um consumidor da Kinesis Client Library em Java

O código a seguir mostra uma implementação de exemplo em Java de `ProcessorFactory` e `RecordProcessor`. Se você quiser aproveitar o recurso de distribuição avançada, consulte Usar consumidores com distribuição avançada.

```
/*
 *  Copyright 2019 Amazon.com, Inc. or its affiliates. All Rights Reserved.
 *
 *  Licensed under the Amazon Software License (the "License").
 *  You may not use this file except in compliance with the License.
 *  A copy of the License is located at
 *
 *  http://aws.amazon.com/asl/
 *
 *  or in the "license" file accompanying this file. This file is distributed
 *  on an "AS IS" BASIS, WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either
 *  express or implied. See the License for the specific language governing
 *  permissions and limitations under the License.
```

```
 */


/*
 * Copyright 2019 Amazon.com, Inc. or its affiliates. All Rights Reserved.
 *
 * Licensed under the Apache License, Version 2.0 (the "License").
 * You may not use this file except in compliance with the License.
 * A copy of the License is located at
 *
 *     http://www.apache.org/licenses/LICENSE-2.0
 *
 * or in the "license" file accompanying this file. This file is distributed
 * on an "AS IS" BASIS, WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either
 * express or implied. See the License for the specific language governing
 * permissions and limitations under the License.
 */

import java.io.BufferedReader;
import java.io.IOException;
import java.io.InputStreamReader;
import java.util.UUID;
import java.util.concurrent.ExecutionException;
import java.util.concurrent.Executors;
import java.util.concurrent.Future;
import java.util.concurrent.ScheduledExecutorService;
import java.util.concurrent.ScheduledFuture;
import java.util.concurrent.TimeUnit;
import java.util.concurrent.TimeoutException;

import org.apache.commons.lang3.ObjectUtils;
import org.apache.commons.lang3.RandomStringUtils;
import org.apache.commons.lang3.RandomUtils;
import org.slf4j.Logger;
import org.slf4j.LoggerFactory;
import org.slf4j.MDC;

import software.amazon.awssdk.core.SdkBytes;
import software.amazon.awssdk.regions.Region;
import software.amazon.awssdk.services.cloudwatch.CloudWatchAsyncClient;
import software.amazon.awssdk.services.dynamodb.DynamoDbAsyncClient;
import software.amazon.awssdk.services.kinesis.KinesisAsyncClient;
import software.amazon.awssdk.services.kinesis.model.PutRecordRequest;
import software.amazon.kinesis.common.ConfigsBuilder;
import software.amazon.kinesis.common.KinesisClientUtil;
import software.amazon.kinesis.coordinator.Scheduler;
import software.amazon.kinesis.exceptions.InvalidStateException;
import software.amazon.kinesis.exceptions.ShutdownException;
import software.amazon.kinesis.lifecycle.events.InitializationInput;
import software.amazon.kinesis.lifecycle.events.LeaseLostInput;
import software.amazon.kinesis.lifecycle.events.ProcessRecordsInput;
import software.amazon.kinesis.lifecycle.events.ShardEndedInput;
import software.amazon.kinesis.lifecycle.events.ShutdownRequestedInput;

import software.amazon.kinesis.processor.ShardRecordProcessor;
import software.amazon.kinesis.processor.ShardRecordProcessorFactory;
import software.amazon.kinesis.retrieval.polling.PollingConfig;

/**
 * This class will run a simple app that uses the KCL to read data and uses the AWS SDK to
 publish data.
 * Before running this program you must first create a Kinesis stream through the AWS
 console or AWS SDK.
 */
public class SampleSingle {
```

```
   private static final Logger log = LoggerFactory.getLogger(SampleSingle.class);

   /**
    * Invoke the main method with 2 args: the stream name and (optionally) the region.
    * Verifies valid inputs and then starts running the app.
    */
   public static void main(String... args) {
       if (args.length < 1) {
           log.error("At a minimum, the stream name is required as the first argument. The
Region may be specified as the second argument.");
           System.exit(1);
       }

       String streamName = args[0];
       String region = null;
       if (args.length > 1) {
           region = args[1];
       }

       new SampleSingle(streamName, region).run();
   }

   private final String streamName;
   private final Region region;
   private final KinesisAsyncClient kinesisClient;

   /**
    * Constructor sets streamName and region. It also creates a KinesisClient object to
send data to Kinesis.
    * This KinesisClient is used to send dummy data so that the consumer has something to
read; it is also used
    * indirectly by the KCL to handle the consumption of the data.
    */
   private SampleSingle(String streamName, String region) {
       this.streamName = streamName;
       this.region = Region.of(ObjectUtils.firstNonNull(region, "us-east-2"));
       this.kinesisClient =
KinesisClientUtil.createKinesisAsyncClient(KinesisAsyncClient.builder().region(this.region));
   }

   private void run() {

       /**
        * Sends dummy data to Kinesis. Not relevant to consuming the data with the KCL
        */
       ScheduledExecutorService producerExecutor =
Executors.newSingleThreadScheduledExecutor();
       ScheduledFuture<?> producerFuture =
producerExecutor.scheduleAtFixedRate(this::publishRecord, 10, 1, TimeUnit.SECONDS);

       /**
        * Sets up configuration for the KCL, including DynamoDB and CloudWatch
dependencies. The final argument, a
        * ShardRecordProcessorFactory, is where the logic for record processing lives, and
is located in a private
        * class below.
        */
       DynamoDbAsyncClient dynamoClient =
DynamoDbAsyncClient.builder().region(region).build();
       CloudWatchAsyncClient cloudWatchClient =
CloudWatchAsyncClient.builder().region(region).build();
       ConfigsBuilder configsBuilder = new ConfigsBuilder(streamName, streamName,
kinesisClient, dynamoClient, cloudWatchClient, UUID.randomUUID().toString(), new
SampleRecordProcessorFactory());

       /**
```

```
        * The Scheduler (also called Worker in earlier versions of the KCL) is the entry
point to the KCL. This
        * instance is configured with defaults provided by the ConfigsBuilder.
        */
       Scheduler scheduler = new Scheduler(
               configsBuilder.checkpointConfig(),
               configsBuilder.coordinatorConfig(),
               configsBuilder.leaseManagementConfig(),
               configsBuilder.lifecycleConfig(),
               configsBuilder.metricsConfig(),
               configsBuilder.processorConfig(),
               configsBuilder.retrievalConfig().retrievalSpecificConfig(new
PollingConfig(streamName, kinesisClient))
       );

       /**
        * Kickoff the Scheduler. Record processing of the stream of dummy data will
continue indefinitely
        * until an exit is triggered.
        */
       Thread schedulerThread = new Thread(scheduler);
       schedulerThread.setDaemon(true);
       schedulerThread.start();

       /**
        * Allows termination of app by pressing Enter.
        */
       System.out.println("Press enter to shutdown");
       BufferedReader reader = new BufferedReader(new InputStreamReader(System.in));
       try {
           reader.readLine();
       } catch (IOException ioex) {
           log.error("Caught exception while waiting for confirm. Shutting down.", ioex);
       }

       /**
        * Stops sending dummy data.
        */
       log.info("Cancelling producer and shutting down executor.");
       producerFuture.cancel(true);
       producerExecutor.shutdownNow();

       /**
        * Stops consuming data. Finishes processing the current batch of data already
received from Kinesis
        * before shutting down.
        */
       Future<Boolean> gracefulShutdownFuture = scheduler.startGracefulShutdown();
       log.info("Waiting up to 20 seconds for shutdown to complete.");
       try {
           gracefulShutdownFuture.get(20, TimeUnit.SECONDS);
       } catch (InterruptedException e) {
           log.info("Interrupted while waiting for graceful shutdown. Continuing.");
       } catch (ExecutionException e) {
           log.error("Exception while executing graceful shutdown.", e);
       } catch (TimeoutException e) {
           log.error("Timeout while waiting for shutdown.  Scheduler may not have
exited.");
       }
       log.info("Completed, shutting down now.");
   }

   /**
    * Sends a single record of dummy data to Kinesis.
    */
   private void publishRecord() {
```

```
        PutRecordRequest request = PutRecordRequest.builder()
                .partitionKey(RandomStringUtils.randomAlphabetic(5, 20))
                .streamName(streamName)
                .data(SdkBytes.fromByteArray(RandomUtils.nextBytes(10)))
                .build();
        try {
            kinesisClient.putRecord(request).get();
        } catch (InterruptedException e) {
            log.info("Interrupted, assuming shutdown.");
        } catch (ExecutionException e) {
            log.error("Exception while sending data to Kinesis. Will try again next
cycle.", e);
        }
    }

    private static class SampleRecordProcessorFactory implements
ShardRecordProcessorFactory {
        public ShardRecordProcessor shardRecordProcessor() {
            return new SampleRecordProcessor();
        }
    }

    /**
     * The implementation of the ShardRecordProcessor interface is where the heart of the
record processing logic lives.
     * In this example all we do to 'process' is log info about the records.
     */
    private static class SampleRecordProcessor implements ShardRecordProcessor {

        private static final String SHARD_ID_MDC_KEY = "ShardId";

        private static final Logger log =
LoggerFactory.getLogger(SampleRecordProcessor.class);

        private String shardId;

        /**
         * Invoked by the KCL before data records are delivered to the ShardRecordProcessor
instance (via
         * processRecords). In this example we do nothing except some logging.
         *
         * @param initializationInput Provides information related to initialization.
         */
        public void initialize(InitializationInput initializationInput) {
            shardId = initializationInput.shardId();
            MDC.put(SHARD_ID_MDC_KEY, shardId);
            try {
                log.info("Initializing @ Sequence: {}",
initializationInput.extendedSequenceNumber());
            } finally {
                MDC.remove(SHARD_ID_MDC_KEY);
            }
        }

        /**
         * Handles record processing logic. The Amazon Kinesis Client Library will invoke
this method to deliver
         * data records to the application. In this example we simply log our records.
         *
         * @param processRecordsInput Provides the records to be processed as well as
information and capabilities
         *                            related to them (e.g. checkpointing).
         */
        public void processRecords(ProcessRecordsInput processRecordsInput) {
            MDC.put(SHARD_ID_MDC_KEY, shardId);
            try {
```

```
                log.info("Processing {} record(s)", processRecordsInput.records().size());
                processRecordsInput.records().forEach(r -> log.info("Processing record pk:
{} -- Seq: {}", r.partitionKey(), r.sequenceNumber()));
            } catch (Throwable t) {
                log.error("Caught throwable while processing records. Aborting.");
                Runtime.getRuntime().halt(1);
            } finally {
                MDC.remove(SHARD_ID_MDC_KEY);
            }
        }

        /** Called when the lease tied to this record processor has been lost. Once the
lease has been lost,
         * the record processor can no longer checkpoint.
         *
         * @param leaseLostInput Provides access to functions and data related to the loss
of the lease.
         */
        public void leaseLost(LeaseLostInput leaseLostInput) {
            MDC.put(SHARD_ID_MDC_KEY, shardId);
            try {
                log.info("Lost lease, so terminating.");
            } finally {
                MDC.remove(SHARD_ID_MDC_KEY);
            }
        }

        /**
         * Called when all data on this shard has been processed. Checkpointing must occur
in the method for record
         * processing to be considered complete; an exception will be thrown otherwise.
         *
         * @param shardEndedInput Provides access to a checkpointer method for completing
processing of the shard.
         */
        public void shardEnded(ShardEndedInput shardEndedInput) {
            MDC.put(SHARD_ID_MDC_KEY, shardId);
            try {
                log.info("Reached shard end checkpointing.");
                shardEndedInput.checkpointer().checkpoint();
            } catch (ShutdownException | InvalidStateException e) {
                log.error("Exception while checkpointing at shard end. Giving up.", e);
            } finally {
                MDC.remove(SHARD_ID_MDC_KEY);
            }
        }

        /**
         * Invoked when Scheduler has been requested to shut down (i.e. we decide to stop
running the app by pressing
         * Enter). Checkpoints and logs the data a final time.
         *
         * @param shutdownRequestedInput Provides access to a checkpointer, allowing a
record processor to checkpoint
         *                               before the shutdown is completed.
         */
        public void shutdownRequested(ShutdownRequestedInput shutdownRequestedInput) {
            MDC.put(SHARD_ID_MDC_KEY, shardId);
            try {
                log.info("Scheduler is shutting down, checkpointing.");
                shutdownRequestedInput.checkpointer().checkpoint();
            } catch (ShutdownException | InvalidStateException e) {
                log.error("Exception while checkpointing at requested shutdown. Giving
up.", e);
            } finally {
                MDC.remove(SHARD_ID_MDC_KEY);
```

```
            }
        }
    }

}
```

Desenvolver um consumidor da Kinesis Client Library em Python

Você pode usar a Kinesis Client Library (KCL) para criar aplicativos que processam dados dos streamings de dados do Kinesis. A Kinesis Client Library está disponível em vários idiomas. Este tópico discute Python.

O KCL é uma biblioteca Java; o suporte para idiomas diferentes do Java é fornecido usando uma interface multilíngue chamadaMultiLangDaemon do. Este daemon é baseado em Java e é executado em segundo plano quando você estiver usando uma linguagem KCL diferente de Java. Portanto, se você instalar o KCL para Python e escrever o aplicativo de consumidor inteiramente em Python, ainda precisará do Java instalado no sistema por causa daMultiLangDaemon do. Além disso,MultiLangO daemon tem algumas configurações padrão que você pode personalizar para o caso de uso. Por exemplo, aAWSRegião à qual ele se conecta. Para obter mais informações sobre aMultiLangDaemon doGitHubSe preferir, acesse oKCLMultiLangProjeto Daemon do.

Para baixar o Python KCL deGitHubSe preferir, acesseKinesis Client Library (Python). Para fazer download do código de exemplo para um aplicativo de consumidor do Python KCL, acesse aProjeto de amostra KCL para Pythonna página doGitHub.

Você precisa concluir as tarefas a seguir ao implementar um aplicativo de consumidor da KCL no Python:

Tarefas

- Implemente oRecordProcessorClasse Methods (Métodos) (p. 144)
- Modificar as propriedades de configuração (p. 146)

Implemente oRecordProcessorClasse Methods (Métodos)

A classe `RecordProcess` precisa estender a classe `RecordProcessorBase` para implementar os seguintes métodos:

```
initialize
process_records
shutdown_requested
```

Este exemplo fornece implementações que você pode usar como ponto de partida.

```
#!/usr/bin/env python

# Copyright 2014-2015 Amazon.com, Inc. or its affiliates. All Rights Reserved.
#
# Licensed under the Amazon Software License (the "License").
# You may not use this file except in compliance with the License.
# A copy of the License is located at
#
# http://aws.amazon.com/asl/
#
# or in the "license" file accompanying this file. This file is distributed
# on an "AS IS" BASIS, WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either
# express or implied. See the License for the specific language governing
# permissions and limitations under the License.

from __future__ import print_function
```

```
import sys
import time

from amazon_kclpy import kcl
from amazon_kclpy.v3 import processor


class RecordProcessor(processor.RecordProcessorBase):
    """
    A RecordProcessor processes data from a shard in a stream. Its methods will be called
 with this pattern:

    * initialize will be called once
    * process_records will be called zero or more times
    * shutdown will be called if this MultiLangDaemon instance loses the lease to this
 shard, or the shard ends due
        a scaling change.
    """
    def __init__(self):
        self._SLEEP_SECONDS = 5
        self._CHECKPOINT_RETRIES = 5
        self._CHECKPOINT_FREQ_SECONDS = 60
        self._largest_seq = (None, None)
        self._largest_sub_seq = None
        self._last_checkpoint_time = None

    def log(self, message):
        sys.stderr.write(message)

    def initialize(self, initialize_input):
        """
        Called once by a KCLProcess before any calls to process_records

        :param amazon_kclpy.messages.InitializeInput initialize_input: Information about
 the lease that this record
            processor has been assigned.
        """
        self._largest_seq = (None, None)
        self._last_checkpoint_time = time.time()

    def checkpoint(self, checkpointer, sequence_number=None, sub_sequence_number=None):
        """
        Checkpoints with retries on retryable exceptions.

        :param amazon_kclpy.kcl.Checkpointer checkpointer: the checkpointer provided to
 either process_records
            or shutdown
        :param str or None sequence_number: the sequence number to checkpoint at.
        :param int or None sub_sequence_number: the sub sequence number to checkpoint at.
        """
        for n in range(0, self._CHECKPOINT_RETRIES):
            try:
                checkpointer.checkpoint(sequence_number, sub_sequence_number)
                return
            except kcl.CheckpointError as e:
                if 'ShutdownException' == e.value:
                    #
                    # A ShutdownException indicates that this record processor should be
 shutdown. This is due to
                    # some failover event, e.g. another MultiLangDaemon has taken the lease
 for this shard.
                    #
                    print('Encountered shutdown exception, skipping checkpoint')
                    return
                elif 'ThrottlingException' == e.value:
```

```
                    #
                    # A ThrottlingException indicates that one of our dependencies is is
over burdened, e.g. too many
                    # dynamo writes. We will sleep temporarily to let it recover.
                    #
                    if self._CHECKPOINT_RETRIES - 1 == n:
                        sys.stderr.write('Failed to checkpoint after {n} attempts, giving
up.\n'.format(n=n))
                        return
                    else:
                        print('Was throttled while checkpointing, will attempt again in {s}
seconds'
                              .format(s=self._SLEEP_SECONDS))
                elif 'InvalidStateException' == e.value:
                    sys.stderr.write('MultiLangDaemon reported an invalid state while
checkpointing.\n')
                else:  # Some other error
                    sys.stderr.write('Encountered an error while checkpointing, error was
{e}.\n'.format(e=e))
            time.sleep(self._SLEEP_SECONDS)

    def process_record(self, data, partition_key, sequence_number, sub_sequence_number):
        """
        Called for each record that is passed to process_records.

        :param str data: The blob of data that was contained in the record.
        :param str partition_key: The key associated with this recod.
        :param int sequence_number: The sequence number associated with this record.
        :param int sub_sequence_number: the sub sequence number associated with this
record.
        """
        ####################################
        # Insert your processing logic here
        ####################################
        self.log("Record (Partition Key: {pk}, Sequence Number: {seq}, Subsequence Number:
{sseq}, Data Size: {ds}"
                 .format(pk=partition_key, seq=sequence_number, sseq=sub_sequence_number,
ds=len(data)))

    def should_update_sequence(self, sequence_number, sub_sequence_number):
        """
        Determines whether a new larger sequence number is available

        :param int sequence_number: the sequence number from the current record
        :param int sub_sequence_number: the sub sequence number from the current record
        :return boolean: true if the largest sequence should be updated, false otherwise
        """
        return self._largest_seq == (None, None) or sequence_number > self._largest_seq[0]
or \
            (sequence_number == self._largest_seq[0] and sub_sequence_number >
self._largest_seq[1])

    def process_records(self, process_records_input):
        """
        Called by a KCLProcess with a list of records to be processed and a checkpointer
which accepts sequence numbers
        from the records to indicate where in the stream to checkpoint.

        :param amazon_kclpy.messages.ProcessRecordsInput process_records_input: the
records, and metadata about the
            records.
        """
        try:
            for record in process_records_input.records:
                data = record.binary_data
                seq = int(record.sequence_number)
```

```
                sub_seq = record.sub_sequence_number
                key = record.partition_key
                self.process_record(data, key, seq, sub_seq)
                if self.should_update_sequence(seq, sub_seq):
                    self._largest_seq = (seq, sub_seq)

            #
            # Checkpoints every self._CHECKPOINT_FREQ_SECONDS seconds
            #
            if time.time() - self._last_checkpoint_time > self._CHECKPOINT_FREQ_SECONDS:
                self.checkpoint(process_records_input.checkpointer,
 str(self._largest_seq[0]), self._largest_seq[1])
                self._last_checkpoint_time = time.time()

        except Exception as e:
            self.log("Encountered an exception while processing records. Exception was
 {e}\n".format(e=e))

    def lease_lost(self, lease_lost_input):
        self.log("Lease has been lost")

    def shard_ended(self, shard_ended_input):
        self.log("Shard has ended checkpointing")
        shard_ended_input.checkpointer.checkpoint()

    def shutdown_requested(self, shutdown_requested_input):
        self.log("Shutdown has been requested, checkpointing.")
        shutdown_requested_input.checkpointer.checkpoint()


if __name__ == "__main__":
    kcl_process = kcl.KCLProcess(RecordProcessor())
    kcl_process.run()
```

Modificar as propriedades de configuração

O exemplo fornece valores padrão para as propriedades de configuração, conforme mostrado no script a seguir. Você pode substituir qualquer uma dessas propriedades por seus próprios valores.

```
# The script that abides by the multi-language protocol. This script will
# be executed by the MultiLangDaemon, which will communicate with this script
# over STDIN and STDOUT according to the multi-language protocol.
executableName = sample_kclpy_app.py

# The name of an Amazon Kinesis stream to process.
streamName = words

# Used by the KCL as the name of this application. Will be used as the name
# of an Amazon DynamoDB table which will store the lease and checkpoint
# information for workers with this application name
applicationName = PythonKCLSample

# Users can change the credentials provider the KCL will use to retrieve credentials.
# The DefaultAWSCredentialsProviderChain checks several other providers, which is
# described here:
# http://docs.aws.amazon.com/AWSJavaSDK/latest/javadoc/com/amazonaws/auth/
DefaultAWSCredentialsProviderChain.html
AWSCredentialsProvider = DefaultAWSCredentialsProviderChain

# Appended to the user agent of the KCL. Does not impact the functionality of the
# KCL in any other way.
processingLanguage = python/2.7

# Valid options at TRIM_HORIZON or LATEST.
```

```
# See http://docs.aws.amazon.com/kinesis/latest/APIReference/
API_GetShardIterator.html#API_GetShardIterator_RequestSyntax
initialPositionInStream = TRIM_HORIZON

# The following properties are also available for configuring the KCL Worker that is
 created
# by the MultiLangDaemon.

# The KCL defaults to us-east-1
#regionName = us-east-1

# Fail over time in milliseconds. A worker which does not renew it's lease within this time
 interval
# will be regarded as having problems and it's shards will be assigned to other workers.
# For applications that have a large number of shards, this msy be set to a higher number
 to reduce
# the number of DynamoDB IOPS required for tracking leases
#failoverTimeMillis = 10000

# A worker id that uniquely identifies this worker among all workers using the same
 applicationName
# If this isn't provided a MultiLangDaemon instance will assign a unique workerId to
 itself.
#workerId =

# Shard sync interval in milliseconds - e.g. wait for this long between shard sync tasks.
#shardSyncIntervalMillis = 60000

# Max records to fetch from Kinesis in a single GetRecords call.
#maxRecords = 10000

# Idle time between record reads in milliseconds.
#idleTimeBetweenReadsInMillis = 1000

# Enables applications flush/checkpoint (if they have some data "in progress", but don't
 get new data for while)
#callProcessRecordsEvenForEmptyRecordList = false

# Interval in milliseconds between polling to check for parent shard completion.
# Polling frequently will take up more DynamoDB IOPS (when there are leases for shards
 waiting on
# completion of parent shards).
#parentShardPollIntervalMillis = 10000

# Cleanup leases upon shards completion (don't wait until they expire in Kinesis).
# Keeping leases takes some tracking/resources (e.g. they need to be renewed, assigned), so
 by default we try
# to delete the ones we don't need any longer.
#cleanupLeasesUponShardCompletion = true

# Backoff time in milliseconds for Amazon Kinesis Client Library tasks (in the event of
 failures).
#taskBackoffTimeMillis = 500

# Buffer metrics for at most this long before publishing to CloudWatch.
#metricsBufferTimeMillis = 10000

# Buffer at most this many metrics before publishing to CloudWatch.
#metricsMaxQueueSize = 10000

# KCL will validate client provided sequence numbers with a call to Amazon Kinesis before
 checkpointing for calls
# to RecordProcessorCheckpointer#checkpoint(String) by default.
#validateSequenceNumberBeforeCheckpointing = true

# The maximum number of active threads for the MultiLangDaemon to permit.
```

```
# If a value is provided then a FixedThreadPool is used with the maximum
# active threads set to the provided value. If a non-positive integer or no
# value is provided a CachedThreadPool is used.
#maxActiveThreads = 0
```

Nome do aplicativo

A KCL exige um nome de aplicativo que seja exclusivo entre seus aplicativos e entre as tabelas do Amazon DynamoDB na mesma região. Ela usa o valor de configuração de nome de aplicativo das seguintes formas:

- Presume-se que todos os operadores associados a esse nome de aplicativo estejam trabalhando juntos no mesmo streaming. Esses operadores podem ser distribuídos entre várias instâncias. Se você executar uma instância adicional do mesmo código de aplicativo, mas com um nome de aplicativo diferente, a KCL trata a segunda instância como um aplicativo totalmente separado que também opera no mesmo stream.
- A KCL cria uma tabela do DynamoDB com o nome do aplicativo e usa essa tabela para manter informações de estado (como pontos de verificação e mapeamento operador-estilhaço) para o aplicativo. Cada aplicativo tem sua própria tabela do DynamoDB. Para obter mais informações, consulte Usando uma tabela de leasing para rastrear os fragmentos processados pelo aplicativo do consumidor KCL (p. 123).

Credenciais

Você deve fazer o seuAWSAs credenciais disponíveis para um dos provedores de credenciais docadeia de provedores de credenciais padrão. Você pode usar a propriedade `AWSCredentialsProvider` para definir um provedor de credenciais. Se você executar o aplicativo de consumidor em uma instância do Amazon EC2, recomendamos que configure essa instância com uma função do IAM.AWSAs credenciais que refletem as permissões associadas à função do IAM são disponibilizadas aos aplicativos na instância por meio de metadados da instância. Essa é a maneira mais segura de gerenciar credenciais para um aplicativo de consumidor em execução em uma instância do EC2.

Desenvolver consumidores personalizados com taxa de transferência compartilhada usando o AWS SDK for Java

Um dos métodos para desenvolver consumidores personalizados do Kinesis Data Streams compartilhados por toda parte é usar as APIs do Amazon Kinesis Data Streams. Esta seção descreve o uso das APIs do Kinesis Data Streams com aAWSSDK for Java. O código de exemplo Java nesta seção demonstra como realizar operações básicas da API do KDS e está dividido logicamente por tipo de operação.

Esses exemplos não representam um código pronto para produção. Eles não verificam todas as exceções possíveis nem levam em conta todas as considerações de segurança ou desempenho possíveis.

Você pode chamar as APIs do Kinesis Data Streams usando outras linguagens de programação diferentes. Para obter mais informações sobre todos os disponíveisAWSSDKs, consulteComece a desenvolver com a Amazon Web Services.

> **Important**
>
> O método recomendado para desenvolver consumidores personalizados do Kinesis Data Streams com compartilhados em todo o é usar a Kinesis Client Library (KCL). A KCL ajuda você a consumir e processar dados de um stream de dados do Kinesis cuidando de muitas das tarefas complexas associadas à computação distribuída. Para obter mais informações, consulteDesenvolver consumidores personalizados com taxa de transferência compartilhada usando a KCL.

Tópicos

Como obter dados de um stream

As APIs do Kinesis Data Streams incluem a`getShardIterator`e`getRecords`métodos que você pode chamar para recuperar registros de um fluxo de dados. Esse é o modelo de extração, em que seu código extrai registros de dados diretamente dos estilhaços do stream de dados.

> **Important**
>
> Recomendamos usar o suporte do processador de registros fornecido pela KCL para recuperar registros de seus streams de dados. Esse é o modelo de envio, em que você implementa o código que processa os dados. O KCL recupera registros de dados do stream de dados e os fornece e entrega ao código de seu aplicativo. Além disso, a KCL fornece as funcionalidades de failover, recuperação e balanceamento de carga. Para obter mais informações, consulteDesenvolver consumidores personalizados com taxa de transferência compartilhada usando a KCL.

No entanto, em alguns casos, você pode preferir usar as APIs do Kinesis Data Streams. Por exemplo, para implementar ferramentas personalizadas para monitorar ou depurar seus streams de dados.

> **Important**
>
> O Kinesis Data Streams aceita alterações feitas no período de retenção de registros de dados do stream de dados. Para obter mais informações, consulte Alterar o período de retenção de dados (p. 84).

Como usar iteradores de estilhaços

Você recupera registros do stream por estilhaço. Para cada estilhaço e para cada lote de registros que recupera desse estilhaço, você precisa obter um iterador de estilhaços. O iterador de estilhaços é usado no objeto `getRecordsRequest` para especificar o estilhaço a partir do qual os registros devem ser recuperados. O tipo associado ao iterador de estilhaços determina o ponto no estilhaço a partir do qual os registros devem ser recuperados (veja mais à frente nesta seção para obter mais detalhes). Para trabalhar com o iterador de estilhaços, você precisa recuperar o estilhaço, conforme abordado em DescribeStreamAPI - Preterido (p. 78).

Obtenha o iterador de estilhaços inicial usando o método `getShardIterator`. Obtenha iteradores de estilhaços para obter mais lotes de registros usando o método `getNextShardIterator` do objeto`getRecordsResult` retornado pelo método `getRecords`. Um iterador de estilhaços é válido por 5 minutos. Se usar um iterador de estilhaços enquanto ele for válido, você receberá um novo. Cada iterador de estilhaços permanecerá válido por 5 minutos, mesmo depois de ser usado.

Para obter o iterador de estilhaços inicial, instancie `GetShardIteratorRequest` e passe-o ao método `getShardIterator`. Para configurar a solicitação, especifique o stream e o ID do estilhaço. Para obter informações sobre como obter os streams em seuAWSconta, consulteListar streams (p. 75). Para obter informações sobre como obter os estilhaços em um stream, consulte DescribeStreamAPI - Preterido (p. 78).

```
String shardIterator;
GetShardIteratorRequest getShardIteratorRequest = new GetShardIteratorRequest();
getShardIteratorRequest.setStreamName(myStreamName);
getShardIteratorRequest.setShardId(shard.getShardId());
```

```
getShardIteratorRequest.setShardIteratorType("TRIM_HORIZON");

GetShardIteratorResult getShardIteratorResult =
 client.getShardIterator(getShardIteratorRequest);
shardIterator = getShardIteratorResult.getShardIterator();
```

Esse código de exemplo especifica `TRIM_HORIZON` como o tipo de iterador ao obter o iterador de estilhaços inicial. Esse tipo de iterador significa que os registros devem ser retornados a partir do primeiro registro adicionado ao estilhaço, em vez de começar com o registro adicionado mais recentemente, também conhecido como agorjeta. Estes são tipos de iterador possíveis:

- `AT_SEQUENCE_NUMBER`
- `AFTER_SEQUENCE_NUMBER`
- `AT_TIMESTAMP`
- `TRIM_HORIZON`
- `LATEST`

Para obter mais informações, consulteShardIteratorTipo.

Alguns tipos de iterador exigem que você especifique um número de sequência, além do tipo. Por exemplo:

```
getShardIteratorRequest.setShardIteratorType("AT_SEQUENCE_NUMBER");
getShardIteratorRequest.setStartingSequenceNumber(specialSequenceNumber);
```

Depois de obter um registro usando `getRecords`, você pode conseguir o número de sequência do registro chamando o método `getSequenceNumber` do registro.

```
record.getSequenceNumber()
```

Além disso, o código que adiciona registros ao stream de dados pode obter o número de sequência de um registro adicional chamando `getSequenceNumber` no resultado de `putRecord`.

```
lastSequenceNumber = putRecordResult.getSequenceNumber();
```

Você pode usar números de sequência para garantir estritamente o ordenamento crescente do registros. Para obter mais informações, consulte o exemplo de código em PutRecordExemplo (p. 104).

O uso doGetRecords

Depois que você obtiver o iterador de estilhaços, instancie um objeto `GetRecordsRequest`. Especifique o iterador para a solicitação usando o método `setShardIterator`.

Opcionalmente, você também pode definir o número de registros a recuperar usando o método `setLimit`. O número de registros retornados por `getRecords` sempre é igual ou menor que esse limite. Se você não especificar esse limite,`getRecords`retorna 10 MB de registros recuperados. O código de exemplo a seguir define esse limite para 25 registros.

Se nenhum registro for retornado, isso significa que não há registros de dados disponíveis atualmente nesse estilhaço no número de sequência referenciado pelo iterador de estilhaços. Nessa situação, o aplicativo deve aguardar um tempo adequado para as fontes de dados do streaming, mas de pelo menos 1 segundo. Em seguida, tente obter os dados do estilhaço novamente usando o iterador de estilhaços retornado pela chamada anterior a `getRecords`. Há uma latência de aproximadamente 3 segundos entre o momento em que um registro é adicionado ao streaming e o momento em que ele está disponível em `getRecords`.

Passe o `getRecordsRequest` para o método `getRecords` e capture o valor retornado como um objeto `getRecordsResult`. Para obter os registros de dados, chame o método `getRecords` no objeto `getRecordsResult`.

```
GetRecordsRequest getRecordsRequest = new GetRecordsRequest();
getRecordsRequest.setShardIterator(shardIterator);
getRecordsRequest.setLimit(25);

GetRecordsResult getRecordsResult = client.getRecords(getRecordsRequest);
List<Record> records = getRecordsResult.getRecords();
```

Para preparar-se para outra chamada para `getRecords`, obtenha o próximo iterador de estilhaços de `getRecordsResult`.

```
shardIterator = getRecordsResult.getNextShardIterator();
```

Para obter os melhores resultados, aguarde pelo menos 1 segundo (1.000 milissegundos) entre as chamadas para `getRecords` a fim de evitar exceder o limite na frequência de `getRecords`.

```
try {
  Thread.sleep(1000);
}
catch (InterruptedException e) {}
```

Normalmente, você deve chamar `getRecords` em um loop, mesmo se estiver recuperando um único registro em um cenário de teste. Uma única chamada para `getRecords` pode retornar uma lista de registros vazia, mesmo quando o estilhaço contém mais registros em números de sequência subsequentes. Quando isso ocorre, o `NextShardIterator` retornado com a lista de registros vazia faz referência a um número de sequência subsequente no estilhaço, e as chamadas posteriores a `getRecords` acabam retornando os registros. O exemplo a seguir demonstra o uso de um loop.

Exemplo: getRecords

O código de exemplo a seguir reflete as dicas de `getRecords` nesta seção, inclusive chamadas em um loop.

```
// Continuously read data records from a shard
List<Record> records;

while (true) {

  // Create a new getRecordsRequest with an existing shardIterator
  // Set the maximum records to return to 25

  GetRecordsRequest getRecordsRequest = new GetRecordsRequest();
  getRecordsRequest.setShardIterator(shardIterator);
  getRecordsRequest.setLimit(25);

  GetRecordsResult result = client.getRecords(getRecordsRequest);

  // Put the result into record list. The result can be empty.
  records = result.getRecords();
```

```
  try {
    Thread.sleep(1000);
  }
  catch (InterruptedException exception) {
    throw new RuntimeException(exception);
  }

  shardIterator = result.getNextShardIterator();
}
```

Se você estiver usando a Kinesis Client Library, ela poderá fazer várias chamadas antes de retornar os dados. Esse comportamento é projetado e não indica um problema com a KCL ou seus dados.

Como adaptar a uma refragmentação

Se`getRecordsResult.getNextShardIterator`retorna`null`, indica que ocorreu uma divisão ou fusão de fragmento que envolveu esse fragmento. Este fragmento está agora em um`CLOSED`state e você leu todos os registros de dados disponíveis deste fragmento.

Nesse cenário, você pode usar`getRecordsResult.childShards`Para aprender sobre os novos estilhaços filhos do estilhaço que está sendo processado que foram criados pela divisão ou fusão. Para obter mais informações, consulteChildShard.

No caso de uma divisão, os dois novos estilhaços têm `parentShardId` igual ao ID do estilhaço que você estava processando anteriormente. O valor de `adjacentParentShardId` dos dois estilhaços é `null`.

No caso de uma fusão, o único estilhaço novo criado tem `parentShardId` igual ao ID de um dos estilhaços pai e `adjacentParentShardId` igual ao ID do outro estilhaço. Seu aplicativo já leu todos os dados de um desses estilhaços. Esse é o estilhaço para o qual `getRecordsResult.getNextShardIterator` retornou `null`. Se a ordem dos dados for importante para o aplicativo, você deverá garantir que ele também leia todos os dados de outro estilhaço pai antes de ler qualquer dado novo de estilhaço filho criado pela fusão.

Se estiver usando vários processadores para recuperar dados do streaming (digamos, um processador por estilhaço) e ocorrer uma divisão ou fusão de estilhaços, você deverá aumentar ou diminuir o número de processadores para se adaptar à alteração no número de estilhaços.

Para obter mais informações sobre a refragmentação, incluindo uma discussão sobre estados de estilhaços (como `CLOSED`), consulte Reestilhaçar um stream (p. 79).

Interagir com dados usando aAWSRegistro de esquemas de Glue

Você pode integrar seus fluxos de dados do Kinesis com oAWSRegistro de esquema de Glue. OAWSO registro de esquemas de Glue permite detectar, controlar e evoluir centralmente esquemas, ao mesmo tempo em que garante que os dados produzidos sejam validados continuamente por um esquemas registrados. O esquema define a estrutura e o formato de um registro de dados. Um esquema é uma especificação versionada para publicação, consumo ou armazenamento de dados confiáveis. OAWSO Glue Schema Registry permite melhorarend-to-endqualidade de dados e governança de dados em seus aplicativos de streaming. Para obter mais informações, consulteAWSRegistro de esquemas de Glue. Uma das maneiras de configurar essa integração é através do`GetRecords`A API do Kinesis Data Streams disponível noAWSSDK do Java.

Para obter instruções detalhadas sobre como configurar a integração do Kinesis Data Streams com o registro de esquemas do usando a`GetRecords`As APIs do Kinesis Data Streams, consulte a seção “Interagir com dados usando as APIs do Kinesis Data Streams” emCaso de uso: Integrar o Amazon Kinesis Data Streams com aAWSRegistro de esquemas de Glue.

Desenvolver consumidores personalizados com taxa de transferência dedicada (distribuição avançada)

No Amazon Kinesis Data Streams, você pode criar consumidores que usam um recurso chamadofan-out aprimorado. Esse recurso permite que consumidores recebam registros de um streaming com taxa de transferência de até 2 MB de dados por segundo por estilhaço. Essa taxa de transferência é dedicada, o que significa que consumidores que usam divisão avançada não precisam lidar com outros clientes que estejam recebendo dados do streaming. O Kinesis Data Streams envia registros de dados do streaming para consumidores que usam a distribuição avançada. Portanto, esses consumidores não precisam sondar dados.

> **Important**
>
> Você pode registrar até vinte consumidores por streaming para usar distribuição avançada.

O diagrama a seguir mostra a arquitetura de distribuição avançada. Se você usar a versão 2.0 ou posterior da Amazon Kinesis Client Library (KCL) para criar um consumidor, a KCL configura o consumidor para usar a distribuição avançada a fim de receber dados de todos os estilhaços do streaming. Se usar a API para criar um consumidor que use distribuição avançada, você poderá se inscrever em estilhaços individuais.

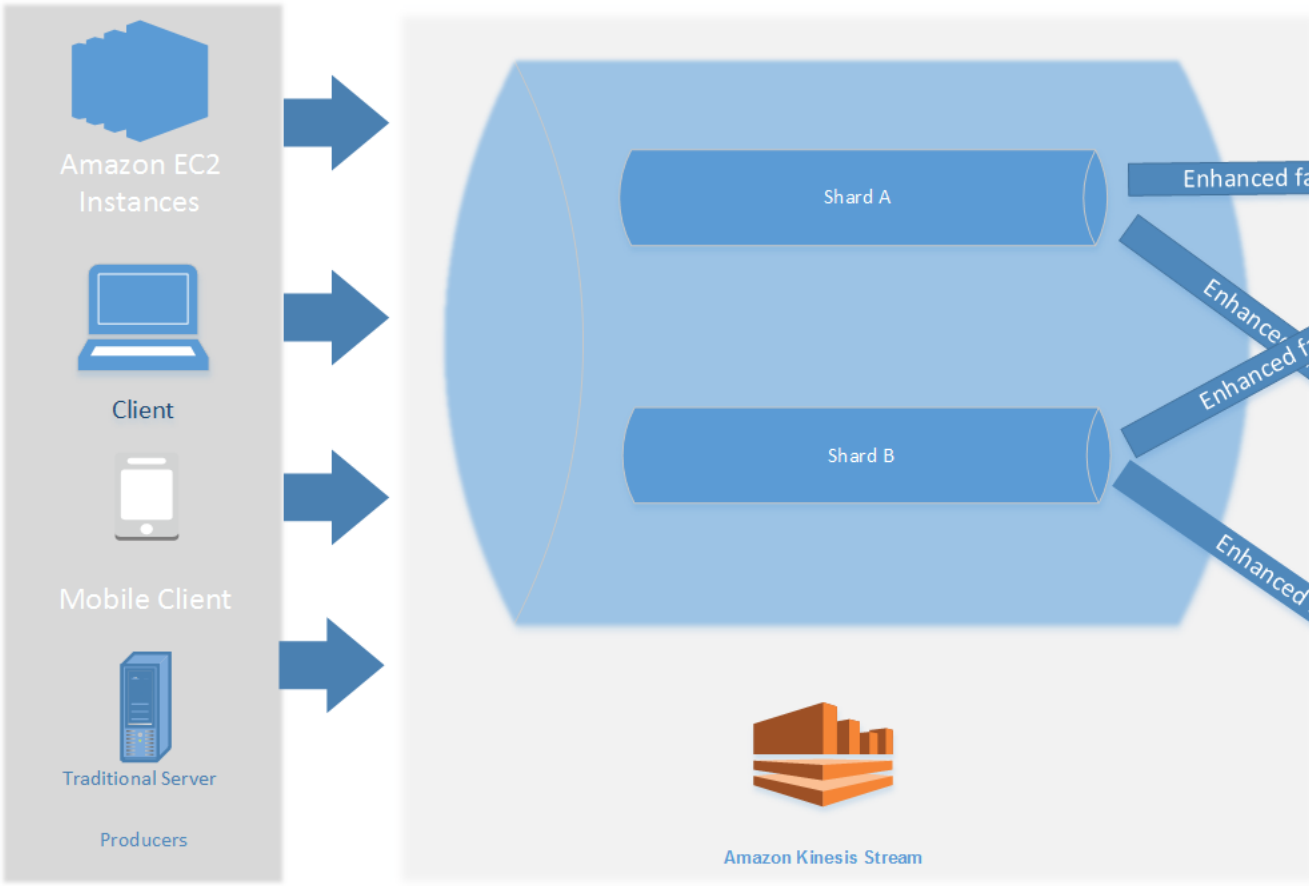

O diagrama mostra o seguinte:

- Um streaming com dois estilhaços.
- Dois consumidores que estão usando a distribuição avançada para receber dados do streaming: O consumidor X e o consumidor Y. Os dois consumidores estão inscritos em todos os estilhaços e em todos os registros do streaming. Se você usar a versão 2.0 ou posterior da KCL para criar um consumidor, a KCL inscreverá automaticamente esse consumidor em todos os estilhaços do streaming. Por outro lado, se usar a API para criar um consumidor, você poderá se inscrever em estilhaços individuais.
- Setas que representam as distribuições avançadas usadas pelos consumidores para receber dados do streaming. Uma distribuição avançada oferece até 2 MB/s de dados por estilhaço, independentemente de qualquer outro dado ou do número total de consumidores.

Tópicos

Desenvolver consumidores de distribuição avançada com o KCL 2.x

Consumidores que usamfan-out aprimoradoNo Amazon Kinesis Data Streams pode receber registros de um streaming de dados com taxa de transferência dedicada de até 2 MB de dados por segundo por estilhaço. Esse tipo de consumidor não precisa lidar com outros consumidores que estejam recebendo dados do streaming. Para obter mais informações, consulte Desenvolver consumidores personalizados com taxa de transferência dedicada (distribuição avançada) (p. 163).

Você pode usar a versão 2.0 ou posterior da Kinesis Client Library (KCL) para desenvolver aplicativos que usam a distribuição avançada para receber dados de streamings. A KCL inscreve automaticamente o aplicativo em todos os estilhaços de um streaming e garante que o aplicativo consumidor pode ler com um valor de taxa de transferência de 2 MB/s por estilhaço. Se você quiser usar o KCL sem ativar a saída avançada, consulteDesenvolver consumidores usando a Kinesis Client Library 2.0.

Tópicos

Desenvolver consumidores de distribuição avançada usando o KCL 2.x em Java

Você pode usar a versão 2.0 ou posterior da Kinesis Client Library (KCL) para desenvolver aplicativos no Amazon Kinesis Data Streams a fim de receber dados de streamings usando a distribuição avançada. O código a seguir mostra uma implementação de exemplo em Java de `ProcessorFactory` e `RecordProcessor`.

Recomendamos que você use `KinesisClientUtil` para criar `KinesisAsyncClient` e configurar `maxConcurrency` no `KinesisAsyncClient`.

> **Important**
>
> O Amazon Kinesis Client pode ter latência significativamente maior, a menos que você configure `KinesisAsyncClient` para ter um `maxConcurrency` alto o suficiente para permitir todas as concessões e usos adicionais do `KinesisAsyncClient`.

```
/*
 *  Copyright 2019 Amazon.com, Inc. or its affiliates. All Rights Reserved.
```

```
 *
 *  Licensed under the Amazon Software License (the "License").
 *  You may not use this file except in compliance with the License.
 *  A copy of the License is located at
 *
 *  http://aws.amazon.com/asl/
 *
 *  or in the "license" file accompanying this file. This file is distributed
 *  on an "AS IS" BASIS, WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either
 *  express or implied. See the License for the specific language governing
 *  permissions and limitations under the License.
 */

/*
 * Copyright 2019 Amazon.com, Inc. or its affiliates. All Rights Reserved.
 *
 * Licensed under the Apache License, Version 2.0 (the "License").
 * You may not use this file except in compliance with the License.
 * A copy of the License is located at
 *
 *     http://www.apache.org/licenses/LICENSE-2.0
 *
 * or in the "license" file accompanying this file. This file is distributed
 * on an "AS IS" BASIS, WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either
 * express or implied. See the License for the specific language governing
 * permissions and limitations under the License.
 */

import java.io.BufferedReader;
import java.io.IOException;
import java.io.InputStreamReader;
import java.util.UUID;
import java.util.concurrent.ExecutionException;
import java.util.concurrent.Executors;
import java.util.concurrent.Future;
import java.util.concurrent.ScheduledExecutorService;
import java.util.concurrent.ScheduledFuture;
import java.util.concurrent.TimeUnit;
import java.util.concurrent.TimeoutException;

import org.apache.commons.lang3.ObjectUtils;
import org.apache.commons.lang3.RandomStringUtils;
import org.apache.commons.lang3.RandomUtils;
import org.slf4j.Logger;
import org.slf4j.LoggerFactory;
import org.slf4j.MDC;

import software.amazon.awssdk.core.SdkBytes;
import software.amazon.awssdk.regions.Region;
import software.amazon.awssdk.services.cloudwatch.CloudWatchAsyncClient;
import software.amazon.awssdk.services.dynamodb.DynamoDbAsyncClient;
import software.amazon.awssdk.services.kinesis.KinesisAsyncClient;
import software.amazon.awssdk.services.kinesis.model.PutRecordRequest;
import software.amazon.kinesis.common.ConfigsBuilder;
import software.amazon.kinesis.common.KinesisClientUtil;
import software.amazon.kinesis.coordinator.Scheduler;
import software.amazon.kinesis.exceptions.InvalidStateException;
import software.amazon.kinesis.exceptions.ShutdownException;
import software.amazon.kinesis.lifecycle.events.InitializationInput;
import software.amazon.kinesis.lifecycle.events.LeaseLostInput;
import software.amazon.kinesis.lifecycle.events.ProcessRecordsInput;
import software.amazon.kinesis.lifecycle.events.ShardEndedInput;
import software.amazon.kinesis.lifecycle.events.ShutdownRequestedInput;
import software.amazon.kinesis.processor.ShardRecordProcessor;
import software.amazon.kinesis.processor.ShardRecordProcessorFactory;
```

```
public class SampleSingle {

    private static final Logger log = LoggerFactory.getLogger(SampleSingle.class);

    public static void main(String... args) {
        if (args.length < 1) {
            log.error("At a minimum, the stream name is required as the first argument. The
 Region may be specified as the second argument.");
            System.exit(1);
        }

        String streamName = args[0];
        String region = null;
        if (args.length > 1) {
            region = args[1];
        }

        new SampleSingle(streamName, region).run();
    }

    private final String streamName;
    private final Region region;
    private final KinesisAsyncClient kinesisClient;

    private SampleSingle(String streamName, String region) {
        this.streamName = streamName;
        this.region = Region.of(ObjectUtils.firstNonNull(region, "us-east-2"));
        this.kinesisClient =
 KinesisClientUtil.createKinesisAsyncClient(KinesisAsyncClient.builder().region(this.region));
    }

    private void run() {
        ScheduledExecutorService producerExecutor =
 Executors.newSingleThreadScheduledExecutor();
        ScheduledFuture<?> producerFuture =
 producerExecutor.scheduleAtFixedRate(this::publishRecord, 10, 1, TimeUnit.SECONDS);

        DynamoDbAsyncClient dynamoClient =
 DynamoDbAsyncClient.builder().region(region).build();
        CloudWatchAsyncClient cloudWatchClient =
 CloudWatchAsyncClient.builder().region(region).build();
        ConfigsBuilder configsBuilder = new ConfigsBuilder(streamName, streamName,
 kinesisClient, dynamoClient, cloudWatchClient, UUID.randomUUID().toString(), new
 SampleRecordProcessorFactory());

        Scheduler scheduler = new Scheduler(
                configsBuilder.checkpointConfig(),
                configsBuilder.coordinatorConfig(),
                configsBuilder.leaseManagementConfig(),
                configsBuilder.lifecycleConfig(),
                configsBuilder.metricsConfig(),
                configsBuilder.processorConfig(),
                configsBuilder.retrievalConfig()
        );

        Thread schedulerThread = new Thread(scheduler);
        schedulerThread.setDaemon(true);
        schedulerThread.start();

        System.out.println("Press enter to shutdown");
        BufferedReader reader = new BufferedReader(new InputStreamReader(System.in));
        try {
            reader.readLine();
        } catch (IOException ioex) {
            log.error("Caught exception while waiting for confirm. Shutting down.", ioex);
        }
```

```
        log.info("Cancelling producer, and shutting down executor.");
        producerFuture.cancel(true);
        producerExecutor.shutdownNow();

        Future<Boolean> gracefulShutdownFuture = scheduler.startGracefulShutdown();
        log.info("Waiting up to 20 seconds for shutdown to complete.");
        try {
            gracefulShutdownFuture.get(20, TimeUnit.SECONDS);
        } catch (InterruptedException e) {
            log.info("Interrupted while waiting for graceful shutdown. Continuing.");
        } catch (ExecutionException e) {
            log.error("Exception while executing graceful shutdown.", e);
        } catch (TimeoutException e) {
            log.error("Timeout while waiting for shutdown. Scheduler may not have
exited.");
        }
        log.info("Completed, shutting down now.");
    }

    private void publishRecord() {
        PutRecordRequest request = PutRecordRequest.builder()
                .partitionKey(RandomStringUtils.randomAlphabetic(5, 20))
                .streamName(streamName)
                .data(SdkBytes.fromByteArray(RandomUtils.nextBytes(10)))
                .build();
        try {
            kinesisClient.putRecord(request).get();
        } catch (InterruptedException e) {
            log.info("Interrupted, assuming shutdown.");
        } catch (ExecutionException e) {
            log.error("Exception while sending data to Kinesis. Will try again next
cycle.", e);
        }
    }

    private static class SampleRecordProcessorFactory implements
ShardRecordProcessorFactory {
        public ShardRecordProcessor shardRecordProcessor() {
            return new SampleRecordProcessor();
        }
    }


    private static class SampleRecordProcessor implements ShardRecordProcessor {

        private static final String SHARD_ID_MDC_KEY = "ShardId";

        private static final Logger log =
LoggerFactory.getLogger(SampleRecordProcessor.class);

        private String shardId;

        public void initialize(InitializationInput initializationInput) {
            shardId = initializationInput.shardId();
            MDC.put(SHARD_ID_MDC_KEY, shardId);
            try {
                log.info("Initializing @ Sequence: {}",
initializationInput.extendedSequenceNumber());
            } finally {
                MDC.remove(SHARD_ID_MDC_KEY);
            }
        }

        public void processRecords(ProcessRecordsInput processRecordsInput) {
            MDC.put(SHARD_ID_MDC_KEY, shardId);
```

```
            try {
                log.info("Processing {} record(s)", processRecordsInput.records().size());
                processRecordsInput.records().forEach(r -> log.info("Processing record pk:
 {} -- Seq: {}", r.partitionKey(), r.sequenceNumber()));
            } catch (Throwable t) {
                log.error("Caught throwable while processing records. Aborting.");
                Runtime.getRuntime().halt(1);
            } finally {
                MDC.remove(SHARD_ID_MDC_KEY);
            }
        }

        public void leaseLost(LeaseLostInput leaseLostInput) {
            MDC.put(SHARD_ID_MDC_KEY, shardId);
            try {
                log.info("Lost lease, so terminating.");
            } finally {
                MDC.remove(SHARD_ID_MDC_KEY);
            }
        }

        public void shardEnded(ShardEndedInput shardEndedInput) {
            MDC.put(SHARD_ID_MDC_KEY, shardId);
            try {
                log.info("Reached shard end checkpointing.");
                shardEndedInput.checkpointer().checkpoint();
            } catch (ShutdownException | InvalidStateException e) {
                log.error("Exception while checkpointing at shard end. Giving up.", e);
            } finally {
                MDC.remove(SHARD_ID_MDC_KEY);
            }
        }

        public void shutdownRequested(ShutdownRequestedInput shutdownRequestedInput) {
            MDC.put(SHARD_ID_MDC_KEY, shardId);
            try {
                log.info("Scheduler is shutting down, checkpointing.");
                shutdownRequestedInput.checkpointer().checkpoint();
            } catch (ShutdownException | InvalidStateException e) {
                log.error("Exception while checkpointing at requested shutdown. Giving
 up.", e);
            } finally {
                MDC.remove(SHARD_ID_MDC_KEY);
            }
        }
    }

}
```

Desenvolver consumidores de saída avançada com a API do Kinesis Data Streams

Fan-out aprimoradoÉ um recurso do Amazon Kinesis Data Streams que permite que os consumidores recebam registros de um streaming de dados com taxa de transferência dedicada de até 2 MB de dados por segundo por estilhaço. Um consumidor que usa distribuição avançada não precisa lidar com outros consumidores que estejam recebendo dados do streaming. Para obter mais informações, consulte Desenvolver consumidores personalizados com taxa de transferência dedicada (distribuição avançada) (p. 163).

Você pode usar operações de API para criar um consumidor que use a distribuição avançada no Kinesis Data Streams.

Para registrar um consumidor com a distribuição avançada usando a API do Kinesis Data Streams

1. ChameRegisterStreamConsumerPara registrar o aplicativo como um consumidor que use a distribuição avançada. O Kinesis Data Streams gera um Amazon Resource Name (ARN — Nome de recurso da Amazon) para o consumidor e o retorna na resposta.
2. Para começar a ouvir um determinado estilhaço, passe o ARN do consumidor em uma chamada paraSubscribeToShard. Em seguida, o Kinesis Data Streams começa a enviar os registros do estilhaço para você, na forma de eventos do tipoSubscribeToShardEventatravés de uma conexão HTTP/2. A conexão permanece aberta por até 5 minutos. Chame SubscribeToShard novamente caso você queira continuar a receber registros do estilhaço após `future`, que é retornado pela chamada para SubscribeToShard, for concluído normal ou excepcionalmente.

   Note

   `SubscribeToShard`A API também retorna a lista dos fragmentos filhos do fragmento atual quando o final do fragmento atual é atingido.
3. Para cancelar o registro de um consumidor que esteja usando a distribuição avançada, chame DeregisterStreamConsumer.

O de código a seguir é um exemplo de como você pode inscrever o consumidor em um estilhaço, renovar a assinatura periodicamente e manipular os eventos.

```
    import software.amazon.awssdk.services.kinesis.KinesisAsyncClient;
    import software.amazon.awssdk.services.kinesis.model.ShardIteratorType;
    import software.amazon.awssdk.services.kinesis.model.SubscribeToShardEvent;
    import software.amazon.awssdk.services.kinesis.model.SubscribeToShardRequest;
    import software.amazon.awssdk.services.kinesis.model.SubscribeToShardResponseHandler;

    import java.util.concurrent.CompletableFuture;

    /**
     * See https://github.com/awsdocs/aws-doc-sdk-examples/blob/master/javav2/example_code/
kinesis/src/main/java/com/example/kinesis/KinesisStreamEx.java
     * for complete code and more examples.
     */
    public class SubscribeToShardSimpleImpl {

        private static final String CONSUMER_ARN = "arn:aws:kinesis:us-
east-1:123456789123:stream/foobar/consumer/test-consumer:1525898737";
        private static final String SHARD_ID = "shardId-000000000000";

        public static void main(String[] args) {

            KinesisAsyncClient client = KinesisAsyncClient.create();

            SubscribeToShardRequest request = SubscribeToShardRequest.builder()
                    .consumerARN(CONSUMER_ARN)
                    .shardId(SHARD_ID)
                    .startingPosition(s -> s.type(ShardIteratorType.LATEST)).build();

            // Call SubscribeToShard iteratively to renew the subscription periodically.
            while(true) {
                // Wait for the CompletableFuture to complete normally or exceptionally.
                callSubscribeToShardWithVisitor(client, request).join();
            }

            // Close the connection before exiting.
            // client.close();
        }
```

```
       /**
        * Subscribes to the stream of events by implementing the
SubscribeToShardResponseHandler.Visitor interface.
        */
       private static CompletableFuture<Void>
callSubscribeToShardWithVisitor(KinesisAsyncClient client, SubscribeToShardRequest
request) {
           SubscribeToShardResponseHandler.Visitor visitor = new
SubscribeToShardResponseHandler.Visitor() {
               @Override
               public void visit(SubscribeToShardEvent event) {
                   System.out.println("Received subscribe to shard event " + event);
               }
           };
           SubscribeToShardResponseHandler responseHandler =
SubscribeToShardResponseHandler
                   .builder()
                   .onError(t -> System.err.println("Error during stream - " +
t.getMessage()))
                   .subscriber(visitor)
                   .build();
           return client.subscribeToShard(request, responseHandler);
       }
   }
```

Se`event.ContinuationSequenceNumber`retorna`null`, indica que ocorreu uma divisão ou fusão de fragmentos que envolveu esse fragmento. Este fragmento está agora em um`CLOSED`state, e você leu todos os registros de dados disponíveis deste fragmento. Nesse cenário, por exemplo acima, você pode usar`event.childShards`Para saber mais sobre os novos estilhaços do estilhaço que está sendo processado que foram criados pela divisão ou fusão. Para obter mais informações, consulteChildShard.

Interagir com dados usando oAWSRegistro de esquemas de Glue

Você pode integrar seus fluxos de dados do Kinesis com oAWSRegistro de esquema de Glue. OAWSO registro de esquemas do Glue permite detectar, controlar e evoluir centralmente esquemas, ao mesmo tempo em que garante que os dados produzidos sejam continuamente validados por um esquemas registrados. O esquema define a estrutura e o formato de um registro de dados. Um esquema é uma especificação versionada para publicação, consumo ou armazenamento de dados confiáveis. OAWSO Glue Schema Registry permite melhorar end-to-end qualidade de dados e governança de dados em seus aplicativos de streaming. Para obter mais informações, consulteAWSRegistro de esquemas de Glue. Uma das maneiras de configurar essa integração é através do`GetRecords`API do Kinesis Data Streams disponível noAWSSDK do Java.

Para obter instruções detalhadas sobre como configurar a integração do Kinesis Data Streams com o registro de esquemas usando a`GetRecords`Consulte as APIs do Kinesis Data Streams, consulte a seção “Interagir com dados usando as APIs do Kinesis Data Streams” noCaso de uso: Integrar o Amazon Kinesis Data Streams com oAWSRegistro de esquemas de Glue.

Gerenciar consumidores de distribuição avançada com o AWS Management Console

Consumidores que usamfan-out aprimoradoNo Amazon Kinesis Data Streams pode receber registros de um streaming de dados com taxa de transferência dedicada de até 2 MB de dados por segundo por estilhaço. Para obter mais informações, consulte Desenvolver consumidores personalizados com taxa de transferência dedicada (distribuição avançada) (p. 163).

Você pode usar o AWS Management Console para ver uma lista de todos os consumidores registrados para usar a distribuição avançada com um streaming específico. Para cada consumidor, você pode ver detalhes como ARN, status, data de criação e métricas de monitoramento.

Para visualizar consumidores registrados para usar distribuição avançada, o status, a data de criação e as métricas no console

1. Faça login no AWS Management Console e abra o console do Kinesis em https://console.aws.amazon.com/kinesis.
2. Selecione Data Streams (Streams de dados) no painel de navegação.
3. Escolha um streaming de dados do Kinesis para ver os detalhes.
4. Na página de detalhes do streaming, escolha a guia Enhanced fan-out (Distribuição avançada).
5. Escolha um consumidor para visualizar seu nome, status e data de registro.

Para cancelar o registro de um consumidor

1. Abra o console do Kinesis em https://console.aws.amazon.com/kinesis.
2. Selecione Data Streams (Streams de dados) no painel de navegação.
3. Escolha um streaming de dados do Kinesis para ver os detalhes.
4. Na página de detalhes do streaming, escolha a guia Enhanced fan-out (Distribuição avançada).
5. Marque a caixa de seleção à esquerda do nome de cada consumidor cujo registro você deseja cancelar.
6. Escolha Deregister consumer (Cancelar registro de consumidor).

Migrar consumidores do KCL 1.x para o KCL 2.x

Este tópico explica as diferenças entre as versões 1.x e 2.x da Biblioteca de Cliente Kinesis (KCL). Ele também mostra como migrar o consumidor da versão 1.x para a versão 2.x da KCL. Depois que você migrar o cliente, ele iniciará o processamento de registros a partir do local verificado pela última vez.

A versão 2.0 da KCL apresenta as seguintes alterações de interface:

Alterações de interface da KCL

Interface KCL 1.x	Interface KCL 2.0
`com.amazonaws.services.kinesis.clientlibrary.interfaces.v2.IRecordProcessor`	`software.amazon.kinesis.processor.ShardRecordProc`
`com.amazonaws.services.kinesis.clientlibrary.interfaces.v2.IRecordProcessorFactory`	`software.amazon.kinesis.processor.ShardRecordProc`
`com.amazonaws.services.kinesis.clientlibrary.interfaces.v2.IShutdownNotificationAware`	Compatível com `software.amazon.kinesis.processor.ShardRecordProc`

Tópicos

- Migrar o processador de registros (p. 172)
- Migrar a Fábrica do Processador de Registros (p. 175)
- Migração do operador (p. 176)
- Configurando o cliente Amazon Kinesis (p. 177)
- Remoção do tempo ocioso (p. 179)
- Remoções de configuração de cliente (p. 179)

Migrar o processador de registros

O exemplo a seguir mostra um processador de registros implementado para KCL 1.x:

```
package com.amazonaws.kcl;

import com.amazonaws.services.kinesis.clientlibrary.exceptions.InvalidStateException;
import com.amazonaws.services.kinesis.clientlibrary.exceptions.ShutdownException;
import
 com.amazonaws.services.kinesis.clientlibrary.interfaces.IRecordProcessorCheckpointer;
import com.amazonaws.services.kinesis.clientlibrary.interfaces.v2.IRecordProcessor;
import
 com.amazonaws.services.kinesis.clientlibrary.interfaces.v2.IShutdownNotificationAware;
import com.amazonaws.services.kinesis.clientlibrary.lib.worker.ShutdownReason;
import com.amazonaws.services.kinesis.clientlibrary.types.InitializationInput;
import com.amazonaws.services.kinesis.clientlibrary.types.ProcessRecordsInput;
import com.amazonaws.services.kinesis.clientlibrary.types.ShutdownInput;

public class TestRecordProcessor implements IRecordProcessor, IShutdownNotificationAware {
    @Override
    public void initialize(InitializationInput initializationInput) {
        //
        // Setup record processor
        //
    }

    @Override
    public void processRecords(ProcessRecordsInput processRecordsInput) {
        //
        // Process records, and possibly checkpoint
        //
    }

    @Override
    public void shutdown(ShutdownInput shutdownInput) {
        if (shutdownInput.getShutdownReason() == ShutdownReason.TERMINATE) {
            try {
                shutdownInput.getCheckpointer().checkpoint();
            } catch (ShutdownException | InvalidStateException e) {
                throw new RuntimeException(e);
            }
        }
    }

    @Override
    public void shutdownRequested(IRecordProcessorCheckpointer checkpointer) {
        try {
            checkpointer.checkpoint();
        } catch (ShutdownException | InvalidStateException e) {
            //
            // Swallow exception
            //
            e.printStackTrace();
        }
    }
}
```

Como migrar a classe de processador de registro

1. Altere as interfaces de `com.amazonaws.services.kinesis.clientlibrary.interfaces.v2.IRecordProcessor` e

`com.amazonaws.services.kinesis.clientlibrary.interfaces.v2.IShutdownNotificationAware` para `software.amazon.kinesis.processor.ShardRecordProcessor`, da seguinte forma:

```
// import com.amazonaws.services.kinesis.clientlibrary.interfaces.v2.IRecordProcessor;
// import
 com.amazonaws.services.kinesis.clientlibrary.interfaces.v2.IShutdownNotificationAware;
import software.amazon.kinesis.processor.ShardRecordProcessor;

// public class TestRecordProcessor implements IRecordProcessor,
 IShutdownNotificationAware {
public class TestRecordProcessor implements ShardRecordProcessor {
```

2. Atualize as instruções `import` para os métodos `initialize` e `processRecords`.

```
// import com.amazonaws.services.kinesis.clientlibrary.types.InitializationInput;
import software.amazon.kinesis.lifecycle.events.InitializationInput;

//import com.amazonaws.services.kinesis.clientlibrary.types.ProcessRecordsInput;
import software.amazon.kinesis.lifecycle.events.ProcessRecordsInput;
```

3. Substitua o método `shutdown` pelos novos métodos a seguir: `leaseLost`, `shardEnded`, e `shutdownRequested`.

```
//    @Override
//    public void shutdownRequested(IRecordProcessorCheckpointer checkpointer) {
//        //
//        // This is moved to shardEnded(...)
//        //
//        try {
//            checkpointer.checkpoint();
//        } catch (ShutdownException | InvalidStateException e) {
//            //
//            // Swallow exception
//            //
//            e.printStackTrace();
//        }
//    }

    @Override
    public void leaseLost(LeaseLostInput leaseLostInput) {

    }

    @Override
    public void shardEnded(ShardEndedInput shardEndedInput) {
        try {
            shardEndedInput.checkpointer().checkpoint();
        } catch (ShutdownException | InvalidStateException e) {
            //
            // Swallow the exception
            //
            e.printStackTrace();
        }
    }

//    @Override
//    public void shutdownRequested(IRecordProcessorCheckpointer checkpointer) {
//        //
//        // This is moved to shutdownRequested(ShutdownReauestedInput)
//        //
//        try {
//            checkpointer.checkpoint();
//        } catch (ShutdownException | InvalidStateException e) {
```

```
//            //
//            // Swallow exception
//            //
//            e.printStackTrace();
//        }
//    }

    @Override
    public void shutdownRequested(ShutdownRequestedInput shutdownRequestedInput) {
        try {
            shutdownRequestedInput.checkpointer().checkpoint();
        } catch (ShutdownException | InvalidStateException e) {
            //
            // Swallow the exception
            //
            e.printStackTrace();
        }
    }
```

Veja a seguir a versão atualizada da classe de processador de registro.

```
package com.amazonaws.kcl;

import software.amazon.kinesis.exceptions.InvalidStateException;
import software.amazon.kinesis.exceptions.ShutdownException;
import software.amazon.kinesis.lifecycle.events.InitializationInput;
import software.amazon.kinesis.lifecycle.events.LeaseLostInput;
import software.amazon.kinesis.lifecycle.events.ProcessRecordsInput;
import software.amazon.kinesis.lifecycle.events.ShardEndedInput;
import software.amazon.kinesis.lifecycle.events.ShutdownRequestedInput;
import software.amazon.kinesis.processor.ShardRecordProcessor;

public class TestRecordProcessor implements ShardRecordProcessor {
    @Override
    public void initialize(InitializationInput initializationInput) {

    }

    @Override
    public void processRecords(ProcessRecordsInput processRecordsInput) {

    }

    @Override
    public void leaseLost(LeaseLostInput leaseLostInput) {

    }

    @Override
    public void shardEnded(ShardEndedInput shardEndedInput) {
        try {
            shardEndedInput.checkpointer().checkpoint();
        } catch (ShutdownException | InvalidStateException e) {
            //
            // Swallow the exception
            //
            e.printStackTrace();
        }
    }

    @Override
    public void shutdownRequested(ShutdownRequestedInput shutdownRequestedInput) {
        try {
```

```
            shutdownRequestedInput.checkpointer().checkpoint();
        } catch (ShutdownException | InvalidStateException e) {
            //
            // Swallow the exception
            //
            e.printStackTrace();
        }
    }
}
```

Migrar a Fábrica do Processador de Registros

A fábrica do processador de registros é responsável por criar processadores de registro quando uma concessão é realizada. Veja a seguir um exemplo de fábrica KCL 1.x.

```
package com.amazonaws.kcl;

import com.amazonaws.services.kinesis.clientlibrary.interfaces.v2.IRecordProcessor;
import com.amazonaws.services.kinesis.clientlibrary.interfaces.v2.IRecordProcessorFactory;

public class TestRecordProcessorFactory implements IRecordProcessorFactory {
    @Override
    public IRecordProcessor createProcessor() {
        return new TestRecordProcessor();
    }
}
```

Migrar a fábrica do processador de registros

1. Altere a interface implementada de `com.amazonaws.services.kinesis.clientlibrary.interfaces.v2.IRecordProcessorFactory` para `software.amazon.kinesis.processor.ShardRecordProcessorFactory`, da seguinte forma:

   ```
   // import com.amazonaws.services.kinesis.clientlibrary.interfaces.v2.IRecordProcessor;
   import software.amazon.kinesis.processor.ShardRecordProcessor;

   // import
    com.amazonaws.services.kinesis.clientlibrary.interfaces.v2.IRecordProcessorFactory;
   import software.amazon.kinesis.processor.ShardRecordProcessorFactory;

   // public class TestRecordProcessorFactory implements IRecordProcessorFactory {
   public class TestRecordProcessorFactory implements ShardRecordProcessorFactory {
   ```

2. Alterar a assinatura de retorno para `createProcessor`.

   ```
   // public IRecordProcessor createProcessor() {
   public ShardRecordProcessor shardRecordProcessor() {
   ```

Veja a seguir um exemplo da fábrica do processador de registros em 2.0:

```
package com.amazonaws.kcl;

import software.amazon.kinesis.processor.ShardRecordProcessor;
import software.amazon.kinesis.processor.ShardRecordProcessorFactory;

public class TestRecordProcessorFactory implements ShardRecordProcessorFactory {
    @Override
    public ShardRecordProcessor shardRecordProcessor() {
```

```
        return new TestRecordProcessor();
    }
}
```

Migração do operador

Na versão 2.0 da KCL, uma nova classe, chamada`Scheduler`, substitui o`Worker`Classe. Veja a seguir um exemplo de um operador da KCL 1.x.

```
final KinesisClientLibConfiguration config = new KinesisClientLibConfiguration(...)
final IRecordProcessorFactory recordProcessorFactory = new RecordProcessorFactory();
final Worker worker = new Worker.Builder()
    .recordProcessorFactory(recordProcessorFactory)
    .config(config)
    .build();
```

Para migrar o operador

1. Altere a instrução `import` para a classe `Worker` para as instruções de importação para as classes `Scheduler` e `ConfigsBuilder`.

   ```
   // import com.amazonaws.services.kinesis.clientlibrary.lib.worker.Worker;
   import software.amazon.kinesis.coordinator.Scheduler;
   import software.amazon.kinesis.common.ConfigsBuilder;
   ```

2. Crie o `ConfigsBuilder` e um `Scheduler` conforme mostrado no exemplo a seguir.

   Recomendamos que você use `KinesisClientUtil` para criar `KinesisAsyncClient` e configurar `maxConcurrency` no `KinesisAsyncClient`.

   > **Important**
   >
   > O Amazon Kinesis Client pode ter latência significativamente maior, a menos que você configure `KinesisAsyncClient` para ter um `maxConcurrency` alto o suficiente para permitir todas as concessões e usos adicionais do `KinesisAsyncClient`.

   ```
   import java.util.UUID;

   import software.amazon.awssdk.regions.Region;
   import software.amazon.awssdk.services.dynamodb.DynamoDbAsyncClient;
   import software.amazon.awssdk.services.cloudwatch.CloudWatchAsyncClient;
   import software.amazon.awssdk.services.kinesis.KinesisAsyncClient;
   import software.amazon.kinesis.common.ConfigsBuilder;
   import software.amazon.kinesis.common.KinesisClientUtil;
   import software.amazon.kinesis.coordinator.Scheduler;

   ...

   Region region = Region.AP_NORTHEAST_2;
   KinesisAsyncClient kinesisClient =
    KinesisClientUtil.createKinesisAsyncClient(KinesisAsyncClient.builder().region(region));
   DynamoDbAsyncClient dynamoClient =
    DynamoDbAsyncClient.builder().region(region).build();
   CloudWatchAsyncClient cloudWatchClient =
    CloudWatchAsyncClient.builder().region(region).build();

   ConfigsBuilder configsBuilder = new ConfigsBuilder(streamName, applicationName,
    kinesisClient, dynamoClient, cloudWatchClient, UUID.randomUUID().toString(), new
    SampleRecordProcessorFactory());
   ```

```
Scheduler scheduler = new Scheduler(
    configsBuilder.checkpointConfig(),
    configsBuilder.coordinatorConfig(),
    configsBuilder.leaseManagementConfig(),
    configsBuilder.lifecycleConfig(),
    configsBuilder.metricsConfig(),
    configsBuilder.processorConfig(),
    configsBuilder.retrievalConfig()
    );
```

Configurando o cliente Amazon Kinesis

Com a versão 2.0 da Biblioteca de Clientes do Kinesis, a configuração do cliente foi movida de uma única classe de configuração (`KinesisClientLibConfiguration`) para seis classes de configuração. A tabela a seguir descreve a migração.

Campos de Configuração e suas Novas Classes

Campo Original	Nova classe de configuração	Descrição
`applicationName`	`ConfigsBuilder`	O nome do aplicativo KCL. Usado como padrão para o `tableName` e o `consumerName`.
`tableName`	`ConfigsBuilder`	Permite substituir o nome da tabela usada para a tabela de concessão do Amazon DynamoDB.
`streamName`	`ConfigsBuilder`	O nome do stream a partir do qual esse aplicativo processa registros.
`kinesisEndpoint`	`ConfigsBuilder`	Essa opção não existe mais. Consulte remoções de configuração de cliente.
`dynamoDBEndpoint`	`ConfigsBuilder`	Essa opção não existe mais. Consulte remoções de configuração de cliente.
`initialPositionInStream`	`RetrievalConfig`	A localização no estilhaço a partir da qual a KCL começa a obter registros, começando com a execução inicial do aplicativo.
`kinesisCredentialsProvider`	`ConfigsBuilder`	Essa opção não existe mais. Consulte remoções de configuração de cliente.
`dynamoDBCredentialsProvider`	`ConfigsBuilder`	Essa opção não existe mais. Consulte remoções de configuração de cliente.
`cloudWatchCredentialsProvider`	`ConfigsBuilder`	Essa opção não existe mais. Consulte remoções de configuração de cliente.
`failoverTimeMillis`	`LeaseManagementConfig`	O número de milissegundos que devem passar antes que se considere uma falha do proprietário da concessão.
`workerIdentifier`	`ConfigsBuilder`	Um identificador exclusivo que representa a instanciação do processador do aplicativo. Isso deve ser exclusivo.
`shardSyncIntervalMillis`	`LeaseManagementConfig`	O tempo entre as chamadas de sincronização de estilhaços.
`maxRecords`	`PollingConfig`	Permite definir o número máximo de registros que o Kinesis retorna.

Campo Original	Nova classe de configuração	Descrição
idleTimeBetweenReadsInMillis	CoordinatorConfig	Essa opção não existe mais. Consulte a remoção do tempo ocioso.
callProcessRecordsEvenForEmptyRecordList	RetrievalConfig	Quando definido, o processador de registros é solicitado mesmo quando nenhum registro foi fornecido pelo Kinesis.
parentShardPollIntervalMillis	CoordinatorConfig	Com que frequência um processador de registros deve sondar a conclusão de estilhaços pai.
cleanupLeasesUponShardCompletion	LeaseManagementConfig	Quando definidas, as concessões são removidas assim que as concessões filho iniciam o processamento.
ignoreUnexpectedChildShards	LeaseManagementConfig	Quando definidos, estilhaços filho que possuem um estilhaço aberto são ignorados. Isso se aplica principalmente ao DynamoDB Streams.
kinesisClientConfig	ConfigsBuilder	Essa opção não existe mais. Consulte remoções de configuração de cliente.
dynamoDBClientConfig	ConfigsBuilder	Essa opção não existe mais. Consulte remoções de configuração de cliente.
cloudWatchClientConfig	ConfigsBuilder	Essa opção não existe mais. Consulte remoções de configuração de cliente.
taskBackoffTimeMillis	LifecycleConfig	O tempo de espera para repetir tarefas com falha.
metricsBufferTimeMillis	MetricsConfig	ControlesCloudWatchPublicação de métricas.
metricsMaxQueueSize	MetricsConfig	ControlesCloudWatchPublicação de métricas.
metricsLevel	MetricsConfig	ControlesCloudWatchPublicação de métricas.
metricsEnabledDimensions	MetricsConfig	ControlesCloudWatchPublicação de métricas.
validateSequenceNumberBeforeCheckpointing	CheckpointConfig	Essa opção não existe mais. Consulte a validação do número de sequência do ponto de verificação.
regionName	ConfigsBuilder	Essa opção não existe mais. Consulte remoção de configuração de cliente.
maxLeasesForWorker	LeaseManagementConfig	O número máximo de concessões que uma única instância do aplicativo deve aceitar.
maxLeasesToStealAtOneTime	LeaseManagementConfig	O número máximo de concessões que um aplicativo deve tentar roubar de uma só vez.
initialLeaseTableReadCapacity	LeaseManagementConfig	Os IOPS de leitura do DynamoDB usados se a Biblioteca de Clientes do Kinesis precisar criar uma nova tabela de concessão do DynamoDB.
initialLeaseTableWriteCapacity	LeaseManagementConfig	Os IOPS de leitura do DynamoDB usados se a Biblioteca de Clientes do Kinesis precisar criar uma nova tabela de concessão do DynamoDB.
initialPositionInStream	LeaseManagementConfig	A posição inicial do aplicativo no stream. Isso é usado somente durante a criação da concessão inicial.

Campo Original	Nova classe de configuração	Descrição
`skipShardSyncAtWorkerInitializationIfLeasesExist`	`CoordinatorConfig`	Desative a sincronização de dados de estilhaço se a tabela de concessão contiver concessões existentes. TODO: KinesisEco-438
`shardPrioritization`	`CoordinatorConfig`	A priorização de estilhaços a ser usada.
`shutdownGraceMillis`	N/D	Essa opção não existe mais. ConsulteMultiLangRemover-nos.
`timeoutInSeconds`	N/D	Essa opção não existe mais. ConsulteMultiLangRemover-nos.
`retryGetRecordsInSeconds`	`PollingConfig`	Configura o atraso entreGetRecordstentativas de falhas.
`maxGetRecordsThreadPool`	`PollingConfig`	O tamanho do grupo de fios usado paraGetRecords.
`maxLeaseRenewalThreads`	`LeaseManagementConfig`	Controla o tamanho do grupo de threads de renovação de concessão. Quanto mais concessões seu aplicativo aceitar, maior esse grupo deve ser.
`recordsFetcherFactory`	`PollingConfig`	Permite substituir a fábrica usada para criar extratores que recuperam dados dos streams.
`logWarningForTaskAfterMillis`	`LifecycleConfig`	Quanto tempo esperar antes de um aviso ser registrado caso uma tarefa não seja concluída.
`listShardsBackoffTimeInMillis`	`RetrievalConfig`	O número de milissegundos de espera entre as chamadas para `ListShards` em caso de falha.
`maxListShardsRetryAttempts`	`RetrievalConfig`	O número máximo de novas tentativas de `ListShards` antes de desistir.

Remoção do tempo ocioso

Na versão 1.x da KCL, `aidleTimeBetweenReadsInMillis`correspondeu a duas quantidades:

- A quantidade de tempo entre as verificações de envio de tarefas.
  Agora você pode configurar esse tempo entre tarefas, definindo `CoordinatorConfig#shardConsumerDispatchPollIntervalMillis`.
- A quantidade de tempo inativo quando nenhum registro foi retornado do Kinesis Data Streams. Na versão 2.0, em distribuição avançada registros são enviados a partir de sua respectiva recuperação. Atividade no do consumidor estilhaço só ocorre quando uma solicitação é enviada.

Remoções de configuração de cliente

Na versão 2.0, a KCL não cria mais clientes. Ela depende do fornecimento de um cliente válido pelo usuário. Com essa alteração, todos os parâmetros de configuração que controlavam a criação do cliente foram removidos. Se precisar desses parâmetros, você pode configurá-los nos clientes antes de fornecê-los ao `ConfigsBuilder`.

Campo removido	Configuração equivalente
`kinesisEndpoint`	Configure o SDK `KinesisAsyncClient` com o endpoint de sua preferência: `KinesisAsyncClient.builder().endpointOverride(URI.create("https://<kinesis endpoint>")).build()`.
`dynamoDBEndpoint`	Configure o SDK `DynamoDbAsyncClient` com o endpoint de sua preferência: `DynamoDbAsyncClient.builder().endpointOverride(URI.create("https://<dynamodb endpoint>")).build()`.
`kinesisClientConfig`	Configure o SDK `KinesisAsyncClient` com a configuração necessária: `KinesisAsyncClient.builder().overrideConfiguration(<your configuration>).build()`.
`dynamoDBClientConfig`	Configure o SDK `DynamoDbAsyncClient` com a configuração necessária: `DynamoDbAsyncClient.builder().overrideConfiguration(<your configuration>).build()`.
`cloudWatchClientConfig`	Configure o SDK `CloudWatchAsyncClient` com a configuração necessária: `CloudWatchAsyncClient.builder().overrideConfiguration(<your configuration>).build()`.
`regionName`	Configure o SDK com a Região de sua preferência. Ela é a mesma para todos os clientes do SDK. Por exemplo, `KinesisAsyncClient.builder().region(Region.US_WEST_2).build()`.

Solução de problemas de consumidores do Kinesis Data Streams

As seções a seguir oferecem soluções para alguns problemas comuns que você pode encontrar ao trabalhar com consumidores do Amazon Kinesis Data Streams.

Alguns registros do Kinesis Data Streams são ignorados ao usar a biblioteca de cliente do Kinesis

A causa mais comum de registros ignorados é uma exceção não processada lançada de `processRecords`. A Kinesis Client Library (KCL) se baseia em sua`processRecords`Para

gerenciar todas as exceções que surjam do processamento de registros de dados. Qualquer exceção lançada de`processRecords`É absorvido pela KCL. Para evitar infinitas tentativas em uma falha recorrente, a KCL não reenvia o lote de registros processados no momento da exceção. O KCL então chama`processRecords`Para o próximo lote de registros de dados sem reiniciar o processador de registros. Isso resulta efetivamente em aplicativos consumidores observando registros ignorados. Para impedir registros ignorados, processe todas as exceções em `processRecords` da forma apropriada.

Registros pertencentes ao mesmo estilhaço são processados por processadores de registros diferentes ao mesmo tempo

Para qualquer aplicativo da Kinesis Client Library (KCL) em execução, um estilhaço só tem um proprietário. No entanto, vários processadores de registro pode temporariamente processar o mesmo estilhaço. No caso de uma instância de operador que perde a conectividade com a rede, a KCL pressupõe que o operador inacessível não está mais processando registros, após o tempo de failover expirar, e instrui outras instâncias de operador a assumir. Por um breve período, novos processadores de registros e processadores de registros provenientes do operador inacessível podem processar dados do mesmo estilhaço.

Você deve definir um tempo de failover que seja apropriado para seu aplicativo. Para aplicativos de baixa latência, o padrão de 10 segundos pode representar o tempo máximo que você deseja esperar. No entanto, nos casos em que você espera problemas de conectividade, como fazer chamadas em áreas geográficas em que a conectividade pode ser perdida com mais frequência, esse número pode ser muito baixo.

O aplicativo deve prever e lidar com esse cenário, especialmente porque a conectividade de rede normalmente é restaurada para o operador anteriormente inacessível. Se um processador de registros tem seus estilhaços executados por outro processador de registros, ele deve lidar com os dois casos seguintes para executar o encerramento normal:

1. Após a chamada atual para`processRecords`Está concluído, a KCL chama o método de desligamento no processador de registros com o motivo de desligamento 'ZOMBIE'. Espera-se que seus processadores de registros limpem quaisquer recursos conforme apropriado e, em seguida, saiam.
2. Quando você tenta criar um ponto de verificação a partir de um operador 'zombie', a KCL lança`ShutdownException`. Depois de receber essa exceção, seu código deve sair do método atual de forma limpa.

Para obter mais informações, consulte Tratar registros duplicados (p. 186).

Aplicativo consumidor está lendo a uma taxa menor que a esperada

Os motivos mais comuns para a taxa de transferência de leitura ser mais lenta do que o esperado são os seguintes:

1. Vários aplicativos consumidores com um total de leituras que excedem os limites por estilhaço. Para obter mais informações, consulte Cotas e limites (p. 7). Nesse caso, aumente o número de fragmentos no stream de dados do Kinesis.
2. O limite que especifica o número máximo de GetRecords por chamada pode ter sido configurado com um valor baixo. Se você estiver usando a KCL, poderá configurar o operador com um valor baixo para a propriedade `maxRecords`. Em geral, recomendamos o uso dos padrões do sistema para essa propriedade.

3. A lógica em sua chamada `processRecords` está demorando mais do que o esperado por várias razões possíveis. A lógica pode usar muitos recursos da CPU, bloquear a E/S ou estar afunilada na sincronização. Para testar se isso é verdadeiro, teste a execução de processadores de registros vazios e comparar a taxa de transferência de leitura. Para obter informações sobre como acompanhar os dados de entrada, consulte Reestilhaçamento, escalabilidade e processamento paralelo (p. 185).

Se você tem apenas um aplicativo consumidor, sempre é possível ler pelo menos duas vezes mais rápido do que a taxa de colocação. Isso porque é possível gravar até 1.000 registros por segundo para gravações, até uma taxa total máxima de gravação de dados de 1 MB por segundo (incluindo chaves de partição). Cada estilhaço aberto pode oferecer suporte a até 5 transações por segundo para leituras, até uma taxa total de leitura de dados máxima de 2 MB por segundo. Observe que cada leitura (chamada a GetRecords) obtém um lote de registros. O tamanho dos dados retornados pelo GetRecords varia de acordo com a utilização do estilhaço. Tamanho máximo de dados queGetRecordsA pode retornar é 10 MB. Se uma chamada retorna esse limite, as chamadas subsequentes feitas nos próximos 5 segundos lançam `ProvisionedThroughputExceededException`.

GetRecordsRetorna um array de registros vazios mesmo quando não há dados no stream

O consumo, ou a obtenção, de registros é um modelo de envio. Espera-se que os desenvolvedores liguemGetRecordsEm um loop contínuo sem retrocesso. Cada chamada a GetRecords também retorna um valor de `ShardIterator` que deve ser usado na próxima iteração do loop.

A operação GetRecords não bloqueia. Em vez disso, ela retorna imediatamente; com registros de dados relevantes ou com um elemento `Records` vazio. Um elemento `Records` vazio é retornado em duas condições:

1. Atualmente, não há mais dados no estilhaço.
2. Não há dados perto da parte do estilhaço indicada pelo `ShardIterator`.

A última condição é sutil, mas é uma característica de compensação necessária para evitar tempo de busca ilimitado (latência) ao recuperar registros. Desse modo, o aplicativo de consumo de streaming deve fazer um loop e chamar GetRecords tratando os registros vazios como de costume.

Em um cenário de produção, o único momento em que o loop contínuo deve ser encerrado é quando o valor de `NextShardIterator` é `NULL`. Quando `NextShardIterator` é `NULL`, significa que o estilhaço foi fechado e o valor de `ShardIterator` apontaria para além do último registro. Se o aplicativo consumidor nunca chamar SplitShard ou MergeShards, o estilhaço permanecerá aberto e as chamadas a GetRecords nunca retornarão um valor de `NextShardIterator` que seja `NULL`.

Se você usar a Kinesis Client Library (KCL), o padrão de consumo acima será abstraído para você. Isso inclui a manipulação automática de um conjunto de estilhaços que mudam dinamicamente. Com a KCL, o desenvolvedor fornece apenas a lógica para processar registros de entrada. Isso é possível porque a biblioteca faz chamadas contínuas a GetRecords para você.

Iterador do estilhaço expira inesperadamente

Um novo iterador de estilhaço é retornado por toda solicitação a GetRecords (como `NextShardIterator`), que você usa na próxima solicitação GetRecords (como `ShardIterator`). Normalmente, esse iterador do estilhaço não expira antes de você usá-lo. No entanto, você pode descobrir que iteradores de estilhaço expiram porque você não chamou GetRecords por mais de cinco minutos, ou porque você executou uma reinicialização do seu aplicativo consumidor.

Se o iterador do estilhaço expirar imediatamente, antes que você possa usá-lo, isso poderá indicar que a tabela do DynamoDB usada pelo Kinesis não tem capacidade suficiente para armazenar os dados de

locação. Essa situação tem maior probabilidade de ocorrer se você tiver um grande número de estilhaços. Para solucionar esse problema, aumente a capacidade de gravação atribuída à tabela do estilhaço. Para obter mais informações, consulte Usando uma tabela de leasing para rastrear os fragmentos processados pelo aplicativo do consumidor KCL (p. 123).

Processamento de registros de consumidores ficando atrasados

Para a maioria dos casos de uso, os aplicativos consumidores estão lendo os últimos dados do stream. Em determinadas circunstâncias, as leituras dos consumidores podem ficar atrasadas, o que pode não ser desejado. Depois de identificar a dimensão do atraso da leitura dos consumidores, veja os motivos mais comuns disso ocorrer.

Comece com a métrica `GetRecords.IteratorAgeMilliseconds`, que rastreia a posição de leitura em todos os estilhaços e consumidores no stream. Observe que, se a idade de um iterador passa de 50% do período de retenção (por padrão,24 horas, configurável até365dias), há risco de perda de dados devido à expiração do registro. Uma solução provisória rápida é aumentar o período de retenção. Isso interrompe a perda de dados importantes enquanto você soluciona o problema. Para obter mais informações, consulte Monitorar o Amazon Kinesis Data Streams Service com o Amazon CloudWatch (p. 190). Em seguida, identifique o quanto atrás do aplicativo consumidor está lendo de cada estilhaço usando um personalizadoCloudWatchmétrica emitida pela Kinesis Client Library (KCL),`MillisBehindLatest`. Para obter mais informações, consulte Monitorar a biblioteca de cliente Kinesis com o Amazon CloudWatch (p. 206).

Veja os motivos mais comuns para consumidores ficarem atrasados:

- Grandes aumentos súbitos em `GetRecords.IteratorAgeMilliseconds` ou `MillisBehindLatest` geralmente indicam um problema transitório, como falhas de operação da API para um aplicativo de downstream. Você deve investigar esses aumentos repentinos se uma das métricas exibir esse comportamento constantemente.
- Um aumento gradual nessas métricas indica que um consumidor não está acompanhando o stream porque não está processando registros com a rapidez necessária. As causas raiz mais comuns para esse comportamento são recursos físicos insuficientes ou lógica de processamento de registros que não escalou com o aumento na taxa de transmissão do stream. Você pode verificar esse comportamento analisando o outro personalizadoCloudWatchmétricas que o KCL emite associadas ao`processTask`operação, incluindo`RecordProcessor.processRecords.Time`,`Success`, e`RecordsProcessed`.
  - Caso veja um aumento na métrica `processRecords.Time` correlacionada ao aumento na taxa de transferência, você deve analisar a lógica do processamento de registros para identificar por que ela não está se dimensionando de acordo com a maior taxa de transferência.
  - Caso veja um aumento nos valores de `processRecords.Time` que não esteja correlacionado com aumento na taxa de transferência, verifique se você está fazendo chamadas de bloqueio no caminho crítico, que muitas vezes são a causa de lentidão no processamento de registros. Uma abordagem alternativa é aumentar o paralelismo, aumentando o número de estilhaços. Finalmente, confirme se você tem uma quantidade adequada de recursos físicos (memória, utilização da CPU etc.) nos nós de processamento subjacentes durante o pico de demanda.

Erro de permissão de chave mestra do KMS não autorizada

Esse erro ocorre quando um aplicativo consumidor lê em um stream criptografado sem permissões na chave mestra do KMS. Para atribuir permissões a um aplicativo para acessar uma chave do KMS, consulteUsar políticas de chaves noAWSKMSeComo usar políticas do IAMAWSKMS.

Problemas comuns, perguntas e ideias de solução de problemas para consumidores

- Por que o gatilho do Kinesis Data Streams não consegue invocar minha função do Lambda?
- Como eu faço para detectar e solucionar problemasReadProvisionedThroughputExceededexceções no Kinesis Data Streams?
- Por que estou enfrentando problemas de alta latência com o Kinesis Data Streams?
- Por que meu fluxo de dados do Kinesis está retornando um erro interno do servidor 500?
- Como soluciono problemas de um aplicativo KCL bloqueado ou preso para Kinesis Data Streams?
- Posso usar diferentes aplicativos da biblioteca de cliente do Amazon Kinesis com a mesma tabela do Amazon DynamoDB?

Tópicos avançados para consumidores do Amazon Kinesis Data Streams

Saiba como otimizar seu consumidor do Amazon Kinesis Data Streams.

Índice

Processamento de baixa latência

Atraso de propagaçãoé definido como oend-to-endA partir do momento em que um registro é gravado no stream até ser lido por um aplicativo de consumidor. Esse atraso varia dependendo de uma série de fatores, mas é afetado principalmente pelo intervalo de sondagem de aplicativos de consumidor.

Para a maioria dos aplicativos, recomendamos a sondagem de cada estilhaço uma vez por segundo por aplicativo. Isso permite que você tenha vários aplicativos de consumidor processando um stream simultaneamente sem atingir os limites do Amazon Kinesis Data Streams de 5`GetRecords`Chamadas por segundo. Além disso, o processamento de lotes de dados maiores tende a ser mais eficiente na redução da latência de rede e outras latências de downstream no seu aplicativo.

Os padrões da KCL estão definidos para seguir a melhor prática de sondagem a cada 1 segundo. Esse padrão gera atrasos de propagação médios que costumam ser menores que 1 segundo.

Os registros do Kinesis Data Streams ficam disponíveis para serem lidos imediatamente após serem gravados. Há alguns casos de uso que precisam aproveitar isso e exigir o consumo de dados do stream assim que ele estiver disponível. Você pode reduzir significativamente o atraso de propagação sobrepondo as configurações padrão do KCL para sondar com mais frequência, como mostrado nos exemplos a seguir.

Código de configuração Java KCL:

```
kinesisClientLibConfiguration = new
        KinesisClientLibConfiguration(applicationName,
        streamName,
```

```
        credentialsProvider,

 workerId).withInitialPositionInStream(initialPositionInStream).withIdleTimeBetweenReadsInMillis(250);
```

Configuração de arquivo de propriedades para Python e Ruby KCL:

```
idleTimeBetweenReadsInMillis = 250
```

> **Note**
>
> Porque o Kinesis Data Streams tem um limite de 5`GetRecords`Chamadas por segundo, por estilhaço, definindo a`idleTimeBetweenReadsInMillis`propriedade inferior a 200ms pode resultar na sua aplicação observando o`ProvisionedThroughputExceededException`Exceção. Muitas dessas exceções podem gerar recuos exponenciais significativos e, portanto, causar latências inesperadas significativas no processamento. Se você definir essa propriedade em 200 ms ou acima e tiver mais de um aplicativo de processamento, ocorrerá limitação semelhante.

O uso doAWS Lambdacom a Kinesis Producer Library

OBiblioteca de produtores Kinesis(KPL) agrega pequenos registros formatados pelo usuário em registros maiores de até 1 MB para usar melhor a taxa de transferência do Amazon Kinesis Data Streams. Embora o KCL para Java seja compatível com a desagregação desses registros, você precisa usar um módulo especial para desagregar registros ao usarAWS Lambdacomo consumidor de seus fluxos. Você pode obter o código do projeto e as instruções necessários doGitHubemMódulos de desagregação da Biblioteca do Produtor Kinesis paraAWSLambda. Os componentes deste projeto oferecem a capacidade de processar dados serializados da KPL dentro doAWS Lambda, em Java, Node.js e Python. Esses componentes também podem ser usados como parte de um aplicativo de várias linguagens da KCL.

Reestilhaçamento, escalabilidade e processamento paralelo

O reestilhaçamento permite aumentar ou diminuir o número de estilhaços em um stream para se adaptar às alterações na taxa de dados que fluem pelo streaming. O reestilhaçamento costuma ser realizado por um aplicativo administrativo que monitora as métricas de tratamento de dados de estilhaço. Embora a própria KCL não inicie as operações de reestilhaçamento, ela é projetada para se adaptar às alterações no número de estilhaços resultantes do reestilhaçamento.

Conforme observado emUsando uma tabela de leasing para rastrear os fragmentos processados pelo aplicativo do consumidor KCL (p. 123), a KCL rastreia os estilhaços no stream usando uma tabela do Amazon DynamoDB. Quando novos estilhaços são criados em consequência do reestilhaçamento, a KCL descobre os novos estilhaços e preenche novas linhas na tabela. Os operadores descobrem automaticamente os novos estilhaços e criam processadores para tratar os dados provenientes deles. A KCL também distribui os estilhaços no stream entre todos os operadores e processadores de registros disponíveis.

A KCL garante que os dados existentes nos estilhaços antes do reestilhaçamento sejam processados primeiro. Depois do processamento dos dados, os dados dos novos estilhaços são enviados para processadores de registros. Dessa forma, a KCL preserva a ordem em que os registros de dados foram adicionados ao stream para uma determinada chave de partição.

Exemplo: Reestilhaçamento, escalabilidade e processamento paralelo

O exemplo a seguir ilustra como a KCL ajuda você a lidar com escalabilidade e reestilhaçamento:

- Por exemplo, se o aplicativo é executado em uma instância do EC2 e processa um stream de dados do Kinesis que tem quatro estilhaços. Esta instância tem um operador da KCL e quatro processadores de registros (um processador de registros para cada estilhaço). Esses quatro processadores de registros são executados em paralelo no mesmo processo.
- Em seguida, se você escalar o aplicativo para usar outra instância, terá duas instâncias processando um único stream que tem quatro estilhaços. Quando o operador do KCL é iniciado na segunda instância, ele faz balanceamento de carga com a primeira instância, de modo que cada instância passa a processar dois estilhaços.
- Se você decidir dividir os quatro estilhaços em cinco, A KCL novamente coordenará o processamento entre as instâncias: uma instância processará três estilhaços e a outra processará dois estilhaços. Uma coordenação semelhante ocorre quando você mescla estilhaços.

Normalmente, quando você usa o KCL, deve garantir que o número de instâncias não exceda o número de estilhaços (exceto para fins de espera de falha). Cada estilhaço é processado por exatamente um operador da KCL e tem exatamente um processador de registros correspondente, para que você nunca precise de várias instâncias para processar apenas um estilhaço. Mas como um operador pode processar qualquer número de estilhaços, tudo bem se o número de estilhaços ultrapassar o número de instâncias.

Para expandir o processamento do seu aplicativo, você deve testar uma combinação destas abordagens:

- Aumentar o tamanho da instância (porque todos os processadores de registros são executados em paralelo em um processo)
- Aumentar o número de instâncias até o número máximo de estilhaços abertos (porque os estilhaços podem ser processados de forma independente)
- Aumentar o número de estilhaços (o que aumenta o nível de paralelismo)

Observe que você pode usar o Auto Scaling para escalar automaticamente suas instâncias com base em métricas apropriadas. Para obter mais informações, consulte o Guia do usuário do Amazon EC2 Auto Scaling.

Quando o reestilhaçamento aumenta o número de estilhaços no stream, o aumento correspondente no número de processadores de registros aumenta a carga nas instâncias do EC2 que os hospedam. Se as instâncias fazem parte de um grupo de Auto Scaling e a carga aumenta suficientemente, o grupo de Auto Scaling adiciona mais instâncias para lidar com o aumento de carga. Você deve configurar suas instâncias para iniciar seu aplicativo Amazon Kinesis Data Streams na inicialização, para que os operadores e processadores de registros adicionais fiquem ativos na nova instância imediatamente.

Para obter mais informações sobre a refragmentação, consulte Reestilhaçar um stream (p. 79).

Tratar registros duplicados

Há dois principais motivos pelos quais os registros podem ser entregues mais de uma vez ao seu aplicativo Amazon Kinesis Data Streams: retentativas de produtor e retentativas de consumidor. Seu aplicativo precisa prever e tratar devidamente o processamento de registros individuais várias vezes.

Retentativas de produtor

Considere um produtor que tem um tempo limite esgotado relacionado à rede depois de fazer uma chamada `aPutRecord`, mas antes de poder receber uma confirmação do Amazon Kinesis Data Streams. O produtor não tem certeza de que o registro foi entregue ao Kinesis Data Streams. Supondo que cada registro é importante para o aplicativo, o produtor teria sido concebido de modo a tentar novamente a chamada com os mesmos dados. Se ambos`PutRecord`As chamadas a para os mesmos dados foram confirmadas com sucesso no Kinesis Data Streams, então haverá dois registros do Kinesis Data Streams. Embora os dois registros tenham dados idênticos, eles também têm números sequenciais exclusivos.

Os aplicativos que precisam de rigorosas garantias devem incorporar uma chave primária ao registro para remover duplicatas mais tarde ao processar. Observe que o número de duplicatas resultante das retentativas de produtor costuma ser baixo em comparação com o número de duplicatas resultante das retentativas de consumidor.

Note

Se você usar oAWSSDK`PutRecord`, o padrãoUma nova configuração faz uma falha`PutRecord`Ligue até três vezes.

Retentativas de consumidor

As retentativas de consumidor (aplicativo de processamento de dados) acontecem quando os processadores de registros são reiniciados. Os processadores de registros do mesmo estilhaço reiniciam nos seguintes casos:

1. Um operador é encerrado inesperadamente
2. Instâncias de operador são adicionadas ou removidas
3. Os estilhaços são mesclados ou divididos
4. O aplicativo é implantado

Em todos esses casos, oshards-to-worker-to-record-processoro mapeamento é atualizado continuamente para o processamento da balança de carga. Processadores de estilhaços que foram migrados para outras instâncias reiniciam o processamento de registros a partir do último ponto de verificação. Isso acarreta processamento de registros duplicado, conforme mostrado no exemplo abaixo. Para obter mais informações sobre balanceamento de carga, consulte Reestilhaçamento, escalabilidade e processamento paralelo (p. 185).

Exemplo: Retentativas de consumidor gerando reentrega de registros

Neste exemplo, você tem um aplicativo que lê continuamente registros de um stream, agrega registros em um arquivo local e faz upload do arquivo para o Amazon S3. Para simplificar, suponha que haja apenas 1 estilhaço e 1 operador processando o estilhaço. Considere a sequência de eventos de exemplo a seguir, supondo que o último ponto de verificação ocorreu no registro de número 10.000:

1. Um operador lê o próximo lote de registros a partir do estilhaço, registros de 10.001 a 20.000.
2. O operador passa o lote de registros para o processador de registros associado.
3. O processador de registros agrega os dados, cria um arquivo do Amazon S3 e faz upload do arquivo para o Amazon S3 com êxito.
4. O operador é encerrado inesperadamente antes que ocorra um novo ponto de verificação.
5. O aplicativo, o operador e o processador de registros são reiniciados.
6. O operador agora começa a ler a partir do último ponto de verificação bem-sucedido, que neste caso é 10.001.

Desse modo, os registros de 10.001 a 20.000 são consumidos mais de uma vez.

Ser resiliente a retentativas de consumidor

Mesmo que os registros possam ser processados mais de uma vez, seu aplicativo pode apresentar efeitos colaterais como se os registros tivessem sido processados apenas uma vez (processamento idempotente). As soluções para esse problema variam em termos de complexidade e precisão. Se o destino dos dados finais puder tratar bem das duplicatas, recomendamos confiar no destino final para obter o processamento idempotente. Por exemplo, comOpenSearchVocê pode usar uma combinação de versionamento e IDs exclusivos para evitar processamento duplicado.

O aplicativo de exemplo da seção anterior lê continuamente os registros de um stream, agrega os registros em um arquivo local e faz upload do arquivo para o Amazon S3. Conforme ilustrado, os registros de 10001 a 20000 são consumidos mais de uma vez, resultando em vários arquivos do Amazon S3 com os mesmos dados. Uma forma de reduzir as duplicatas desse exemplo é garantir que a etapa 3 use o seguinte esquema:

1. O processador de registros usa um número fixo de registros por arquivo do Amazon S3, como 5.000.
2. O nome do arquivo usa esse esquema: Prefixo do Amazon S3, id do estilhaço e`First-Sequence-Num`. Neste caso, pode ser algo como `sample-shard000001-10001`.
3. Depois de fazer upload do arquivo do Amazon S3, defina o ponto de verificação especificando`Last-Sequence-Num`. Neste caso, o ponto de verificação seria definido no registro de número 15.000.

Com esse esquema, mesmo se os registros forem processados mais de uma vez, o arquivo do Amazon S3 resultante terá o mesmo nome e os mesmos dados. As retentativas geram apenas a gravação dos mesmos dados no mesmo arquivo mais de uma vez.

No caso de uma operação de reestilhaçamento, o número de registros deixados no estilhaço pode ser menor que o número fixo necessário. Nesse caso, seu`shutdown()`O método precisa esvaziar o arquivo para o Amazon S3 e ponto de verificação no último número de sequência. O esquema acima também é compatível com as operações de reestilhaçamento.

Tratar inicialização, desligamento e limitação

Veja aqui algumas considerações adicionais para incorporar ao projeto do seu aplicativo do Amazon Kinesis Data Streams.

Índice

Inicializar produtores de dados e consumidores de dados

Por padrão, a KCL começa a ler registros da ponta do stream, que é o registro adicionado mais recentemente. Nessa configuração, se um aplicativo de produção de dados adicionar registros ao stream antes da execução de qualquer processador de registros de recebimento, os registros não serão lidos pelos processadores de registros após a inicialização.

Para alterar o comportamento dos processadores de registros para que eles sempre leiam dados a partir do início do stream, defina o seguinte valor no arquivo de propriedades do seu aplicativo Amazon Kinesis Data Streams:

```
initialPositionInStream = TRIM_HORIZON
```

Por padrão, o Amazon Kinesis Data Streams armazena todos os dados por 24 horas. Ele também suporta retenção prolongada de até 7 dias e a retenção de longo prazo de até 365 dias. Esse período é chamado de período de retenção. Definir a posição de início como `TRIM_HORIZON` inicia o processador de registros com os dados mais antigos no stream, conforme definido pelo período de retenção. Mesmo com a definição de `TRIM_HORIZON`, se um processador de registros iniciar após decorrido um tempo maior que o período de retenção, alguns dos registros no stream não estarão mais disponíveis. Por esse motivo, você deve sempre ter aplicativos de consumidor lendo do stream e usar a métrica `GetRecords.IteratorAgeMilliseconds` do CloudWatch para monitorar se os aplicativos estão acompanhando os dados recebidos.

Em alguns cenários, pode ser adequado aos processadores de registros perder os primeiros registros no stream. Por exemplo, você pode executar alguns registros iniciais pelo stream para testar se o stream está funcionandoend-to-endConforme o esperado. Depois de fazer essa verificação inicial, você inicia seus operadores e começa a colocar os dados de produção no stream.

Para obter mais informações sobre a configuração de `TRIM_HORIZON`, consulte Como usar iteradores de estilhaços (p. 159).

Desligando um aplicativo do Amazon Kinesis Data Streams

Quando seu aplicativo Amazon Kinesis Data Streams tiver concluído a tarefa pretendida, você deverá desligá-lo encerrando as instâncias do EC2 em que está em execução. É possível encerrar as instâncias usando o AWS Management Console ou a AWS CLI.

Depois de desligar seu aplicativo Amazon Kinesis Data Streams, você deve excluir a tabela do Amazon DynamoDB do que a KCL usou para rastrear o estado do aplicativo.

Limitação de leitura

A taxa de transferência de um stream é provisionada no nível do estilhaço. Cada estilhaço tem uma taxa de transferência de leitura de até 5 transações por segundo para leituras, até uma taxa total de leitura de dados máxima de 2 MB por segundo. Se um aplicativo (ou grupo de aplicativos que opera no mesmo stream) tentar obter dados de um estilhaço a uma taxa mais rápida, o Kinesis Data Streams limitará as operações Get correspondentes.

Em um aplicativo do Amazon Kinesis Data Streams, se um processador de registros processar dados mais rapidamente do que o limite, como no caso de um failover, ocorrerá limitação. Como o KCL gerencia as interações entre o aplicativo e o Kinesis Data Streams, as exceções de limitação ocorrem no código KCL, e não no código do aplicativo. No entanto, como a KCL registra essas exceções, você as vê nos logs.

Se você achar que o seu aplicativo fica limitado de forma consistente, considere aumentar o número de estilhaços do stream.

Monitoramento do Amazon Kinesis Data Streams

Você pode monitorar seus streaming de dados no Amazon Kinesis Data Streams usando os seguintes recursos:

- Métricas do CloudWatch (p. 190)— O Kinesis Data Streams envia a Amazon CloudWatch Métricas personalizadas do com monitoramento detalhado para cada streaming.
- Agente Kinesis (p. 202)— O Kinesis Agent publica personalizado CloudWatch Métricas para ajudar a avaliar se o agente está funcionando conforme o esperado.
- Registro em log de API (p. 202)— Uso do Kinesis Data StreamsAWS CloudTrailPara registrar chamadas à API e armazenar os dados em um bucket do Amazon S3.
- Biblioteca de cliente Kinesis (p. 206)A Biblioteca de cliente Kinesis (KCL) oferece métricas por estilhaço, operador e aplicativo KCL.
- Biblioteca de produtores do Kinesis (p. 216)A Biblioteca de Produtor Kinesis (KPL) oferece métricas por estilhaço, operador e aplicativo KPL.

Para obter mais informações sobre problemas de monitoramento, perguntas e solução de problemas comuns, consulte o seguinte:

- Quais métricas devo usar para monitorar e solucionar problemas do Kinesis Data Streams?
- Por que o IteratorAgeMilliseconds valor no Kinesis Data Streams continua aumentando?

Monitorar o Amazon Kinesis Data Streams Service com o Amazon CloudWatch

Amazon Kinesis Data Streams e Amazon CloudWatch O são integrados, permitindo coletar, visualizar e analisar as métricas do CloudWatch para os streamings de dados do Kinesis para os streamings de dados do Kinesis. Por exemplo, para rastrear o uso de estilhaços, você pode monitorar as `IncomingBytes` e as métricas de `OutgoingBytes` e compará-las com o número de estilhaços no stream.

As métricas configuradas para os streams são coletadas e enviadas automaticamente ao CloudWatch A cada minuto. As métricas são arquivadas por duas semanas. Depois desse período, os dados serão descartados.

A tabela a seguir descreve o monitoramento de nível de estilhaço avançado e nível de stream básico para streaming de dados do Kinesis.

Type	Descrição
Básico (nível de stream)	Dados de nível de stream são enviados automaticamente a cada minuto, sem custo adicional.
Avançado (nível de estilhaço)	Dados de nível de estilhaço são enviados a cada minuto por um custo adicional. Para obter

Type	Descrição
	esse nível de dados, você precisa habilitá-lo especificamente para o stream usando oEnableEnhancedMonitoringoperação. Para obter mais informações sobre definição de preço, consulte oAmazônia CloudWatch Página do produto.

Dimensões e métricas do Amazon Kinesis Data Streams

O Kinesis Data Streams envia as métricas para CloudWatch Em dois níveis: no nível do stream e, opcionalmente, do estilhaço. As métricas no nível do stream se destinam aos casos de uso de monitoramento mais comuns em condições normais. As métricas em nível de estilhaço são para tarefas de monitoramento específicas, geralmente relacionadas à solução de problemas, e são habilitadas com o uso doEnableEnhancedMonitoringoperação.

Para obter uma explicação sobre as estatísticas obtidas em CloudWatch métricas, consulteEstatísticas do CloudWatchnoAmazônia CloudWatch Guia do usuário do.

Tópicos

Métricas no nível do fluxo básicas

O namespace `AWS/Kinesis` inclui métricas de nível do fluxo a seguir.

O Kinesis Data Streams envia essas métricas em nível de streaming ao CloudWatch a cada minuto. Essas métricas estão sempre disponíveis.

Métrica	Descrição
`GetRecords.Bytes`	O número de bytes recuperados do stream do Kinesis, medido ao longo do período especificado. As estatísticas mínima, máxima e média representam os bytes em uma única operação `GetRecords` para o fluxo no período especificado. Nome da métrica do nível de estilhaço: `OutgoingBytes` Dimensões: StreamName Estatísticas: mínima, máxima, média, média, soma, amostras, amostras Unidades: Bytes
`GetRecords.IteratorAge`	Essa métrica foi substituída. Use `GetRecords.IteratorAgeMilliseconds`.

Métrica	Descrição
`GetRecords.IteratorAgeMilliseconds`	A idade do último registro em todos `GetRecords` Chamadas feitas contra um stream Kinesis, medido ao longo do período especificado. Idade é a diferença entre a hora atual e quando o último registro da chamada `GetRecords` foi gravado no stream. As estatísticas de mínimo e máximo podem ser usadas para acompanhar o progresso dos aplicativos de consumidores do Kinesis do. Um valor zero indica que os registros lidos estão em completa sincronização com o stream. Nome da métrica do nível de estilhaço: `IteratorAgeMilliseconds` Dimensões: StreamName Estatísticas: Amostras mínima, máxima, média Unidades: Milissegundos
`GetRecords.Latency`	O tempo gasto por operação `GetRecords`, medido ao longo do período de tempo especificado. Dimensões: StreamName Estatísticas: mínimo, máximo, média Unidades: Milissegundos
`GetRecords.Records`	O número de registros recuperados do estilhaço, medido ao longo do período de tempo especificado. As estatísticas mínima, máxima e média representam os registros em uma única operação `GetRecords` para o fluxo no período especificado. Nome da métrica do nível de estilhaço: `OutgoingRecords` Dimensões: StreamName Estatísticas: mínima, máxima, média, média, soma, amostras, amostras Unidades: Contagem
`GetRecords.Success`	O número de operações `GetRecords` bem-sucedidas por stream, medido ao longo do período de tempo especificado. Dimensões: StreamName Estatísticas: Média, Soma, Amostras Unidades: Contagem

Métrica	Descrição
`IncomingBytes`	O número de bytes colocados com sucesso no stream Kinesis ao longo do período especificado. Essa métrica inclui bytes das operações `PutRecord` e `PutRecords`. As estatísticas mínima, máxima e média representam os bytes em uma única operação put para o fluxo no período especificado. Nome da métrica do nível de estilhaço: `IncomingBytes` Dimensões: StreamName Estatísticas: mínima, máxima, média, média, soma, amostras, amostras Unidades: Bytes
`IncomingRecords`	O número de registros colocados com sucesso no stream do Kinesis ao longo do período de tempo especificado. Essa métrica inclui registros das operações `PutRecord` e `PutRecords`. As estatísticas mínima, máxima e média representam os registros em uma única operação put para o fluxo no período especificado. Nome da métrica do nível de estilhaço: `IncomingRecords` Dimensões: StreamName Estatísticas: mínima, máxima, média, média, soma, amostras, amostras Unidades: Contagem
`PutRecord.Bytes`	O número de bytes colocados no stream do Kinesis usando o`PutRecord`operação ao longo do período especificado. Dimensões: StreamName Estatísticas: mínima, máxima, média, média, soma, amostras, amostras Unidades: Bytes
`PutRecord.Latency`	O tempo gasto por operação `PutRecord`, medido ao longo do período de tempo especificado. Dimensões: StreamName Estatísticas: mínimo, máximo, média Unidades: Milissegundos

Métrica	Descrição
`PutRecord.Success`	O número de bem-sucedidos`PutRecord`Operações por stream Kinesis, medido ao longo do período especificado. A média reflete a porcentagem de gravações bem-sucedidas em um stream. Dimensões: StreamName Estatísticas: Média, Soma, Amostras Unidades: Contagem
`PutRecords.Bytes`	O número de bytes colocados no stream do Kinesis usando o`PutRecords`operação ao longo do período especificado. Dimensões: StreamName Estatísticas: mínima, máxima, média, média, soma, amostras, amostras Unidades: Bytes
`PutRecords.Latency`	O tempo gasto por operação `PutRecords`, medido ao longo do período de tempo especificado. Dimensões: StreamName Estatísticas: mínimo, máximo, média Unidades: Milissegundos
`PutRecords.Records`	Essa métrica foi substituída. Use `PutRecords.SuccessfulRecords`. Dimensões: StreamName Estatísticas: mínima, máxima, média, média, soma, amostras, amostras Unidades: Contagem
`PutRecords.Success`	O número de`PutRecords`Operações com pelo menos um registro bem-sucedido, por stream do Kinesis medido ao longo do período especificado. Dimensões: StreamName Estatísticas: Média, Soma, Amostras Unidades: Contagem

Métrica	Descrição
`PutRecords.TotalRecords`	O número total de registros enviados em um`PutRecords`Operação por stream de dados Kinesis, medido ao longo do período especificado. Dimensões: StreamName Estatísticas: mínima, máxima, média, média, soma, amostras, amostras Unidades: Contagem
`PutRecords.SuccessfulRecords`	O número de registros bem-sucedidos em um`PutRecords`Operação por stream de dados Kinesis, medido ao longo do período especificado. Dimensões: StreamName Estatísticas: mínima, máxima, média, média, soma, amostras, amostras Unidades: Contagem
`PutRecords.FailedRecords`	O número de registros rejeitados por causa de falhas internas em uma`PutRecords`Operação por stream de dados Kinesis, medido ao longo do período especificado. Falhas internas ocasionais devem ser esperadas e devem ser repetidas. Dimensões: StreamName Estatísticas: mínima, máxima, média, média, soma, amostras, amostras Unidades: Contagem
`PutRecords.ThrottledRecords`	O número de registros rejeitados por causa da limitação em um`PutRecords`Operação por stream de dados Kinesis, medido ao longo do período especificado. Dimensões: StreamName Estatísticas: mínima, máxima, média, média, soma, amostras, amostras Unidades: Contagem

Métrica	Descrição
`ReadProvisionedThroughputExceeded`	O número de chamadas `GetRecords` limitadas para o fluxo ao longo do período especificado. A estatística mais usada para essa métrica é Média. Quando a estatística mínima tem um valor de 1, todos os registros foram limitados ao fluxo durante o período especificado. Quando a estatística máxima tem um valor de 0 (zero), nenhum registro foi limitado ao fluxo durante o período especificado. Nome da métrica do nível de estilhaço: `ReadProvisionedThroughputExceeded` Dimensões: StreamName Estatísticas: mínima, máxima, média, média, soma, amostras, amostras Unidades: Contagem
`SubscribeToShard.RateExceeded`	Essa métrica é emitida quando uma tentativa de nova assinatura apresenta falha porque já existe uma assinatura ativa com o mesmo consumidor ou se você exceder o número de chamadas por segundo permitido para essa operação. Dimensões: StreamName
`SubscribeToShard.Success`	Essa métrica registra se a assinatura SubscribeToShard foi estabelecida com êxito. A assinatura se mantém ativa por no máximo 5 minutos. Portanto, essa métrica é emitida pelo menos uma vez a cada 5 minutos. Dimensões: StreamName
`SubscribeToShardEvent.Bytes`	O número de bytes recebidos do estilhaço, medidos no período especificado. As estatísticas mínima, máxima e média representam os bytes publicados em um único evento no período especificado. Nome da métrica do nível de estilhaço: `OutgoingBytes` Dimensões: StreamName Estatísticas: mínima, máxima, média, média, soma, amostras, amostras Unidades: Bytes
`SubscribeToShardEvent.MillisBehindLatest`	A diferença entre a hora atual e o momento em que o último registro do SubscribeToShard evento foi escrito no fluxo. Dimensões: StreamName Estatísticas: Amostras mínima, máxima, média Unidades: Milissegundos

Métrica	Descrição
`SubscribeToShardEvent.Records`	O número de registros recebidos do estilhaço, medidos no período especificado. As estatísticas mínima, máxima e média representam os registros em um único evento no período especificado. Nome da métrica do nível de estilhaço: `OutgoingRecords` Dimensões: StreamName Estatísticas: mínima, máxima, média, média, soma, amostras, amostras Unidades: Contagem
`SubscribeToShardEvent.Success`	Essa métrica é emitida sempre que um evento é publicado com êxito. Ela será emitida somente quando houver uma assinatura ativa. Dimensões: StreamName Estatísticas: mínima, máxima, média, média, soma, amostras, amostras Unidades: Contagem
`WriteProvisionedThroughputExceeded`	O número de registros rejeitados por causa da limitação para o fluxo ao longo do período especificado. Essa métrica inclui a limitação das operações `PutRecord` e `PutRecords`. A estatística mais usada para essa métrica é Média. Quando a estatística mínima tem um valor diferente de zero, nenhum registro é limitado ao fluxo durante o período especificado. Quando a estatística máxima tem um valor de 0 (zero), nenhum registro foi limitado ao fluxo durante o período especificado. Nome da métrica do nível de estilhaço: `WriteProvisionedThroughputExceeded` Dimensões: StreamName Estatísticas: mínima, máxima, média, média, soma, amostras, amostras Unidades: Contagem

Métricas do nível de estilhado aprimoradas

O namespace `AWS/Kinesis` inclui métricas de nível do estilhaço a seguir.

O Kinesis envia as seguintes métricas em nível de estilhaço ao CloudWatch A cada minuto. Cada dimensão métrica cria 1 CloudWatch métrica e faz aproximadamente 43.200`PutMetricData`Chamadas de API por mês. Essas métricas não são permitidas por padrão. Há uma cobrança para as métricas aprimoradas emitidas pelo Kinesis. Para obter mais informações, consulteAmazônia CloudWatch Definição

de preçossob o títuloMétricas personalizadas do Amazon CloudWatch. As cobranças são indicadas por estilhaço pela métrica por mês.

Métrica	Descrição
`IncomingBytes`	O número de bytes colocados com sucesso no estilhaço ao longo do período especificado. Essa métrica inclui bytes das operações `PutRecord` e `PutRecords`. As estatísticas mínima, máxima e média representam os bytes em uma única operação put para o estilhaço no período especificado. Nome da métrica no nível do fluxo: `IncomingBytes` Dimensões: StreamName, SardId Estatísticas: mínima, máxima, média, média, soma, amostras, amostras Unidades: Bytes
`IncomingRecords`	O número de registros colocados com sucesso no estilhaço ao longo do período especificado. Essa métrica inclui registros das operações `PutRecord` e `PutRecords`. As estatísticas mínima, máxima e média representam os registros em uma única operação put para o estilhaço no período especificado. Nome da métrica no nível do fluxo: `IncomingRecords` Dimensões: StreamName, SardId Estatísticas: mínima, máxima, média, média, soma, amostras, amostras Unidades: Contagem
`IteratorAgeMilliseconds`	A idade do último registro em todas as chamadas `GetRecords` feitas com relação a um estilhaço, medida ao longo do período de tempo especificado. Idade é a diferença entre a hora atual e quando o último registro da chamada `GetRecords` foi gravado no stream. As estatísticas de mínimo e máximo podem ser usadas para acompanhar o progresso dos aplicativos de consumidores do Kinesis do. Um valor de 0 (zero) indica que os registros lidos estão em completa sincronização com o fluxo. Nome da métrica no nível do fluxo: `GetRecords.IteratorAgeMilliseconds` Dimensões: StreamName, SardId Estatísticas: Amostras mínima, máxima, média Unidades: Milissegundos
`OutgoingBytes`	O número de bytes recuperados do estilhaço, medido ao longo do período de tempo especificado. As estatísticas mínima, máxima e média representam os bytes retornados em uma única operação `GetRecords` ou publicados em

Métrica	Descrição
	um único evento `SubscribeToShard` para o estilhaço no período especificado. Nome da métrica no nível do fluxo: `GetRecords.Bytes` Dimensões: StreamName, SardId Estatísticas: mínima, máxima, média, média, soma, amostras, amostras Unidades: Bytes
`OutgoingRecords`	O número de registros recuperados do estilhaço, medido ao longo do período de tempo especificado. As estatísticas mínima, máxima e média representam os registros retornados em uma única operação `GetRecords` ou publicados em um único evento `SubscribeToShard` para o estilhaço no período especificado. Nome da métrica no nível do fluxo: `GetRecords.Records` Dimensões: StreamName, SardId Estatísticas: mínima, máxima, média, média, soma, amostras, amostras Unidades: Contagem
`ReadProvisionedThroughputExceeded`	O número de chamadas `GetRecords` limitadas para o estilhaço ao longo do período especificado. Esta contagem de exceções abrange todas as dimensões dos seguintes limites: 5 leituras por estilhaço por segundo ou 2 MB por segundo por estilhaço. A estatística mais usada para essa métrica é Média. Quando a estatística mínima tem um valor de 1, todos os registros foram limitados ao estilhaço durante o período especificado. Quando a estatística máxima tem um valor de 0 (zero), nenhum registro foi limitado ao estilhaço durante o período especificado. Nome da métrica no nível do fluxo: `ReadProvisionedThroughputExceeded` Dimensões: StreamName, SardId Estatísticas: mínima, máxima, média, média, soma, amostras, amostras Unidades: Contagem

Métrica	Descrição
`WriteProvisionedThroughputExceeded`	O número de registros rejeitados por causa da limitação para o estilhaço ao longo do período especificado. Esta métrica inclui limitação das operações `PutRecord` e `PutRecords` e abrange todas as dimensões os seguintes limites: 1.000 registros por segundo por estilhaço ou 1 MB por segundo por estilhaço. A estatística mais usada para essa métrica é Média. Quando a estatística mínima tem um valor diferente de zero, nenhum registro é limitado ao estilhaço durante o período especificado. Quando a estatística máxima tem um valor de 0 (zero), nenhum registro foi limitado ao estilhaço durante o período especificado. Nome da métrica no nível do fluxo: `WriteProvisionedThroughputExceeded` Dimensões: StreamName, SardId Estatísticas: mínima, máxima, média, média, soma, amostras, amostras Unidades: Contagem

Dimensões para métricas do Amazon Kinesis Data Streams

Dimensão	Descrição
`StreamName`	O nome do fluxo do Kinesis. Todas as estatísticas disponíveis são filtradas por `StreamName`.

Métricas recomendadas do Amazon Kinesis Data Streams

Diversas métricas do Amazon Kinesis Data Streams podem ser de interesse específico para os clientes do Kinesis Data Streams do. A lista a seguir oferece métricas recomendadas e suas utilizações.

Métrica	Observações sobre o uso
`GetRecords.IteratorAgeMilliseconds`	Rastreia as posições de leitura em todos os estilhaços e consumidores no stream. Se a idade de um iterador passa de 50% do período de retenção (por padrão 24 horas, configurável até 7 dias), há risco de perda de dados devido à expiração de registro. Recomendamos usar o CloudWatch Os alarmes do na estatística Máxima para alertá-lo antes de essa perda ser um risco. Para ver um exemplo de cenário que usa essa métrica, consulte Processamento de registros de consumidores ficando atrasados (p. 183).
`ReadProvisionedThroughputExceeded`	Quando o processamento do registro do lado do consumidor está ficando para trás, às vezes é difícil saber onde está o gargalo. Use essa métrica para determinar se as leituras estão sendo limitadas por terem ultrapassado os

Métrica	Observações sobre o uso
	limites de taxa de transferência de leitura. A estatística mais usada para essa métrica é Média.
`WriteProvisionedThroughputExceeded`	Elabora a finalidade da métrica `ReadProvisionedThroughputExceeded`, mas para o lado do produtor (put) do stream. A estatística mais usada para essa métrica é Média.
`PutRecord.Success`, `PutRecords.Success`	Recomendamos usar CloudWatch Os alarmes do na estatística Média para indicar se os registros estão falhando no stream. Escolha um ou ambos os tipos put, dependendo do que o produtor usa. Se estiver usando o Kinesis Producer Library (KPL), use `PutRecords.Success`.
`GetRecords.Success`	Recomendamos usar CloudWatch Os alarmes do na estatística Média para indicar se os registros estão falhando a partir do stream.

Acessar a Amazon CloudWatch Métricas do Kinesis Data Streams

Você pode monitorar métricas para Kinesis Data Streams usando o CloudWatch console, a linha de comando ou o CloudWatch API. Os procedimentos a seguir mostram como acessar as métricas usando os seguintes métodos:

Para acessar as métricas usando a CloudWatch console

1. Abrir o CloudWatch Console dohttps://console.aws.amazon.com/cloudwatch/.
2. Na barra de navegação, escolha uma Região.
3. No painel de navegação, escolha Metrics (Métricas).
4. No painel CloudWatch Metrics by Category (Métricas do CloudWatch por categoria), selecione Kinesis Metrics (Métricas do Kinesis).
5. Clique na linha relevante para visualizar as estatísticas para o MetricName e o StreamName especificados.

   Observações: A maioria dos nomes estatísticos do console corresponde ao correspondente CloudWatch nomes de métricas listados acima, exceto paraTaxa de transferência de leituraeTaxa de transferência de gravação. Essas estatísticas são calculadas em intervalos de cinco minutos: Taxa de transferência de gravaçãoMonitora o`IncomingBytes`Métrica do CloudWatch eTaxa de transferência de leituramonitores`GetRecords.Bytes`.
6. (Opcional) No painel gráfico, selecione uma estatística e um período e, em seguida, crie uma CloudWatch alarme usando essas configurações.

Para acessar as métricas usando a AWS CLI

Use os comandos list-metrics e get-metric-statistics.

Para acessar as métricas usando a CloudWatch CLI

Use os comandos mon-list-metrics e mon-get-stats.

Para acessar as métricas usando a CloudWatch API

Use as operações ListMetrics e GetMetricsStatistics.

Monitorar a Health do agente Kinesis Data Streams com o Amazon CloudWatch

O agente publica personalizado CloudWatch métricas com um namespace deAWSKinesisAgent. Essas métricas ajudam você a avaliar se o agente está enviando dados ao Kinesis Data Streams conforme especificado, além de se ela está íntegra e consumindo a quantidade apropriada de CPU e de recursos de memória no produtor de dados do. As métricas, como número de registros e bytes enviados, são úteis para compreender a taxa em que o agente está enviando dados ao stream. Quando essas métricas ficarem abaixo dos limites esperados em alguns percentuais ou caírem para zero, isso poderá indicar problemas de configuração, erros de rede ou problemas de integridade do agente. As métricas como consumo de CPU e memória no host e contadores de erros do agente indicam uso de recurso por parte do produtor de dados e fornece informações sobre erros potenciais de configuração ou de host. Por fim, o agente também registra exceções de serviço para ajudar a investigar problemas do agente. Essas métricas são reportadas na Região especificada na configuração de agente `cloudwatch.endpoint`. As métricas do Cloudwatch publicadas a partir de vários agentes do Kinesis são agregadas ou combinadas. Para obter mais informações sobre a configuração do agente, consulte Configurações do agente (p. 107).

Monitorar com o CloudWatch

O agente Kinesis Data Streams envia as seguintes métricas ao CloudWatch.

Métrica	Descrição
`BytesSent`	O número de bytes enviados para o Kinesis Data Streams ao longo do período especificado. Unidades: Bytes
`RecordSendAttempts`	O número de tentativas de registro (primeira vez ou como nova tentativa) em uma chamada para `PutRecords` no período especificado. Unidades: Contagem
`RecordSendErrors`	O número de registros que retornaram status de falha em uma chamada para `PutRecords`, incluindo novas tentativas, no período especificado. Unidades: Contagem
`ServiceErrors`	O número de chamadas para `PutRecords` que resultaram em erro de serviço (diferente de um erro de controle de utilização) no período especificado. Unidades: Contagem

Registro de chamadas de API do Amazon Kinesis Data Streams comAWS CloudTrail

O Amazon Kinesis Data Streams está integrado aoAWS CloudTrail, um serviço que fornece um registro das ações executadas por um usuário, uma função ou umaAWSserviço no Kinesis Data Streams. CloudTrail Captura todas as chamadas de API para Kinesis Data Streams como eventos. As chamadas capturadas incluem as chamadas do console do Kinesis Data Streams e as chamadas de código para as operações da API do Kinesis Data Streams. Se você criar uma trilha, poderá habilitar a entrega contínua

do CloudTrail Eventos para um bucket do Amazon S3, incluindo eventos para Kinesis Data Streams. Se não configurar uma trilha, você ainda poderá visualizar os eventos mais recentes no CloudTrail Console doHistórico do evento. Usando as informações coletadas pelo CloudTrail, é possível determinar a solicitação feita para o Kinesis Data Streams, o endereço IP no qual a solicitação foi feita, além de detalhes adicionais.

Para saber mais sobre o CloudTrail, incluindo como configurá-lo e ativá-lo, consulte o Guia do usuário do AWS CloudTrail.

Informações do Kinesis Data Streams no CloudTrail

O CloudTrail é habilitado em sua conta da AWS quando ela é criada. Quando ocorre a atividade do evento com suporte no Kinesis Data Streams, essa atividade é registrada em um CloudTrail evento junto com outrosAWSEventos de serviço emHistórico do evento. Você pode visualizar, pesquisar e baixar os eventos recentes em sua conta da AWS. Para obter mais informações, consulte Como visualizar eventos com o histórico de eventos do CloudTrail.

Para obter um registro contínuo de eventos em seuAWSConta, incluindo eventos do Kinesis Data Streams, crie uma trilha. UMAtrilhaativa CloudTrail Para fornecer arquivos de log a um bucket do Amazon S3. Por padrão, quando você cria uma trilha no console, ela é aplicada a todas as regiões da AWS. A trilha registra em log eventos de todas as regiões na partição da AWS e entrega os arquivos de log para o bucket do Amazon S3 especificado por você. Além disso, você pode configurar outrosAWSServiços para analisar e atuar mais profundamente sobre os dados do evento coletados no CloudTrail logs. Para obter mais informações, consulte as informações a seguir:

- Visão geral da criação de uma trilha
- CloudTrail Serviços compatíveis e integrações do
- Configuração de notificações do Amazon SNS para o CloudTrail
- Receber CloudTrail Arquivos de log do de várias regiõeseReceber CloudTrail Arquivos de log do de várias contas

O Kinesis Data Streams oferece suporte ao registro das ações a seguir como eventos no CloudTrail Arquivos de log:

- AddTagsToStream
- CreateStream
- DecreaseStreamRetentionPeriod
- DeleteStream
- DeregisterStreamConsumer
- DescribeStream
- DescribeStreamConsumer
- DisableEnhancedMonitoring
- EnableEnhancedMonitoring
- IncreaseStreamRetentionPeriod
- ListStreamConsumers
- ListStreams
- ListTagsForStream
- MergeShards
- RegisterStreamConsumer
- RemoveTagsFromStream

- SplitShard
- StartStreamEncryption
- StopStreamEncryption
- UpdateShardCount

Cada entrada de log ou evento contém informações sobre quem gerou a solicitação. As informações de identidade ajudam a determinar:

- Se a solicitação foi feita com credenciais de usuário raiz ou do AWS Identity and Access Management (IAM).
- Se a solicitação foi feita com credenciais de segurança temporárias de uma função ou de um usuário federado.
- Se a solicitação foi feita por outro serviço da AWS.

Para obter mais informações, consulte o Elemento userIdentity do CloudTrail.

Exemplo: Entradas do arquivo de log do Kinesis Data Streams

Uma trilha é uma configuração que permite a entrega de eventos como arquivos de log a um bucket do Amazon S3 especificado. CloudTrail Os arquivos de log do contêm uma ou mais entradas de log. Um evento representa uma única solicitação de qualquer fonte e inclui informações sobre a ação solicitada, a data e a hora da ação, os parâmetros de solicitação e assim por diante. CloudTrail Os arquivos de log do não são um rastreamento de pilha ordenada de chamadas de API pública. Dessa forma, eles não são exibidos em uma ordem específica.

O exemplo a seguir mostra um CloudTrail Entrada de log do que demonstra a`CreateStream`,`DescribeStream`,`ListStreams`,`DeleteStream`,`SplitShard`, e`MergeShards`ações.


```
{
    "Records": [
        {
            "eventVersion": "1.01",
            "userIdentity": {
                "type": "IAMUser",
                "principalId": "EX_PRINCIPAL_ID",
                "arn": "arn:aws:iam::012345678910:user/Alice",
                "accountId": "012345678910",
                "accessKeyId": "EXAMPLE_KEY_ID",
                "userName": "Alice"
            },
            "eventTime": "2014-04-19T00:16:31Z",
            "eventSource": "kinesis.amazonaws.com",
            "eventName": "CreateStream",
            "awsRegion": "us-east-1",
            "sourceIPAddress": "127.0.0.1",
            "userAgent": "aws-sdk-java/unknown-version Linux/x.xx",
            "requestParameters": {
                "shardCount": 1,
                "streamName": "GoodStream"
            },
            "responseElements": null,
            "requestID": "db6c59f8-c757-11e3-bc3b-57923b443c1c",
            "eventID": "b7acfcd0-6ca9-4ee1-a3d7-c4e8d420d99b"
        },
```

```
        {
            "eventVersion": "1.01",
            "userIdentity": {
                "type": "IAMUser",
                "principalId": "EX_PRINCIPAL_ID",
                "arn": "arn:aws:iam::012345678910:user/Alice",
                "accountId": "012345678910",
                "accessKeyId": "EXAMPLE_KEY_ID",
                "userName": "Alice"
            },
            "eventTime": "2014-04-19T00:17:06Z",
            "eventSource": "kinesis.amazonaws.com",
            "eventName": "DescribeStream",
            "awsRegion": "us-east-1",
            "sourceIPAddress": "127.0.0.1",
            "userAgent": "aws-sdk-java/unknown-version Linux/x.xx",
            "requestParameters": {
                "streamName": "GoodStream"
            },
            "responseElements": null,
            "requestID": "f0944d86-c757-11e3-b4ae-25654b1d3136",
            "eventID": "0b2f1396-88af-4561-b16f-398f8eaea596"
        },
        {
            "eventVersion": "1.01",
            "userIdentity": {
                "type": "IAMUser",
                "principalId": "EX_PRINCIPAL_ID",
                "arn": "arn:aws:iam::012345678910:user/Alice",
                "accountId": "012345678910",
                "accessKeyId": "EXAMPLE_KEY_ID",
                "userName": "Alice"
            },
            "eventTime": "2014-04-19T00:15:02Z",
            "eventSource": "kinesis.amazonaws.com",
            "eventName": "ListStreams",
            "awsRegion": "us-east-1",
            "sourceIPAddress": "127.0.0.1",
            "userAgent": "aws-sdk-java/unknown-version Linux/x.xx",
            "requestParameters": {
                "limit": 10
            },
            "responseElements": null,
            "requestID": "a68541ca-c757-11e3-901b-cbcfe5b3677a",
            "eventID": "22a5fb8f-4e61-4bee-a8ad-3b72046b4c4d"
        },
        {
            "eventVersion": "1.01",
            "userIdentity": {
                "type": "IAMUser",
                "principalId": "EX_PRINCIPAL_ID",
                "arn": "arn:aws:iam::012345678910:user/Alice",
                "accountId": "012345678910",
                "accessKeyId": "EXAMPLE_KEY_ID",
                "userName": "Alice"
            },
            "eventTime": "2014-04-19T00:17:07Z",
            "eventSource": "kinesis.amazonaws.com",
            "eventName": "DeleteStream",
            "awsRegion": "us-east-1",
            "sourceIPAddress": "127.0.0.1",
            "userAgent": "aws-sdk-java/unknown-version Linux/x.xx",
            "requestParameters": {
                "streamName": "GoodStream"
            },
            "responseElements": null,
```

```
            "requestID": "f10cd97c-c757-11e3-901b-cbcfe5b3677a",
            "eventID": "607e7217-311a-4a08-a904-ec02944596dd"
        },
        {
            "eventVersion": "1.01",
            "userIdentity": {
                "type": "IAMUser",
                "principalId": "EX_PRINCIPAL_ID",
                "arn": "arn:aws:iam::012345678910:user/Alice",
                "accountId": "012345678910",
                "accessKeyId": "EXAMPLE_KEY_ID",
                "userName": "Alice"
            },
            "eventTime": "2014-04-19T00:15:03Z",
            "eventSource": "kinesis.amazonaws.com",
            "eventName": "SplitShard",
            "awsRegion": "us-east-1",
            "sourceIPAddress": "127.0.0.1",
            "userAgent": "aws-sdk-java/unknown-version Linux/x.xx",
            "requestParameters": {
                "shardToSplit": "shardId-000000000000",
                "streamName": "GoodStream",
                "newStartingHashKey": "11111111"
            },
            "responseElements": null,
            "requestID": "a6e6e9cd-c757-11e3-901b-cbcfe5b3677a",
            "eventID": "dcd2126f-c8d2-4186-b32a-192dd48d7e33"
        },
        {
            "eventVersion": "1.01",
            "userIdentity": {
                "type": "IAMUser",
                "principalId": "EX_PRINCIPAL_ID",
                "arn": "arn:aws:iam::012345678910:user/Alice",
                "accountId": "012345678910",
                "accessKeyId": "EXAMPLE_KEY_ID",
                "userName": "Alice"
            },
            "eventTime": "2014-04-19T00:16:56Z",
            "eventSource": "kinesis.amazonaws.com",
            "eventName": "MergeShards",
            "awsRegion": "us-east-1",
            "sourceIPAddress": "127.0.0.1",
            "userAgent": "aws-sdk-java/unknown-version Linux/x.xx",
            "requestParameters": {
                "streamName": "GoodStream",
                "adjacentShardToMerge": "shardId-000000000002",
                "shardToMerge": "shardId-000000000001"
            },
            "responseElements": null,
            "requestID": "e9f9c8eb-c757-11e3-bf1d-6948db3cd570",
            "eventID": "77cf0d06-ce90-42da-9576-71986fec411f"
        }
    ]
}
```


Monitorar a biblioteca de cliente Kinesis com o Amazon CloudWatch

OBiblioteca de cliente Kinesis(KCL) para Amazon Kinesis Data Streams publica Amazon personalizada CloudWatch Usar métricas em seu nome, usando o nome do aplicativo KCL como o namespace.

Você pode visualizar essas métricas navegando até oConsole do CloudWatche escolhendoMétricas personalizadas do. Para obter mais informações sobre métricas personalizadas, consultePublicar métricas personalizadasnoAmazônia CloudWatch Guia do usuário do.

Há uma cobrança nominal para as métricas obtidas por upload no no. CloudWatch pelo KCL; especificamente,Amazônia CloudWatch Métricas personalizadas doeAmazônia CloudWatch Solicitações da API doAplicam-se cobranças aplicáveis. Para obter mais informações, consulteAmazônia CloudWatch Definição de preços.

Tópicos

Métricas e namespace

O namespace usado para fazer o carregamento de métricas é o nome do aplicativo especificado quando você executar o KCL.

Dimensões e níveis de métricas

Há duas opções para controlar quais métricas são carregadas para o CloudWatch:

níveis de métrica

Cada métrica é atribuída a um nível individual. Quando você define um nível de relatório de métricas, as métricas com um nível individual abaixo do nível de relatório não são enviadas ao CloudWatch. Os níveis são: `NONE`, `SUMMARY` e `DETAILED`. A configuração padrão é`DETAILED`Ou seja, todas as métricas são enviadas ao CloudWatch. Um nível de relatório `NONE` significa que nenhuma métrica é enviada. Para obter informações sobre quais níveis são atribuídos a quais métricas, consulte Lista de métricas (p. 208).

dimensões habilitadas

Cada métrica do KCL tem dimensões associadas que também são enviadas ao CloudWatch. No KCL 2.x, se o KCL estiver configurado para processar um único fluxo de dados, todas as dimensões métricas (`Operation`,`ShardId`, e`WorkerIdentifier`Por padrão, as) estão ativadas. Além disso, no KCL 2.x, se o KCL estiver configurado para processar um único fluxo de dados,`Operation`Não é possível desativar a dimensão. No KCL 2.x, se o KCL estiver configurado para processar vários fluxos de dados, todas as métricas dimenções (`Operation`,`ShardId`,`StreamId`, e`WorkerIdentifier`Por padrão, as) estão ativadas. Além disso, no KCL 2.x, se o KCL estiver configurado para processar vários fluxos de dados, o`Operation`O e a`StreamId`Dimensões não podem ser desativadas.`StreamId`A dimenção está disponível somente para métricas por estilhaço.

No KCL 1.x, apenas o`Operation`O e a`ShardId`As dimensões do são habilitadas por padrão, e o`WorkerIdentifier`dimensão está desativada. No KCL 1.x, o`Operation`Não é possível desativar a dimensão.

Para obter mais informações sobre CloudWatch dimensões métricas, consulte oDimensõesseção na Amazon CloudWatch Tópico de conceitos, noAmazônia CloudWatch Guia do usuário do.

Quando o`WorkerIdentifier`A dimensão está habilitada, se um valor diferente é usado para a propriedade do ID do operador toda vez que um determinado operador do KCL é reiniciado, novos conjuntos de métricas com novos conjuntos de métricas com novos`WorkerIdentifier`valores de

dimensão são enviados para o CloudWatch. Se você precisar do`WorkerIdentifier`O valor da dimensão para ser o mesmo entre reinicializações de um operador do KCL específico; é necessário especificar explicitamente o mesmo valor do ID do operador durante a inicialização para cada operador. Observe que o valor do ID do operador para cada operador do KCL ativo precisa ser exclusivo em todos os operadores da KCL.

Configuração da métrica

Os níveis métrica e as dimensões habilitadas podem ser configurados com a KinesisClientLibConfiguration A instância, que é passada ao operador na inicialização do aplicativo KCL. No MultiLangDaemon O caso`metricsLevel`e`metricsEnabledDimensions`As propriedades podem ser especificadas no arquivo .properties usado para ativar o MultiLangDaemon Aplicativo KCL.

Os níveis métricos podem ser atribuídos a um dos três valores: NENHUM, RESUMO ou DETALHADO. Os valores de dimensões habilitadas precisam ser strings separadas por vírgulas com a lista de dimensões que são permitidas para o CloudWatch Métricas do . As dimensões usadas pelo aplicativo KCL são`Operation`,`ShardId`, e`WorkerIdentifier`.

Lista de métricas

As tabelas a seguir listam as métricas do KCL, agrupadas por escopo e operação.

Tópicos

Métricas por aplicativo KCL

Essas métricas são agregadas em todos os operadores da KCL no escopo do aplicativo, conforme definido pela Amazon CloudWatch Namespace.

Tópicos

InitializeTask

O`InitializeTask`A operação é responsável por inicializar o processador de registros para o aplicativo KCL. A lógica dessa operação inclui a obtenção de um iterador de estilhaços do Kinesis Data Streams e a inicialização do processador de registros.

Métrica	Descrição
KinesisDataFetcher.getIterator.Success	O número de bem-sucedidos`GetShardIterator`operações por aplicativo KCL.

Métrica	Descrição
	Nível de métrica: Detalhado Unidades: Contagem
KinesisDataFetcher.getIteratorTime.Time	Tempo gasto por `GetShardIterator` operação para o aplicativo KCL fornecido. Nível de métrica: Detalhado Unidades: Milissegundos
RecordProcessor.initialize.Time	Tempo percorrido pelo método de inicialização do processador de registros. Nível de métrica: Resumo Unidades: Milissegundos
Bem-sucedida	Número de inicializações bem-sucedidas do processador de registros. Nível de métrica: Resumo Unidades: Contagem
Tempo	Tempo gasto pelo operador da KCL para a inicialização do processador de registros. Nível de métrica: Resumo Unidades: Milissegundos

ShutdownTask

A operação `ShutdownTask` inicia a sequência de desligamento para o processamento de estilhaço. Isso pode ocorrer porque um estilhaço é dividido ou mesclado, ou quando a concessão do estilhaço é perdida no operador. Em ambos os casos, a função `shutdown()` do processador de registros é chamada. Novos estilhaços também são descobertos no caso em que um estilhaço é dividido ou mesclado, resultando na criação de um ou dois novos estilhaços.

Métrica	Descrição
CreateLease.Success	Número de vezes que novos estilhaços filho são adicionados com sucesso à tabela do DynamoDB do aplicativo KCL após o desligamento do estilhaço pai. Nível de métrica: Detalhado Unidades: Contagem
CreateLease.Time	Tempo usado para adicionar informações do novo estilhaço filho à tabela do DynamoDB do aplicativo KCL. Nível de métrica: Detalhado Unidades: Milissegundos
UpdateLease.Success	Número de pontos de verificação finais bem-sucedidos durante o desligamento do processador de registros. Nível de métrica: Detalhado

Métrica	Descrição
	Unidades: Contagem
UpdateLease.Time	Tempo necessário para a operação de pontos de verificação durante o desligamento do processador de registros. Nível de métrica: Detalhado Unidades: Milissegundos
RecordProcessor.shutdown.Time	Tempo percorrido pelo método de desligamento do processador de registros. Nível de métrica: Resumo Unidades: Milissegundos
Bem-sucedida	Número de tarefas de desligamento bem-sucedidas. Nível de métrica: Resumo Unidades: Contagem
Tempo	Tempo percorrido pelo operador da KCL para a tarefa de desligamento. Nível de métrica: Resumo Unidades: Milissegundos

ShardSyncTask

O`ShardSyncTask`A operação detecta alterações nas informações de estilhaços do stream de dados do Kinesis, para que novos estilhaços possam ser processados pelo aplicativo KCL.

Métrica	Descrição
CreateLease.Success	Número de tentativas bem-sucedidas para adicionar novas informações de estilhaços à tabela do DynamoDB do aplicativo KCL. Nível de métrica: Detalhado Unidades: Contagem
CreateLease.Time	Tempo usado para adicionar informações do novo estilhaço à tabela do DynamoDB do aplicativo KCL. Nível de métrica: Detalhado Unidades: Milissegundos
Bem-sucedida	Número de operações bem-sucedidas de sincronização de estilhaços. Nível de métrica: Resumo Unidades: Contagem
Tempo	Tempo percorrido para a operação de sincronização de estilhaços. Nível de métrica: Resumo

Métrica	Descrição
	Unidades: Milissegundos

BlockOnParentTask

Se o estilhaço é dividido ou mesclado com outros, novos estilhaços filhos são criados. O`BlockOnParentTask`A operação garante que o processamento de registros dos novos estilhaços não será iniciado até que os estilhaços pai sejam completamente processados pela KCL.

Métrica	Descrição
Bem-sucedida	Número de verificações bem-sucedidas para a conclusão de estilhaços pai. Nível de métrica: Resumo Unidades: Contagem
Tempo	Tempo percorrido para a conclusão de estilhaços pai. Nível de métrica: Resumo Unidade: Milissegundos

PeriodicShardSyncManager

O`PeriodicShardSyncManager`é responsável por examinar os fluxos de dados que estão sendo processados pelo aplicativo consumidor KCL, identificar fluxos de dados com arrendamentos parciais e entregá-los para sincronização.

As seguintes métricas estão disponíveis quando o KCL está configurado para processar um único fluxo de dados (então o valor de NumStreamsToSync e NumStreamsWithPartialLeases está definido como 1) e também quando o KCL está configurado para processar vários fluxos de dados.

Métrica	Descrição
NumStreamStoSync	O número de fluxos de dados (porAWSconta) sendo processado pelo aplicativo consumidor que contém arrendamentos parciais e que devem ser distribuídos para sincronização. Nível de métrica: Resumo Unidades: Contagem
NumStreamsWithPartialLeases	O número de fluxos de dados (porAWSconta) que o aplicativo do consumidor está processando que contém arrendamentos parciais. Nível de métrica: Resumo Unidades: Contagem
Bem-sucedida	O número de vezes`PeriodicShardSyncManager`foi capaz de identificar com êxito locações parciais nos fluxos de dados que o aplicativo do consumidor está processando. Nível de métrica: Resumo

Métrica	Descrição
	Unidades: Contagem
Tempo	A quantidade de tempo (em milissegundos) que `oPeriodicShardSyncManager`leva para examinar os fluxos de dados que o aplicativo consumidor está processando, a fim de determinar quais fluxos de dados requerem sincronização de fragmento. Nível de métrica: Resumo Unidades: Milissegundos

MultistreamTracker

O`MultistreamTracker`permite que você crie aplicativos de consumidor KCL que podem processar vários fluxos de dados ao mesmo tempo.

Métrica	Descrição
DeletedStreams.count	O número de fluxos de dados excluídos neste período de tempo. Nível de métrica: Resumo Unidades: Contagem
ActiveStreams.count	O número de fluxos de dados ativos sendo processados. Nível de métrica: Resumo Unidades: Contagem
StreamSpendingDeletion.count	O número de fluxos de dados que estão pendentes de exclusão com base em`FormerStreamsLeasesDeletionStrategy`. Nível de métrica: Resumo Unidades: Contagem

Métricas por operador

Essas métricas são agregadas em todos os processadores de registros que consomem dados de um stream de dados do Kinesis, como uma instância do Amazon EC2.

Tópicos

- RenewAllLeases (p. 212)
- TakeLeases (p. 213)

RenewAllLeases

A operação `RenewAllLeases` renova periodicamente concessões de estilhaços de propriedade de uma determinada instância de operador.

Métrica	Descrição
RenewLease.Success	Número de renovações bem-sucedidas de concessões por parte do operador. Nível de métrica: Detalhado Unidades: Contagem
RenewLease.Time	O tempo necessário para a operação de renovação de concessões. Nível de métrica: Detalhado Unidades: Milissegundos
CurrentLeases	Número de concessões de estilhaços pertencentes ao operador depois que todas as concessões foram renovadas. Nível de métrica: Resumo Unidades: Contagem
LostLeases	Número de concessões de estilhaços perdidas após uma tentativa de renovar todas as concessões pertencentes ao operador. Nível de métrica: Resumo Unidades: Contagem
Bem-sucedida	Número de vezes que a operação de renovação da concessão foi bem-sucedida para o operador. Nível de métrica: Resumo Unidades: Contagem
Tempo	Tempo percorrido para renovar todas as concessões para o operador. Nível de métrica: Resumo Unidades: Milissegundos

TakeLeases

O`TakeLeases`A operação equilibra o processamento de registros entre todos os operadores da KCL. Se o operador do KCL atual tem menos concessões de estilhaços que o necessário, usa concessões de estilhaços de outro operador que está sobrecarregado.

Métrica	Descrição
ListLeases.Success	Número de vezes que todas as concessões de estilhaços foram recuperadas com sucesso da tabela do DynamoDB do aplicativo KCL. Nível de métrica: Detalhado Unidades: Contagem
ListLeases.Time	Tempo usado para recuperar todas as concessões de estilhaços da tabela do DynamoDB do aplicativo KCL.

Métrica	Descrição
	Nível de métrica: Detalhado Unidades: Milissegundos
TakeLease.Success	Número de vezes que o operador usou com êxito concessões de estilhaços de outros operadores da KCL. Nível de métrica: Detalhado Unidades: Contagem
TakeLease.Time	Tempo percorrido para atualizar a tabela de concessão com concessões executadas pelo operador. Nível de métrica: Detalhado Unidades: Milissegundos
NumWorkers	Número total de operadores, conforme identificado por um operador específico. Nível de métrica: Resumo Unidades: Contagem
NeededLeases	Número de concessões de estilhaços que o operador atual precisa para uma carga de processamento de estilhaços equilibrada. Nível de métrica: Detalhado Unidades: Contagem
LeasesToTake	O número de concessões que o operador tentará executar. Nível de métrica: Detalhado Unidades: Contagem
TakenLeases	Número de concessões realizadas com sucesso pelo operador. Nível de métrica: Resumo Unidades: Contagem
TotalLeases	Número total de estilhaços que o aplicativo KCL está processando. Nível de métrica: Detalhado Unidades: Contagem
ExpiredLeases	Número total de estilhaços que não estão sendo processados por nenhum operador, conforme identificado pelo operador específico. Nível de métrica: Resumo Unidades: Contagem

Métrica	Descrição
Bem-sucedida	Número de vezes que a operação `TakeLeases` foi concluída com sucesso. Nível de métrica: Resumo Unidades: Contagem
Tempo	Tempo percorrido pela operação `TakeLeases` para um operador. Nível de métrica: Resumo Unidades: Milissegundos

Métricas por estilhaço

Essas métricas são agregadas em um único processador de registros.

ProcessTask

O`ProcessTask`Chamadas de operaçãoGetRecordsCom a posição do iterador atual para recuperar registros do stream e chama o processador de registros do e chama o processador de registros`processRecords`função.

Métrica	Descrição
KinesisDataFetcher.getRecords.Success	Número de bem-sucedidos`GetRecords`operações por fragmento de fluxo de dados do Kinesis. Nível de métrica: Detalhado Unidades: Contagem
KinesisDataFetcher.getRecords.Time	Tempo gasto por`GetRecords`operação para o estilhaço de fluxo de dados do Kinesis. Nível de métrica: Detalhado Unidades: Milissegundos
UpdateLease.Success	Número de pontos de verificação bem-sucedidos feitos pelo processador de registros para o determinado estilhaço. Nível de métrica: Detalhado Unidades: Contagem
UpdateLease.Time	Tempo percorrido para cada operação de ponto de verificação para o determinado estilhaço. Nível de métrica: Detalhado Unidades: Milissegundos
DataBytesProcessed	Tamanho total de registros processados em bytes em cada chamada de `ProcessTask`. Nível de métrica: Resumo

Métrica	Descrição
	Unidades: Byte
RecordsProcessed	Número de registros processados em cada chamada de `ProcessTask`. Nível de métrica: Resumo Unidades: Contagem
ExpiredIterator	Número de ExpiredIteratorException recebido ao ligar`GetRecords`. Nível de métrica: Resumo Unidades: Contagem
MillisBehindLatest	Tempo em que o iterador atual está atrás do registro mais recente (ponta) no estilhaço. Esse valor é menor ou igual à diferença da hora entre o registro mais recente em uma resposta e a hora atual. Esse é um reflexo mais preciso da distância em que um estilhaço está da ponta do que a comparação de time stamps no último registro de resposta. Esse valor se aplica ao último lote de registros, não a uma média de todos os time stamps em cada registro. Nível de métrica: Resumo Unidades: Milissegundos
RecordProcessor.processRecords.Time	Tempo percorrido pelo método `processRecords` do processador de registros. Nível de métrica: Resumo Unidades: Milissegundos
Bem-sucedida	Número de operações bem-sucedidas de tarefas do processo. Nível de métrica: Resumo Unidades: Contagem
Tempo	Tempo percorrido para a operação de tarefas do processo. Nível de métrica: Resumo Unidades: Milissegundos

Monitorando a biblioteca do produtor Kinesis com o Amazon CloudWatch

OBiblioteca de produtores do Kinesis(KPL) para Amazon Kinesis Data Streams publica Amazon personalizada CloudWatch Métricas em seu nome. Você pode visualizar essas métricas navegando até oConsole do CloudWatche escolhendoMétricas personalizadas do. Para obter mais informações sobre métricas personalizadas, consultePublicar métricas personalizadasnoAmazônia CloudWatch Guia do usuário do.

Há uma cobrança nominal para as métricas obtidas por upload no no. CloudWatch pela KPL; especificamente, a Amazon CloudWatch Métricas personalizadas e Amazon CloudWatch Aplicam-se

cobranças de solicitações de API. Para obter mais informações, consulteAmazônia CloudWatch Definição de preços. A coleta de métricas locais não gera cobranças do CloudWatch.

Tópicos

Métricas, dimensões e namespaces

Você pode especificar um nome de aplicativo ao ativar o KPL, que é, então, usado como parte do namespace durante o carregamento de métricas. Isso é opcional; a KPL oferece um valor padrão se um nome de aplicativo não é definido.

Você também pode configurar a KPL para adicionar dimensões adicionais arbitrárias às métricas. Isso é útil se você deseja dados mais refinados no seu CloudWatch Métricas do . Por exemplo, você pode adicionar o nome de host como uma dimensão, o que permite que você identifique distribuições de carga irregulares na frota. Todas as definições de configuração da KPL são imutáveis; portanto, não é possível alterar essas dimensões adicionais após a instância do KPL ser inicializada.

Granularidade e nível de métrica

Há duas opções para controlar o número de métricas carregadas para o CloudWatch:

nível de métrica

Este é um indicador aproximado da importância de uma métrica. Cada métrica é atribuída a um nível. Ao definir um nível, as métricas com níveis menores não são enviadas ao CloudWatch. Os níveis são `NONE`, `SUMMARY` e `DETAILED`. A configuração padrão é `DETAILED`. Ou seja, todas as métricas. `NONE` significa que não há métricas, de modo que nenhuma métrica é atribuída a esse nível.

granularidade

Controla se a mesma métrica é emitida em níveis adicionais de granularidade. Os níveis são `GLOBAL`, `STREAM` e `SHARD`. A configuração padrão é `SHARD`, que contém as métricas mais granulares.

Quando `SHARD` é escolhida, as métricas são emitidas com o nome do stream e o ID do estilhaço como dimensões. Além disso, a mesma métrica também é emitida com somente a dimensão do nome do stream, e a métrica sem o nome do stream. Isso significa que, para uma métrica específica, dois fluxos com dois fragmentos cada produzirão sete CloudWatch Métricas: uma para cada estilhaço, um para cada stream e uma geral; todas descrevem as mesmas estatísticas, mas em diferentes níveis de granularidade. Para ter um esclarecimento, consulte o diagrama abaixo.

Os diferentes níveis de granularidade formam uma hierarquia, e todas as métricas no sistema formam árvores, enraizadas nos nomes da métrica:

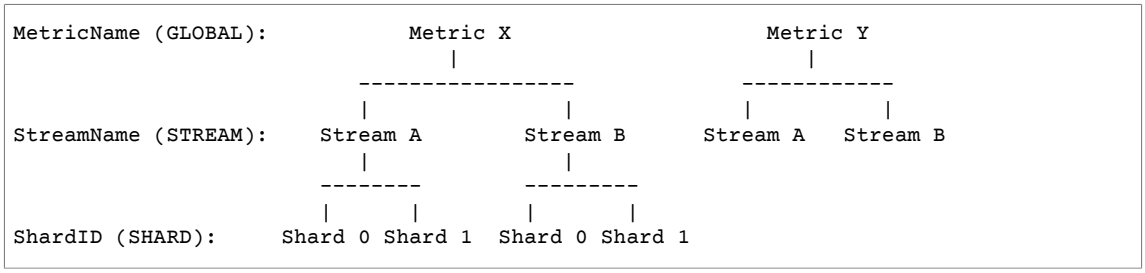

Nem todas as métricas estão disponíveis no nível de estilhaço; algumas são de nível de stream ou globais por natureza. Elas não são produzidas no nível de estilhaço, mesmo se você tiver habilitado as métricas nesse nível (`Metric Y` no diagrama acima).

Quando você especifica uma dimensão adicional, precisa fornecer valores para `tuple:<DimensionName, DimensionValue, Granularity>`. A granularidade é usada para determinar onde a dimensão personalizada é inserida na hierarquia: `GLOBAL` significa que a dimensão adicional é inserida após o nome da métrica, `STREAM` significa que ela é inserida após o nome do stream e `SHARD` significa que ela é inserida depois do ID de estilhaço. Se várias dimensões adicionais são fornecidas por nível de granularidade, elas são inseridas na ordem determinada.

Acesso local e Amazon CloudWatch Carregar

Métricas para a instância atual da KPL estão disponíveis localmente em tempo real; é possível consultar a KPL a qualquer momento para obtê-las. A KPL calcula localmente a soma, a média, o mínimo, o máximo, e a contagem de cada métrica, como no CloudWatch.

Você pode obter estatísticas que são cumulativas desde o início do programa até o presente momento ou usar uma janela contínua ao longo dos últimos N segundos, em que N é um número inteiro entre 1 e 60.

Todas as métricas estão disponíveis para carregamento ao CloudWatch. Isso é especialmente útil para agregar dados em vários hosts, monitoramentos e alarmes. Essa funcionalidade não está disponível localmente.

Conforme descrito anteriormente, é possível selecionar de quais métricas fazer upload com as configurações de nível de métrica e granularidade. As métricas que não são carregadas estão disponíveis localmente.

Carregar pontos de dados individualmente é insustentável, porque isso pode produzir milhões de carregamentos por segundo se o tráfego for alto. Por esse motivo, a KPL agrega métricas localmente em buckets de 1 minuto e faz upload de um objeto de estatística para CloudWatch Uma vez por minuto, por métrica ativada.

Lista de métricas

Métrica	Descrição
`UserRecordsReceived`	Contagem de quantos registros de usuário lógicos foram recebidos pelo núcleo KPL para operações put. Não disponível no nível de estilhaço. Nível de métrica: Detalhado Unidade: contagem
`UserRecordsPending`	Exemplo periódico de quantos registros de usuário estão pendentes atualmente. Um registro está pendente se está atualmente em buffer e esperando para ser enviado ou se foi enviado e está em trânsito para o serviço de back-end. Não disponível no nível de estilhaço. A KPL oferece um método dedicado para recuperar essa métrica em nível global para os clientes gerenciarem a taxa de colocação. Nível de métrica: Detalhado Unidade: contagem

Métrica	Descrição
`UserRecordsPut`	Contagem de quantos registros de usuário lógicos foram colocados com êxito. A KPL não conta registros com falhas para essa métrica. Isso permite que a média ofereça a taxa de sucesso, que a contagem ofereça o total de tentativas e que a diferença entre a contagem e a soma ofereça o número de falhas. Nível de métrica: Resumo Unidade: contagem
`UserRecordsDataPut`	Bytes nos registros de usuário lógicos colocados com êxito. Nível de métrica: Detalhado Unidade: Bytes
`KinesisRecordsPut`	Contagem de quantos registros do Kinesis Data Streams foram colocados com sucesso (cada registro do Kinesis Data Streams pode conter vários registros de usuário). O KPL retorna zero para registros com falha. Isso permite que a média ofereça a taxa de sucesso, que a contagem ofereça o total de tentativas e que a diferença entre a contagem e a soma ofereça o número de falhas. Nível de métrica: Resumo Unidade: contagem
`KinesisRecordsDataPut`	Bytes nos registros do Kinesis Data Streams. Nível de métrica: Detalhado Unidade: Bytes
`ErrorsByCode`	Contagem de cada tipo de código de erro. Apresenta uma dimensão adicional de `ErrorCode`, além de dimensões normais, como `StreamName` e `ShardId`. Nem todo erro pode ser rastreado até um estilhaço. Os erros que não podem ser rastreados são apenas emitidos nos níveis globais ou de stream. Essa métrica captura informações sobre fatores como limitações, alterações no mapa de estilhaços, falhas internas, serviço indisponível, limites de tempo e assim por diante. Os erros da API Kinesis Data Streams são contados uma vez por registro do Kinesis Data Streams. Vários registros de usuário em um registro do Kinesis Data Streams não geram várias contagens. Nível de métrica: Resumo Unidade: contagem
`AllErrors`	Isso é acionado pelos mesmos erros de Erros por código, mas não faz distinção entre tipos. Isso é útil como um monitor geral da taxa de erros sem exigir uma soma manual das contagens de todos os tipos diferentes de erros. Nível de métrica: Resumo Unidade: contagem

Métrica	Descrição
`RetriesPerRecord`	Número de tentativas realizadas por registro de usuário. Zero é emitido para registros que são bem-sucedidos em uma tentativa. Os dados são emitidos no momento em que um usuário termina (quando o registro é bem-sucedido ou não pode mais ser repetido). Registro Se o time-to-live É um valor grande, essa métrica pode estar significativamente atrasada. Nível de métrica: Detalhado Unidade: contagem
`BufferingTime`	O tempo entre um registro de usuário que chega ao KPL e sai para o back-end. Essas informações são transmitidas de volta ao usuário por registro, mas também estão disponíveis como estatística agregada. Nível de métrica: Resumo Unidade: Milissegundos
`Request Time`	O tempo necessário para executar `PutRecordsRequests`. Nível de métrica: Detalhado Unidade: Milissegundos
`User Records per Kinesis Record`	O número de registros de usuário lógicos agregados em um único registro do Kinesis Data Streams. Nível de métrica: Detalhado Unidade: contagem
`Amazon Kinesis Records per PutRecordsRequest`	O número de registros do Kinesis Data Streams agregados em uma únicaPutRecordsRequest. Não disponível no nível de estilhaço. Nível de métrica: Detalhado Unidade: contagem
`User Records per PutRecordsRequest`	O número total de registros de usuário contidos em um `PutRecordsRequest`. Isso é equivalente aproximadamente ao produto das últimas duas métricas. Não disponível no nível de estilhaço. Nível de métrica: Detalhado Unidade: contagem

Segurança no Amazon Kinesis Data Streams

A segurança da nuvem na AWS é a nossa maior prioridade. Como um cliente da AWS, você se beneficiará de um datacenter e uma arquitetura de rede criados para atender os requisitos da maioria das organizações com exigências de segurança.

A segurança é uma responsabilidade compartilhada entre a AWS e você. O modelo de responsabilidade compartilhada descreve isto como segurança da nuvem e segurança na nuvem:

- Segurança da nuvem: a AWS é responsável pela proteção da infraestrutura que executa produtos da AWS na Nuvem AWS. A AWS também fornece serviços que podem ser usados com segurança. A eficácia da nossa segurança é regularmente testada e verificada por auditores de terceiros como parte dos Programas de conformidade da AWS. Para saber mais sobre os programas de conformidade que se aplicam ao Kinesis Data Streams, consulteAWSServiços no escopo pelo programa de conformidade.
- Segurança da nuvem: sua responsabilidade é determinada pelo serviço da AWS que você usa. Você também é responsável por outros fatores, incluindo a confidencialidade de seus dados, os requisitos da sua organização e as leis e regulamentos aplicáveis.

Esta documentação ajuda a entender como aplicar o modelo de responsabilidade compartilhada ao usar o Kinesis Data Streams. Os tópicos a seguir mostram como configurar o Kinesis Data Streams para atender aos seus objetivos de segurança e compatibilidade. Você também aprenderá a usar outrosAWSServiços que podem ajudar você a monitorar e proteger seus recursos do Kinesis Data Streams.

Tópicos

Proteção de dados no Amazon Kinesis Data Streams

Criptografia do lado do servidor usandoAWS Key Management Service(AWS KMSO) facilita cumprir os rigorosos requisitos de gerenciamento de dados criptografando os dados em repouso no Amazon Kinesis Data Streams.

> Note
>
> Se você precisar de módulos criptográficos validados pelo FIPS 140-2 ao acessar a AWS por meio de uma interface de linha de comando ou uma API, use um endpoint do FIPS. Para obter mais informações sobre endpoints do FIPS, consulte Federal Information Processing Standard (FIPS) 140-2.

Tópicos

O que é criptografia no lado do servidor para o Kinesis Data Streams?

A criptografia no lado do servidor é um recurso do Amazon Kinesis Data Streams que criptografa automaticamente os dados antes de estarem em repouso usando umAWS KMSChave mestra de cliente (CMK) especificada por você. Os dados são criptografados antes de serem gravados na camada de armazenamento do stream do Kinesis e descriptografados depois de recuperados do armazenamento. Como resultado, seus dados são criptografados em repouso no serviço Kinesis Data Streams. Isso permite que você atenda a requisitos normativos rígidos e aprimore a segurança de seus dados.

Com a criptografia no lado do servidor, seus produtores e consumidores de stream do Kinesis não precisam gerenciar chaves mestras ou operações de criptografia. Seus dados são criptografados automaticamente à medida que entram e saem do serviço Kinesis Data Streams, de modo que os dados em repouso ficam criptografados.AWS KMSO fornece todas as chaves mestras usadas pelo recurso de criptografia no lado do servidor.AWS KMSFacilita o uso de uma CMK for Kinesis gerenciada peloAWS, especificado pelo usuárioAWS KMSCMK ou uma chave mestra importada para oAWS KMSserviçoServiço

> **Note**
>
> Criptografia no lado do servidor criptografa os dados de entrada somente após a criptografia ser ativada. Os dados preexistentes em um stream não criptografado não são criptografados após a ativação da criptografia no lado do servidor.

Custos, regiões e considerações sobre desempenho

Ao aplicar criptografia no lado do servidor, você está sujeito aos custos de uso da chave e da API do AWS KMS. Ao contrário das chaves mestras do KMS personalizadas, a chave mestra do cliente (CMK) do `(Default) aws/kinesis` é oferecida gratuitamente. No entanto, você ainda deverá pagar os custos de uso da API que o Amazon Kinesis Data Streams gera em seu nome.

Os custos de uso da API aplicam-se a cada CMK, incluindo as personalizadas. Chamadas do Kinesis Data StreamsAWS KMSAproximadamente a cada cinco minutos quando está alterando a chave de dados. Em um mês de 30 dias, o custo total doAWS KMSAs chamadas à API do iniciadas por um stream do Kinesis devem ser de apenas alguns dólares. Esse custo cresce com o número de credenciais de usuário que você usa nos seus produtores e consumidores de dados, pois cada credencial de usuário requer uma chamada de API exclusiva para o AWS KMS. Quando você usa uma função do IAM para autenticação, cada chamada de função assumida resulta em credenciais de usuário exclusivas. Para economizar gastos com o KMS, armazene em cache as credenciais de usuário que são retornadas pela chamada de função assumida.

Veja a seguir a descrição dos custos por recurso:

Chaves

- A CMK para Kinesis gerenciada porAWS(alias =`aws/kinesis`O) é gratuito.
- As chaves do KMS geradas pelo usuário estão sujeitas aos custos de chave do KMS. Para obter mais informações, consulteAWSPreços do Key Management Service.

Os custos de uso da API aplicam-se a cada CMK, incluindo as personalizadas. O Kinesis Data Streams chama o KMS aproximadamente a cada 5 minutos quando está alterando a chave de dados. Em um mês de 30 dias, o custo total das chamadas à API do KMS iniciadas por um stream de dados do Kinesis deve ser de apenas alguns dólares. Observe que esse custo cresce com o número de credenciais de usuário que você usa nos seus produtores e consumidores de dados, pois cada credencial de usuário requer uma chamada de API exclusiva para oAWSKMS. Quando você usa a função do IAM para autenticação, cada chamada assume-role-call resultará em credenciais de usuário exclusivas e talvez você queira armazenar em cache as credenciais de usuário retornadas pelo assume-role-call para economizar custos do KMS.

Uso da API do KMS

Para cada fluxo criptografado, ao ler do TIP e usar uma única chave de acesso de conta/usuário do IAM entre leitores e escritores, o serviço Kinesis chama oAWS KMSAtende aproximadamente 12 vezes a cada 5 minutos. Não ler do TIP pode levar a chamadas mais altas paraAWS KMSserviçoServiço As solicitações à API para gerar novas chaves de criptografia de dados estão sujeitas aos custos de uso do AWS KMS. Para obter mais informações, consulteAWSPreços do Key Management Service: Uso.

Disponibilidade da criptografia no lado do servidor por região

Atualmente, a criptografia no lado do servidor dos streamings do Kinesis estão disponíveis em todas as regiões compatíveis com o Kinesis Data Streams, incluindoAWS GovCloud (Oeste dos EUA) e as regiões da China. Para obter mais informações sobre regiões suportadas pelo Kinesis Data Streams, consultehttps://docs.aws.amazon.com/general/latest/gr/ak.html.

Considerações sobre desempenho

Devido à sobrecarga de serviço da aplicação de criptografia, a aplicação de criptografia do lado do servidor aumenta a latência típica de `PutRecord`, `PutRecords` e `GetRecords` em menos de 100 µs.

Como começo a usar a criptografia no lado do servidor?

A maneira mais fácil de começar a usar a criptografia no lado do servidor é usar oAWS Management Consolee a chave de serviço do Amazon Kinesis KMS,`aws/kinesis`.

O procedimento a seguir demonstra como ativar a criptografia no lado do servidor para um stream do Kinesis stream do.

Para ativar a criptografia no lado do servidor para um stream do Kinesis

1. Faça login noAWS Management Consolee abra oConsole do Amazon Kinesis Data Streams.
2. Crie ou selecione um stream do Kinesis noAWS Management Console.
3. Selecione a guia Details (Detalhes).
4. Em Server-side encryption (Criptografia no lado do servidor), selecione Edit (Editar).
5. A não ser que você queira usar uma chave mestra do KMS gerada pelo usuário, selecione a chave mestra do KMS (Default) aws/kinesis ((Padrão) aws/kinesis). Essa é a chave mestra do KMS gerada pelo serviço Kinesis. Selecione Enabled (Habilitado) e, em seguida, selecione Save (Salvar).

   Note

   A chave mestra padrão do serviço Kinesis é gratuita, porém, as chamadas à API feitas pelo Kinesis para oAWS KMSo serviço está sujeito aos custos de uso do KMS.
6. O fluxo passa por um estado pending (pendente). Assim que o fluxo voltar a um estado active (ativo) com a criptografia habilitada, todos os dados recebidos gravados no fluxo serão criptografados usando a chave mestra selecionada do KMS.

7. Para desabilitar a criptografia do lado do servidor, selecione Disabled (Desabilitada) em Server-side encryption (Criptografia do lado do servidor) no AWS Management Console e, em seguida, selecione Save (Salvar).

Criação e uso de chaves mestras do KMS geradas pelo usuário

Esta seção descreve como criar e usar suas próprias chaves mestras do KMS em vez de usar a chave mestra administrada pelo Amazon Kinesis.

Criação de chaves mestras do KMS geradas pelo usuário

Para obter instruções sobre como criar suas próprias chaves mestras, consulteCriação de chavesnoAWS Key Management ServiceGuia do desenvolvedor. Depois de criar chaves para sua conta, o serviço Kinesis Data Streams retorna essas chaves naKMS master keyLista.

Uso de chaves mestras do KMS geradas pelo usuário

Assim que as permissões corretas forem aplicadas aos seus consumidores, produtores e administradores, você poderá usar chaves mestras do KMS personalizadas por conta própriaAWSconta ou outraAWSconta. Todas as chaves mestras do KMS em sua conta aparecem na lista KMS Master Key (Chave mestra do KMS) no AWS Management Console.

Para usar chaves mestras do KMS personalizadas localizadas em outra conta, você precisa de permissões para usar essas chaves. Você também deve especificar o ARN da chave mestra do KMS na caixa de entrada ARN no AWS Management Console.

Permissões para usar as chaves mestras do KMS geradas pelo usuário

Antes que você possa usar a criptografia no lado do servidor com uma chave mestra do KMS gerada pelo usuário, você deve configurar as políticas de chaves do AWS KMS para permitir a criptografia de streams e a criptografia e a descriptografia de registros de stream. Para obter mais exemplos e informações sobreAWS KMSpermissões, consulteAWSPermissões da API do KMS Referência de ações e recursos.

> **Note**
>
> O uso da chave padrão do serviço para criptografia não requer a aplicação de permissões personalizadas do IAM.

Antes de usar as chaves mestras do KMS geradas pelo usuário, verifique se seus produtores e consumidores de stream do Kinesis (principais do IAM) são usuários na política de chaves mestras do KMS. Caso contrário, as gravações e as leituras de um streaming falharão, o que pode resultar, em última análise, em perda de dados, processamento atrasado, ou travamento de aplicativos. Você pode gerenciar permissões para chaves do KMS usando políticas do IAM. Para obter mais informações, consulteComo usar políticas do IAMAWSKMS.

Exemplo de permissões de produtor

Seus produtores de streaming do Kinesis devem ter `kms:GenerateDataKey`permissão.

```
{
  "Version": "2012-10-17",
  "Statement": [
```

```
    {
        "Effect": "Allow",
        "Action": [
            "kms:GenerateDataKey"
        ],
        "Resource": "arn:aws:kms:us-
west-2:123456789012:key/1234abcd-12ab-34cd-56ef-1234567890ab"
    },
    {
        "Effect": "Allow",
        "Action": [
            "kinesis:PutRecord",
            "kinesis:PutRecords"
        ],
        "Resource": "arn:aws:kinesis:*:123456789012:MyStream"
    }
  ]
}
```

Exemplo de permissões de consumidor

Seus consumidores do stream do Kinesis devem ter o`kms:Decrypt`permissão.

```
{
  "Version": "2012-10-17",
  "Statement": [
    {
        "Effect": "Allow",
        "Action": [
            "kms:Decrypt"
        ],
        "Resource": "arn:aws:kms:us-
west-2:123456789012:key/1234abcd-12ab-34cd-56ef-1234567890ab"
    },
    {
        "Effect": "Allow",
        "Action": [
            "kinesis:GetRecords",
            "kinesis:DescribeStream"
        ],
        "Resource": "arn:aws:kinesis:*:123456789012:MyStream"
    }
  ]
}
```

Amazon Kinesis Data Analytics eAWS LambdaUse funções para consumir fluxos do Kinesis. Adicione a permissão `kms:Decrypt` às funções que esses consumidores usam.

Permissões de administrador de stream

Os administradores de stream do Kinesis devem ter autorização para chamar`kms:List*`e`kms:DescribeKey*`.

Verificação e solução de problemas de permissões de chaves do KMS

Depois de ativar a criptografia em um stream do Kinesis, recomendamos que você monitore o sucesso de sua`putRecord`,`putRecords`, e`getRecords`chamadas usando a seguinte Amazon CloudWatch Métricas :

- `PutRecord.Success`
- `PutRecords.Success`
- `GetRecords.Success`

Para obter mais informações, consulteMonitoramento do Amazon Kinesis Data Streams (p. 190)

Usar o Amazon Kinesis Data Streams com VPC endpoints de interface

Você pode usar um VPC endpoint de interface para evitar que o tráfego entre sua Amazon VPC e o Kinesis Data Streams saia da rede da Amazon. VPC endpoints de interface não exigem um gateway de Internet, dispositivo NAT, conexão VPN ou conexão do AWS Direct Connect. Os endpoints de interface da VPC são desenvolvidos peloAWSPrivateLink, umAWStecnologia que permite a comunicação privada entreAWSServiços da usando uma elastic network interface com IPs privados em sua Amazon VPC. Para obter mais informações, consulteAmazon Virtual Private CloudeVPC endpoints de interface (AWSPrivateLink).

Tópicos

- Usar VPC endpoints de interface para o Kinesis Data Streams (p. 226)
- Controlar o acesso a endpoints de VPCE para o Kinesis Data Streams (p. 226)
- Disponibilidade de políticas de VPC endpoint para o Kinesis Data Streams (p. 227)

Usar VPC endpoints de interface para o Kinesis Data Streams

Para começar, você não precisa alterar as configurações para os fluxos, produtores ou consumidores. Basta criar um VPC endpoint de interface para que o tráfego do Kinesis Data Streams de entrada e de saída do para os recursos da Amazon VPC comece a fluir por meio do VPC endpoint de interface. Para obter mais informações, consulte Criação de um endpoint de interface.

A chamada da Kinesis Producer Library (KPL) e a Kinesis Consumer Library (KCL)AWSserviços como a Amazon CloudWatch O e o Amazon DynamoDB usando VPC endpoints públicos ou privados de interface, o que estiver em uso. Por exemplo, se o aplicativo KCL estiver sendo executado em uma VPC com interface do DynamoDB com VPC endpoints habilitados, as chamadas entre o DynamoDB e seu aplicativo KCL estão fluindo por meio do VPC endpoint de interface.

Controlar o acesso a endpoints de VPCE para o Kinesis Data Streams

As políticas de VPC endpoint permitem que você controle o acesso anexando uma política a um VPC endpoint ou usando campos adicionais em uma política anexada a um usuário, um grupo ou uma função do IAM para restringir o acesso a ocorrer apenas por meio do VPC endpoint especificado. Essas políticas podem ser usadas para restringir o acesso a fluxos específicos a um VPC endpoint especificado quando usadas em conjunto com as políticas do IAM para conceder acesso somente a ações de fluxo de dados do Kinesis por meio do VPC endpoint especificado.

Veja a seguir exemplos de políticas de endpoint para acessar fluxos de dados do Kinesis.

- Exemplo de política de VPC: acesso somente leitura — esse exemplo de política pode ser anexado a um VPC endpoint. (Para obter mais informações, consulte Como controlar o acesso aos recursos da Amazon VPC). Ele restringe as ações a somente listar e descrever um fluxo de dados do Kinesis por meio do VPC endpoint ao qual está anexado.

```
{
  "Statement": [
    {
      "Sid": "ReadOnly",
      "Principal": "*",
      "Action": [
        "kinesis:List*",
        "kinesis:Describe*"
      ],
      "Effect": "Allow",
      "Resource": "*"
    }
  ]
}
```

- Exemplo de política de VPC: restringir o acesso a um fluxo de dados específico do Kinesis — esse exemplo de política pode ser anexado a um VPC endpoint. Ele restringe o acesso a um fluxo de dados específico por meio do VPC endpoint ao qual está anexado.

```
{
  "Statement": [
    {
      "Sid": "AccessToSpecificDataStream",
      "Principal": "*",
      "Action": "kinesis:*",
      "Effect": "Allow",
      "Resource": "arn:aws:kinesis:us-east-1:123456789012:stream/MyStream"
    }
  ]
}
```

- Exemplo de política do IAM: restringir o acesso a um fluxo específico apenas de determinado VPC endpoint — esse exemplo de política pode ser anexado a um usuário, uma função ou um grupo do IAM. Ele restringe o acesso a um fluxo de dados especificado do Kinesis para ocorrer somente em determinado VPC endpoint.

```
{
   "Version": "2012-10-17",
   "Statement": [
      {
         "Sid": "AccessFromSpecificEndpoint",
         "Action": "kinesis:*",
         "Effect": "Deny",
         "Resource": "arn:aws:kinesis:us-east-1:123456789012:stream/MyStream",
         "Condition": { "StringNotEquals" : { "aws:sourceVpce": "vpce-11aa22bb" } }
      }
   ]
}
```

Disponibilidade de políticas de VPC endpoint para o Kinesis Data Streams

VPC endpoints de interface do Kinesis Data Streams com políticas são compatíveis com as seguintes regiões:

- Europa (Paris)

- Europa (Irlanda)
- Leste dos EUA (Norte da Virgínia)
- Europe (Stockholm)
- Leste dos EUA (Ohio)
- Europa (Frankfurt)
- América do Sul (São Paulo)
- Europa (Londres)
- Ásia-Pacífico (Tóquio)
- US West (N. California)
- Ásia-Pacífico (Cingapura)
- Asia Pacific (Sydney)
- China (Beijing)
- China (Ningxia)
- Asia Pacific (Hong Kong)
- Middle East (Bahrain)
- Europe (Milan)
- Africa (Cape Town)
- Asia Pacific (Mumbai)
- Ásia-Pacífico (Seul)
- Canada (Central)
- Oeste dos EUA (Oregon), exceto usw2-az4
- AWS GovCloud (Leste dos EUA)
- AWS GovCloud (Oeste dos EUA)
- Asia Pacific (Osaka)

Controlar o acesso a recursos do Amazon Kinesis Data Streams usando o IAM

AWS Identity and Access ManagementO (IAM) permite que você faça o seguinte:

- Criar usuários e grupos na conta da AWS
- Atribua credenciais de segurança exclusivas a cada usuário em sua conta da AWS
- Controle as permissões de cada usuário para executar tarefas usando recursos da AWS
- Permita que os usuários em outra conta da AWS compartilhem seus recursos da AWS
- Crie funções para sua conta da AWS e defina os usuários ou os serviços que podem assumi-las
- Use identidades existentes em sua empresa a fim de conceder permissões para executar tarefas usando recursos da AWS

Ao usar o IAM com o Kinesis Data Streams, você pode controlar se os usuários de sua organização podem executar uma tarefa usando ações específicas da API do Kinesis Data Streams e se podem usar ações específicas da API do Kinesis Data Streams e se podem usar específicasAWSrecursos da AWS.

Se você estiver desenvolvendo um aplicativo usando a Biblioteca de cliente do Kinesis (KCL), sua política deverá incluir permissões para o Amazon DynamoDB e o Amazon CloudWatch; a KCL usa o DynamoDB para rastrear informações de estado do aplicativo e CloudWatch Para enviar métricas da KCL para o

CloudWatch em seu nome. Para obter mais informações sobre o recurso KCL, consulte Desenvolver consumidores do KCL 1.x (p. 133).

Para obter mais informações sobre IAM, consulte o seguinte:

- AWS Identity and Access Management (IAM)
- Conceitos básicos
- Guia do usuário do IAM

Para obter mais informações sobre o IAM e o Amazon DynamoDB, consulteUsar o IAM para controlar o acesso aos recursos do Amazon DynamoDBnoGuia do desenvolvedor do Amazon DynamoDB.

Para obter mais informações sobre o IAM e o Amazon CloudWatch, consulteControle do acesso dos usuários aoAWSContanoAmazônia CloudWatch Guia do usuário do.

Índice

Sintaxe da política

A política do IAM é um documento JSON que consiste em uma ou mais declarações. Cada instrução é estruturada da seguinte maneira:

```
{
  "Statement":[{
    "Effect":"effect",
    "Action":"action",
    "Resource":"arn",
    "Condition":{
      "condition":{
        "key":"value"
        }
      }
    }
  ]
}
```

Existem vários elementos que compõem uma instrução:

- Efeito: OefeitoPode ser`Allow`ou`Deny`. Por padrão, os usuários do IAM não têm permissão para usar recursos e ações da API. Por isso, todas as solicitações são negadas. Uma permissão explícita substitui o padrão. Uma negação explícita substitui todas as permissões.
- Ação: OaçãoÉ a ação de API específica para a qual você está concedendo ou negando a permissão.
- Recurso: O recurso afetado pela ação. Para especificar um recurso na declaração, você precisa usar o Amazon Resource Name (ARN – Nome de recurso da Amazon).
- Condição: As condições são opcionais. Elas podem ser usadas para controlar quando as políticas entrarão em vigor.

Conforme cria e gerencia políticas do IAM, você pode querer usar oGerador de políticas do IAMO e aSimulador de políticas do IAM.

Ações para o Kinesis Data Streams

Em uma declaração de política do IAM, é possível especificar qualquer ação de API de qualquer serviço que dê suporte ao IAM. Para o Kinesis Data Streams, use o seguinte prefixo com o nome da ação da API: `kinesis:`. Por exemplo:`kinesis:CreateStream`,`kinesis:ListStreams`, `ekinesis:DescribeStreamSummary`.

Para especificar várias ações em uma única declaração, separe-as com vírgulas, conforme o seguinte:

```
"Action": ["kinesis:action1", "kinesis:action2"]
```

Também é possível especificar várias ações usando caracteres curinga. Por exemplo, você pode especificar todas as ações cujo nome começa com a palavra "Obter", conforme o seguinte:

```
"Action": "kinesis:Get*"
```

Para especificar todas as operações do Kinesis Data Streams, use o asterisco (*) conforme o seguinte:

```
"Action": "kinesis:*"
```

Para obter a lista completa de ações da API do Kinesis Data Streams, consulte oReferência da API do Amazon Kinesis.

Nomes de recursos da Amazon (ARNs) para Kinesis Data Streams

Cada declaração de política do IAM se aplica aos recursos que você especifica usando os ARNs.

Use o seguinte formato de recurso do ARN para fluxos de dados do Kinesis:

```
arn:aws:kinesis:region:account-id:stream/stream-name
```

Por exemplo:

```
"Resource": arn:aws:kinesis:*:111122223333:stream/my-stream
```

Exemplo de políticas para o Kinesis Data Streams

As políticas de exemplo a seguir demonstram como você pode controlar o acesso do usuário aos streamings de dados do Kinesis.

Example 1: Permitir que os usuários obtenham dados de um stream

Esta política permite que um usuário ou grupo execute as operações `DescribeStreamSummary`, `GetShardIterator` e `GetRecords` no stream especificado e `ListStreams` em qualquer stream. Esta política pode ser aplicada a usuários que devem conseguir obter dados de um stream específico.

```
{
    "Version": "2012-10-17",
    "Statement": [
```

```
        {
            "Effect": "Allow",
            "Action": [
                "kinesis:Get*",
                "kinesis:DescribeStreamSummary"
            ],
            "Resource": [
                "arn:aws:kinesis:us-east-1:111122223333:stream/stream1"
            ]
        },
        {
            "Effect": "Allow",
            "Action": [
                "kinesis:ListStreams"
            ],
            "Resource": [
                "*"
            ]
        }
    ]
}
```

Example 2: Permitir que os usuários adicionem dados a qualquer stream na conta

Esta política permite que um usuário ou grupo use a operação `PutRecord` com qualquer um dos streams da conta. Esta política pode ser aplicada a usuários que devem conseguir adicionar registros de dados a todos os streams em uma conta.

```
{
    "Version": "2012-10-17",
    "Statement": [
        {
            "Effect": "Allow",
            "Action": [
                "kinesis:PutRecord"
            ],
            "Resource": [
                "arn:aws:kinesis:us-east-1:111122223333:stream/*"
            ]
        }
    ]
}
```

Example 3: Permitir qualquer ação do Kinesis Data Streams em um determinado stream

Esta política permite que um usuário ou grupo use qualquer operação do Kinesis Data Streams no stream especificado. Esta política poderia ser aplicada a usuários que devem ter controle administrativo por meio de um stream específico.

```
{
    "Version": "2012-10-17",
    "Statement": [
        {
            "Effect": "Allow",
            "Action": "kinesis:*",
            "Resource": [
                "arn:aws:kinesis:us-east-1:111122223333:stream/stream1"
            ]
        }
    ]
}
```

Example 4: Permitir qualquer ação do Kinesis Data Streams em qualquer stream

Esta política permite que um usuário ou grupo use qualquer operação do Kinesis Data Streams em qualquer stream em uma conta. Como esta política concede acesso total a todos os streams, você deve restringi-la somente aos administradores.

```
{
    "Version": "2012-10-17",
    "Statement": [
        {
            "Effect": "Allow",
            "Action": "kinesis:*",
            "Resource": [
                "arn:aws:kinesis:*:111122223333:stream/*"
            ]
        }
    ]
}
```

Validação de conformidade para Amazon Kinesis Data Streams

Auditores de terceiros avaliam a segurança e a conformidade do Amazon Kinesis Data Streams como parte de váriosAWSProgramas de conformidade. Isso inclui SOC, PCI, FedRAMP, HIPAA e outros.

Para obter uma lista dos produtos da AWS no escopo de programas de conformidade específicos, consulte Produtos da AWS no escopo por programa de conformidade. Para obter informações gerais, consulte Programas de conformidade da AWS.

Você pode baixar relatórios de auditoria de terceiros usando o AWS Artifact. Para obter mais informações, consulte Download de relatórios no AWS Artifact.

Sua responsabilidade de conformidade ao usar o Kinesis Data Streams é determinada pela confidencialidade dos dados, pelos objetivos de conformidade da empresa e pelos regulamentos e leis aplicáveis. Se o seu uso do Kinesis Data Streams estiver sujeito à conformidade com padrões, como HIPAA, PCI ou FedRAMP,AWSO fornece recursos para ajudar:

- Guias de início rápido de segurança e conformidade: estes guias de implantação abordam as considerações de arquitetura e fornecem etapas para a implantação de ambientes de linha de base concentrados em conformidade e segurança na AWS.
- Whitepaper Architecting for HIPAA Security and Compliance: este whitepaper descreve como as empresas podem usar a AWS para criar aplicações em conformidade com a HIPAA.
- AWSRecursos de conformidade— Essa coleção de manuais e guias pode ser aplicada ao seu setor e local
- AWS Config— IssoAWSServiço que avalia até que ponto suas configurações de recursos estão em conformidade com práticas internas, diretrizes do setor e regulamentações.
- AWS Security Hub: esse serviço da AWS fornece uma visão abrangente do estado de sua segurança na AWS que ajuda você a conferir sua conformidade com padrões e práticas recomendadas de segurança do setor.

Resiliência no Amazon Kinesis Data Streams

A infraestrutura global da AWS é criada com base em regiões da AWS e zonas de disponibilidade. As regiões da AWS As regiões fornecem várias zonas de disponibilidade separadas e isoladas fisicamente,

as quais são conectadas com baixa latência, altas taxas de transferência e redes altamente redundantes. Com as zonas de disponibilidade, você pode projetar e operar aplicativos e bancos de dados que executam o failover automaticamente entre as zonas de disponibilidade sem interrupção. As zonas de disponibilidade são mais altamente disponíveis, tolerantes a falhas e escaláveis que uma ou várias infraestruturas de data center tradicionais.

Para obter mais informações sobre regiões e zonas de disponibilidade da AWS, consulte Infraestrutura global da AWS.

Além doAWSEm infraestrutura global, o Kinesis Data Streams oferece vários recursos para ajudar a oferecer suporte às suas necessidades de resiliência de dados e backup.

Recuperação de desastres no Amazon Kinesis Data Streams

A falha pode ocorrer nos seguintes níveis quando você usa um aplicativo do Amazon Kinesis Data Streams para processar dados de um stream:

- Um processador de registros pode falhar
- Um operador pode falhar ou a instância do aplicativo que instanciou o operador pode falhar
- Uma instância do EC2 que hospeda uma ou mais instâncias do aplicativo pode falhar

Falha do processador de registros

O operador invoca os métodos de processador de registros usando tarefas ExecutorService do Java. Se uma tarefa falhar, o operador manterá o controle do estilhaço que o processador de registros estava processando. O operador inicia uma nova tarefa de processador de registros para processar esse estilhaço. Para obter mais informações, consulte Limitação de leitura (p. 189).

Falha de operador ou aplicativo

Se um operador (ou uma instância do aplicativo Amazon Kinesis Data Streams) falhar, você deverá detectar tratar a situação. Por exemplo, se o método `Worker.run` lançar uma exceção, você deverá identificá-la e tratá-la.

Se o próprio aplicativo falhar, você deverá detectar isso e reiniciá-lo. Quando o aplicativo é iniciado, ele instancia um novo operador, que, por sua vez, instancia novos processadores de registros aos quais são atribuídos estilhaços automaticamente para processamento. Podem ser os mesmos estilhaços que esses processadores de registros estavam processando antes da falha ou estilhaços novos para esses processadores.

Em uma situação em que o operador ou o aplicativo falha, a falha não é detectada e há outras instâncias do aplicativo sendo executadas em outras instâncias do EC2, os operadores nessas outras instâncias lidam com a falha. Eles criam processadores de registro adicionais para processar os estilhaços que não estão mais sendo processados pelo operador com falha. A carga nessas outras instâncias do EC2 aumenta de forma correspondente.

O cenário descrito aqui assume que, embora o operador ou aplicativo tenha falhado, a instância do EC2 que o hospeda ainda está em execução e, portanto, não é reiniciada por um grupo de Auto Scaling.

Falha na instância do Amazon EC2

Recomendamos que você execute as instâncias do EC2 referentes ao seu aplicativo em um grupo do Auto Scaling. Dessa forma, se uma das instâncias do EC2 falhar, o grupo Auto Scaling iniciará automaticamente

uma nova instância para substituí-la. Você deve configurar as instâncias para iniciar seu aplicativo Amazon Kinesis Data Streams na inicialização.

Segurança de infraestrutura no Kinesis Data Streams

Como um serviço gerenciado, o Amazon Kinesis Data Streams é protegido peloAWSProcedimentos de segurança de rede global da descritos noAmazon Web Services: Visão geral dos processos de segurançaWhitepaper.

Você usaAWSEditar chamadas à API do para acessar o Kinesis Data Streams por meio da rede. Os clientes devem oferecer suporte a Transport Layer Security (TLS) 1.0 ou posterior. Recomendamos TLS 1.2 ou posterior. Os clientes também devem ter suporte a conjuntos de criptografia com perfect forward secrecy (PFS) como Ephemeral Diffie-Hellman (DHE) ou Ephemeral Elliptic Curve Diffie-Hellman (ECDHE). A maioria dos sistemas modernos como Java 7 e versões posteriores oferece suporte a esses modos.

Além disso, as solicitações devem ser assinadas usando um ID da chave de acesso e uma chave de acesso secreta associada a uma entidade principal do IAM. Ou você pode usar o AWS Security Token Service (AWS STS) para gerar credenciais de segurança temporárias para assinar solicitações.

Melhores práticas de segurança para o Kinesis Data Streams

O Amazon Kinesis Data Streams fornece uma série de recursos de segurança a serem considerados no desenvolvimento e na implementação das suas próprias políticas de segurança. As melhores práticas a seguir são diretrizes gerais e não representam uma solução completa de segurança. Como essas práticas recomendadas podem não ser adequadas ou suficientes no seu ambiente, trate-as como considerações úteis em vez de requisitos.

Implemente o acesso de privilégio mínimo

Ao conceder permissões, você decide quem as recebe quais permissões para quais recursos do Kinesis Data Streams. Você habilita ações específicas que quer permitir nesses recursos. Portanto, você deve conceder somente as permissões necessárias para executar uma tarefa. A implementação do privilégio de acesso mínimo é fundamental para reduzir o risco de segurança e o impacto que pode resultar de erros ou usuários mal-intencionados.

Usar funções do IAM

Aplicativos produtores e clientes devem ter credenciais válidas para acessar fluxos de dados do Kinesis. Você não deve armazenarAWSCredenciais diretamente em um aplicativo cliente ou em um bucket do Amazon S3. Essas são credenciais de longo prazo que não são automaticamente alternadas e podem ter um impacto comercial significativo se forem comprometidas.

Em vez disso, você deve usar uma função do IAM para gerenciar credenciais temporárias para os aplicativos produtores e clientes para acessar fluxos de dados do Kinesis. Quando você usa uma função, não precisa usar credenciais de longo prazo (como um nome de usuário e uma senha ou chaves de acesso) para acessar outros recursos.

Para obter mais informações, consulte os seguintes tópicos no Manual do usuário do IAM:

- Funções do IAM
- Cenários comuns para funções: Usuários, aplicativos e serviços

Implemente a criptografia do lado do servidor em recursos dependentes

Dados em repouso e dados em trânsito podem ser criptografados no Kinesis Data Streams. Para obter mais informações, consulte Proteção de dados no Amazon Kinesis Data Streams (p. 221).

Usar o CloudTrail Para monitorar chamadas à API

O Kinesis Data Streams é integrado aoAWS CloudTrail, um serviço que fornece um registro das ações executadas por um usuário, uma função ou umAWSserviçoServiço no Kinesis Data Streams.

Usando as informações coletadas pelo CloudTrail, é possível determinar a solicitação feita para o Kinesis Data Streams, o endereço IP no qual a solicitação foi feita, quem a fez e quando ela foi feita, além de outros detalhes.

Para obter mais informações, consulte the section called “Registro de chamadas de API do Amazon Kinesis Data Streams comAWS CloudTrail” (p. 202).

Histórico do documento

A tabela a seguir descreve alterações importantes feitas na documentação do Amazon Kinesis Data Streams.

Alteração	Descrição	Alterado em
Adicionado suporte para os modos de capacidade de fluxo de dados sob demanda e provisionado.	Adição do Escolher o modo de capacidade do fluxo de dados (p. 68).	29 de novembro de 2021
Novo conteúdo de criptografia do lado do servidor	Adição do Proteção de dados no Amazon Kinesis Data Streams (p. 221).	7 de julho de 2017
Novo conteúdo para aprimorar o conteúdo CloudWatch Métricas do .	Atualizado Monitoramento do Amazon Kinesis Data Streams (p. 190).	19 de abril de 2016
Novo conteúdo para aprimorar o agente do Kinesis.	Atualizado Escrever no Amazon Kinesis Data Streams usando o Kinesis Agent (p. 105).	11 de abril de 2016
Novo conteúdo para o uso de agentes do Kinesis.	Adição do Escrever no Amazon Kinesis Data Streams usando o Kinesis Agent (p. 105).	2 de outubro de 2015
Atualização do conteúdo da KPL para a versão 0.10.0.	Adição do Desenvolver produtores usando a da Amazon Kinesis Producer Library (p. 88).	15 de julho de 2015
Atualização do tópico sobre métricas da KCL com métricas configuráveis.	Adição do Monitorar a biblioteca de cliente Kinesis com o Amazon CloudWatch (p. 206).	9 de julho de 2015
Reorganização do conteúdo.	Reorganização significativa dos tópicos do conteúdo para obter visualização em árvore mais concisa e agrupamento mais lógico.	01 de julho de 2015
Novo tópico do guia do desenvolvedor da KPL.	Adição do Desenvolver produtores usando a da Amazon Kinesis Producer Library (p. 88).	02 de junho de 2015
Novo tópico sobre métricas da KCL.	Adição do Monitorar a biblioteca de cliente Kinesis com o Amazon CloudWatch (p. 206).	19 de maio de 2015
Compatibilidade com KCL .NET	Adição do Desenvolver um consumidor da Kinesis Client Library em .NET (p. 141).	1 de maio de 2015
Compatibilidade com KCL Node.js	Adição do Desenvolver um consumidor da Kinesis Client Library em Node.js (p. 138).	26 de março de 2015

Alteração	Descrição	Alterado em
Compatibilidade com KCL Ruby	Adição de links para a biblioteca KCL Ruby.	12 de janeiro de 2015
Nova API de PutRecords	Adicionadas informações sobre o Novo PutRecords API parathe section called “Adicionar vários registros comPutRecords” (p. 101).	15 de dezembro de 2014
Compatibilidade com atribuição de tags	Adição do Atribuir tags no Amazon Kinesis Data Streams (p. 85).	11 de setembro de 2014
Novo CloudWatch métrica	Adição da métrica `GetRecords.IteratorAgeMilliseconds` a Dimensões e métricas do Amazon Kinesis Data Streams (p. 191).	3 de setembro de 2014
Novo capítulo de monitoramento	Adicionadas Monitoramento do Amazon Kinesis Data Streams (p. 190) e Monitorar o Amazon Kinesis Data Streams Service com o Amazon CloudWatch (p. 190).	30 de julho de 2014
Limite padrão de estilhaço	Atualização do Cotas e limites (p. 7): o limite padrão de estilhaço foi elevado de 5 para 10.	25 de fevereiro de 2014
Limite padrão de estilhaço	Atualização do Cotas e limites (p. 7): o limite padrão de estilhaço foi elevado de 2 para 5.	28 de janeiro de 2014
Atualizações de versão de API	Atualizações para a versão 2013-12-02 da API do Kinesis Data Streams.	12 de dezembro de 2013
Versão inicial	Versão inicial do Guia do desenvolvedor do Amazon Kinesis.	14 de novembro de 2013

Glossário da AWS

Para obter a terminologia mais recente da AWS, consulte o glossário da AWS na Referência geral da AWS.

As traduções são geradas por tradução automática. Em caso de conflito entre o conteúdo da tradução e da versão original em inglês, a versão em inglês prevalecerá.